面向多智能体系统的高效通信技术研究

姓名：柯逸宸

学号：3220241499

学院：计算机学院

2026 年 6 月

专

面向多智能体系统的高效通信技术研究

柯逸宸

北京理工大学

中图分类号：TQ028.1
UDC 分类号：540
学校代码：10007

★ 学生类型
□ 工程硕博士专项
□ 交叉研究方向
□ 政府项目留学生

面向多智能体系统的高效通信技术研究

作 者 姓 名　柯逸宸
二级培养单位　计算机学院
指 导 教 师　李四教授
行业合作导师　李五教授
答辩委员会主席　王五教授
申 请 类 别　材料与化工博士
学 位 领 域　计算机技术
学位授予单位　北京理工大学
论文提交日期　2026 年 6 月

Synthesis and Application on textile of the Shape Memory Polyurethane

Candidate Name:	Yichen Ke
School or Department:	Materials Science and Engineering
Faculty Advisor:	Prof. Li Si
Industry Collaboration Mentor:	Prof. Li Wu
Chair of the Defense Committee:	Prof. Wang Wu
Degree:	Doctor of Materials
	and Chemical Engineering
Major:	Materials Science and Engineering
Degree by:	Beijing Institute of Technology
Submission date:	June, 2026

研究成果声明

本人郑重声明：所提交的学位论文是我本人在指导教师的指导下独立完成的研究成果。文中所撰写内容符合以下学术规范（请勾选）：

☑ 论文综述遵循“适当引用”的规范，全部引用的内容不超过 50%。

☑ 论文中的研究数据及结果不存在篡改、剽窃、抄袭、伪造等学术不端行为，并愿意承担因学术不端行为所带来的一切后果和法律责任。

☑ 文中依法引用他人的成果，均已做出明确标注或得到许可。

☑ 论文内容未包含法律意义上已属于他人的任何形式的研究成果，也不包含本人已用于其他学位申请的论文或成果。

☑ 与本人一同工作的合作者对此研究工作所做的任何贡献均已在学位论文中作了明确的说明并表示了谢意。

特此声明。

签　　名：　　日 期：

关于学位论文使用权的说明

本人完全了解北京理工大学有关保管、使用学位论文的规定，其中包括：

① 学校有权保管、并向有关部门送交学位论文的原件与复印件；

② 学校可以采用影印、缩印或其它复制手段复制并保存学位论文；

③ 学校可允许学位论文被查阅或借阅；

④ 学校可以学术交流为目的，复制赠送和交换学位论文；

⑤ 学校可以公布学位论文的全部或部分内容（保密学位论文在解密后遵守此规定）。

签　　名：　　日　期：

导师签名：　　日　期：

致谢

时光荏苒，岁月如梭。回首三载硕士求学之路，从初入校园的懵懂求知，到潜心科研的深耕笃行，这段充实而珍贵的旅程，承载着我的成长与蜕变，也留存着无数温暖与感动。值此论文落笔、学业将成之际，谨向所有给予我指导、陪伴与支持的师长、同窗、亲友，致以最诚挚的谢意。

首先，我由衷感谢我的硕士导师唐博老师和申乔木老师。求学三年，老师们严谨务实的治学态度和深耕求索的科研精神始终潜移默化地影响着我。在学术研究中，老师们循循善诱，包容我探索中的失误，耐心解答我的困惑，引导我树立科学的研究思维与严谨的学术素养。师恩深重，铭记于心，老师们的教诲与期许，将成为我未来求学、工作与人生道路上砥砺前行的不竭动力。

最想感谢我的家人与至亲挚友。感谢父母、姐姐多年来的默默付出、无私包容与全力支持。二十余载求学路，你们始终是我最坚实的后盾、最温暖的港湾。你们无条件的理解、信任与支持，让我能够心无旁骛地深耕学业、追逐理想，无惧前路风雨，勇敢奔赴每一段旅程。家人的温情与期许，是我一路前行的底气与勇气。感谢亲友们的牵挂与陪伴，在我迷茫焦虑、疲惫懈怠时给予我安慰与鼓励，支撑我不断坚持、稳步前行。

行文至此，百感交集。硕士生涯的结束，不是终点，而是全新的起点。前路漫漫，亦灿灿。未来，我将怀揣所有的感恩与期许，带着求学期间收获的知识、勇气与坚守，不忘初心、脚踏实地，笃行致远、砥砺前行，在未来的人生道路上继续深耕精进，不负师长教诲、不负亲友期许、不负韶华时光。

面向多智能体系统的高效通信技术研究

摘要：大语言模型驱动的多智能体系统能够通过角色分工、协作推理和多轮通信提升复杂任务求解能力，但密集通信也会引入显著的上下文冗余、推理成本和工具调用开销。一方面，智能体之间传递的自然语言消息通常包含与接收方职责弱相关的推理过程、多个前驱节点的重复观点以及不断累积的历史信息，容易造成 Token 消耗增加和关键信息稀释。另一方面，在搜索、代码执行和文本检查等工具调用场景中，工具观察结果可能沿通信边在多个智能体之间传播，使单次工具调用开销被通信图结构进一步放大。针对上述问题，本文围绕多智能体系统中的高效通信技术展开研究，在不修改底层大语言模型参数的前提下，分别从通信内容和通信结构两个层面提出优化方法。

首先，本文提出面向语义冗余的消息压缩框架。该框架将多智能体通信中的语义冗余归纳为角色不匹配、多前驱重复和跨轮历史累积三类，并分别设计角色感知压缩、节点感知聚合和分歧感知压缩模块。角色感知压缩根据接收方职责筛选发送方推理内容，节点感知聚合对多个前驱智能体的相似观点进行去重并保留来源信息，分歧感知压缩从多轮历史中提取共识、分歧及其简要依据，从而提高通信内容的信息密度。实验结果表明，该框架能够在多数知识问答、数学推理和代码生成任务上保持或提升任务准确率，并降低完全通信拓扑带来的额外推理成本。

其次，本文提出面向通信边冗余的图剪枝算法。该方法将多智能体系统中的空间边和时间边建模为可学习概率，以任务正确性为收益项，并引入模型输出 Token、工具调用次数和工具观察 Token 三类边级成本信号构建优化目标，使通信结构学习能够刻画不同发送方、不同轮次和不同工具观察带来的成本差异。在此基础上，本文引入 Taylor 一阶重要性评估，根据边参数及其梯度估计移除通信边对目标函数的影响，并周期性剪除低重要性边。实验结果表明，在 AIME、GAIA、GPQA 和 BigCodeBench 等工具调用任务中，该方法能够相对已有多智能体通信基线改善准确率–成本权衡，尤其在 GAIA 和 GPQA 等任务中表现出较好的通信边筛选能力。总体而言，本文从消息级压缩和图结构剪枝两个角度缓解多智能体系统中的语义冗余问题和通信边冗余问题，为构建低成本、可扩展的多智能体推理系统提供了可行方案。

关键词：多智能体系统；高效通信；消息压缩；图剪枝；工具调用

Synthesis and Application on textile of the Shape Memory Polyurethane

Abstract: Large-language-model-driven multi-agent systems improve complex task solving through role specialization, collaborative reasoning, and multi-round communication. However, dense communication also introduces substantial contextual redundancy, inference cost, and tool-use overhead. On the one hand, natural language messages exchanged among agents often contain reasoning traces weakly related to the receiver's responsibility, repeated opinions from multiple predecessors, and accumulated historical content, which increases token consumption and dilutes key information. On the other hand, in tool-augmented scenarios such as web search, code execution, and text checking, tool observations may propagate through multiple communication edges and further amplify the cost of a single tool call. To address these issues, this thesis studies efficient communication techniques for multi-agent systems and proposes two optimization methods from the perspectives of communication content and communication structure, without modifying the parameters of the underlying large language models.

First, this thesis proposes a message compression framework for semantic redundancy. The framework categorizes semantic redundancy in multi-agent communication into three types: mismatch between sender messages and receiver roles, repeated information from multiple predecessor agents, and accumulation of multi-round historical context. Accordingly, it designs three modules, namely role-aware compression, node-aware aggregation, and disagreement-aware compression. Role-aware compression filters sender reasoning according to the responsibility of the receiver. Node-aware aggregation removes semantically similar statements from multiple predecessors while preserving source information. Disagreement-aware compression extracts consensus answers, conflicting candidates, and concise supporting rationales from historical interactions. Experimental results show that the proposed framework can maintain or improve task accuracy on most knowledge question answering, mathematical reasoning, and code generation tasks, while reducing the additional inference cost introduced by fully connected communication.

Second, this thesis proposes a graph pruning algorithm for redundancy in communication edges. The method models spatial and temporal edges in a multi-agent system as learnable probabilities, and constructs an edge-level optimization objective by jointly considering task correctness, model output tokens, tool call frequency, and tool observation tokens. This design enables communication-structure learning to capture cost differences across senders, reasoning rounds, and tool observations. Furthermore, a first-order Taylor importance estimator is introduced to evaluate the influence of removing each edge based on its parameter value and gradient, and low-importance communication edges are pruned periodically. Experimental results on tool-augmented tasks including AIME, GAIA, GPQA, and BigCodeBench demonstrate that the proposed method improves the accuracy-cost trade-off over existing multi-agent communication baselines, especially on tasks that require evidence selection and tool-result integration. Overall, this thesis mitigates semantic redundancy and redundancy in communication edges through message compression and graph pruning, providing a practical approach for building cost-efficient and scalable multi-agent reasoning systems.

Key Words: multi-agent systems; efficient communication; message compression; graph pruning; tool use

目次

1 绪论 1
1.1 研究背景及意义 1
1.2 国内外研究现状 5
1.3 本文主要研究内容及贡献 7
1.3.1 面向语义冗余的消息压缩框架 8
1.3.2 面向通信边冗余的图剪枝算法 9
1.4 论文组织结构 9
2 相关工作 11
2.1 多智能体系统 11
2.2 语义冗余问题 12
2.2.1 定义和分类 12
2.2.2 通用应对策略 13
2.3 通信边冗余 15
2.3.1 定义和分类 15
2.3.2 通用应对策略 15
2.4 本章小结 18
3 面向语义冗余的消息压缩框架 19
3.1 引言 19
3.2 消息压缩框架 19
3.2.1 多智能体系统任务执行流程 19
3.2.2 消息压缩框架执行流程 19
3.2.3 功能模块设计 20
3.3 实验设置 22
3.3.1 数据集 23
3.3.2 对比基准 23
3.3.3 实现细节 23
3.3.4 评估指标 24

3.4 实验结果与分析 25
3.4.1 任务准确率结果 26
3.4.2 消耗成本结果 29
3.4.3 小模型超过大模型的可能性分析 30
3.4.4 结果分析 31
3.5 本章小结 31
4 面向通信边冗余的图剪枝算法 33
4.1 引言 33
4.2 图剪枝算法 34
4.2.1 问题定义与工具成本建模 34
4.2.2 可学习通信边概率建模 35
4.2.3 成本感知优化目标 35
4.2.4 Taylor 一阶重要性剪枝 36
4.2.5 算法流程 37
4.3 实验设置 38
4.3.1 数据集 38
4.3.2 对比基准 39
4.3.3 实现细节 39
4.3.4 评估指标 40
4.4 实验结果与分析 40
4.4.1 任务准确率结果 41
4.4.2 消耗成本结果 43
4.4.3 结果分析 45
4.5 本章小结 45
结论 47
参考文献 49
附录 A 费马大定理的证明 57
附录 B Maxwell Equations 58

附录 C 要求 59
C.1 一级标题 59
C.1.1 二级标题 59
攻读学位期间发表论文与研究成果清单 60
作者简介 61

插图

图 1.1 多智能体系统的 Token 消耗对比和不同智能体数量下的输入 Token 变化 . 3
图 1.2 完全连接拓扑（Full Topology） 8
图 2.1 多智能体的两条研究路线 11
图 2.2 压缩示意图 13
图 2.3 图生成技术示意图 15
图 2.4 图剪枝技术示意图 16
图 2.5 拓扑搜索技术示意图 17
图 3.1 多智能体系统标准任务执行流程示意图 20
图 3.2 消息压缩框架 20
图 3.3 六个数据集在不同模型下的平均准确率对比 26
图 3.4 各数据集上不同模型与方法的准确率对比 27
图 3.5 六个数据集在不同模型下的平均推理成本对比 29
图 3.6 MMLU 上小模型相对大模型最佳基线的准确率差距 30
图 4.1 Qwen3-14B 在 AIME 任务上的准确率结果 41
图 4.2 MiniMax-M3 在 GAIA 和 GPQA 任务上的准确率结果 43
图 4.3 MiniMax-M3 在 MATH500 和 BigCodeBench 任务上的准确率结果 43
图 4.4 MiniMax-M3 代表性任务上的准确率–成本权衡 44

表格

表 3.1 实验评测数据集概览 23
表 3.2 API 调用单价对比表 24
表 3.3 本文方法相对多智能体通信基线的推理成本降低情况 29
表 4.1 工具调用实验任务与默认工具配置 38
表 4.2 Qwen3-14B 下面向通信边冗余的图剪枝结果 41
表 4.3 MiniMax-M3 下面向通信边冗余的图剪枝结果 42
表 4.4 本文方法相对 AgentPrune+Tools 的主实验推理成本对比 44

主要符号对照表

LLM	大语言模型（Large Language Model）
MAS	多智能体系统（Multi-Agent System）
Agent	智能体，通常以大语言模型为核心推理器，并结合规划、记忆或工具调用机制完成任务
API	应用程序接口（Application Programming Interface）
Token	大语言模型输入或输出中的词元，是本文衡量上下文长度与调用成本的基本单位
CoT	思维链（Chain of Thought）
ToT	思维树（Tree of Thoughts）
GoT	思维图（Graph of Thoughts）
DAG	有向无环图（Directed Acyclic Graph）
Direct	单智能体直接回答基线方法
FullConnected	完全连接多智能体通信基线方法
AgentPrune	基于可学习通信边和图剪枝的多智能体通信优化基线方法
$G = (V, E)$	多智能体系统的通信图，其中 V 表示智能体节点集合，E 表示通信边集合
G^*	训练结束后采样得到并在推理阶段固定使用的通信图
V	通信图中的智能体节点集合
E	通信图中的通信边集合
$\mathcal{E}^*$	固定通信图 G^* 中的通信边集合
$\mathcal{A}$	多智能体系统中的智能体集合
n	多智能体系统中的智能体数量
A_i	第 i 个智能体
i, j, u, v	智能体或通信节点索引
t	多轮协作推理中的轮次索引
$m_{u\to v}^{(t)}$	第 t 轮中发送方智能体 u 传递给接收方智能体 v 的消息

$r_i^{(t)}$	第 i 个智能体在第 t 轮生成的推理文本
$\hat{y}_i^{(t)}$	第 i 个智能体在第 t 轮给出的候选答案
$q_i^{(t)}$	第 i 个智能体在第 t 轮产生的工具调用相关信息
s	角色感知压缩中的候选推理句子
d_v	接收方智能体 v 的角色描述
$\phi(\cdot)$	文本编码函数，用于将句子或角色描述映射为向量表示
$\mathrm{sim}(\cdot)$	语义相似度函数
$\cos(\cdot)$	余弦相似度函数
$o_i^{(t)}$	第 i 个智能体在第 t 轮的结构化输出，包含推理文本、候选答案和工具调用信息
$c_i^{(t)}$	第 i 个智能体在第 t 轮的发送方成本
$O_i^{(t)}$	第一类边级成本信号，表示第 i 个智能体在第 t 轮生成的模型输出 Token 数
$K_i^{(t)}$	第二类边级成本信号，表示第 i 个智能体在第 t 轮的工具调用次数
$Z_i^{(t)}$	第三类边级成本信号，表示第 i 个智能体在第 t 轮产生的工具观察结果 Token 数
N_o, N_k, N_z	输出 Token 数、工具调用次数和工具观察 Token 数的归一化系数
$\lambda_o, \lambda_k, \lambda_z$	输出 Token 数、工具调用次数和工具观察 Token 数对应的成本权重
$e = (i, j)$	由发送方智能体 i 指向接收方智能体 j 的一条潜在通信边
$\mathcal{C}_e^{(t)}$	通信边 e 在第 t 轮的边级成本
$z_e^{(t)}$	通信边 e 在第 t 轮的采样状态，取 1 表示该边被激活，取 0 表示该边不参与通信
z_e^*	训练结束后生成固定通信图时通信边 e 的最终采样状态
$\tau(e, t)$	通信边 e 在第 t 轮进行成本归因时对应的发送方轮次
θ_e	通信边 e 对应的可学习 logit 参数
p_e	通信边 e 的保留概率
$\sigma(\cdot)$	Sigmoid 函数
τ_p	边概率建模中的采样温度系数

Bernoulli$(\cdot)$	伯努利分布
x	输入任务样本
y	输入任务样本对应的标准答案
$\hat{y}$	多智能体系统生成的最终答案
$S(\hat{y}, y)$	衡量生成答案与标准答案一致性的任务评分函数
$R_e^{(t)}$	通信边 e 在第 t 轮的边级效用
$\mathcal{E}_{\text{sample}}$	一次任务执行中被记录的边采样事件集合
$\mathcal{E}_{\text{active}}$	当前仍处于活跃状态、可参与剪枝评估的通信边集合
$\mathcal{L}_{\text{pg}}$	用于优化通信边采样概率的策略梯度损失
$\Delta\mathcal{L}_{\text{pg},e}$	移除通信边 e 后边策略损失变化的一阶估计
$\Delta\theta_e$	对通信边参数 θ_e 施加的参数扰动
I_e	基于 Taylor 一阶展开计算得到的通信边重要性
ρ	每次 Taylor 重要性剪枝中低重要性边的剪除比例
$\mathcal{P}$	Taylor 重要性剪枝得到的待剪枝通信边集合
$\mathcal{S}$	从活跃通信边集合中选取的候选剪枝子集

1 绪论

1.1 研究背景及意义

近年来，以Transformer架构为基础的大语言模型（Large Language Models，LLMs）[1]在自然语言理解、逻辑推理、文本生成和代码生成等任务中取得了重要进展。以GPT-4系列[2]、LLaMA系列[3-5]和Qwen系列[6-8]为代表的基础模型，已经能够在开放问答、数学推理、程序合成、信息抽取和复杂指令遵循等场景中表现出较强的生成式推理能力。上述模型为复杂任务自动化提供了统一的语言接口和推理基础，也为多个智能体围绕同一任务进行分工、协作和验证提供了可能。

然而，大语言模型本身并不能完全满足复杂现实任务的需求。首先，模型参数中固化的知识具有时间滞后性，难以及时覆盖不断变化的外部世界知识[9]。其次，模型的上下文窗口即使不断扩展，仍然会受到输入长度、推理延迟和调用成本的限制；当上下文过长时，模型还容易出现“迷失在中间（Lost in the Middle）”现象，即对位于长文本中部的关键信息关注不足[10-11]。再次，单次模型调用缺少与外部环境的持续交互能力，难以主动检索信息、执行代码、检查中间结果或根据反馈修正推理路径。上述限制使得单一大语言模型在软件工程、科学计算、开放环境问答和具身智能等任务中仍然存在可靠性不足、知识更新困难和错误难以自我修复等问题[12-14]。

为了弥补单次模型调用在规划、反馈和外部执行方面的不足，研究者开始将大语言模型组织为智能体（Agent）[15]。智能体通常以大语言模型为核心推理器，并在其外部加入任务规划、工具调用、记忆管理和反馈修正等机制。思维链（Chain of Thought，CoT）[16]、自一致性（Self-Consistency）[17]、思维树（Tree of Thoughts，ToT）[18]和思维图（Graph of Thoughts，GoT）[19]等方法，主要通过显式化或扩展推理路径提升复杂问题求解能力；Toolformer[20]、ToolLLM[21]和ReAct[22]等工作进一步将推理与行动结合，使模型能够在“思考–行动–观察”的闭环中调用搜索、计算器、代码执行器和外部API等工具；Reflexion[23]、Generative Agents[24]和Voyager[25]等研究则通过自然语言反馈、长时记忆和环境交互提升智能体在多轮任务中的持续改进能力。

智能体使大语言模型能够以更接近任务执行流程的方式持续感知、规划、执行和反馈。对于需要外部知识、复杂推理或长周期交互的任务，智能体可以把模型能力与外部工具能力结合起来，从而缓解单模型知识封闭、执行能力不足和缺少反馈的问

题。但单智能体仍受限于单一角色视角、单条推理路径和有限的自我纠错能力。当任务需要多个专业角色协作、不同推理路径相互验证或多个工具结果共同汇总时，仅依靠单个智能体往往难以稳定获得可靠结果。

在此背景下，多智能体系统（Multi-Agent Systems，MAS）进一步引入角色分工、协同推理和信息共享机制[26-27]。当任务同时涉及规划、检索、执行、验证和汇总等环节时，多个具备不同职责或工具权限的智能体可以围绕同一目标形成互补视角，并通过消息传递完成任务分解、候选答案生成、交叉检查和最终决策。与单智能体相比，多智能体系统的潜在优势并不只是增加模型调用次数，而是通过角色差异和协作式纠错降低单一路径推理失败的风险。

已有研究表明，多智能体系统在软件开发、开放式问题求解和复杂推理任务中具有应用价值[12,28-29]。多智能体辩论等研究也说明，不同模型或不同角色之间的交叉质询能够改善事实性和推理鲁棒性[26,30]。这些工作表明，角色分工、通信路径和信息汇总方式会影响系统性能。若通信机制设计合理，不同智能体能够补充彼此的知识、发现候选答案中的错误并提升最终输出的可靠性；若通信机制设计不充分，系统可能只是增加对话规模，额外上下文和重复讨论反而会抵消协作带来的收益。

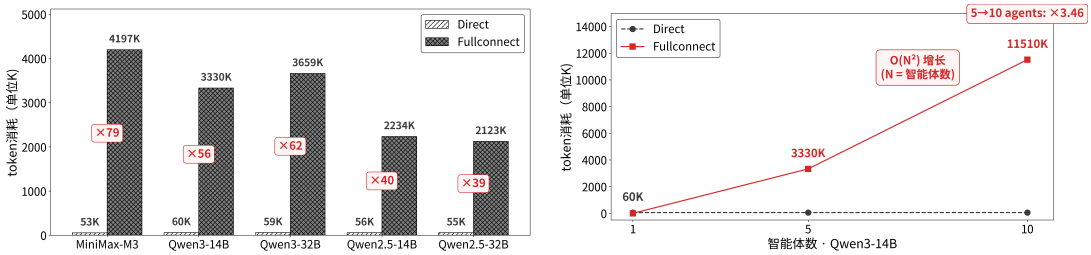
多智能体协作的关键并非简单增加智能体数量，而是在合适的时机交换有效信息。从系统结构看，多智能体系统可以表示为一个带有节点和边的通信图：节点代表智能体，边代表信息传递路径。每个智能体在当前轮次生成的中间推理、候选答案或工具观察，需要通过通信边传递给后继智能体；上一轮协作产生的历史状态，也可能在下一轮继续作为上下文使用。因此，通信拓扑决定哪些智能体能够读取哪些上游输出，消息内容决定下游智能体实际接收到什么信息，跨轮记忆则决定历史推理如何影响后续协作。

不同通信结构决定了信息覆盖范围、协作顺序和成本上界。通信过少时，系统难以充分利用多角色互补；通信过多时，系统又会被冗余上下文和高昂调用成本拖累。因此，多智能体系统性能不仅取决于单个智能体能力，还高度依赖通信结构和通信内容是否高效。

现有多智能体系统在通信机制上仍以粗粒度设计为主。一方面，许多系统采用静态或人工预设拓扑，通信边在任务执行前即被固定，难以根据任务类型、推理阶段和工具使用情况动态调整。另一方面，智能体之间传递的消息往往是完整自然语言输出，包括中间推理、背景解释、候选答案、工具观察和格式化说明等内容。对于下游智能

体而言，这些完整消息并不总是全部有用：某些内容与接收方角色无关，某些观点已经被多个上游智能体重复表达，某些历史信息在后续轮次中的贡献有限。

如图1.1所示，当智能体数量和交互轮次增加时，多智能体系统中的输入词元（Token）数量和整体调用成本会随之增长。在完全连接拓扑下，若每一轮每个智能体都向其他智能体传递完整输出，则通信边数量会随智能体数量呈平方级增长；若系统还保留跨轮历史，则上下文长度会进一步随轮次累积。对于按 Token 计费的闭源模型和商业 API 而言，这种增长会导致部署成本和推理延迟上升；对于本地部署模型而言，过长上下文也会增加显存占用和推理时间。



(a) 多智能体系统的 Token 消耗　　(b) 不同智能体数量下的输入 Token

图 1.1　多智能体系统的 Token 消耗对比和不同智能体数量下的输入 Token 变化

通信开销的增加并不一定带来任务性能提升。相反，冗长、重复和弱相关的上下文会降低下游智能体提取关键信息的效率。当模型需要在较长历史对话中寻找有效证据时，关键线索可能被无关解释、重复推理或过长工具返回结果淹没，从而引发长上下文注意力衰减问题[10]。因此，多智能体通信优化需要同时回答两个问题：一条通信边上传递的内容是否有效，以及这条通信边本身是否仍然值得保留。

本文将上述通信瓶颈分解为两个相互关联但层次不同的问题。语义冗余问题发生在既定通信边上的消息内容内部，表现为同一条自然语言消息包含较多与接收方角色无关的解释、重复推理、弱相关背景或过长历史摘要。该问题关注在既定通信边上应该传递什么内容，哪些信息应被保留，哪些冗余文本可以被压缩。通信边冗余问题发生在通信图结构层面，表现为某些智能体之间的连接本身贡献有限，甚至会传播高成本、低收益的工具观察和历史状态。该问题关注哪些智能体之间需要保持通信，哪些边应当被削弱或剪除。

这两个问题在工具调用场景中更加突出。具备工具使用能力的智能体不仅生成自然语言推理，还会调用搜索、代码执行、文本检查和外部 API 等工具[20-22]。工具返回内容往往较长，并可能包含网页片段、运行日志、候选代码、异常信息或中间计算结

果。在单智能体系统中，这些观察主要增加当前智能体的上下文；而在多智能体系统中，工具观察还可能沿通信边传播给多个下游智能体，触发重复阅读、重复分析甚至二次工具调用。因此，一条通信边的成本不再只由消息长度决定，还与发送方工具调用次数、工具返回 Token 和下游传播范围有关。

基于上述分析，本文将多智能体高效通信研究划分为内容层面和结构层面两条互补路线：内容层面通过消息压缩缓解语义冗余问题，提高既定通信边上传递信息的密度；结构层面通过图剪枝缓解通信边冗余问题，减少低贡献通信边和高成本工具观察传播。二者共同服务于同一目标，即在保持或提升多智能体协作收益的同时，降低 Token 消耗、工具调用开销和整体推理成本。

研究多智能体系统中的高效通信机制具有明确的理论意义和实际价值。本文将多智能体系统中的通信效率问题明确拆分为“消息内容是否冗余”和“通信边是否必要”两个层次，为理解大语言模型多智能体协作中的成本–质量权衡提供了更清晰的分析框架。现有研究往往分别关注提示词压缩、长上下文处理或通信拓扑优化，但较少将自然语言消息内部冗余与通信图结构冗余放在统一视角下讨论。本文围绕语义冗余问题和通信边冗余问题展开研究，有助于揭示多智能体系统中上下文膨胀、信息重复、工具观察传播和通信边贡献差异之间的关系。

在方法层面，本文旨在不改变底层大语言模型参数的前提下提升多智能体通信效率。对于闭源商业模型或难以微调的大模型系统而言，外部通信机制优化具有较强的通用性和可迁移性。消息压缩方法可以嵌入智能体之间的信息传递过程，使下游智能体接收信息密度更高的上下文；图剪枝方法则可以从通信结构角度选择贡献更高的边，使系统不必无差别地保留所有潜在连接。两类方法分别对应“传什么”和“向谁传”两个关键决策。

在实际应用层面，高效通信是多智能体系统实现大规模部署的重要前提。在工业和企业应用中，任务通常需要多轮推理、多工具调用和多角色协作，如果每个智能体都接收未筛选的完整历史消息，系统成本会随任务复杂度上升。通过减少冗余 Token 数量、压缩低贡献历史信息、削弱高成本低收益通信边，本文研究能够降低 API 调用开销和推理延迟，提高多智能体系统在实际应用中的经济可行性。同时，经过筛选和压缩的通信内容能够减少无关信息干扰，使下游智能体更便于定位关键证据和主要分歧，从而有助于提升任务完成质量和系统稳定性。

1.2 国内外研究现状

随着大语言模型从单次问答扩展到多轮任务执行，国内外研究逐渐围绕智能体协作、上下文压缩和通信结构优化形成了较为清晰的研究脉络。总体来看，相关工作可以分为三条路线：第一类研究关注如何将多个大语言模型调用组织为可协作的智能体系统，重点解决复杂任务中的角色分工、对话调度和工具使用问题；第二类研究关注如何压缩冗长提示词或对话历史，重点减少输入上下文中的低贡献语义内容；第三类研究关注如何优化多智能体通信图或工作流结构，重点减少低贡献智能体、冗余通信边和无效协作路径。本节从上述三条路线概括国内外研究现状，具体方法分类将在第2章进一步展开。

在多智能体协作框架方面，已有研究首先证明了将多个智能体组织起来可以提升复杂任务处理能力。多智能体辩论方法通过让多个模型或多个角色给出独立推理，再经由辩论、投票或评审机制形成最终答案，从而提升事实性和推理鲁棒性[26,30]。面向软件工程和复杂任务执行的 ChatDev[12]、MetaGPT[28]和 AutoGen[29]等框架，则进一步将角色分工、流程控制、工具调用和结果汇总纳入统一协作过程。CAMEL[31]、AgentVerse[32]和 ChatEval[33]等工作从角色扮演、智能体社会和多智能体评估角度探索多个智能体之间的交互方式。这些研究推动了多智能体系统从简单对话走向结构化任务执行，也说明系统性能不仅取决于单个模型能力，还与角色设置、通信方式和信息汇总策略密切相关。

然而，现有多智能体框架为了保证协作信息充分共享，往往倾向于保留较长历史上下文，或采用较密集的通信拓扑。对于小规模任务，这种设计能够降低系统实现难度；但当智能体数量、交互轮次和工具调用次数增加后，完整消息广播会增加 Token 成本和推理延迟。同时，冗长历史并不总是带来更多有效信息，弱相关解释、重复推理和过期状态还可能干扰下游智能体定位关键证据。因此，在多智能体框架逐渐成熟之后，如何提高通信效率成为进一步提升系统可用性的关键问题。

在语义内容压缩方面，国内外研究主要围绕长上下文压缩和提示词压缩展开。SelectiveContext[34]通过词元或短语的信息量估计过滤低信息量内容，LLMLingua[35]进一步提出从粗到细的提示词压缩框架，LLMLingua-2[36]将压缩过程转化为词元级保留预测问题，以提升压缩效率和跨任务泛化能力。后续研究进一步从长上下文场景、软提示压缩和任务反馈等角度提升压缩质量[37-39]。此外，检索增强与选择性压缩方法也

尝试在外部证据进入模型前筛选信息，以减少冗余上下文带来的推理负担[40-42]。这类方法为降低长上下文推理成本提供了重要基础，也为多智能体消息压缩提供了可借鉴的技术路径。

但将通用提示词压缩方法应用于多智能体通信仍存在不足。普通长文本压缩通常把输入视为一个整体文本，主要判断哪些词元、短语或句子应被保留；而多智能体通信消息具有明确的发送方、接收方、前驱节点和轮次状态。同一段推理对求解智能体可能有用，对验证智能体可能只需保留结论和证据；同一事实若已由多个前驱节点重复表达，继续保留全部表述只会增加上下文长度；跨轮历史中真正影响后续推理的也往往不是完整对话，而是共识、分歧和关键依据。因此，多智能体场景中的语义压缩需要结合角色关系、节点关系和历史状态，而不能仅以文本长度缩减作为目标。

在通信结构优化方面，相关研究从图结构学习、图剪枝和工作流搜索等角度减少无效通信。早期深度多智能体通信研究已经从可学习消息、注意力通信和何时通信等角度探索协作结构[43-45]。在大语言模型多智能体系统中，DyLAN[46]通过动态选择参与求解的智能体减少无效讨论轮次，CommFormer[47]、G-Designer[48]和 MCGD[49]等工作从图建模或图生成角度学习通信拓扑。AgentPrune[50]将多智能体系统建模为空间–时间通信图，并通过可学习掩码剪除低贡献通信边；AgentDropout[51]、SafeSieve[52]和 AGP[53]则从节点丢弃、渐进式剪枝和自适应稀疏化等角度进一步优化通信结构。与此同时，GPTSwarm[54]、AFlow[55]和 ADAS[56]等方法把智能体系统视为可搜索或可优化的工作流，通过拓扑搜索或架构搜索获得更高效的协作路径。

上述通信结构优化方法能够有效减少部分低贡献节点和通信边，但在工具调用型多智能体系统中仍面临新的成本建模问题。具备工具使用能力的智能体不仅产生自然语言推理，还可能调用搜索、代码执行或文本检查工具；工具增强语言模型和函数调用框架已经表明，外部工具会改变模型的上下文组织方式和任务执行流程[57-59]。这些工具返回内容常常包含网页片段、运行日志、异常信息或中间证据，长度和贡献差异较大。当这类工具观察沿通信边传播时，一条边的成本不再只由是否存在决定，还与发送方工具调用次数、工具返回 Token 和下游传播范围有关。因此，如果图剪枝方法只依据最终任务效用或边采样概率进行判断，就难以区分低成本高贡献边与高成本低收益边。

综合来看，现有研究已经分别从协作框架、语义内容压缩和通信结构优化三个方向推动了大语言模型多智能体系统的发展，但仍缺少对“消息内容冗余”和“通信边

冗余”的统一分析。本文不以训练更强的基座模型或重构完整智能体框架为目标，而是在现有多智能体系统之上研究可插拔的通信优化方法：一方面，从消息内容层面压缩既定通信边上传递的自然语言信息，使下游智能体接收更短、更集中、更符合角色需求的上下文；另一方面，从通信图结构层面学习不同边在任务正确性和工具成本之间的权衡，减少低贡献通信路径和高成本工具观察传播。

因此，本文将普通多智能体推理任务和工具调用增强任务分别作为两个实验场景。普通推理任务用于检验消息级语义压缩是否能够提高上下文信息密度，工具调用增强任务用于检验通信边成本异质性下的图剪枝效果。本文在评价中同时关注任务准确率、Token 成本、工具调用次数和工具 Token，避免将通信优化简单等同于减少文本长度或减少边数量。只有在基本保持任务质量的前提下降低成本，或在相近成本下获得更高准确率时，多智能体通信优化才具有实际意义。

1.3 本文主要研究内容及贡献

本文围绕多智能体系统中的高效通信技术展开研究，目标是在不改动底层大语言模型参数的前提下，通过消息级压缩和图结构剪枝提升多智能体系统的准确率–成本平衡。总体思路是：首先分析多智能体系统中通信成本和上下文膨胀的来源，将其归纳为语义冗余问题和通信边冗余问题；随后分别从通信内容和通信结构两个层面提出方法；最后在多类知识理解、数学推理、代码生成和工具调用任务上验证方法有效性。

为明确本文研究边界，本文将多智能体通信中的基础对象定义如下。设多智能体系统由若干智能体节点构成，通信拓扑表示智能体之间的信息传递路径。若同一轮中某个智能体输出被传递给另一个智能体，则该路径构成空间通信边；若上一轮智能体状态被保留并传递到下一轮，则构成时间通信边。智能体在边上传递的内容称为语义消息，通常包含中间推理、候选答案、工具观察和历史摘要等信息。

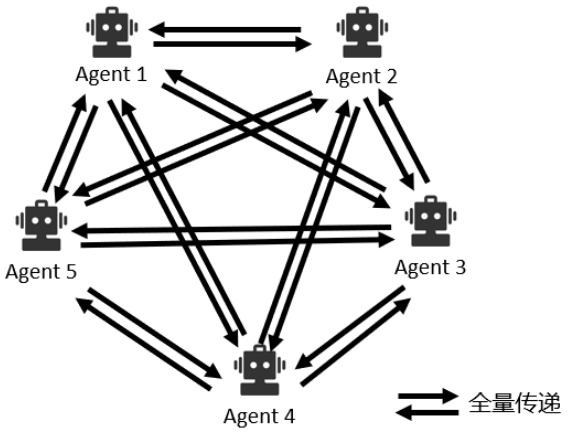


图 1.2　完全连接拓扑（Full Topology）

在完全拓扑中，每个智能体都可以接收其他智能体的输出，如图1.2所示。这种拓扑能够保证信息覆盖，但也最容易产生冗余通信。结合前文分析，本文聚焦以下两个研究问题。

问题 1.1 语义冗余问题：在多智能体持续协作过程中，随着交互轮次增加和上游节点增多，智能体之间传递的自然语言消息会出现角色不匹配、观点重复和历史累积等问题。如何根据接收方角色、前驱节点差异和跨轮历史状态，筛选并保留对后续推理有效的信息，从而在降低 Token 成本的同时保持任务准确率?

问题 1.2 通信边冗余问题：在工具调用型多智能体系统中，不同通信边携带的模型输出、工具调用次数和工具观察 Token 差异较大。如何将通信边贡献建模为可学习概率，并结合任务正确性与工具调用成本判断低贡献通信边，从而动态压缩通信图结构?

1.3.1 面向语义冗余的消息压缩框架

针对既定通信边上自然语言消息冗长、重复和弱相关的问题，本文提出面向语义冗余的消息压缩框架。该工作关注“通信时应传递什么内容”，目标是在不改变原有多智能体拓扑和底层模型的前提下，对智能体之间传递的推理内容进行细粒度筛选与聚合。

具体而言，本文设计了角色感知压缩、节点感知聚合和分歧感知压缩三个模块。角色感知压缩根据接收方智能体职责过滤发送方消息中的无关推理内容，解决完整消息与接收方需求不匹配的问题；节点感知聚合对多个前驱智能体传来的相似观点进行去重和来源标注，解决多前驱消息重复的问题；分歧感知压缩从跨轮历史中提取共识

答案、候选分歧及其理由，解决多轮协作中历史上下文持续膨胀的问题。通过上述设计，本文方法能够在保留关键语义信息的同时减少冗余 Token 数量，提高下游智能体接收上下文的信息密度。

在实验方面，本文在 MMLU、GSM8K、AQuA、MultiArith、SVAMP 和 HumanEval 等任务上评估消息压缩框架，并与 Direct、FullConnected 和 AgentPrune 等基线进行对比。实验结果表明，该方法能够在多数任务上保持或提升任务准确率，同时相对于完全通信拓扑降低推理成本。

1.3.2 面向通信边冗余的图剪枝算法

针对工具调用场景中通信边成本差异较大的问题，本文提出面向通信边冗余的图剪枝算法。该工作关注“哪些智能体之间需要通信”，目标是在搜索、代码执行和文本检查等工具增强任务中，识别并剪除低贡献、高成本的通信边，从图结构层面降低多智能体系统的冗余通信开销。

具体而言，本文将智能体通信边建模为可学习概率，在训练过程中结合任务正确性、模型输出 Token、工具调用次数和工具返回 Token 构造边级优化目标。与只根据最终任务效用评估通信结构的方法不同，本文进一步将工具调用带来的额外成本归因到具体发送方和通信边，使系统能够区分高贡献通信边与传播冗余工具观察的低贡献通信边。在此基础上，本文引入 Taylor 一阶重要性评估，根据边参数与梯度共同衡量移除该边对目标函数的影响，并对低重要性边进行动态剪枝。

在实验方面，本文以 AIME、GAIA、GPQA 和 BigCodeBench 作为主实验任务，并以 MATH500 作为准确率接近饱和场景下的补充任务，验证面向通信边冗余的图剪枝算法的有效性。实验结果表明，该方法能够在工具调用场景中更合理地平衡任务准确率与推理成本，并在多个任务上相对完全通信或原始 AgentPrune 基线减少冗余工具信息传播。

1.4 论文组织结构

本文后续章节组织如下：第2章介绍多智能体系统、语义冗余问题和通信边冗余问题相关研究，分析现有方法的优势与不足；第 3 章围绕面向语义冗余的消息压缩框架展开，给出系统执行流程、核心模块设计以及实验结果分析；第4章进一步面向工具调用场景，介绍面向通信边冗余的图剪枝算法及 Taylor 一阶重要性剪枝策略；最后，

总结全文工作并讨论后续研究方向。

2 相关工作

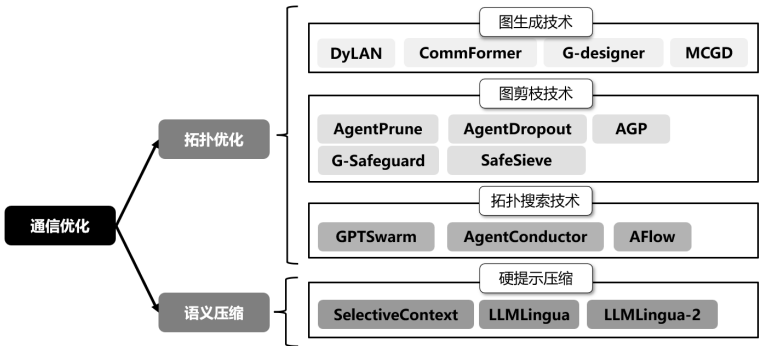


图 2.1　多智能体的两条研究路线

第1章从问题提出角度说明了多智能体系统中的通信瓶颈。本章进一步从已有研究脉络出发，梳理多智能体系统、语义冗余问题和通信边冗余问题相关工作。依据优化对象的不同，相关方法可分为两类：一类关注智能体协作的组织方式与通信路径，核心问题是“哪些智能体之间需要通信”；另一类关注通信路径上传递的自然语言内容，核心问题是“通信时应传递什么信息”。本章重点分析各类方法的研究思路、适用范围和不足，为后续两项工作提供方法背景。

2.1 多智能体系统

第1章已从问题提出角度说明多智能体系统的研究动机。本节进一步从系统实现视角归纳现有大语言模型多智能体系统的主要形态。总体来看，相关工作可以分为角色协作型、工具增强型和通信组织型三类；三类方法分别强调任务如何分工、外部能力如何接入以及信息如何在智能体之间流动。

角色协作型系统通过提示词、角色职责和对话协议把复杂任务拆解为多个协作环节。多智能体辩论方法利用多个模型或多个角色之间的交叉质询提升答案可靠性[26,30]；ChatDev 和 MetaGPT 等框架则将软件开发或复杂任务执行组织为阶段化流程，使不同角色在较明确的任务边界内协同工作[12,28]。这类方法的优势在于能够把单模型难以完成的任务拆解为更稳定的协作过程，但其通信方式往往依赖预设流程和较充分的信息共享，容易在多轮交互中累积重复上下文。

工具增强型系统关注智能体如何调用外部模型、API、搜索引擎或代码执行器。MRKL、HuggingGPT 和 Gorilla 等工作从工具路由、模型调度和 API 使用角度增强大

语言模型的执行能力[57-59]；API-Bank、WebGPT 和 ReWOO 等研究进一步表明，工具调用会把检索证据、函数返回和中间观察写入上下文[60-62]。在多智能体场景中，这些外部观察不仅影响当前智能体，还可能被传递给后续智能体，从而使通信成本和工具成本耦合起来。

通信组织型系统则关注智能体之间的信息流如何被组织。可编程对话框架、智能体社会模拟和工作流编排方法为多智能体交互提供了不同组织形式[29,31-32]；外部记忆和并行函数调用等机制也使跨轮状态管理和工具观察传播更加复杂[63-64]。因此，多智能体系统的通信效率不仅取决于是否存在多个角色，还取决于消息内容是否精炼、通信路径是否必要以及工具观察是否被重复传播。基于这一点，后续两节分别从消息内容层面的语义冗余问题和通信路径层面的通信边冗余问题展开讨论。

2.2 语义冗余问题

2.2.1 定义和分类

在既定通信拓扑下，从语义维度对智能体传递的上下文消息进行压缩，是降低大语言模型推理成本和上下文占用的另一项重要手段。与拓扑优化关注“哪些智能体之间需要通信”不同，语义冗余问题更关注“沿通信链路传递什么内容”。在多智能体系统中，语义冗余问题通常指智能体之间传递的自然语言消息中包含较多重复推理、弱相关背景、低贡献解释或过长历史记忆，使下游智能体需要在更长上下文中寻找有效信息。

结合多智能体通信过程，语义冗余问题可分为三类。第一类是**角色不匹配冗余**，即发送方完整推理并不完全符合接收方智能体的角色职责，导致下游节点接收较多与自身任务无关的信息。第二类是**多前驱重复冗余**，即多个上游智能体围绕同一事实、同一公式或同一候选答案给出相似表述，增加上下文长度但信息增量有限。第三类是**跨轮历史冗余**，即多轮协作中历史消息逐轮累积，使后续智能体难以从冗长上下文中定位当前共识、关键分歧和有效证据。

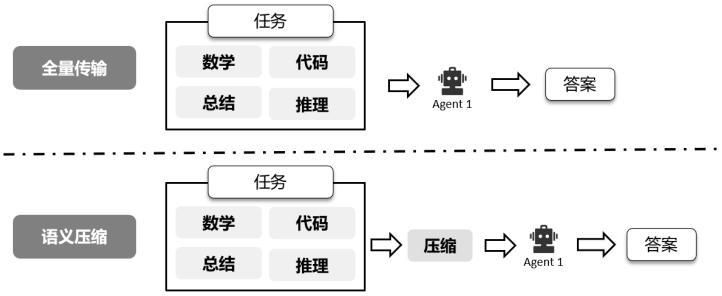


图 2.2　压缩示意图

2.2.2 通用应对策略

硬提示词压缩旨在通过对原始文本进行修改，生成可读且更为精简的自然语言序列。与软提示压缩将上下文映射为不可读的连续向量不同，硬提示词压缩保留了自然语言形式，因此更便于人工检查、跨模型迁移以及在多智能体通信场景中复用。与之相关的软提示和上下文状态压缩方法通常把历史信息压缩为特殊向量、摘要状态或可复用记忆，从而减少后续模型调用中的显式文本长度[38,65]。根据压缩机制的不同，硬提示词压缩相关研究可划分为以下两个方向[66]：

基于过滤的压缩方法：此类方法通过评估词元、短语或句子的重要性，剔除冗余和低信息量的部分，并在保持原文顺序的基础上生成压缩后的上下文。早期代表性工作 SelectiveContext[34]利用较小规模的因果语言模型计算词元的自信息或困惑度，将低自信息内容视为更容易由上下文预测、因而冗余度更高的部分，再按照词元、短语或句子粒度进行过滤。该方法无需额外训练，能够应用于黑盒 LLM，但由于其重要性评估主要依赖语言统计特征，可能误删对特定任务有用但语言上并不突出的信息。LLMLingua[35]进一步提出粗到细的压缩框架，首先通过预算控制器在指令、示例和问题等不同提示词组成部分之间分配压缩率，再利用小模型估计词元困惑度或信息熵，逐步保留高信息量词元。LongLLMLingua 则面向长上下文场景进一步考虑查询相关性和文档级信息筛选[37]。相比简单过滤，上述方法考虑了提示词内部不同模块的重要性差异，并通过迭代式压缩缓解局部删除造成的上下文断裂问题，因此能够在较高压缩率下保持较好的下游任务性能。

后续的 LLMLingua-2[36]则引入了数据蒸馏机制，将压缩任务从基于困惑度的无监督筛选转化为词元级二分类任务。具体而言，该方法先利用强模型生成抽取式压缩结果，再通过自动对齐为原始文本中的词元标注“保留”或“删除”标签，并训练轻量级双向编码器预测每个词元的重要性。推理时，模型按照保留概率选择满足压缩预算的词元，并保持其原始顺序。由于双向编码器能够同时利用左右上下文，LLMLingua-

2 在压缩速度、忠实度和跨任务泛化方面均优于单纯依赖困惑度的方法。进一步地，TACO-RL[39]将强化学习引入过滤式压缩过程，将每个词元的保留或删除视为动作，并根据下游任务表现给予奖励。检索增强场景中的 RECOMP 也体现了选择性保留外部证据、减少冗余文档输入的思路[40]。通过这种方式，压缩器能够根据具体任务目标动态调整剪枝策略，使其更倾向于保留与当前查询或任务评价指标直接相关的信息，从而弥补任务无关过滤方法在语义选择上的不足。

基于重写的压缩方法：与简单的删除词元不同，此类方法利用语言模型的生成与概括能力，主动将冗长的上下文重写为更紧凑的自然语言表达。其核心优势在于能够跨越句子边界进行信息重组，将分散在原文不同位置的关键信息合并为更短的表述，从而避免纯过滤方法可能造成的语义割裂或可读性下降。例如 Nano-Capsulator 框架[67]不再从原始提示词中选择词元，而是训练一个生成式压缩模型，将长提示词封装为更短的 Capsule Prompt。该模型在训练过程中同时考虑语义保持和下游任务效用：一方面要求压缩后的自然语言表示尽可能保留原始提示词的核心含义，另一方面又通过目标 LLM 在相关任务上的输出表现约束压缩结果，使其在压缩长度的同时仍能有效引导模型完成任务。

与过滤式方法相比，基于重写的压缩能够生成较为流畅、连贯且可读的压缩文本，尤其适合处理包含重复解释、长链式推理示例或多轮对话历史的上下文。在多智能体系统中，这类方法可用于将某一智能体的长篇推理过程、观察记录或工具调用结果重写为面向后续智能体的短摘要，从而减少跨智能体传递的词元数量。检索增强生成和多文档问答中的证据压缩同样强调在生成前压缩外部信息，以降低模型读取无关文本的负担[41-42]。然而，这类方法也存在潜在风险：由于压缩过程依赖生成模型，可能出现关键信息遗漏、语义偏移甚至事实性错误。因此，在高精度任务中，重写式压缩通常需要结合任务反馈、事实一致性检测或保守的压缩率设置，以在压缩效率与语义可靠性之间取得平衡。

总体来看，通用提示词压缩方法为缓解语义冗余问题提供了基础，但其优化对象多为单模型输入，通常不显式区分发送方角色、接收方需求、多个前驱节点之间的信息重复以及跨轮历史的时序价值。同时，KV 缓存压缩和流式注意力等系统优化方法主要面向推理内存与上下文窗口效率，并不判断跨智能体消息对接收方是否有用[68-69]。因此，在多智能体通信场景中，语义压缩还需要结合角色关系、节点关系和历史状态进行针对性建模，以避免将对下游智能体有用的关键信息一并删除。

2.3 通信边冗余

2.3.1 定义和分类

通信边冗余问题是指多智能体系统中存在低贡献、重复或成本过高的信息传递路径，使系统在没有获得相应任务收益的情况下产生额外 Token 消耗、工具调用开销和上下文膨胀。与语义冗余问题关注单条消息内部内容不同，通信边冗余问题关注“哪些边应当存在、哪些边应当被削弱或剪除”。在工具调用场景中，该问题更为突出，因为一条通信边不仅传递发送方的自然语言推理，还可能传播搜索结果、代码执行结果和文本检查结果等高成本工具观察。

通信边冗余问题可分为三类。第一类是**空间边冗余**，即同一轮内过密的智能体连接使多个下游节点读取相似或低贡献的上游输出。第二类是**时间边冗余**，即跨轮历史状态被未经筛选地传递，导致早期低贡献历史信息在多轮推理中持续占用上下文。第三类是**工具传播冗余**，即外部工具返回的长观察结果沿通信边反复传播，增加模型输入 Token、工具 Token 和推理成本。

2.3.2 通用应对策略

针对通信边冗余问题，现有方法通常将智能体视为节点、通信链路视为边，并通过图生成、图剪枝和拓扑搜索等方式减少低贡献通信路径[70]。这类方法的共同目标是在保持协作收益的同时，使信息只沿更有贡献的边传播。早期多智能体强化学习中的通信学习方法已经验证，可学习消息通道和通信门控能够在协作任务中减少无效交互[43-45]。

基于图生成的策略：图生成方法旨在根据任务条件自适应构造通信拓扑，而非完全依赖人工预设结构。

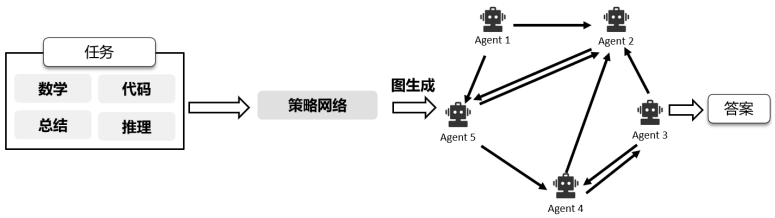


图 2.3　图生成技术示意图

DyLAN（Dynamic LLM-Agent Network）[46]不预先固定所有智能体之间的通信关系，而是将多智能体协作过程建模为随任务推进变化的前馈式动态网络。其核心机制

包括两个阶段：首先在候选智能体集合中进行团队优化，利用 Agent Importance Score 评估不同智能体在当前任务上的边际贡献；随后在任务求解阶段，根据每一轮智能体输出的有效性动态选择后续参与通信的节点。DyLAN 还引入早停机制，当系统已经形成足够稳定的答案或共识时提前终止多轮交互。因此，该方法主要通过减少低贡献智能体的参与次数和削减无效讨论轮次降低成本，并动态生成更贴合当前查询的通信图。注意力通信、图信息瓶颈和目标通信等方法也为稀疏化智能体交互提供了图建模基础[71-73]。

CommFormer[47]将多智能体强化学习中的智能体表示为图节点，将通信信道表示为有向边，并通过可微的图结构学习机制直接优化通信拓扑。其关键做法是对离散边选择进行连续松弛，使邻接矩阵能够参与梯度更新，同时在 Transformer 结构中引入关系增强注意力，以建模智能体间的依赖关系。G-Designer[48]面向 LLM 多智能体系统，将每个智能体的基础模型、角色、状态、工具插件等编码为节点特征，并额外引入任务虚拟节点来表达当前查询需求，随后使用变分图自编码器生成面向特定任务的通信图。MCGD[49]则从多智能体强化学习角度构建稀疏协调图，通过图扩散模型学习有效交互模式，体现了只显式建模关键邻居关系、避免全体智能体两两交互的思路。

基于图剪枝的策略：图剪枝方法通常从密集拓扑出发，逐步删除低贡献节点或通信边，使冗余通信图收敛为更稀疏的协作结构。

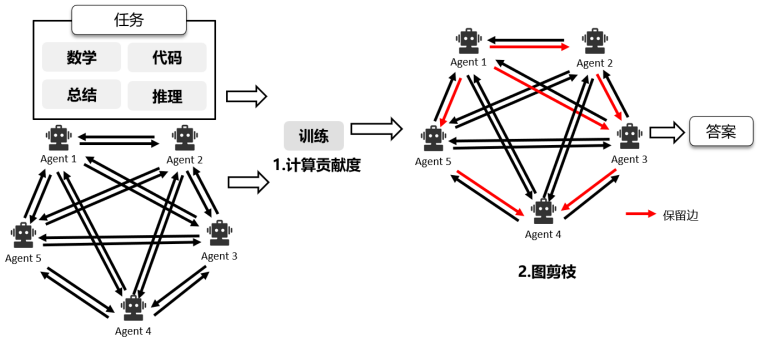


图 2.4　图剪枝技术示意图

AgentPrune[50]将 LLM 多智能体系统表示为空间-时间通信图：同一轮智能体之间的信息交换为“空间边”，跨轮历史传递为“时间边”。它为这些边学习可剪枝的图掩码，并通过系统效用评估器判断不同边对任务结果的贡献。由于外部 LLM 调用和任务评估通常不可微，AgentPrune 使用策略梯度方法优化掩码参数，并最终执行一次性硬剪枝。AgentDropout[51]在边剪枝基础上进一步引入节点丢弃，通过 Node Dropout 和 Edge Dropout 同时减少智能体输入、输出和后续通信边。SafeSieve[52]采用渐进式软剪

枝策略，结合 LLM 语义评估、角色互补性和历史任务表现修正边权，并利用聚类机制保持核心功能簇连通性。AGP（Adaptive Graph Pruning）[53]同时进行节点级硬剪枝和边级软剪枝，使系统能够针对不同查询生成不同规模的稀疏拓扑。G-Safeguard[74]则从安全角度构建 multi-agent utterance graph，用于识别异常节点与异常话语，并通过隔离风险节点或剪断高风险外发边阻止恶意信息扩散。

基于拓扑搜索的策略：拓扑搜索通过在智能体算子和通信边构成的较大搜索空间中探索高效工作流，通常结合强化学习、蒙特卡洛树搜索或网络架构搜索算法。

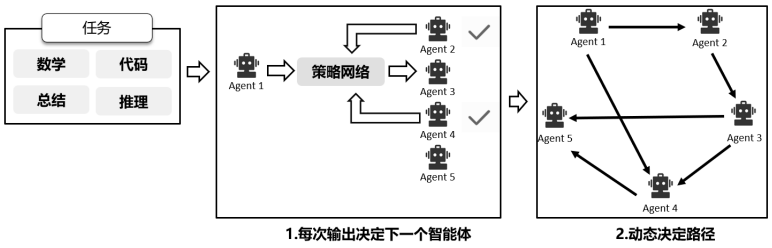


图 2.5　拓扑搜索技术示意图

GPTSwarm[54]将语言智能体系统统一建模为可优化图：节点可以是 LLM 调用、工具或数据处理函数，边表示信息流。它为候选边分配可学习的采样概率，在无环图空间中采样候选拓扑，并通过 REINFORCE 等策略梯度方法根据任务效用更新边概率。AgentConductor[75]面向竞赛级代码生成任务，训练 LLM 为每个问题动态生成 YAML 格式的分层 DAG 拓扑，并根据编译、运行和测试反馈多轮调整拓扑。AFlow[55]将 agentic workflow 表示为可执行代码中的算子组合与依赖关系，并使用蒙特卡洛树搜索探索 Generate、Review、Revise、Ensemble、Test、Programmer 等工作流算子。MASS（Multi-Agent System Search）[76]交错优化 prompt 和 topology，并对低收益模块进行影响力剪枝。MaAS（Multi-agent Architecture Search via Agentic Supernet）[77]提出智能体超网，使每个查询只激活少量算子路径。DynaSwarm[78]则在 GPTSwarm 式参数化通信图基础上引入样本级动态选择，根据输入样本路由到不同稀疏候选结构。近期自动化智能体设计和工作流编译研究进一步说明，prompt、工具调用和拓扑结构可以被统一纳入系统级搜索空间[56,79-80]。

上述研究说明，减少无效节点、无效边和低收益工作流能够缓解多智能体系统的通信负担。但现有方法大多将通信边代价视为同质，或者主要依据任务效用判断边是否保留，对工具调用场景中“某条边传播了多少工具观察、造成多少下游上下文膨胀、带来了多少额外调用成本”刻画不足。尤其在搜索、代码执行和文本检查等工具

增强任务中，一条边的贡献不仅取决于是否提高最终答案，还取决于它是否传播了高成本、低增益的工具信息。因此，本文第四章提出面向通信边冗余的图剪枝算法，将通信边建模为可学习概率，并把任务正确性、模型输出 Token、工具调用次数和工具观察 Token 三类边级成本信号共同纳入优化目标，从而解决工具调用场景下通信边贡献异质、成本难以归因和低贡献边难以及时剪除的问题。

2.4 本章小结

本章围绕多智能体系统及其通信效率优化相关研究进行了梳理。首先，多智能体系统通过角色分工、协作推理和工具调用提升复杂任务处理能力，但也带来了通信路径膨胀和上下文累积问题。其次，语义冗余问题主要表现为角色不匹配、多前驱重复和跨轮历史冗余，现有过滤式与重写式压缩方法为减少自然语言上下文提供了基础，但仍需面向多智能体通信场景进一步适配。最后，通信边冗余问题主要表现为空间边、时间边和工具传播冗余，现有图生成、图剪枝和拓扑搜索方法能够从结构层面降低系统开销，但对工具调用场景下的边级成本归因、工具观察传播和动态低贡献边识别仍不充分。上述不足共同构成了本文后续两个工作的主要动机：第三章从语义内容层面提出面向语义冗余的消息压缩框架，第四章从通信结构层面提出面向通信边冗余的图剪枝算法。

3 面向语义冗余的消息压缩框架

3.1 引言

上一章从相关工作角度梳理了多智能体系统、语义冗余问题和通信边冗余问题。可以看到，现有方法虽然能够在一定程度上降低通信开销，但在多智能体协作场景中仍面临三类细粒度语义冗余问题：发送方完整推理与接收方角色需求不匹配，多个前驱节点传递相似或重复观点，以及多轮历史记忆持续累积导致上下文膨胀。针对这些问题，本章提出面向语义冗余的消息压缩框架，从角色、节点和时序三个维度对通信内容进行压缩，在不改变底层大语言模型能力的前提下提升通信内容的信息密度。

3.2 消息压缩框架

本节首先描述标准多智能体系统的任务执行流程，随后给出消息压缩框架的整体执行过程，并详细介绍角色感知压缩、节点感知聚合和分歧感知压缩三个核心模块。

3.2.1 多智能体系统任务执行流程

多智能体系统通过角色分工与协作推理来完成目标。如图3.1所示，其标准任务执行流程主要包含以下四个核心环节：

1. **任务输入：**接收并标准化外部任务，为智能体构建结构化的上下文环境。
2. **协作推理：**依托预设的通信拓扑，各智能体结合自身角色与前驱节点的历史信息进行多轮次推理，并持续传递中间结果。
3. **结果聚合：**采用投票或共识决策机制，对各智能体的候选答案进行汇总，输出最终可靠结果。
4. **性能评测：**系统性评估模型在任务准确率及通信成本（如词元消耗、推理延迟）上的综合表现。

3.2.2 消息压缩框架执行流程

为解决多智能体协作中的信息冗余问题，本课题在智能体与智能体之间的通信中引入了**消息压缩框架**。该框架从角色、节点和时序三个维度对通信内容进行压缩。

具体执行流程包含以下三个核心步骤：

1. **角色感知压缩：**针对接收方信息需求的不对称性，根据下游角色的具体职责，过

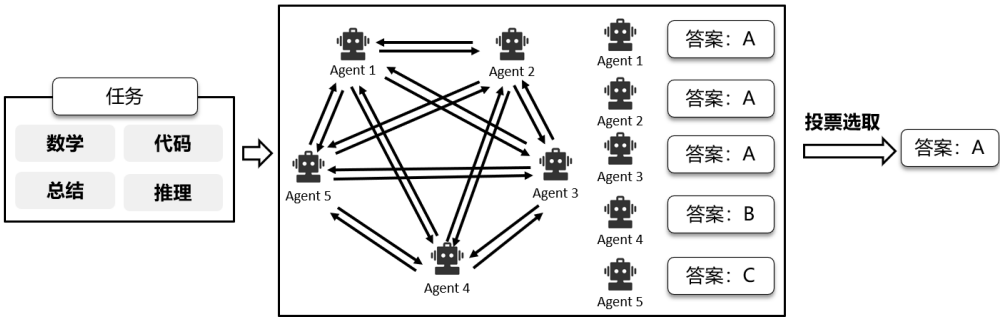


图 3.1　多智能体系统标准任务执行流程示意图

滤前驱智能体消息中的无关推理内容，从而使下游智能体能够获得与自身任务更相关的信息。

2. **节点感知聚合：**针对多个前驱节点可能产生相似推理内容的问题，将不同节点传来的相似推理过程进行去重，避免相同观点在下游智能体上下文中重复出现，从而减少冗余消息传递。

3. **分歧感知压缩：**针对多轮对话记录过长的问题，通过提取历史轮次中的共识与分歧内容，压缩上一轮次传递的信息，并保留有效信息供本轮智能体参考。

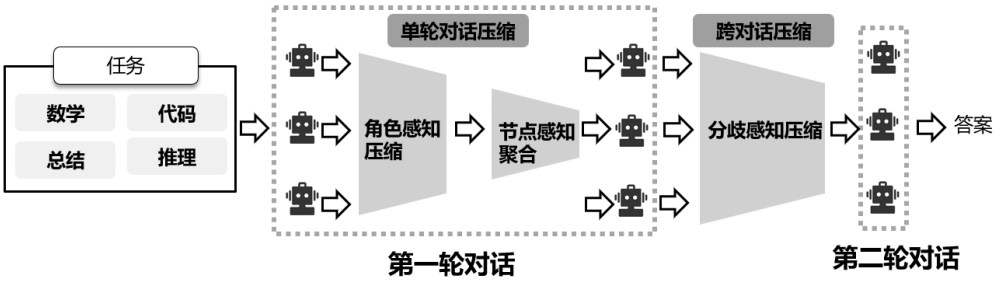


图 3.2　消息压缩框架

3.2.3 功能模块设计

本节介绍消息压缩框架的三个核心模块：角色感知消息压缩、节点感知消息聚合和时序答案一致性摘要。三者分别处理多智能体通信中的三类冗余：第一类是发送方推理内容与接收方角色无关，第二类是多个前驱智能体给出了相似推理，第三类是跨轮历史持续累积导致上下文过长。为避免符号堆叠，本文仅保留必要定义，并重点说明各模块的输入、处理逻辑和输出结果。

设多智能体系统的通信图为 $G = (V, E)$。在第 t 轮中，发送方智能体 u 传递给接收方智能体 v 的消息表示为

$$m_{u \to v}^{(t)} = (r_u^{(t)}, a_u^{(t)}),$$

其中 $r_u^{(t)}$ 表示推理内容，$a_u^{(t)}$ 表示最终答案。本文的压缩操作主要作用于推理内容 $r_u^{(t)}$，原则上不直接改写答案字段，从而避免压缩过程破坏最终判断。

3.2.3.1 角色感知压缩模块

角色感知压缩模块解决的是“消息是否适合当前接收方”的问题。在多智能体系统中，不同智能体承担的职责不同。例如，负责规划的智能体更需要任务拆解和约束信息，负责验证的智能体更关注候选答案、错误风险和反例。如果发送方的完整推理被直接转发给所有下游节点，接收方会同时看到大量与自身职责无关的内容，既增加 token 成本，也容易稀释真正有用的信息。

该模块的处理流程分为三步。首先，将发送方的推理文本按句子切分，得到若干候选推理片段。其次，将每个句子与接收方角色描述进行语义匹配，匹配分数由文本向量的余弦相似度给出：

$$\mathrm{sim}(s, d_v) = \cos(\phi(s), \phi(d_v)),$$

其中 s 表示候选句子，d_v 表示接收方角色描述，$\phi(\cdot)$ 表示文本编码函数。最后，系统根据同一条消息内部的相似度分布自动确定保留阈值，只保留与接收方角色更相关的句子；若保留文本仍超过角色预算，则按原始顺序截断到预算范围内。

该模块的输出仍然是一条结构化消息：推理字段被替换为筛选后的短文本，答案字段保持不变。这样做的好处是，接收方能够获得更贴近自身职责的上下文，同时不会因为压缩推理过程而丢失发送方给出的最终答案。

3.2.3.2 节点感知聚合模块

节点感知聚合模块解决的是“多个前驱消息之间是否重复”的问题。对于同一个接收方节点，多个上游智能体可能从不同角度得出相近结论，也可能在推理过程中反复陈述同一事实。如果将这些内容直接拼接，下游节点会接收到大量重复表达，导致上下文变长，但信息增量有限。

该模块会先收集接收方节点所有前驱智能体的压缩后推理句子，并为每个句子保留来源角色标签。随后，系统按照句子出现顺序逐一检查候选内容：若当前句子与已保留句子的语义相似度高于冗余阈值，则认为它提供的信息已经被覆盖，不再重复加入；若相似度低于阈值，则将其作为新的有效信息保留。本文实现中，冗余判定阈值取 0.70，用于在“去重”和“保留多样观点”之间取得平衡。

聚合后的推理内容由若干带角色标签的句子组成。角色标签的作用是保留信息来源，使下游智能体不仅知道“有哪些观点被保留”，也能知道“这些观点来自哪个角色”。对于多个前驱节点给出的答案，模块采用简单投票生成聚合答案；若出现票数接近或无法明确多数的情况，则保留多个候选答案及其来源，交由后续节点继续判断。

通过该模块，系统不再把多个前驱消息拼接，而是先做跨节点去重和来源标注。这样既能减少重复 token，也能提高下游上下文的信息密度。

3.2.3.3 分歧感知压缩模块

分歧感知压缩模块解决的是“跨轮历史如何保留”的问题。多智能体协作通常需要多轮执行，如果每一轮都完整保存所有智能体的推理和答案，历史记忆会快速膨胀。过长的历史不仅增加推理成本，还可能使模型在后续轮次中难以抓住当前最关键的共识和分歧。

该模块在每一轮协作结束后运行。系统首先收集本轮所有智能体的答案，并对答案文本进行规则化处理，例如去除多余空格、统一大小写、去掉常见答案前缀和标点。经过规则化后，表达相同含义的答案会被归入同一个答案组。基于答案组数量，系统生成两类摘要。

当所有智能体的答案归入同一组时，说明本轮协作已经形成共识。此时摘要只保留共识答案，以及最能代表该结论的简短理由。代表理由通常来自推理内容较完整的智能体，并只保留核心句子，避免把完整推理链再次写入历史。

当答案被分成多个组时，说明智能体之间仍存在分歧。此时摘要会记录每个候选答案、支持该答案的智能体数量，以及对应的简短理由。这样，下一轮智能体能够直接看到当前争议点，而不需要重新阅读上一轮所有冗长输出。

最终生成的摘要会写入各智能体的历史记忆，作为下一轮推理的压缩上下文。该模块只依赖规则化文本处理、答案分组和简短摘要模板，不额外调用大语言模型，因此能够在控制成本的同时保留跨轮协作中最重要的信息。

3.3 实验设置

为验证面向语义冗余的消息压缩框架在不同任务类型和不同基座模型上的有效性，本文在综合知识、数学推理和代码生成任务上开展实验，并从任务准确率与推理成本两个维度进行评估。

3.3.1 数据集

为全面客观地评估模型能力，本文选取多智能体系统研究中常用的 6 个数据集，涵盖综合知识、数学推理和代码生成三个核心能力维度。具体任务特征与选取依据如表3.1所示。

任务类型	数据集名称	描述	样本数量
综合知识	MMLU[81]	涵盖 57 个不同学科的综合性基准	153
数学推理	GSM8K[82]	小学数学应用题数据集	1319
	AQuA[83]	复杂的代数应用题	254
	MultiArith[84]	多步算术运算	600
	SVAMP[85]	语义和扰动生成的数学题	1000
代码生成	HumanEval[86]	生成完整 Python 代码	164

表 3.1　实验评测数据集概览

3.3.2 对比基准

实验设置了四类对比基准。首先是 Direct 方法，即单智能体直接完成任务，不引入智能体间通信，用于衡量单模型基础能力和最低推理成本。其次是 Fullconnect 方法，上游智能体生成的原始输出直接、完整地透传给下游智能体，不进行任何截断，从而保留完整上下文内容，代表多智能体通信开销的上限及任务基础性能的对照标准。第三是 AgentPrune 方法，作为当前多智能体系统拓扑优化的代表性方法，该基线对智能体间的通信边进行剪枝。最后是本文方法，即引入本文设计的消息压缩模块，在智能体交互前对冗长推理和弱相关背景进行压缩，仅保留与后续推理更相关的关键信息。

3.3.3 实现细节

为了保证实验结论的客观性与普适性，本文选取三个主流大语言模型作为多智能体的基座模型。这些模型在 API 调用成本上存在显著差异，具体计费标准如表3.2所示。

模型名称	输入价格（千 tokens）	输出价格（千 tokens）
Qwen2.5-14B-Instruct	¥0.0007	¥0.0007
Qwen3-14B	¥0.0005	¥0.0020
MinMax-M3	¥0.0021	¥0.0084

表 3.2　API 调用单价对比表

Qwen2.5-14B-Instruct：作为 2024 年开源指令模型的代表，其在通用问答、指令遵循与文本生成等任务中表现出较高的稳定性。本研究将其设为基础对照组，旨在与 Qwen3-14B 形成严格的控制变量（参数量级一致）。通过引入该对照组，重点考察在缺乏新一代推理与指令优化机制的前提下，消息压缩策略对任务生成质量、词元消耗及调用成本的具体影响。

Qwen3-14B：作为中等规模参数开源模型的代表，该模型在推理效率、部署成本与基础性能之间实现了较优的平衡。结合表3.2数据可知，其 API 调用成本相对较低。选取该模型旨在探究消息压缩策略在低成本、常规算力约束下，对实际任务效能及经济成本的优化潜力。

MiniMax-M3：引入该闭源商业模型旨在拓展实验基座的架构多样性，并构建高成本模型对照场景。鉴于其 API 调用费率较高（输入与输出单价约为 Qwen3-14B 的 4 倍以上），在处理长文本任务时容易产生较高的边际成本。选取该模型旨在验证消息压缩策略在面对高资源消耗型商业大模型时，能否有效降低计算冗余并实现成本缩减。

在所有实验中，均采用相同的系统提示词、智能体数量、超参数以及数据集划分，以确保实验结果的可比性。本文实验图表均由统一格式的实验结果表生成，表中记录了模型、方法、输入词元数、输出词元数、推理成本和准确率等字段。其中，推理成本按照输入、输出 Token 数量与表3.2中的 API 单价换算，单位为人民币元；同一数据集内各方法采用相同评测规模，因此成本数值主要用于横向比较不同通信策略的相对开销。对于同一数据集、同一模型和同一方法，结果表仅保留一次完整评测结果，避免在论文中选择性呈现局部最优实验。

3.3.4 评估指标

本文主要从任务完成质量与通信成本两个维度，选取了以下两项核心评价指标：

准确率 (Accuracy)：衡量模型完成任务的有效性。针对 MMLU 及四项数学推理

数据集（GSM8K、AQuA、MultiArith、SVAMP），提取模型最终输出的答案与标准答案进行精确匹配以计算正确率；对于 HumanEval 代码生成数据集，则以测试用例的通过率（Pass@1）作为准确率进行评估。

推理成本 (Inference Cost)：衡量多智能体通信过程中的经济开销。具体统计系统完成对应评测集推理时，由输入词元和输出词元产生的 API 调用费用，单位为人民币元。

3.4 实验结果与分析

本阶段实验在 MMLU、GSM8K、AQuA、MultiArith、SVAMP 和 HumanEval 六个数据集上展开，覆盖通用知识理解、数学推理、多项选择推理和代码生成等不同任务类型。实验对比了 Direct、Fullconnect、AgentPrune 和本文方法。

为保证总体结果统计的可解释性，本文在主实验中选取 MiniMax-M3、Qwen3-14B 和 Qwen2.5-14B-Instruct 作为主要分析模型，并按模型分别计算其在可用数据集上的平均表现。三个主分析模型均覆盖 MMLU、GSM8K、AQuA、MultiArith、SVAMP 和 HumanEval 六个数据集，因此总体图中的 $n = 6$ 表示每个模型均按六个数据集求平均。总体实验不将所有模型和数据集混合为单一平均值，而是分别展示三个模型下不同方法的平均表现，以避免不同模型能力水平和价格体系带来的统计偏差。

需要说明的是，本节柱状图展示的是固定评测集上的单次完整评测汇总结果，尚未包含多随机种子重复实验和置信区间。因此，本文在分析中不将 0.1 至 0.3 个百分点以内的小幅差异解释为统计显著优势，而更关注跨数据集趋势、成本下降幅度以及准确率与成本之间的综合权衡。对于 AQuA 和 HumanEval 等本文方法未取得最优准确率的数据集，正文仍保留并分析其原因，以保证实验呈现的完整性。准确率柱状图均采用 0–100% 的完整纵轴范围，避免因截断纵轴放大不同方法之间的视觉差异。

3.4.1 任务准确率结果

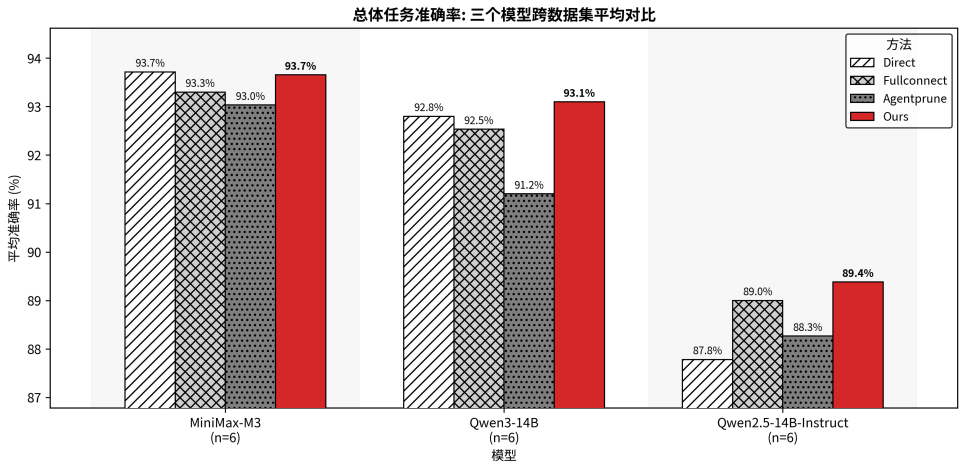
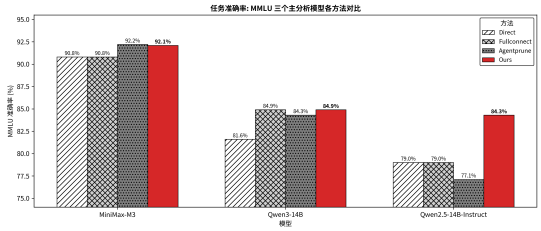


图 3.3　六个数据集在不同模型下的平均准确率对比

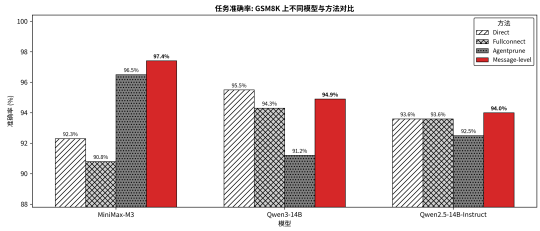
图3.3展示了三个主要模型在不同方法下的跨数据集平均准确率。整体来看，本文方法在 Qwen3-14B 和 Qwen2.5-14B-Instruct 上均取得最高平均准确率，在 MiniMax-M3 上与 Direct 方法基本持平，同时高于 Fullconnect 和 AgentPrune。这说明本文方法在不同模型能力水平下均具有较好的稳定性，尤其在中小规模模型上能够带来更明显的性能收益。

具体而言，在 Qwen3-14B 上，本文方法的平均准确率达到 93.10%，高于 Direct 的 92.80%、Fullconnect 的 92.53% 和 AgentPrune 的 91.20%。在 Qwen2.5-14B-Instruct 上，本文方法的平均准确率为 89.38%，高于 Direct 的 87.78%、Fullconnect 的 89.00% 和 AgentPrune 的 88.27%。在 MiniMax-M3 上，Direct 方法的平均准确率为 93.72%，本文方法为 93.66%，二者差距仅为 0.06 个百分点，基本处于同一水平；同时，本文方法仍高于 Fullconnect 和 AgentPrune。

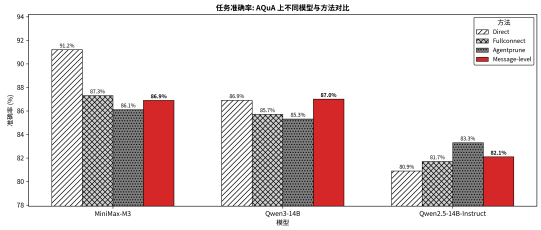
为了避免总体平均掩盖不同任务类型的差异，下面进一步按数据集展开分析。总体上，本文方法在 MMLU、GSM8K、MultiArith 和 SVAMP 上表现较强，在 AQuA 和 HumanEval 上则呈现出更明显的任务依赖性，说明消息级协作更适合知识理解和数学推理类任务，而在多项选择干扰项较强或代码生成需要执行反馈的任务中仍有改进空间。



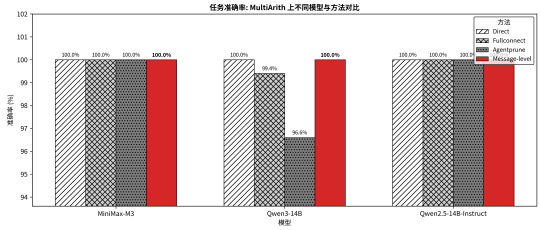
(a) MMLU 准确率



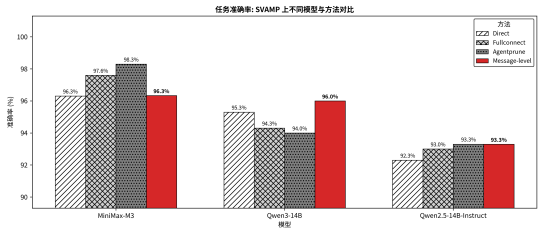
(b) GSM8K 准确率



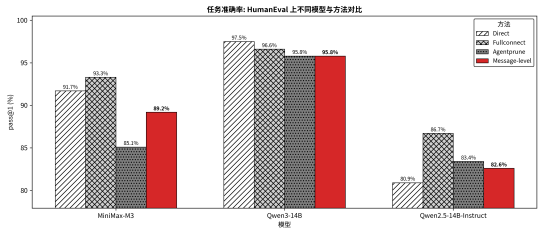
(c) AQuA 准确率



(d) MultiArith 准确率



(e) SVAMP 准确率



(f) HumanEval 准确率

图 3.4　各数据集上不同模型与方法的准确率对比

MMLU 在 MMLU 数据集上，本文方法整体表现较为稳定。在主分析的三个模型中，本文方法的平均准确率为 87.10%，高于 Direct 的 83.80%、Fullconnect 的 84.90% 和 AgentPrune 的 84.53%。其中，Qwen2.5-14B-Instruct 的提升最明显，本文方法达到 84.30%，相比 Direct 和 Fullconnect 均提升 5.30 个百分点，相比 AgentPrune 提升 7.20 个百分点。Qwen3-14B 上，本文方法达到 84.90%，与 Fullconnect 持平，并高于 Direct 和 AgentPrune。MiniMax-M3 上，本文方法为 92.10%，与 AgentPrune 的 92.20% 基本持平，并高于 Direct 和 Fullconnect。

GSM8K 在该数据集上，本文方法在三个主分析模型上的平均准确率为 95.44%，高于 Direct 的 93.80%、Fullconnect 的 92.90% 和 AgentPrune 的 93.40%。其中，MiniMax-M3 使用本文方法达到 97.41%，分别高于 Direct、Fullconnect 和 AgentPrune 5.11、6.61 和 0.91 个百分点，说明消息级协作能够增强复杂算术推理中的答案鲁棒性。Qwen3-14B 上，Direct 方法为 95.50%，略高于本文方法的 94.90%；但本文方法仍高于 Fullconnect 和 AgentPrune。Qwen2.5-14B-Instruct 上，本文方法达到 94.00%，高于 Direct 和 Fullconnect

的 93.60%，也高于 AgentPrune 的 92.50%，说明新增结果进一步支持本文方法在数学推理任务上的稳定收益。

AQuA 在 AQuA 数据集上，结果更具任务依赖性。三个模型上，本文方法的平均准确率为 85.33%，低于 Direct 的 86.33%，但高于 Fullconnect 和 AgentPrune 的 84.90%。分模型看，Qwen3-14B 使用本文方法达到 87.00%，为该模型下最高结果，相比 Direct、Fullconnect 和 AgentPrune 分别提升 0.10、1.30 和 1.69 个百分点；Qwen2.5-14B-Instruct 上，本文方法为 82.10%，高于 Direct 和 Fullconnect，但低于 AgentPrune；MiniMax-M3 上，Direct 方法达到 91.20%，明显高于其他协作方法。这说明多项选择推理任务中，额外消息可能同时带来有用信息和干扰信息，需要更强的任务自适应筛选。

MultiArith 在 MultiArith 数据集上，各方法整体接近饱和。本文方法在三个主分析模型上均达到 100.00%，与 Direct 的平均表现持平，并高于 Fullconnect 的 99.80% 和 AgentPrune 的 98.87%。其中，Qwen3-14B 上 Fullconnect 为 99.40%、AgentPrune 为 96.60%，而本文方法保持 100.00%，说明在较简单的算术推理任务中，消息级协作至少不会破坏已有推理能力，并能够避免部分结构化协作方法带来的性能波动。

SVAMP 相比 MultiArith，SVAMP 更强调语义理解和问题变体。三个主分析模型上，本文方法的平均准确率为 95.21%，与 AgentPrune 的 95.20% 基本持平，并高于 Direct 的 94.63% 和 Fullconnect 的 94.97%。其中，Qwen3-14B 使用本文方法达到 96.00%，高于 Direct、Fullconnect 和 AgentPrune；Qwen2.5-14B-Instruct 上，本文方法达到 93.30%，与 AgentPrune 持平；MiniMax-M3 上，AgentPrune 达到 98.30%，高于本文方法的 96.33%。这说明本文方法在中小规模模型上的收益更明显，而强模型在部分任务上对协作结构的敏感性更高。

HumanEval 在 HumanEval 数据集上，本文方法并未取得最优平均结果。三个主分析模型中，Fullconnect 的平均准确率为 92.20%，Direct 为 90.03%，本文方法为 89.20%，AgentPrune 为 88.10%。分模型看，MiniMax-M3 和 Qwen2.5-14B-Instruct 上 Fullconnect 表现最好，Qwen3-14B 上 Direct 表现最好；本文方法在 MiniMax-M3 上高于 AgentPrune，在 Qwen3-14B 上与 AgentPrune 持平，在 Qwen2.5-14B-Instruct 上高于 Direct 方法 1.70 个百分点但低于 Fullconnect。该结果说明，对于代码生成任务，仅依赖消息级协作可能不足以替代代码执行、单元测试或错误反馈机制，后续应将消息筛选与可执行验证结合起来。

3.4.2 消耗成本结果

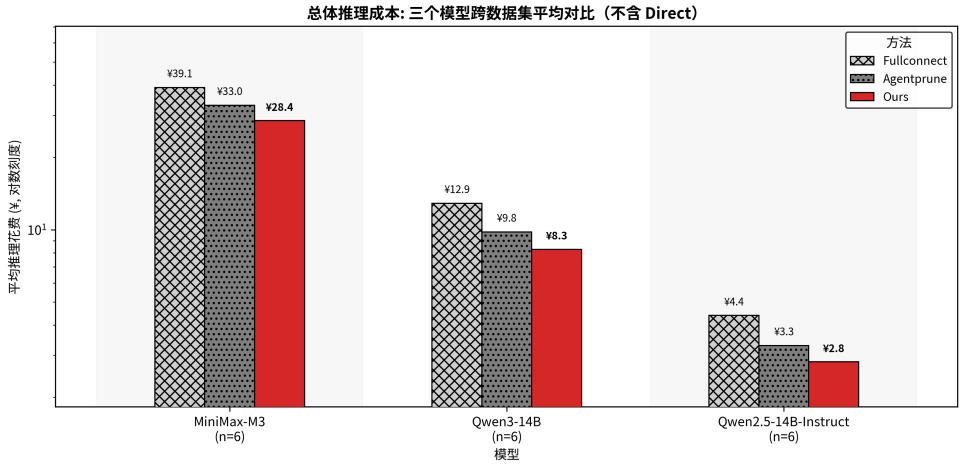


图 3.5　六个数据集在不同模型下的平均推理成本对比

图3.5展示了三个主要模型在不同方法下的跨数据集平均推理成本。Direct 方法不包含智能体间通信，其成本更多反映单智能体执行的低消耗下界，不能直接说明消息压缩对多智能体通信链路的优化效果。因此，后续表格不再将 Direct 作为成本优化对照，而是以 Fullconnect 和 AgentPrune 作为多智能体通信基线，重点观察本文方法在保留协作结构时能否降低冗余消息带来的额外开销。

相比 Fullconnect，本文方法在六个数据集上均降低了三模型平均推理成本，其中 MMLU 降低约 38.83%，GSM8K 降低约 31.70%，SVAMP 降低约 36.21%，MultiArith 降低约 34.34%，HumanEval 降低约 21.63%。相比 AgentPrune，本文方法在 MMLU、GSM8K、MultiArith、SVAMP 和 HumanEval 上均取得成本下降；AQuA 上相对 AgentPrune 成本有所增加，但仍低于 Fullconnect，说明多项选择推理任务中的消息筛选强度仍需进一步自适应调整。

表 3.3　本文方法相对多智能体通信基线的推理成本降低情况

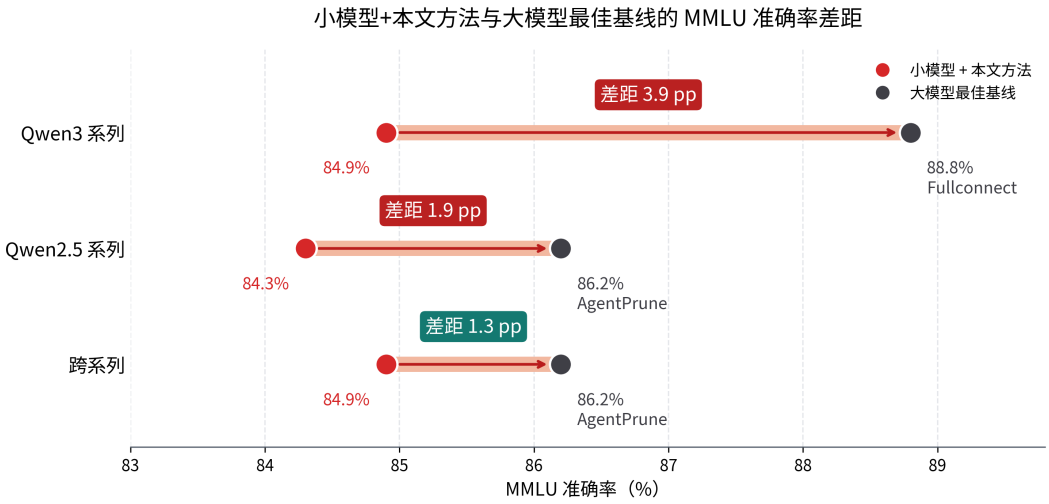
数据集	Fullconnect 成本	AgentPrune 成本	本文方法成本	相对 Fullconnect 变化	相对 Fullconnect 降幅	相对 AgentPrune 变化	相对 AgentPrune 降幅
MMLU	7.70	6.27	**4.71**	**-2.99**	**38.83%**	**-1.56**	**24.88%**
GSM8K	50.71	42.45	**34.63**	**-16.08**	**31.70%**	**-7.82**	**18.42%**
AQuA	21.79	13.79	**16.51**	**-5.28**	**24.23%**	+2.72	-19.72%
MultiArith	5.30	4.32	**3.48**	**-1.82**	**34.34%**	**-0.84**	**19.44%**
SVAMP	10.88	9.43	**6.94**	**-3.94**	**36.21%**	**-2.49**	**26.41%**
HumanEval	16.32	15.88	**12.79**	**-3.53**	**21.63%**	**-3.09**	**19.46%**
平均	**18.78**	**15.36**	**13.18**	**-5.61**	**29.85%**	**-2.18**	**14.20%**

表3.3中，成本均为三个主分析模型的平均推理成本；成本变化定义为本文方法成

本减去对应基线成本，负值表示成本降低；成本降幅为正表示成本下降，负值表示成本增加。可以看到，本文方法相对 Fullconnect 的平均成本由 18.78 降至 13.18，平均降幅为 29.85%；相对 AgentPrune 的平均成本由 15.36 降至 13.18，平均降幅为 14.20%。这说明消息级压缩的主要价值并不是与无通信 Direct 方法比较绝对低消耗，而是在已有多智能体通信结构内部压缩语义冗余，从而降低完全通信或结构剪枝基线中的额外 Token 开销。

3.4.3 小模型超过大模型的可能性分析

除比较不同方法的整体准确率和推理成本外，本文进一步关注一个实际问题：在引入消息压缩后，较小规模模型是否可能接近甚至超过更大规模模型。该问题对于多智能体系统部署具有现实意义，因为小模型通常具有更低的调用成本；如果通信优化能够弥补部分模型能力差距，则系统可以在成本受限场景中获得更高的性价比。



注：大模型最佳基线在 Direct、Fullconnect、AgentPrune 中选取；最接近的是跨系列，仅落后 1.3 pp。

图 3.6　MMLU 上小模型相对大模型最佳基线的准确率差距

图3.6以 MMLU 为例，展示小模型采用本文方法后相对大模型最佳基线的准确率差值，其中负值表示小模型仍低于对应的大模型基线。结果显示，小模型 + 本文方法尚未在该数据集上超过大模型最佳基线，但在 Qwen3 系列、Qwen2.5 系列和跨系列对比中，差距分别为 3.90、1.90 和 1.30 个百分点。也就是说，消息压缩不能直接消除模型规模带来的基础能力差距，但可以在一定程度上降低小模型与大模型之间的性能间隔。

从机制上看，小模型更容易受到冗余上下文、重复推理和无关消息的干扰，因此

消息压缩带来的收益往往更明显。当任务主要依赖可提取的关键信息、标准化推理步骤或多智能体之间的互补观点时，小模型有机会通过更高质量的通信上下文接近大模型表现，甚至在部分强噪声或高成本通信场景中超过大模型的低效协作基线。相反，对于 AQuA、HumanEval 等更依赖复杂选项辨析或可执行验证的任务，仅压缩消息仍不足以稳定弥补模型能力差距。

因此，本章实验更支持：小模型通过通信优化具备接近大模型的潜力，但尚不能认为可以普遍超过大模型。后续若要进一步验证“小模型超过大模型”的可能性，需要在更多数据集上加入小模型 + 压缩方法与大模型 Direct、Fullconnect、AgentPrune 等基线的成对比较，并结合成本指标判断其是否形成真正的准确率–成本优势。

3.4.4 结果分析

综合六个数据集的细分结果可以看出，本文方法的优势更适合概括为在多数任务和模型上提升或保持准确率，而不是在所有单项任务上绝对最优。尤其在 MMLU、GSM8K、MultiArith 和 SVAMP 上，本文方法体现出较好的稳定性；而在 AQuA 和 HumanEval 上，不同任务类型对协作信息的需求差异更明显，说明后续需要根据任务类型、模型能力和推理不确定性动态调整消息筛选强度。由于当前实验尚未加入多次重复运行的方差统计，本文对 MiniMax-M3 上 0.06 个百分点这类极小差异只作同等水平处理，不作为方法优劣的主要依据。

综上，本文方法的目标在多智能体协作场景下实现更合理的准确率–成本平衡。实验结果表明，消息级协作能够在减少冗余通信的同时保持多智能体推理收益，为构建更高效的多智能体大模型推理系统提供了一种可行方向。

3.5 本章小结

本章围绕多智能体系统中的语义冗余问题，提出并实现了面向语义冗余的消息压缩框架。首先，本文分析了标准多智能体任务执行流程中的消息传递瓶颈，并将压缩模块嵌入智能体之间的通信链路；其次，分别设计了角色感知压缩、节点感知聚合和分歧感知压缩三个模块，以减少无关推理、重复观点和跨轮历史累积带来的上下文开销；最后，通过多个知识理解、数学推理和代码生成数据集上的实验，验证了该方法能够在多数任务中保持或提升准确率，并降低相对于完全通信拓扑的推理成本。

实验结果表明，消息级压缩能够在不改变底层基座模型的前提下改善多智能体协

作的准确率–成本平衡，为后续进一步研究任务自适应压缩强度、压缩模块消融分析以及与拓扑剪枝方法的联合优化提供了基础。

4 面向通信边冗余的图剪枝算法

4.1 引言

上一章从语义内容出发，研究了如何在多智能体系统内部压缩智能体之间传递的自然语言消息。然而，在更复杂的工具调用场景中，仅压缩消息内容仍不足以解决全部通信成本问题。随着大语言模型智能体逐步具备搜索、代码执行、文本检查和外部 API 调用能力[20-21]，以及外部记忆管理、并行函数调用等系统能力[63-64]，多智能体系统的成本不再只来自模型输入输出 Token，还来自工具调用次数、工具返回内容长度以及工具观察结果在智能体之间的重复传播。

工具调用型智能体通常遵循 “推理–行动–观察” 的闭环过程[22]：智能体先根据任务生成中间推理，再决定是否调用搜索、代码执行或文本检查等外部工具，随后把工具返回结果写入上下文并继续推理。在单智能体系统中，工具观察主要影响当前智能体的上下文长度；而在多智能体系统中，某个智能体产生的工具观察还可能沿通信边传播给多个后继智能体，进而触发下游重复分析或二次工具调用。因此，工具调用成本具有明显的图结构放大效应。

在这类场景下，通信边的价值具有更强的异质性。一条边如果连接的是高质量求解智能体和最终验证智能体，可能显著提升任务正确率；但如果该边只是传播冗长的工具观察、重复的中间代码或无关搜索结果，就会增加下游上下文长度，并进一步放大系统开销。因此，面向工具调用任务的通信优化需要同时回答两个问题：第一，哪些智能体之间的通信确实有助于最终任务正确性；第二，哪些通信边会携带高成本工具信息，应当在图结构层面被抑制或剪除。

现有多智能体通信图优化方法通常将边的重要性与任务效用直接关联[50,54]，但较少显式区分普通推理输出和工具调用输出。针对这一不足，本章提出一种面向通信边冗余的图剪枝算法。该方法将智能体通信边建模为可学习概率，在训练过程中以任务正确性为收益项，并引入模型输出 Token、工具调用次数和工具观察 Token 三类边级成本信号构造优化目标；进一步引入 Taylor 一阶重要性评估[87-89]，对低贡献通信边进行动态剪枝，从而在多轮推理中获得更稀疏、成本更可控的通信结构。

4.2 图剪枝算法

4.2.1 问题定义与工具成本建模

设多智能体系统包含 n 个智能体，记为 $\mathcal{A} = \{A_i\}_{i=1}^{n}$。系统在多轮协作过程中通过通信图传递中间推理、候选答案、工具观察和历史状态。本文将通信图中的候选边划分为两类：空间边表示同一推理轮次内由发送方智能体到接收方智能体的信息传递，时间边表示相邻推理轮次之间历史状态或记忆信息的延续。与不使用外部工具的多智能体推理不同，工具调用型任务中的消息不仅包含自然语言推理，还可能携带搜索结果、代码执行输出、文本检查结果等外部观察。因此，通信边的开销不仅取决于边数量和消息长度，还与发送方在相应轮次产生的工具调用行为密切相关。

设第 t 轮中智能体 A_i 的输出为

$$o_i^{(t)} = \left(r_i^{(t)}, \hat{y}_i^{(t)}, q_i^{(t)}\right), \tag{4.1}$$

其中 $r_i^{(t)}$ 表示推理文本，$\hat{y}_i^{(t)}$ 表示候选答案，$q_i^{(t)}$ 表示工具调用相关信息，包括工具类型、调用参数、返回观察以及调用轮次等元数据。为统一度量不同工具行为对通信成本的影响，本文引入三类边级成本信号，分别刻画发送方模型输出长度、工具调用次数和工具观察长度，并定义发送方成本：

$$c_i^{(t)} = \lambda_o \frac{O_i^{(t)}}{N_o} + \lambda_k \frac{K_i^{(t)}}{N_k} + \lambda_z \frac{Z_i^{(t)}}{N_z}, \tag{4.2}$$

其中 $O_i^{(t)}$ 为智能体 A_i 在第 t 轮生成的模型输出 Token 数，$K_i^{(t)}$ 为工具调用次数，$Z_i^{(t)}$ 为工具观察结果 Token 数；N_o、N_k 和 N_z 为归一化系数，λ_o、λ_k 和 λ_z 为对应成本项的权重。通过归一化处理，三类不同量纲的边级信号可以被纳入同一优化目标，从而为后续通信边学习提供可比较的成本惩罚。

对于一条由智能体 A_i 指向智能体 A_j 的潜在通信边 $e = (i, j)$，若该边在第 t 轮被激活，则接收方智能体 A_j 将读取发送方智能体 A_i 的当前输出或历史记忆。因此，边级成本应归因于发送方在对应轮次产生的模型输出和工具观察。本文定义边 e 在第 t 轮的成本为

$$\mathcal{C}_e^{(t)} = \mathbf{1}\left(z_e^{(t)} = 1\right) c_i^{(\tau(e,t))}, \tag{4.3}$$

其中 $z_e^{(t)}$ 表示边 e 在第 t 轮是否被采样并加入实际通信图，$\tau(e,t)$ 表示成本归因对应

的发送方轮次。对于空间边，$\tau(e,t)=t$；对于时间边，$\tau(e,t)=t-1$。该定义区分了当前轮输出传播和跨轮记忆传播，使边级成本能够反映工具观察在通信图中的扩散开销。

4.2.2 可学习通信边概率建模

为使通信结构能够根据任务反馈自适应调整，本文为每条潜在通信边 e 引入可学习参数 θ_e，并将边保留概率定义为

$$p_e=\sigma\left(\frac{\theta_e}{\tau_p}\right), \tag{4.4}$$

其中 $\sigma(\cdot)$ 为 Sigmoid 函数，τ_p 为采样温度系数。训练阶段的边状态由伯努利分布采样得到：

$$z_e^{(t)}\sim \text{Bernoulli}(p_e). \tag{4.5}$$

若 $z_e^{(t)}=1$ 且该边不破坏空间有向无环执行顺序，则发送方智能体被加入接收方智能体的前驱集合；若 $z_e^{(t)}=0$，该边在当前轮次中不参与通信。

为兼顾通信结构的全局稳定性与推理阶段差异，本文分别为空间边和时间边维护可学习 logit 参数。在静态图设置下，各推理轮次共享同一组空间边和时间边概率；在动态图设置下，不同轮次维护独立的边概率参数，使系统能够在任务规划、信息整合和结果验证等阶段形成差异化通信结构。训练过程中，系统记录每次边采样事件的对数概率 $\log\pi_\theta(z_e^{(t)})$，使任务正确性和工具成本能够通过策略梯度影响通信边概率。具有较高任务贡献且成本可控的边将获得更高保留概率；频繁传播高成本工具观察但对最终答案贡献有限的边，其保留概率将在训练中逐步降低。训练结束后，学习得到的概率图将被离散化为固定通信图，用于验证或测试阶段推理。

4.2.3 成本感知优化目标

给定任务样本 x 及标准答案 y，设多智能体系统生成的最终答案为 $\hat{y}$。本文采用任务评分函数 $S(\hat{y},y)$ 衡量答案正确性，函数取值范围为 $[0,1]$。对于数学推理和多项选择任务，该函数可由答案匹配结果给出；对于开放问答任务，则可由规范化匹配、别名匹配或任务专用评测器计算。

传统通信图优化通常以最终任务得分作为通信边学习的主要信号，较少区分不同边所携带的工具调用成本。由于一次任务执行只能观察到当前采样通信图下的整体结

果，本文不对单条边的严格反事实贡献作独立估计，而是构造用于策略梯度优化的边级效用信号：

$$R_e^{(t)} = S(\hat{y}, y) - \mathcal{C}_e^{(t)}. \tag{4.6}$$

该效用信号将最终任务得分与被采样边携带的成本惩罚结合起来，用于强化高质量、低成本的通信决策。对于未被采样的边，其工具成本项为零；对于被采样的边，系统根据发送方在对应轮次的模型输出 Token、工具调用次数和工具观察 Token 计算成本惩罚。因此，该目标并不声称精确度量单条边的独立因果贡献，而是为通信边概率学习提供可训练、可归因的优化信号。

由于通信边采样属于离散结构决策，本文采用策略梯度形式优化边概率。对于一次任务执行中记录的边采样事件集合 $\mathcal{E}_{\text{sample}}$，边策略损失定义为

$$\mathcal{L}_{\text{pg}} = -\sum_{(e,t)\in\mathcal{E}_{\text{sample}}} \log \pi_\theta(z_e^{(t)}) R_e^{(t)}. \tag{4.7}$$

该损失鼓励系统提高高效用通信决策的出现概率，并降低低效用通信决策的出现概率。与在样本级统一扣除工具成本的方法相比，边级成本归因能够区分不同发送方智能体的工具使用差异，使通信结构学习从粗粒度任务反馈转化为细粒度边级反馈。

4.2.4 Taylor 一阶重要性剪枝

在边概率训练过程中，仅依据 logit 大小进行剪枝难以准确反映边对目标函数的影响。例如，某些边的当前采样概率较低，但其梯度较大，说明继续优化可能显著改变任务目标；相反，某些边虽然采样概率较高，但梯度接近零，说明其边际贡献有限。受模型剪枝中梯度敏感性和损失扰动估计思想的启发，本文采用 Taylor 一阶展开评估通信边的重要性[88-90]。

对于边参数 θ_e，移除该边可表示为对参数施加扰动 $\Delta\theta_e = -\theta_e$。根据 Taylor 一阶展开，目标函数变化的一阶估计为

$$\Delta\mathcal{L}_{\text{pg},e} \approx \frac{\partial \mathcal{L}_{\text{pg}}}{\partial \theta_e} \Delta\theta_e. \tag{4.8}$$

据此，本文定义边重要性为

$$I_e = \left| \theta_e \frac{\partial \mathcal{L}_{\text{pg}}}{\partial \theta_e} \right|. \tag{4.9}$$

该指标同时考虑边参数规模和损失梯度，可用于估计删除该通信边对边策略损失造成的一阶影响。训练过程中，系统在完成反向传播后、进入下一轮采样前，对所有仍处于活跃状态的边计算 I_e，并按重要性从小到大排序，剪除比例为 ρ 的低重要性边：

$$\mathcal{P} = \text{argmin}_{\mathcal{S}\subseteq\mathcal{E}_{\text{active}},\,|\mathcal{S}|=\rho|\mathcal{E}_{\text{active}}|} \sum_{e\in\mathcal{S}} I_e. \tag{4.10}$$

剪枝集合 $\mathcal{P}$ 中的边在后续图构造中被屏蔽，不再参与采样和消息传递。

该剪枝策略具有两方面作用。首先，边重要性由成本感知边策略损失导出，剪枝结果同时受到任务正确性和工具调用成本惩罚项影响，而不是仅根据静态通信概率排序。其次，该策略可扩展至多轮动态图设置，对不同推理阶段的空间边和时间边分别计算重要性，从而形成阶段自适应的稀疏通信结构。与面向模型参数量压缩的稀疏化方法不同[91-93]，本文剪枝对象是多智能体通信边，其目标是降低跨智能体消息传播和工具观察扩散造成的系统级开销。

4.2.5 算法流程

综合上述建模与优化目标，本文方法的训练与执行过程如下。为避免训练阶段随机采样影响测试稳定性，本文将边概率学习与测试阶段推理明确分离：训练阶段通过采样通信图学习边保留倾向，训练结束后仅采样一次得到固定通信图，验证或测试阶段始终使用该固定图。

1. **潜在通信图初始化：**根据智能体数量和初始拓扑构造空间边与时间边掩码，并为每条潜在通信边初始化可学习 logit 参数。

2. **训练阶段通信图采样：**在训练集上执行多轮训练。每次训练执行前，系统根据当前边保留概率采样一个临时通信图，并在该通信图上运行多智能体推理过程。该临时通信图只用于当前训练样本或当前训练批次，不作为最终测试图直接使用。

3. **边级效用与参数更新：**训练样本推理结束后，根据最终答案评分获得任务正确性信号，并将发送方模型输出 Token、工具调用次数和工具观察 Token 归因到训练时的边采样决策，得到边级效用。随后根据公式4.7计算边策略损失并进行反向传播，更新空间边和时间边的 logit 参数。

4. **训练阶段重要性剪枝：**在完成若干轮边概率更新后，按照固定间隔计算活跃边的 Taylor 一阶重要性，并根据公式4.10剪除低重要性边，更新通信掩码。被剪除的边在后续训练采样和最终图生成中均不再参与通信。

5. **最终通信图生成：**训练结束后，基于学习得到的边保留概率和剪枝后的通信掩码，对空间边和时间边进行一次通信图采样，得到固定通信图 G^*。形式化地，设 $\mathcal{E}_{\text{active}}$ 为剪枝后仍保留的活跃边集合，对每条 $e \in \mathcal{E}_{\text{active}}$ 采样 $z_e^* \sim \text{Bernoulli}(p_e)$，并令 $\mathcal{E}^* = \{e \in \mathcal{E}_{\text{active}} \mid z_e^* = 1\}$、$G^* = (V, \mathcal{E}^*)$。该步骤将训练得到的概率化通信结构转化为后续推理使用的确定结构。

6. **固定通信图推理：**在验证集或测试集上固定使用 G^* 进行多智能体推理。推理阶段不再更新边参数，不再执行 Taylor 剪枝，也不再为每个样本重新采样通信图；系统仅按照固定通信图传递消息，并统计任务准确率、工具调用次数、工具 Token、模型 Token 成本和边稀疏率等指标。

上述流程将训练阶段和推理阶段明确分离。训练阶段的采样用于估计不同通信边的任务贡献和工具成本，并通过策略梯度更新边保留概率；训练完成后，系统只采样一次得到固定通信图，并在推理阶段保持该通信图不变。由此，本文方法能够在保留关键跨智能体信息流的同时，避免测试阶段通信结构持续随机变化，减少低贡献通信边和高成本工具观察的传播。

4.3 实验设置

4.3.1 数据集

为验证本文方法在工具调用场景下的有效性，实验选取多个需要外部工具辅助的基准任务进行评测，覆盖数学竞赛推理、开放问答、专家问答、数学推理和代码生成等任务类型。具体任务、默认工具配置与主要评价指标如表4.1所示。

表 4.1　工具调用实验任务与默认工具配置

数据集	任务类型	默认工具	主要评价指标
AIME[94]	数学竞赛推理	Web 搜索、代码生成	数值答案准确率
GAIA[95]	开放问答	Web 搜索、代码生成、文本检查	问答匹配准确率
GPQA[96]	多项选择专家问答	Web 搜索、代码生成、文本检查	选项准确率
MATH500[97]	数学推理	Web 搜索、代码生成	规范化答案准确率
BigCodeBench[98]	代码生成	代码生成	代码通过率

4.3.2 对比基准

实验设置了四类对比基准，用于比较单智能体、完全通信、多智能体图剪枝以及本文方法在工具调用场景下的准确率–成本表现。

- **DirectAnswer：**单智能体直接回答，可选择是否启用工具。
- **FullConnected：**多智能体完全连接通信，所有智能体输出均可被后续智能体读取。
- **AgentPrune：**基于可学习通信边和图剪枝的多智能体通信优化方法。
- **本文方法：**在 AgentPrune 基础上加入工具成本感知的边级效用信号，并使用 Taylor 一阶重要性进行动态剪枝。

4.3.3 实现细节

本文选取 Qwen3-14B 和 MiniMax-M3[99]作为基座模型。其中，Qwen3-14B 报告 AIME、GAIA、MATH500 和 BigCodeBench 四个工具任务结果，MiniMax-M3 报告 AIME、GAIA、GPQA、MATH500 和 BigCodeBench 五个工具任务结果，用于观察不同成本和能力水平的基座模型下面向通信边冗余的图剪枝效果。

对于 AIME 和 MATH500，实验默认启用搜索与代码执行工具；对于 BigCodeBench，实验默认启用代码生成工具；对于 GAIA 和 GPQA 等开放问答或专家问答任务，实验同时启用搜索、代码执行和文本检查工具。考虑到本章方法主要针对工具调用、证据筛选和通信边价值差异，Qwen3-14B 结果以 AIME、GAIA 和 BigCodeBench 作为主实验任务，MiniMax-M3 结果以 AIME、GAIA、GPQA 和 BigCodeBench 作为主实验任务，并将 MATH500 作为准确率接近饱和的补充任务用于观察成本控制效果。对于需要训练通信边概率的 AgentPrune 和本文方法，训练阶段成本另行记录，不并入测试阶段成本；表中成本均为测试阶段推理成本，由输入 Token、输出 Token 及对应模型 API 价格计算得到，单位为人民币元。同一数据集内各方法采用相同测试规模，因而成本数值用于比较不同通信图策略在相同任务设置下的相对推理开销。

在本文方法的实现中，工具成本感知训练和 Taylor 一阶剪枝分别通过独立配置开启。系统在图构造阶段记录空间边与时间边的采样状态、边索引、发送方、接收方、轮次和对数概率；训练结束后，基于学习得到的边概率和剪枝掩码一次性采样固定通信图，并在验证或测试阶段关闭边参数更新与随机采样；在评估阶段按样本、智能体和轮次统计模型 Token 与工具调用元数据。三类边级成本信号中，输出 Token、工具

调用次数和工具 Token 的惩罚权重分别设为 0.05、0.10 和 0.10，Token 与工具调用次数的归一化系数分别设为 10000 和 10；Taylor 剪枝默认每 2 轮训练触发一次，每次剪除 10% 的活跃边。

4.3.4 评估指标

本文主要从任务完成质量、工具使用成本和通信图成本三个维度进行评估。

准确率 (Accuracy)：衡量模型完成任务的有效性。AIME 和 MATH500 采用规范化数值或公式答案匹配，GPQA 采用选项准确率，GAIA 采用问答匹配准确率，BigCodeBench 采用代码通过率。

工具使用成本 (Tool Cost)：衡量工具调用带来的额外开销，包括工具调用次数和工具返回 Token 数。该指标用于分析外部搜索、代码执行和文本检查结果在多智能体通信图中的传播成本。

推理成本 (Inference Cost)：衡量测试阶段模型输入输出 Token 对应的 API 调用成本，单位为人民币元，同时结合空间边与时间边稀疏率观察通信图压缩效果。由于工具调用会影响后续智能体上下文长度，本文同时统计工具成本和模型 Token 成本，以便分析二者之间的耦合关系。

4.4 实验结果与分析

本章实验图表均以表4.2和表4.3中的测试阶段结果为基础绘制。考虑到面向通信边冗余的图剪枝算法主要针对工具调用、证据筛选和通信边价值差异，Qwen3-14B 结果将 AIME、GAIA 和 BigCodeBench 作为主实验任务，MiniMax-M3 结果将 AIME、GAIA、GPQA 和 BigCodeBench 作为主实验任务，并将 MATH500 作为准确率接近饱和的补充任务。正文图形用于展示代表性任务上的趋势差异，完整数值仍以结果表为准。与第三章类似，本章结果为固定评测集上的单次完整评测结果，尚未包含多随机种子重复实验和置信区间，因此正文主要分析跨任务趋势和相对成本变化，不将小幅差异单独解释为统计显著优势。

需要说明的是，本文方法并不以在所有方法中取得最低绝对调用花费为目标。Direct+Tools 不包含多智能体通信结构，其低消耗主要来自单智能体执行方式，不能直接反映通信图剪枝效果；FullConnected+Tools 在部分任务中也可能因输出长度或工具使用偶然较少而获得较低测试消耗。因此，正文图形不再强调绝对花费柱状对比，

而是采用相对 AgentPrune+Tools 的准确率变化和成本变化表示方法，在已有多智能体图剪枝基线内部考察本文方法是否更有效地保留高价值通信边。

4.4.1 任务准确率结果

表4.2展示了 Qwen3-14B 在主实验任务和补充任务上的结果。每个单元格以“准确率/推理成本”形式展示。在 AIME、GAIA 和 BigCodeBench 三个主实验任务上，本文方法的平均准确率为 41.50%，高于 Direct+Tools 的 37.30%、FullConnected+Tools 的 41.47% 和 AgentPrune+Tools 的 39.27%。该结果说明，在中等规模开源模型上，通信边剪枝带来的收益存在任务依赖性，不能简单概括为所有任务均取得最高准确率。

表 4.2　Qwen3-14B 下面向通信边冗余的图剪枝结果

数据集	Direct+Tools	FullConnected+Tools	AgentPrune+Tools	本文方法
AIME	55.00 / 1.73	63.30 / 3.64	60.00 / 8.01	65.00 / 7.22
GAIA	13.90 / 1.21	20.60 / 2.96	16.30 / 3.88	17.50 / 2.81
MATH500	78.50 / 2.45	93.50 / 4.59	94.00 / 6.00	92.50 / 5.72
BigCodeBench	43.00 / 2.11	40.50 / 5.81	41.50 / 7.83	42.00 / 7.00

从单项任务看，本文方法在 AIME 上取得 65.00% 准确率，高于 Direct+Tools 的 55.00%、FullConnected+Tools 的 63.30% 和 AgentPrune+Tools 的 60.00%。这说明在数学竞赛题中，工具调用带来的代码执行和检索结果需要被选择性传播；完全连接通信虽然提高了信息覆盖度，但仍会传递部分冗余工具观察，而本文方法能够更稳定地保留高价值边。图4.1进一步展示了 AIME 任务上的准确率结果。

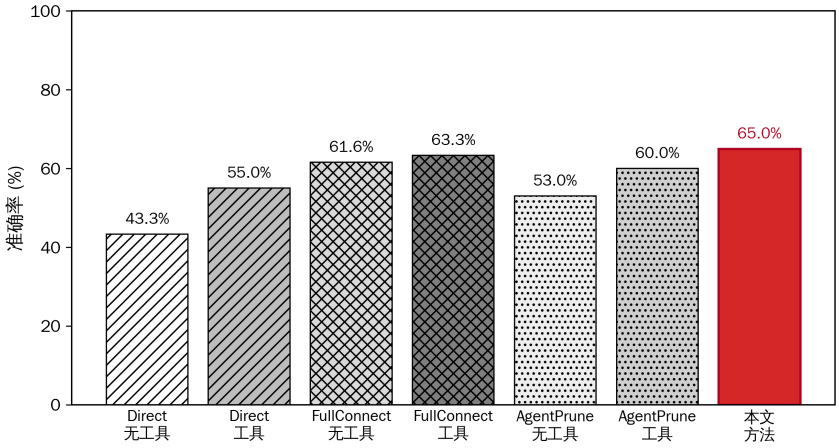


图 4.1　Qwen3-14B 在 AIME 任务上的准确率结果

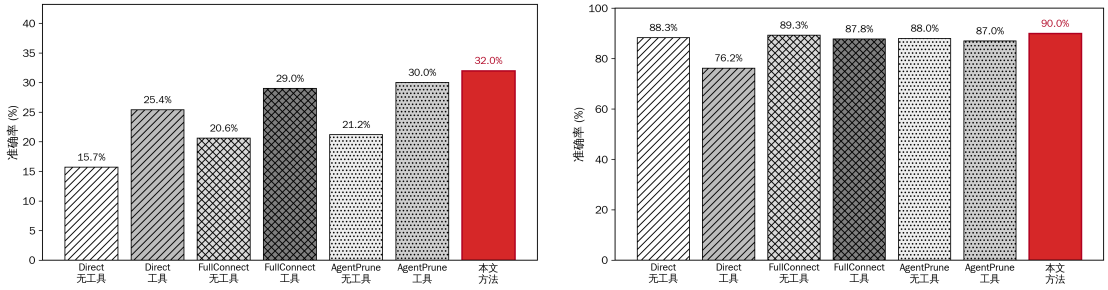
同时，Qwen3-14B 上的结果也暴露了本方法在部分任务上的边界。例如，GAIA 上本文方法准确率为 17.50%，低于 FullConnected+Tools 的 20.60%，但推理成本由 2.96 降至 2.81；MATH500 上本文方法准确率为 92.50%，低于 AgentPrune+Tools 的 94.00%，但推理成本由 6.00 降至 5.72。为避免将该类小幅差异过度解释为方法优劣，本文将 Qwen3-14B 结果主要作为开源模型上的辅助验证，并在后续分析中结合 MiniMax-M3 结果讨论方法更适用的任务条件。

表4.3展示了 MiniMax-M3 上的结果。相比 Qwen3-14B，MiniMax-M3 具有更高的调用成本，因此更适合观察通信边剪枝带来的成本–质量权衡。在 AIME、GAIA、GPQA 和 BigCodeBench 四个主实验任务上，本文方法的平均准确率为 66.71%，高于 Direct+Tools 的 48.10%、FullConnected+Tools 的 63.03% 和 AgentPrune+Tools 的 63.50%；平均推理成本为 25.81，低于 AgentPrune+Tools 的 28.25。该结果表明，在高成本基座模型和工具观察较长的任务中，本文方法并非简单追求最低调用成本，而是相对既有多智能体图剪枝基线更有效地保留高价值通信边。

表 4.3　MiniMax-M3 下面向通信边冗余的图剪枝结果

数据集	Direct+Tools	FullConnected+Tools	AgentPrune+Tools	本文方法
AIME	73.30 / 5.87	88.30 / 16.18	95.00 / 22.99	98.33 / 27.19
GAIA	25.40 / 5.87	29.00 / 26.11	30.00 / 29.36	32.00 / 23.16
GPQA	76.20 / 11.03	87.80 / 28.06	87.00 / 44.75	90.00 / 37.75
MATH500	85.00 / 3.59	95.00 / 10.35	95.50 / 11.89	95.00 / 10.99
BigCodeBench	17.50 / 21.00	47.00 / 12.68	42.00 / 15.88	46.50 / 15.15

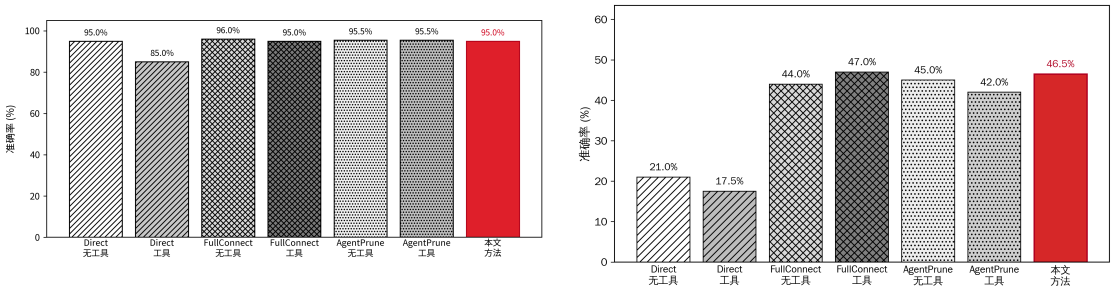
AIME 上，本文方法达到 98.33%，高于 Direct+Tools 的 73.30%、FullConnected+Tools 的 88.30% 和 AgentPrune+Tools 的 95.00%；GAIA 上，本文方法达到 32.00%，同时高于三个对比基线，且测试消耗低于 FullConnected+Tools 和 AgentPrune+Tools；GPQA 上，本文方法达到 90.00%，高于 FullConnected+Tools 的 87.80% 和 AgentPrune+Tools 的 87.00%，成本相对 AgentPrune+Tools 降低约 15.64%。这些结果说明，在需要检索、工具执行和证据整合的任务中，边级成本惩罚信号有助于减少低价值工具信息传播。图4.2展示了 MiniMax-M3 在 GAIA 和 GPQA 任务上的准确率结果。



(a) GAIA 准确率　　(b) GPQA 准确率

图 4.2　MiniMax-M3 在 GAIA 和 GPQA 任务上的准确率结果

MATH500 作为补充任务主要用于观察准确率接近饱和时的成本控制效果。MiniMax-M3 上，本文方法在 MATH500 达到 95.00%，与 FullConnected+Tools 持平，略低于 AgentPrune+Tools 的 95.50%，但相对 AgentPrune+Tools 降低约 7.56% 测试成本；Qwen3-14B 上也呈现出类似的成本下降和准确率小幅波动。因此，MATH500 不适合作为本文方法准确率优势的核心证据，更适合作为成本控制与准确率饱和之间的补充分析。BigCodeBench 则更能体现代码生成工具调用场景下的边价值差异，MiniMax-M3 上本文方法达到 46.50%，高于 AgentPrune+Tools 的 42.00%，且相对 AgentPrune+Tools 降低约 4.61% 测试成本。



(a) MATH500 准确率　　(b) BigCodeBench 准确率

图 4.3　MiniMax-M3 在 MATH500 和 BigCodeBench 任务上的准确率结果

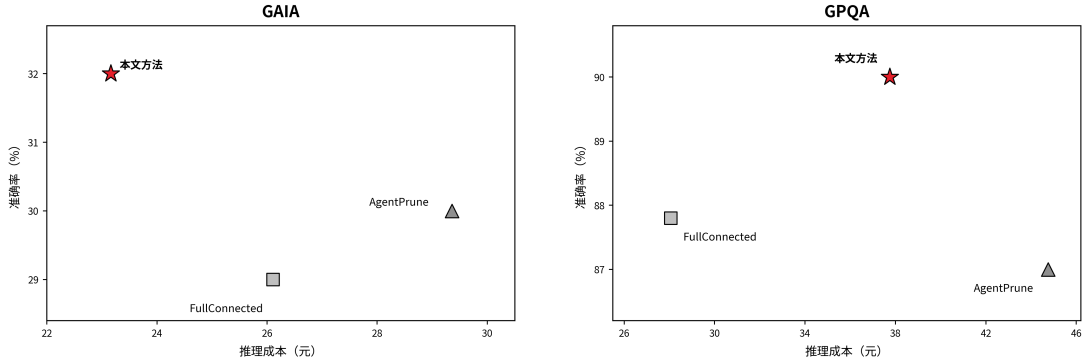
4.4.2 消耗成本结果

从测试阶段消耗看，工具调用场景中的成本变化不仅来自智能体之间的消息长度，也受到工具调用次数和工具返回 Token 数影响。若只比较各方法的绝对成本，Direct+Tools 往往因不包含多智能体通信而具有天然低消耗，容易使读者将“绝对成本最低”误解为本文方法的主要优化目标。事实上，本章方法关注的是在已有多智能体通信图剪枝基础上，进一步识别并压缩低价值通信边。因此，本节以 AgentPrune+Tools 作为主要成本对照，先通过表4.4量化本文方法的推理成本变化，再结合图4.4观察质量–消耗权衡。

表 4.4　本文方法相对 AgentPrune+Tools 的主实验推理成本对比

基座模型	数据集	AgentPrune+Tools 成本（元）	本文方法成本（元）	成本变化（元）	成本降幅
Qwen3-14B	AIME	8.01	7.22	-0.79	9.86%
Qwen3-14B	GAIA	3.88	2.81	-1.07	27.58%
Qwen3-14B	BigCodeBench	7.83	7.00	-0.83	10.60%
Qwen3-14B	**主实验平均**	**6.57**	**5.68**	**-0.90**	**13.64%**
MiniMax-M3	AIME	22.99	27.19	+4.20	-18.27%
MiniMax-M3	GAIA	29.36	23.16	-6.20	21.12%
MiniMax-M3	GPQA	44.75	37.75	-7.00	15.64%
MiniMax-M3	BigCodeBench	15.88	15.15	-0.73	4.60%
MiniMax-M3	**主实验平均**	**28.25**	**25.81**	**-2.43**	**8.61%**

表4.4中，成本变化定义为本文方法成本减去 AgentPrune+Tools 成本，负值表示成本降低；成本降幅为正表示成本下降，负值表示成本增加。可以看到，Qwen3-14B 三个主实验任务均取得成本下降，平均推理成本由 6.57 降至 5.68，降幅为 13.64%。MiniMax-M3 上，GAIA、GPQA 和 BigCodeBench 三个任务均降低推理成本，四个主实验任务平均成本由 28.25 降至 25.81，降幅为 8.61%。AIME 任务的成本有所增加，但同时准确率由 95.00% 提升至 98.33%，说明在部分高难数学竞赛任务中，额外工具验证可能带来更高质量收益。



(a) GAIA 任务　　(b) GPQA 任务

图 4.4　MiniMax-M3 代表性任务上的准确率–成本权衡

图4.4展示了 MiniMax-M3 在 GAIA 和 GPQA 两个代表性任务上的准确率–成本关系。GAIA 上，本文方法相较 FullConnected+Tools 和 AgentPrune+Tools 同时取得更高准确率和更低推理成本，说明工具成本感知的边级效用信号能够减少低价值工具观察传播。GPQA 上，本文方法取得最高准确率，且相对 AgentPrune+Tools 降低推理成本，

但成本仍高于 FullConnected+Tools，说明在专家问答任务中需要在证据充分性和成本控制之间做权衡。由此可见，本文方法的核心优势并不是在所有多智能体通信基线上取得最低绝对成本，而是在已有图剪枝方法基础上更合理地区分高价值通信边和低价值通信边。

4.4.3 结果分析

综合 Qwen3-14B 和 MiniMax-M3 结果可以看出，本文方法更适用于工具观察冗余较多、通信边价值差异明显的任务，如 AIME、GAIA、GPQA 以及 BigCodeBench。在这些任务中，工具成本感知训练信号能够促使系统保留与最终验证、证据整合和代码检查更相关的通信边，从而提升准确率或改善相对成本表现。MATH500 结果则说明，当任务准确率已接近饱和时，图剪枝方法更主要体现为成本控制，准确率可能出现小幅波动。

同时，实验也表明工具调用并非总是带来稳定收益。对于强知识型、多选项干扰任务，外部工具返回的信息若不能被有效筛选，可能反而干扰模型原有推理。本文方法虽然通过边级成本惩罚减少了部分冗余传播，但仍需要进一步引入工具观察质量评估或任务难度自适应权重。

总体而言，本文方法的优势不在于所有任务上同时实现最高准确率和最低绝对成本，而在于把工具调用成本纳入通信图学习目标，使剪枝结果更接近真实部署中的成本–质量权衡。相比仅根据边概率或静态拓扑进行剪枝，工具成本感知策略能够更细粒度地区分不同发送方、不同轮次和不同工具观察带来的边际价值。

4.5 本章小结

本章提出了面向通信边冗余的图剪枝算法。该方法首先将多智能体系统中的空间边和时间边建模为可学习概率，并在训练阶段通过临时采样通信图学习不同边的保留倾向；随后以任务正确性为收益项，并结合模型输出 Token、工具调用次数和工具观察 Token 三类边级成本信号构造边级效用，使通信边学习过程能够感知外部工具带来的额外成本；最后引入 Taylor 一阶重要性评估，在训练过程中剪除低重要性边，并在训练结束后采样得到固定通信图用于验证或测试推理。

实验结果表明，在 MiniMax-M3 上，本文方法在 AIME、GAIA、GPQA 和 BigCodeBench 四个主实验任务上的平均准确率高于三个对比基线，并且相对 Agent-

Prune+Tools 降低了平均推理成本；在 MATH500 补充任务上，本文方法保持与 Full-Connected+Tools 相同的准确率，并降低 AgentPrune+Tools 成本。Qwen3-14B 结果显示，中等规模开源模型上的收益更具任务依赖性，尤其在开放问答和代码生成等工具任务中仍需进一步引入工具观察质量评估。该工作从图结构层面补充了上一章的语义消息压缩方法，共同构成面向多智能体系统高效通信的两条优化路径。

结论

本文围绕大语言模型多智能体系统中的高效通信问题展开研究。针对多智能体协作过程中存在的上下文膨胀、重复消息传播、工具观察扩散和推理成本上升等问题，本文将通信冗余划分为语义冗余问题和通信边冗余问题，并分别从通信内容和通信结构两个层面提出优化方法。本文的核心目标并非简单减少智能体数量或压缩全部文本，而是在保持多智能体协作收益的前提下，提高有效信息密度，降低冗余 Token 消耗和工具调用带来的额外开销，从而改善多智能体系统的准确率–成本权衡。

针对语义冗余问题，本文提出了面向语义冗余的消息压缩框架。该框架从角色、节点和时序三个维度分析多智能体通信中的冗余来源，分别设计了角色感知压缩、节点感知聚合和分歧感知压缩模块。角色感知压缩根据接收方智能体职责筛选发送方推理内容，减少与下游任务弱相关的解释；节点感知聚合对多个前驱智能体传递的相似观点进行去重，并保留来源信息；分歧感知压缩从多轮历史中提取共识答案、候选分歧和简要依据，避免完整历史在后续轮次中持续累积。实验结果表明，该框架能够在多数知识理解、数学推理和代码生成任务中保持或提升任务准确率，并相对完全通信拓扑和已有图剪枝基线降低推理成本。其中，在三个主分析模型和六个数据集的平均结果上，本文方法相对 Fullconnect 的平均推理成本降低 29.85%，相对 AgentPrune 的平均推理成本降低 14.20%。

针对通信边冗余问题，本文提出了面向通信边冗余的图剪枝算法。该方法将多智能体系统中的空间边和时间边建模为可学习概率，并以任务正确性为收益项，将模型输出 Token、工具调用次数和工具观察 Token 三类边级成本信号共同纳入优化目标，使通信边学习能够感知不同发送方、不同轮次和不同工具观察带来的成本差异。在此基础上，本文引入 Taylor 一阶重要性评估，根据边参数与梯度估计移除通信边对目标函数的影响，并周期性剪除低重要性边。实验结果表明，该方法更适用于工具观察冗余较多、通信边价值差异明显的任务。在 MiniMax-M3 上，本文方法在 AIME、GAIA、GPQA 和 BigCodeBench 四个主实验任务上的平均准确率高于三个对比基线，且相对 AgentPrune+Tools 降低了平均推理成本；在 Qwen3-14B 上，本文方法在主实验任务中也取得了相对 AgentPrune+Tools 的平均成本下降。

本文的创新点主要体现在以下三个方面。首先，本文从问题建模层面将多智能体

通信冗余明确拆分为消息内容层面的语义冗余和通信图结构层面的通信边冗余，为分析大语言模型多智能体系统中的成本–质量权衡提供了更清晰的框架。其次，本文面向多智能体通信消息的特点设计了角色感知、节点感知和分歧感知的压缩机制，使消息压缩不再只依赖通用文本长度缩减，而是结合接收方职责、前驱节点差异和跨轮历史状态进行针对性筛选。最后，本文将工具调用成本引入通信边学习过程，并结合 Taylor 一阶重要性进行动态图剪枝，使图结构优化能够更细粒度地区分高价值通信边和低价值工具观察传播路径。

从应用价值看，本文研究能够为低成本、可扩展的多智能体系统部署提供方法支持。在企业问答、代码生成、复杂推理、自动化办公和工具增强智能体等场景中，多智能体系统通常需要多轮交互和多次外部工具调用，若通信内容和通信结构缺乏控制，系统成本会随智能体数量和交互轮次快速上升。本文提出的消息压缩框架和图剪枝算法均不依赖底层大语言模型参数更新，具有较好的可插拔性和迁移潜力，可用于降低 API 调用成本、缩短推理延迟，并减少无关信息对下游智能体判断的干扰。因此，本文工作具有一定的经济价值和工程应用前景，也为多智能体系统从实验环境走向实际部署提供了可参考的通信优化思路。

同时，本文工作仍存在进一步完善空间。第一，当前实验主要基于固定评测集上的完整评测结果，后续需要加入更多随机种子、显著性检验和更大规模任务，以进一步验证方法稳定性。第二，本文的压缩强度、成本权重和剪枝比例仍主要采用预设配置，未来可以结合任务难度、模型不确定性和工具返回质量进行自适应调整。第三，在代码生成和多项选择等部分任务中，单纯的消息压缩或通信边剪枝仍难以完全替代执行反馈、事实核验和工具观察质量评估，后续可进一步研究消息压缩、图剪枝、检索增强和可执行验证之间的联合优化。第四，随着多智能体系统逐渐应用于真实开放环境，通信优化还需要进一步考虑隐私保护、安全约束、失败恢复和长期记忆管理等问题。

综上所述，本文从通信内容和通信结构两个层面对大语言模型多智能体系统中的冗余通信问题进行了研究，分别提出面向语义冗余的消息压缩框架和面向通信边冗余的图剪枝算法。实验结果表明，两项工作能够在不同任务场景下改善多智能体系统的准确率–成本权衡，为构建更加高效、低成本和可扩展的多智能体推理系统提供了有益探索。

参考文献

[1] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.[Z].

[2] ACHIAM J, ADLER S, AGARWAL S, et al. Gpt-4 technical report[J]. arXiv preprint arXiv:2303.08774, 2023.[EB/OL]. https://arxiv.org/abs/2303.08774.

[3] TOUVRON H, LAVRIL T, IZACARD G, et al. Llama: Open and efficient foundation language models[J]. arXiv preprint arXiv:2302.13971, 2023.[EB/OL]. https://arxiv.org/abs/2302.13971.

[4] TOUVRON H, MARTIN L, STONE K, et al. Llama 2: Open foundation and fine-tuned chat models[J]. arXiv preprint arXiv:2307.09288, 2023.[EB/OL]. https://arxiv.org/abs/2307.09288.

[5] GRATTAFIORI A, DUBEY A, JAUHRI A, et al. The llama 3 herd of models[J]. arXiv preprint arXiv:2407.21783, 2024.[EB/OL]. https://arxiv.org/abs/2407.21783.

[6] BAI J, BAI S, CHU Y, et al. Qwen technical report[J]. arXiv preprint arXiv:2309.16609, 2023.[EB/OL]. https://arxiv.org/abs/2309.16609.

[7] HUI B, YANG J, CUI Z, et al. Qwen2.5-coder technical report[J]. arXiv preprint arXiv:2409.12186, 2024.[EB/OL]. https://arxiv.org/abs/2409.12186.

[8] YANG A, LI A, YANG B, et al. Qwen3 technical report[J]. arXiv preprint arXiv:2505.09388, 2025.[EB/OL]. https://arxiv.org/abs/2505.09388.

[9] LAZARIDOU A, KUNCORO A, GRIBOVSKAYA E, et al. Mind the gap: Assessing temporal generalization in neural language models[J]. Advances in Neural Information Processing Systems, 2021, 34: 29348-29363.[Z].

[10] LIU N F, LIN K, HEWITT J, et al. Lost in the middle: How language models use long contexts[J]. Transactions of the association for computational linguistics, 2024, 12: 157-173.[Z].

[11] BAI Y, LV X, ZHANG J, et al. Longbench: A bilingual, multitask benchmark for long context understanding[C]//Proceedings of the 62nd annual meeting of the association for computational linguistics (volume 1: Long papers). 2024: 3119-3137.[Z].

[12] QIAN C, LIU W, LIU H, et al. Chatdev: Communicative agents for software development[C]//Proceedings of the 62nd annual meeting of the association for computational linguistics (volume 1: Long papers). 2024: 15174-15186.[Z].

[13] BOIKO D A, MACKNIGHT R, KLINE B, et al. Autonomous chemical research with large language models[J]. Nature, 2023, 624(7992): 570-578.[Z].

[14] DRIESS D, XIA F, SAJJADI M S M, et al. Palm-e: An embodied multimodal language model[J]. arXiv preprint arXiv:2303.03378, 2023.[EB/OL]. https://arxiv.org/abs/2303.03378.

[15] XI Z, CHEN W, GUO X, et al. The rise and potential of large language model based agents: A survey[J]. Science China Information Sciences, 2025, 68(2): 121101.[Z].

[16] WEI J, WANG X, SCHUURMANS D, et al. Chain-of-thought prompting elicits reasoning in large language models[J]. Advances in neural information processing systems, 2022, 35: 24824-24837.[Z].

[17] WANG X, WEI J, SCHUURMANS D, et al. Self-consistency improves chain of thought reasoning in language models[J]. arXiv preprint arXiv:2203.11171, 2022.[EB/OL]. https://arxiv.org/abs/2203.11171.

[18] YAO S, YU D, ZHAO J, et al. Tree of thoughts: Deliberate problem solving with large language models[J]. Advances in neural information processing systems, 2023, 36: 11809-11822.[Z].

[19] BESTA M, BLACH N, KUBICEK A, et al. Graph of thoughts: Solving elaborate problems with large language models[C]//Proceedings of the AAAI conference on artificial intelligence. 2024, 38(16): 17682-17690.[Z].

[20] SCHICK T, DWIVEDI-YU J, DESSÌ R, et al. Toolformer: Language models can teach themselves to use tools[J]. Advances in neural information processing systems, 2023, 36: 68539-68551.[Z].

[21] QIN Y, LIANG S, YE Y, et al. Toolllm: Facilitating large language models to master 16000+ real-world apis[C]//International Conference on Learning Representations. 2024, 2024: 9695-9717.[Z].

[22] YAO S, ZHAO J, YU D, et al. React: Synergizing reasoning and acting in language models[J]. arXiv preprint arXiv:2210.03629, 2022.[EB/OL]. https://arxiv.org/abs/2210.03629.

[23] SHINN N, CASSANO F, GOPINATH A, et al. Reflexion: Language agents with verbal reinforcement learning[J]. Advances in neural information processing systems, 2023, 36: 8634-8652.[Z].

[24] PARK J S, O'BRIEN J, CAI C J, et al. Generative agents: Interactive simulacra of human behavior[C]//Proceedings of the 36th annual acm symposium on user interface software and technology. 2023: 1-22.[Z].

[25] WANG G, XIE Y, JIANG Y, et al. Voyager: An open-ended embodied agent with large language models[J]. arXiv preprint arXiv:2305.16291, 2023.[EB/OL]. https://arxiv.org/abs/2305.16291.

[26] DU Y, LI S, TORRALBA A, et al. Improving factuality and reasoning in language models through multiagent debate[J]. arXiv preprint arXiv:2305.14325, 2023.[EB/OL]. https://arxiv.org/abs/2305.14325.

[27] GUO T, CHEN X, WANG Y, et al. Large language model based multi-agents: A survey of progress and challenges[J]. arXiv preprint arXiv:2402.01680, 2024.[EB/OL]. https://arxiv.org/abs/2402.01680.

[28] HONG S, ZHUGE M, CHEN J, et al. MetaGPT: Meta programming for a multi-agent collaborative framework[C]//International Conference on Learning Representations. 2024, 2024: 23247-23275.[Z].

[29] WU Q, BANSAL G, ZHANG J, et al. Autogen: Enabling next-gen llm applications via multi-agent conversation[J]. arXiv preprint arXiv:2308.08155, 2023.[EB/OL]. https://arxiv.org/abs/2308.08155.

[30] LIANG T, HE Z, JIAO W, et al. Encouraging divergent thinking in large language models through multi-agent debate[C]//Proceedings of the 2024 conference on empirical methods in natural language processing. 2024: 17889-17904.[Z].

[31] LI G, HAMMOUD H, ITANI H, et al. Camel: Communicative agents for" mind" exploration of large language model society[J]. Advances in neural information processing systems, 2023, 36: 51991-52008.[Z].

[32] CHEN W, SU Y, ZUO J, et al. AgentVerse: Facilitating multi-agent collaboration and exploring emergent behaviors[J]. arXiv preprint arXiv:2308.10848, 2023.[EB/OL]. https://arxiv.org/abs/2308.10848.

[33] CHAN C M, CHEN W, SU Y, et al. ChatEval: Towards better LLM-based evaluators through multi-agent debate[J]. arXiv preprint arXiv:2308.07201, 2023.[EB/OL]. https://arxiv.org/abs/2308.07201.

[34] LI Y, DONG B, GUERIN F, et al. Compressing context to enhance inference efficiency of large language models[C]//Proceedings of the 2023 conference on empirical methods in natural language processing. 2023: 6342-6353.[Z].

[35] JIANG H, WU Q, LIN C Y, et al. Llmlingua: Compressing prompts for accelerated inference of large language models[C]//Proceedings of the 2023 conference on empirical methods in natural language processing. 2023: 13358-13376.[Z].

[36] PAN Z, WU Q, JIANG H, et al. Llmlingua-2: Data distillation for efficient and faithful task-agnostic prompt compression[C]//Findings of the Association for Computational Linguistics: ACL 2024. 2024: 963-981.[Z].

[37] JIANG H, WU Q, LUO X, et al. LongLLMLingua: Accelerating and enhancing LLMs in long context scenarios via prompt compression[C]//Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics. 2024.[Z].

[38] MU J, LI X L, GOODMAN N. Learning to compress prompts with gist tokens[J]. arXiv preprint arXiv:2304.08467, 2023.[EB/OL]. https://arxiv.org/abs/2304.08467.

[39] SHANDILYA S, XIA M, GHOSH S, et al. Taco-rl: Task aware prompt compression optimization with reinforcement learning[C]//Findings of the Association for Computational Linguistics: ACL 2025. 2025: 1582-1597.[Z].

[40] XU F, SHI W, CHOI E. RECOMP: Improving retrieval-augmented LMs with compression and selective augmentation[J]. arXiv preprint arXiv:2310.04408, 2023.[EB/OL]. https://arxiv.org/abs/2310.04408.

[41] LEWIS P, PEREZ E, PIKTUS A, et al. Retrieval-augmented generation for knowledge-intensive NLP tasks[C]//Advances in Neural Information Processing Systems. 2020, 33: 9459-9474.[Z].

[42] IZACARD G, GRAVE E. Leveraging passage retrieval with generative models for open domain question answering[C]//Proceedings of the 16th Conference of the European Chapter of the Association for Computational Linguistics. 2021: 874-880.[Z].

[43] SUKHBAATAR S, SZLAM A, FERGUS R. Learning multiagent communication with backpropagation[C]//Advances in Neural Information Processing Systems. 2016, 29: 2244-2252.[Z].

[44] FOERSTER J, ASSAEL I A, DE FREITAS N, et al. Learning to communicate with deep multi-agent reinforcement learning[C]//Advances in Neural Information Processing Systems. 2016, 29.[Z].

[45] SINGH A, JAIN T, SUKHBAATAR S. Learning when to communicate at scale in multiagent cooperative and competitive tasks[C]//International Conference on Learning Representations. 2019.[Z].

[46] LIU Z, ZHANG Y, LI P, et al. Dynamic llm-agent network: An llm-agent collaboration framework with agent team optimization[J]. arXiv preprint arXiv:2310.02170, 2023.[EB/OL]. https://arxiv.org/abs/2310.02170.

[47] HU S, SHEN L, ZHANG Y, et al. Learning multi-agent communication from graph modeling perspective[J]. arXiv preprint arXiv:2405.08550, 2024.[EB/OL]. https://arxiv.org/abs/2405.08550.

[48] ZHANG G, YUE Y, SUN X, et al. G-designer: Architecting multi-agent communication topologies via graph neural networks[J]. arXiv preprint arXiv:2410.11782, 2024.[EB/OL]. https://arxiv.org/abs/2410.11782.

[49] ZENG X, SU H, WANG Z, et al. Graph diffusion for robust multi-agent coordination[C]//Forty-second International Conference on Machine Learning. 2025.[Z].

[50] ZHANG G, YUE Y, LI Z, et al. Cut the crap: An economical communication pipeline for llm-based multi-agent systems[C]//International Conference on Learning Representations. 2025, 2025: 75389-75428.[Z].

[51] WANG Z, WANG Y, LIU X, et al. Agentdropout: Dynamic agent elimination for token-efficient and high-performance llm-based multi-agent collaboration[C]//Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2025: 24013-24035.[Z].

[52] ZHANG R, ZHAO X, WANG R, et al. Safesieve: From heuristics to experience in progressive pruning for llm-based multi-agent communication[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2026, 40(35): 29892-29900.[Z].

[53] LI B, ZHAO Z, LEE D H, et al. Adaptive graph pruning for multi-agent communication[J]. arXiv preprint arXiv:2506.02951, 2025.[EB/OL]. https://arxiv.org/abs/2506.02951.

[54] ZHUGE M, WANG W, KIRSCH L, et al. Gptswarm: Language agents as optimizable graphs[C]//Forty-first International Conference on Machine Learning. 2024.[Z].

[55] ZHANG J, XIANG J, YU Z, et al. Automating agentic workflow generation, 2024a[J]. URL https://arxiv.org/abs/2410.10762.[Z].

[56] HU S, LU C, CLUNE J. Automated design of agentic systems[J]. arXiv preprint arXiv:2408.08435, 2024.[EB/OL]. https://arxiv.org/abs/2408.08435.

[57] KARPAS E, ABEND O, BELINKOV Y, et al. MRKL systems: A modular, neuro-symbolic architecture that combines large language models, external knowledge sources and discrete reasoning[J]. arXiv preprint arXiv:2205.00445, 2022.[EB/OL]. https://arxiv.org/abs/2205.00445.

[58] SHEN Y, SONG K, TAN X, et al. HuggingGPT: Solving AI tasks with ChatGPT and its friends in Hugging Face[J]. arXiv preprint arXiv:2303.17580, 2023.[EB/OL]. https://arxiv.org/abs/2303.17580.

[59] PATIL S G, ZHANG T, WANG X, et al. Gorilla: Large language model connected with massive APIs[J]. arXiv preprint arXiv:2305.15334, 2023.[EB/OL]. https://arxiv.org/abs/2305.15334.

[60] LI M, ZHAO Y, YU B, et al. API-Bank: A comprehensive benchmark for tool-augmented LLMs[C]//Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing. 2023.[Z].

[61] NAKANO R, HILTON J, BALAJI S, et al. WebGPT: Browser-assisted question-answering with human feedback[J]. arXiv preprint arXiv:2112.09332, 2021.[EB/OL]. https://arxiv.org/abs/2112.09332.

[62] XU B, PENG Z, LEI B, et al. ReWOO: Decoupling reasoning from observations for efficient augmented language models[J]. arXiv preprint arXiv:2305.18323, 2023.[EB/OL]. https://arxiv.org/abs/2305.18323.

[63] PACKER C, FANG V, PATIL S G, et al. MemGPT: Towards LLMs as operating systems[J]. arXiv preprint arXiv:2310.08560, 2023.[EB/OL]. https://arxiv.org/abs/2310.08560.

[64] KIM S, MOON S, TUMANOV A. An LLM compiler for parallel function calling[J]. arXiv preprint arXiv:2312.04511, 2023.[EB/OL]. https://arxiv.org/abs/2312.04511.

[65] CHEVALIER A, WETTIG A, AJITH A, et al. Adapting language models to compress contexts[C]//Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing. 2023.[Z].

[66] LI Z, LIU Y, SU Y, et al. Prompt compression for large language models: A survey[C]//Proceedings of the 2025 Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers). 2025: 7182-7195.[Z].

[67] CHUANG Y N, XING T, CHANG C Y, et al. Learning to compress prompt in natural language formats[C]//Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers). 2024: 7756-7767.[Z].

[68] ZHANG Z, SHENG Y, ZHOU T, et al. H2O: Heavy-hitter oracle for efficient generative inference of large language models[J]. arXiv preprint arXiv:2306.14048, 2023.[EB/OL]. https://arxiv.org/abs/2306.14048.

[69] XIAO G, TIAN Y, CHEN B, et al. Efficient streaming language models with attention sinks[J]. arXiv preprint arXiv:2309.17453, 2023.[EB/OL]. https://arxiv.org/abs/2309.17453.

[70] WEI T, LI T W, LIU Z, et al. Agentic reasoning for large language models[J]. arXiv preprint arXiv:2601.12538, 2026.[EB/OL]. https://arxiv.org/abs/2601.12538.

[71] DAS A, GERVET T, ROMOFF J, et al. TarMAC: Targeted multi-agent communication[C]//Proceedings of the 36th International Conference on Machine Learning. 2019: 1538-1546.[Z].

[72] DING S, DU W, DING L, et al. Learning efficient and robust multi-agent communication via graph information bottleneck[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2024, 38(16): 17346-17353.[Z].

[73] JIANG J, LU Z. Learning attentional communication for multi-agent cooperation[C]//Advances in Neural Information Processing Systems. 2018, 31: 7265-7275.[Z].

[74] WANG S, ZHANG G, YU M, et al. G-safeguard: A topology-guided security lens and treatment on llm-based multi-agent systems[C]//Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2025: 7261-7276.[Z].

[75] WANG S, LU R, YANG Z, et al. Agentconductor: Topology evolution for multi-agent competition-level code generation[J]. arXiv preprint arXiv:2602.17100, 2026.[EB/OL]. https://arxiv.org/abs/2602.17100.

[76] ZHOU H, WAN X, SUN R, et al. Multi-agent design: Optimizing agents with better prompts and topologies[J]. arXiv preprint arXiv:2502.02533, 2025.[EB/OL]. https://arxiv.org/abs/2502.02533.

[77] ZHANG G, NIU L, FANG J, et al. Multi-agent architecture search via agentic supernet[J]. arXiv preprint arXiv:2502.04180, 2025.[EB/OL]. https://arxiv.org/abs/2502.04180.

[78] LEONG H Y, WU Y. DynaSwarm: Dynamically graph structure selection for llm-based multi-agent system[J]. arXiv preprint arXiv:2507.23261, 2025.[EB/OL]. https://arxiv.org/abs/2507.23261.

[79] YUAN S, SONG K, CHEN J, et al. EvoAgent: Towards automatic multi-agent generation via evolutionary algorithms[J]. arXiv preprint arXiv:2406.14228, 2024.[EB/OL]. https://arxiv.org/abs/2406.14228.

[80] KHATTAB O, SINGHVI A, MAHESHWARI P, et al. DSPy: Compiling declarative language model calls into self-improving pipelines[J]. arXiv preprint arXiv:2310.03714, 2023.[EB/OL]. https://arxiv.org/abs/2310.03714.

[81] Hendrycks D, Burns C, Basart S, et al. Measuring Massive Multitask Language Understanding[J]. ArXiv preprint arXiv:2009.03300, 2020.

[82] Cobbe K, Kosaraju V, Bavarian M, et al. Training Verifiers to Solve Math Word Problems[J]. ArXiv preprint arXiv:2110.14168, 2021.

[83] Ling W, Yogatama D, Dyer C, et al. Program Induction by Rationale Generation: Learning to Solve and Explain Algebraic Word Problems[C]. Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2017: 158-167.

[84] Roy S, Roth D. Solving General Arithmetic Word Problems[C]. Proceedings of the 2015 Conference on Empirical Methods in Natural Language Processing. 2015: 1743-1752.

[85] Patel A, Bhattamishra S, Goyal N. Are NLP Models Really Able to Solve Simple Math Word Problems?[C]. Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. 2021: 2080-2094.

[86] Chen M, Tworek J, Jun H, et al. Evaluating Large Language Models Trained on Code[J]. ArXiv preprint arXiv:2107.03374, 2021.

[87] Molchanov P, Tyree S, Karras T, et al. Pruning Convolutional Neural Networks for Resource Efficient Inference[C]. International Conference on Learning Representations. 2017.

[88] LECUN Y, DENKER J S, SOLLA S A. Optimal brain damage[C]//Advances in Neural Information Processing Systems. 1989, 2: 598-605.[Z].

[89] LEE N, AJANTHAN T, TORR P H S. SNIP: Single-shot network pruning based on connection sensitivity[C]//International Conference on Learning Representations. 2019.[Z].

[90] SANH V, WOLF T, RUSH A M. Movement pruning: Adaptive sparsity by fine-tuning[C]//Advances in Neural Information Processing Systems. 2020, 33: 20378-20389.[Z].

[91] SUN M, LIU Z, BOWEN T, et al. A simple and effective pruning approach for large language models[J]. arXiv preprint arXiv:2306.11695, 2023.[EB/OL]. https://arxiv.org/abs/2306.11695.

[92] MA X, FANG G, WANG X. LLM-Pruner: On the structural pruning of large language models[C]//Advances in Neural Information Processing Systems. 2023, 36.[Z].

[93] XIA M, GAO T, ZENG Z, et al. Sheared LLaMA: Accelerating language model pre-training via structured pruning[J]. arXiv preprint arXiv:2310.06694, 2023.[EB/OL]. https://arxiv.org/abs/2310.06694.

[94] Mathematical Association of America. American Invitational Mathematics Examination[Z]. Contest problem set. 2025.

[95] MIALON G, FOURRIER C, SWIFT C, et al. Gaia: a benchmark for general ai assistants[C]//International Conference on Learning Representations. 2024.[Z].

[96] REIN D, HOU B L, STICKLAND A C, et al. GPQA: A graduate-level google-proof q&a benchmark[C]//First Conference on Language Modeling. 2024.[Z].

[97] HENDRYCKS D, BURNS C, KADAVATH S, et al. Measuring mathematical problem solving with the math dataset[C]//Proceedings of the Neural Information Processing Systems Track on Datasets and Benchmarks. 2021.[Z].

[98] ZHUO T Y, VU M C, CHIM J, et al. Bigcodebench: Benchmarking code generation with diverse function calls and complex instructions[C]//International Conference on Learning Representations. 2025.[Z].

[99] Lai X, Xu W, Yang Y, et al. MiniMax Sparse Attention[J]. ArXiv preprint arXiv:2606.13392, 2026.

附录 A
费马大定理的证明

关于此，我确信已发现了一种美妙的证法，可惜这里空白的地方太小，写不下。

附录 B

Maxwell Equations

因为在柱坐标系下，$\bar{\bar{\mu}}$ 是对角的，所以 Maxwell 方程组中电场 **E** 的旋度
所以 **H** 的各个分量可以写为：

$$H_r = \frac{1}{\mathbf{i}\omega\mu_r}\frac{1}{r}\frac{\partial E_z}{\partial\theta} \tag{B.1a}$$

$$H_\theta = -\frac{1}{\mathbf{i}\omega\mu_\theta}\frac{\partial E_z}{\partial r} \tag{B.1b}$$

同样地，在柱坐标系下，$\bar{\bar{\epsilon}}$ 是对角的，所以 Maxwell 方程组中磁场 **H** 的旋度

$$\nabla\times\mathbf{H} = -\mathbf{i}\omega\mathbf{D} \tag{B.2a}$$

$$\left[\frac{1}{r}\frac{\partial}{\partial r}(rH_\theta) - \frac{1}{r}\frac{\partial H_r}{\partial\theta}\right]\hat{\mathbf{z}} = -\mathbf{i}\omega\bar{\bar{\epsilon}}\mathbf{E} = -\mathbf{i}\omega\epsilon_z E_z\hat{\mathbf{z}} \tag{B.2b}$$

$$\frac{1}{r}\frac{\partial}{\partial r}(rH_\theta) - \frac{1}{r}\frac{\partial H_r}{\partial\theta} = -\mathbf{i}\omega\epsilon_z E_z \tag{B.2c}$$

由此我们可以得到关于 E_z 的波函数方程：

$$\frac{1}{\mu_\theta\epsilon_z}\frac{1}{r}\frac{\partial}{\partial r}\left(r\frac{\partial E_z}{\partial r}\right) + \frac{1}{\mu_r\epsilon_z}\frac{1}{r^2}\frac{\partial^2 E_z}{\partial\theta^2} + \omega^2 E_z = 0 \tag{B.3}$$

附录 C
要求

有些材料编入文章主体会有损于编排的条理性和逻辑性，或有碍于文章结构的紧凑和突出主题思想等，这些材料可作为附录另页排在参考文献之后，也可以单编成册。下列内容可作为附录：

1. 为了整篇论文材料的完整，但编入正文有损于编排的条理性和逻辑性的材料，这一类材料包括比正文更为详尽的信息、研究方法和技术等更深入的叙述，以及建议可阅读的参考文献题录和对了解正文内容有用的补充信息等；
2. 由于篇幅过大或取材的复制资料不便于编入正文的材料；
3. 不便于编入正文的罕见珍贵资料；
4. 一般读者无须阅读，但对本专业同行有参考价值的资料；
5. 某些重要的原始数据、推导、计算程序、框图、结构图、注释、统计表、计算机打印输出件等；

C.1 一级标题

C.1.1 二级标题

攻读学位期间发表论文与研究成果清单

[1] Doe J, **Zhang S**. The Book with Title[M]. Dummy Publisher, 2000. (已出版.)

[2] **张**三, 李杰, 罗运军. 交联型与线形水性聚氨酯的形状记忆性能比较[J]. 化工进展, 2006(01): 78-81. (EI 收录, 检索号:06129773469. 已刊出.)

[3] 李杰, **张**三, 罗运军. 交联型与线形水性聚氨酯的形状记忆性能比较[J]. 化工进展, 2007(01): 78-81. (EI 收录, 检索号:06129773469. 已刊出.)

[4] **Zhang S**. The Book without Title[M]. Dummy Publisher, 2100. (已出版.)

作者简介

本人……

早年对作者简介的要求：“硕士学位论文不必提供作者简介。博士学位论文应该提供作者简介，主要包括：姓名、性别、出生年月、民族、出生地；简要学历、工作经历（职务）；攻读学位期间取得的其他研究成果或奖励。”