面向多智能体系统的高效通信技术研究

姓名：柯逸宸

学号：3220241499

学院：计算机学院

2026 年 6 月

专

面向多智能体系统的高效通信技术研究

柯逸宸

北京理工大学

中图分类号：TQ028.1
UDC 分类号：540
学校代码：10007

★ 学生类型
□ 工程硕博士专项
□ 交叉研究方向
□ 政府项目留学生

面向多智能体系统的高效通信技术研究

作 者 姓 名　柯逸宸
二级培养单位　计算机学院
指 导 教 师　李四教授
行业合作导师　李五教授
答辩委员会主席　王五教授
申 请 类 别　材料与化工博士
学 位 领 域　计算机技术
学位授予单位　北京理工大学
论文提交日期　2026 年 6 月

Synthesis and Application on textile of the Shape Memory Polyurethane

Candidate Name:	Yichen Ke
School or Department:	Materials Science and Engineering
Faculty Advisor:	Prof. Li Si
Industry Collaboration Mentor:	Prof. Li Wu
Chair of the Defense Committee:	Prof. Wang Wu
Degree:	Doctor of Materials
	and Chemical Engineering
Major:	Materials Science and Engineering
Degree by:	Beijing Institute of Technology
Submission date:	June, 2026

研究成果声明

本人郑重声明：所提交的学位论文是我本人在指导教师的指导下独立完成的研究成果。文中所撰写内容符合以下学术规范（请勾选）：

☑ 论文综述遵循“适当引用”的规范，全部引用的内容不超过 50%。

☑ 论文中的研究数据及结果不存在篡改、剽窃、抄袭、伪造等学术不端行为，并愿意承担因学术不端行为所带来的一切后果和法律责任。

☑ 文中依法引用他人的成果，均已做出明确标注或得到许可。

☑ 论文内容未包含法律意义上已属于他人的任何形式的研究成果，也不包含本人已用于其他学位申请的论文或成果。

☑ 与本人一同工作的合作者对此研究工作所做的任何贡献均已在学位论文中作了明确的说明并表示了谢意。

特此声明。

签　　名：　　日 期：

关于学位论文使用权的说明

本人完全了解北京理工大学有关保管、使用学位论文的规定，其中包括：

① 学校有权保管、并向有关部门送交学位论文的原件与复印件；

② 学校可以采用影印、缩印或其它复制手段复制并保存学位论文；

③ 学校可允许学位论文被查阅或借阅；

④ 学校可以学术交流为目的，复制赠送和交换学位论文；

⑤ 学校可以公布学位论文的全部或部分内容（保密学位论文在解密后遵守此规定）。

签　　名：　　日　期：

导师签名：　　日　期：

致谢

本论文的工作是在导师……

对学位论文的编写或相关工作的开展等给予帮助的组织和个人宜致谢，包括：

——国家科学基金，资助研究工作的奖学金基金，合同单位，资助或支持的企业、组织或个人；

——协助完成研究工作和提供便利条件的组织或个人；

——在研究工作中提出建议和提供帮助的人；

——给予转载和引用权的资料、图片、文献、研究思想和设想的所有者；

——其他应感谢的组织和个人。

面向多智能体系统的高效通信技术研究

摘要：本文……

（摘要是一篇具有独立性和完整性的短文，应概括而扼要地反映出本论文的主要内容。包括研究目的、研究方法、研究结果和结论等，特别要突出研究结果和结论。中文摘要力求语言精炼准确，博士学位论文建议 1000~1200 字，硕士学位论文摘要建议 500~800 字。摘要中不可出现参考文献、图、表、化学结构式、非公知公用的符号和术语。英文摘要与中文摘要的内容应完全一致，在语法、用词上应准确无误，语言简练通顺。以外文撰写的学位论文，应以同种语言撰写外文摘要。除外文摘要外，应有中文摘要，置于外文摘要页的后面，并标注中文关键词，为能完整描述学位论文的主要内容，中文摘要宜不少于 5000 字。）

关键词：多智能体系统；通信技术；（**硕士**一般选 3 ~ 6 个单词或专业术语，**博士**一般选 3 ~ 8 个单词或专业术语，且中英文关键词必须对应。【提醒】关键词不要与学科或专业名称等专有名词一致或相近。）——请在“main.tex”开头设置

Synthesis and Application on textile of the Shape Memory Polyurethane

Abstract: In order to exploit...

Lorem ipsum dolor sit amet, officia excepteur ex fugiat reprehenderit enim labore culpa sint ad nisi Lorem pariatur mollit ex esse exercitation amet. Nisi anim cupidatat excepteur officia. Reprehenderit nostrud nostrud ipsum Lorem est aliquip amet voluptate voluptate dolor minim nulla est proident. Nostrud officia pariatur ut officia. Sit irure elit esse ea nulla sunt ex occaecat reprehenderit commodo officia dolor Lorem duis laboris cupidatat officia voluptate. Culpa proident adipisicing id nulla nisi laboris ex in Lorem sunt duis officia eiusmod. Aliqua reprehenderit commodo ex non excepteur duis sunt velit enim. Voluptate laboris sint cupidatat ullamco ut ea consectetur et est culpa et culpa duis.

Key Words: shape memory properties; polyurethane; textile; synthesis; application

目次

1 绪论 1
1.1 研究背景及意义 1
1.2 国内外研究现状 5
1.3 本文主要研究内容及贡献 7
1.3.1 面向语义冗余的消息压缩框架 8
1.3.2 面向通信边冗余的图剪枝算法 9
1.4 论文组织结构 9
2 相关工作 10
2.1 多智能体系统 10
2.2 语义冗余问题 11
2.2.1 定义和分类 11
2.2.2 通用应对策略 12
2.3 通信边冗余 14
2.3.1 定义和分类 14
2.3.2 通用应对策略 14
2.4 本章小结 17
3 面向语义冗余的消息压缩框架 18
3.1 引言 18
3.2 消息压缩框架 18
3.2.1 多智能体系统任务执行流程 18
3.2.2 消息压缩框架执行流程 18
3.2.3 功能模块设计 19
3.3 实验设置 21
3.3.1 数据集 22
3.3.2 对比基准 22
3.3.3 实现细节 22
3.3.4 评估指标 23

3.4 实验结果与分析 24
3.4.1 任务准确率结果 25
3.4.2 消耗成本结果 28
3.4.3 结果分析 29
3.5 本章小结 30
4 面向通信边冗余的图剪枝算法 31
4.1 引言 31
4.2 图剪枝算法 32
4.2.1 工具调用场景建模 32
4.2.2 可学习通信边概率建模 33
4.2.3 成本感知优化目标 33
4.2.4 Taylor 一阶重要性剪枝 34
4.2.5 训练与执行流程 35
4.3 实验设置 36
4.3.1 数据集 36
4.3.2 对比基准 37
4.3.3 实现细节 37
4.3.4 评估指标 38
4.4 实验结果与分析 38
4.4.1 任务准确率结果 38
4.4.2 消耗成本结果 42
4.4.3 结果分析 45
4.5 本章小结 46
结论 47
参考文献 48
附录 A 费马大定理的证明 56
附录 B Maxwell Equations 57

附录 C　要求 58
C.1　一级标题 58
C.1.1　二级标题 58
攻读学位期间发表论文与研究成果清单 59
作者简介 60

插图

图 1.1 多智能体系统的 Token 消耗对比和不同智能体数量下的输入 Token 变化 . 3
图 1.2 完全连接拓扑（Full Topology） 8
图 2.1 多智能体的两条研究路线 10
图 2.2 压缩示意图 12
图 2.3 图生成技术示意图 14
图 2.4 图剪枝技术示意图 15
图 2.5 拓扑搜索技术示意图 16
图 3.1 多智能体系统标准任务执行流程示意图 19
图 3.2 消息压缩框架 19
图 3.3 六个数据集在不同模型下的平均准确率对比（纵轴为 0–100%） 25
图 3.4 各数据集上不同模型与方法的准确率对比（纵轴为 0–100%） 26
图 3.5 六个数据集在不同模型下的平均推理成本对比（单位：元） 28
图 3.6 各数据集上不同模型的推理成本比较（单位：元） 29
图 4.1 Qwen3-14B 在 AIME 任务上的推理成本（单位：元）与准确率结果 39
图 4.2 Qwen3-14B 在 AIME 任务上的工具调用次数与工具 Token 结果 40
图 4.3 Qwen3-14B 在扩展工具任务上的准确率结果 41
图 4.4 Qwen3-14B 在 MATH500 和 BigCodeBench 任务上的推理成本结果（单位：元） 41
图 4.5 MiniMax-M3 在 GAIA 和 GPQA 任务上的推理成本（单位：元）与准确率结果 43
图 4.6 MiniMax-M3 在 HLE 和 MuSiQue 任务上的推理成本（单位：元）与准确率结果 44
图 4.7 MiniMax-M3 在 MATH500 和 BigCodeBench 任务上的推理成本（单位：元）与准确率结果 45

表格

表 3.1　实验评测数据集概览 22
表 3.2　API 调用单价对比表 23
表 4.1　工具调用实验任务与默认工具配置 37
表 4.2　Qwen3-14B 下面向通信边冗余的图剪枝结果（准确率% / 推理成本，单位：元） 39
表 4.3　MiniMax-M3 下面向通信边冗余的图剪枝结果（准确率% / 推理成本，单位：元） 42

主要符号对照表

BIT	北京理工大学的英文缩写
LaTeX	一个很棒的排版系统
LaTeX 2_ε	一个很棒的排版系统的最新稳定版
ctex	成套的中文 LaTeX 解决方案，由一帮天才们开发
$e^{\pi i} + 1 = 0$	一个集自然界五大常数一体的炫酷方程

1 绪论

1.1 研究背景及意义

近年来，以Transformer架构为基础的大语言模型（Large Language Models，LLMs）[1]在自然语言理解、逻辑推理、文本生成和代码生成等任务中取得了重要进展。以GPT-4系列[2]、LLaMA 系列[3-5]和 Qwen 系列[6-8]为代表的基础模型，已经能够在开放问答、数学推理、程序合成、信息抽取和复杂指令遵循等场景中表现出较强的生成式推理能力。上述模型为复杂任务自动化提供了统一的语言接口和推理基础，也为多个智能体围绕同一任务进行分工、协作和验证提供了可能。

然而，大语言模型本身并不能完全满足复杂现实任务的需求。首先，模型参数中固化的知识具有时间滞后性，难以及时覆盖不断变化的外部世界知识[9]。其次，模型的上下文窗口即使不断扩展，仍然会受到输入长度、推理延迟和调用成本的限制；当上下文过长时，模型还容易出现“迷失在中间（Lost in the Middle）”现象，即对位于长文本中部的关键信息关注不足[10-11]。再次，单次模型调用缺少与外部环境的持续交互能力，难以主动检索信息、执行代码、检查中间结果或根据反馈修正推理路径。上述限制使得单一大语言模型在软件工程、科学计算、开放环境问答和具身智能等任务中仍然存在可靠性不足、知识更新困难和错误难以自我修复等问题[12-14]。

为了弥补单次模型调用在规划、反馈和外部执行方面的不足，研究者开始将大语言模型组织为智能体（Agent）[15]。智能体通常以大语言模型为核心推理器，并在其外部加入任务规划、工具调用、记忆管理和反馈修正等机制。思维链（Chain of Thought，CoT）[16]、自一致性（Self-Consistency）[17]、思维树（Tree of Thoughts，ToT）[18]和思维图（Graph of Thoughts，GoT）[19]等方法，主要通过显式化或扩展推理路径提升复杂问题求解能力；Toolformer[20]、ToolLLM[21]和 ReAct[22]等工作进一步将推理与行动结合，使模型能够在“思考–行动–观察”的闭环中调用搜索、计算器、代码执行器和外部 API 等工具；Reflexion[23]、Generative Agents[24]和 Voyager[25]等研究则通过自然语言反馈、长时记忆和环境交互提升智能体在多轮任务中的持续改进能力。

智能体使大语言模型能够以更接近任务执行流程的方式持续感知、规划、执行和反馈。对于需要外部知识、复杂推理或长周期交互的任务，智能体可以把模型能力与外部工具能力结合起来，从而缓解单模型知识封闭、执行能力不足和缺少反馈的问

题。但单智能体仍受限于单一角色视角、单条推理路径和有限的自我纠错能力。当任务需要多个专业角色协作、不同推理路径相互验证或多个工具结果共同汇总时，仅依靠单个智能体往往难以稳定获得可靠结果。

在此背景下，多智能体系统（Multi-Agent Systems，MAS）进一步引入角色分工、协同推理和信息共享机制[26-27]。当任务同时涉及规划、检索、执行、验证和汇总等环节时，多个具备不同职责或工具权限的智能体可以围绕同一目标形成互补视角，并通过消息传递完成任务分解、候选答案生成、交叉检查和最终决策。与单智能体相比，多智能体系统的潜在优势并不只是增加模型调用次数，而是通过角色差异和协作式纠错降低单一路径推理失败的风险。

已有研究表明，多智能体系统在软件开发、开放式问题求解和复杂推理任务中具有应用价值[12,28-29]。多智能体辩论等研究也说明，不同模型或不同角色之间的交叉质询能够改善事实性和推理鲁棒性[26,30]。这些工作表明，角色分工、通信路径和信息汇总方式会影响系统性能。若通信机制设计合理，不同智能体能够补充彼此的知识、发现候选答案中的错误并提升最终输出的可靠性；若通信机制设计不充分，系统可能只是增加对话规模，额外上下文和重复讨论反而会抵消协作带来的收益。

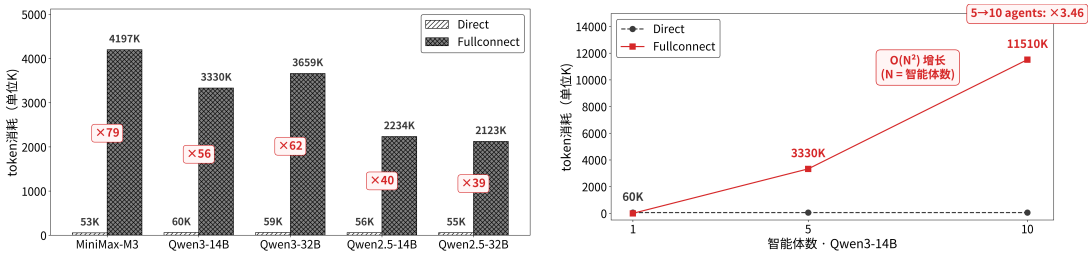
多智能体协作的关键并非简单增加智能体数量，而是在合适的时机交换有效信息。从系统结构看，多智能体系统可以表示为一个带有节点和边的通信图：节点代表智能体，边代表信息传递路径。每个智能体在当前轮次生成的中间推理、候选答案或工具观察，需要通过通信边传递给后继智能体；上一轮协作产生的历史状态，也可能在下一轮继续作为上下文使用。因此，通信拓扑决定哪些智能体能够读取哪些上游输出，消息内容决定下游智能体实际接收到什么信息，跨轮记忆则决定历史推理如何影响后续协作。

不同通信结构决定了信息覆盖范围、协作顺序和成本上界。通信过少时，系统难以充分利用多角色互补；通信过多时，系统又会被冗余上下文和高昂调用成本拖累。因此，多智能体系统性能不仅取决于单个智能体能力，还高度依赖通信结构和通信内容是否高效。

现有多智能体系统在通信机制上仍以粗粒度设计为主。一方面，许多系统采用静态或人工预设拓扑，通信边在任务执行前即被固定，难以根据任务类型、推理阶段和工具使用情况动态调整。另一方面，智能体之间传递的消息往往是完整自然语言输出，包括中间推理、背景解释、候选答案、工具观察和格式化说明等内容。对于下游智能

体而言，这些完整消息并不总是全部有用：某些内容与接收方角色无关，某些观点已经被多个上游智能体重复表达，某些历史信息在后续轮次中的贡献有限。

如图1.1所示，当智能体数量和交互轮次增加时，多智能体系统中的输入词元（Token）数量和整体调用成本会随之增长。在完全连接拓扑下，若每一轮每个智能体都向其他智能体传递完整输出，则通信边数量会随智能体数量呈平方级增长；若系统还保留跨轮历史，则上下文长度会进一步随轮次累积。对于按 Token 计费的闭源模型和商业 API 而言，这种增长会导致部署成本和推理延迟上升；对于本地部署模型而言，过长上下文也会增加显存占用和推理时间。



(a) 多智能体系统的 Token 消耗　　(b) 不同智能体数量下的输入 Token

图 1.1　多智能体系统的 Token 消耗对比和不同智能体数量下的输入 Token 变化

通信开销的增加并不一定带来任务性能提升。相反，冗长、重复和弱相关的上下文会降低下游智能体提取关键信息的效率。当模型需要在较长历史对话中寻找有效证据时，关键线索可能被无关解释、重复推理或过长工具返回结果淹没，从而引发长上下文注意力衰减问题[10]。因此，多智能体通信优化需要同时回答两个问题：一条通信边上传递的内容是否有效，以及这条通信边本身是否仍然值得保留。

本文将上述通信瓶颈分解为两个相互关联但层次不同的问题。语义冗余问题发生在既定通信边上的消息内容内部，表现为同一条自然语言消息包含较多与接收方角色无关的解释、重复推理、弱相关背景或过长历史摘要。该问题关注在既定通信边上应该传递什么内容，哪些信息应被保留，哪些冗余文本可以被压缩。通信冗余问题发生在通信图结构层面，表现为某些智能体之间的连接本身贡献有限，甚至会传播高成本、低收益的工具观察和历史状态。该问题关注哪些智能体之间需要保持通信，哪些边应当被削弱或剪除。

这两个问题在工具调用场景中更加突出。具备工具使用能力的智能体不仅生成自然语言推理，还会调用搜索、代码执行、文本检查和外部 API 等工具[20-22]。工具返回内容往往较长，并可能包含网页片段、运行日志、候选代码、异常信息或中间计算结

果。在单智能体系统中，这些观察主要增加当前智能体的上下文；而在多智能体系统中，工具观察还可能沿通信边传播给多个下游智能体，触发重复阅读、重复分析甚至二次工具调用。因此，一条通信边的成本不再只由消息长度决定，还与发送方工具调用次数、工具返回 Token 和下游传播范围有关。

基于上述分析，本文将多智能体高效通信研究划分为内容层面和结构层面两条互补路线：内容层面通过消息压缩缓解语义冗余问题，提高既定通信边上传递信息的密度；结构层面通过图剪枝缓解通信冗余问题，减少低贡献通信边和高成本工具观察传播。二者共同服务于同一目标，即在保持或提升多智能体协作收益的同时，降低 Token 消耗、工具调用开销和整体推理成本。

研究多智能体系统中的高效通信机制具有明确的理论意义和实际价值。本文将多智能体系统中的通信效率问题明确拆分为“消息内容是否冗余”和“通信边是否必要”两个层次，为理解大语言模型多智能体协作中的成本–质量权衡提供了更清晰的分析框架。现有研究往往分别关注提示词压缩、长上下文处理或通信拓扑优化，但较少将自然语言消息内部冗余与通信图结构冗余放在统一视角下讨论。本文围绕语义冗余问题和通信冗余问题展开研究，有助于揭示多智能体系统中上下文膨胀、信息重复、工具观察传播和通信边贡献差异之间的关系。

在方法层面，本文旨在不改变底层大语言模型参数的前提下提升多智能体通信效率。对于闭源商业模型或难以微调的大模型系统而言，外部通信机制优化具有较强的通用性和可迁移性。消息压缩方法可以嵌入智能体之间的信息传递过程，使下游智能体接收信息密度更高的上下文；图剪枝方法则可以从通信结构角度选择贡献更高的边，使系统不必无差别地保留所有潜在连接。两类方法分别对应“传什么”和“向谁传”两个关键决策。

在实际应用层面，高效通信是多智能体系统实现大规模部署的重要前提。在工业和企业应用中，任务通常需要多轮推理、多工具调用和多角色协作，如果每个智能体都接收未筛选的完整历史消息，系统成本会随任务复杂度上升。通过减少冗余 Token 数量、压缩低贡献历史信息、削弱高成本低收益通信边，本文研究能够降低 API 调用开销和推理延迟，提高多智能体系统在实际应用中的经济可行性。同时，经过筛选和压缩的通信内容能够减少无关信息干扰，使下游智能体更便于定位关键证据和主要分歧，从而有助于提升任务完成质量和系统稳定性。

1.2 国内外研究现状

随着大语言模型从单次问答扩展到多轮任务执行，国内外研究逐渐围绕智能体协作、上下文压缩和通信结构优化形成了较为清晰的研究脉络。总体来看，相关工作可以分为三条路线：第一类研究关注如何将多个大语言模型调用组织为可协作的智能体系统，重点解决复杂任务中的角色分工、对话调度和工具使用问题；第二类研究关注如何压缩冗长提示词或对话历史，重点减少输入上下文中的低贡献语义内容；第三类研究关注如何优化多智能体通信图或工作流结构，重点减少低贡献智能体、冗余通信边和无效协作路径。本节从上述三条路线概括国内外研究现状，具体方法分类将在第2章进一步展开。

在多智能体协作框架方面，已有研究首先证明了将多个智能体组织起来可以提升复杂任务处理能力。多智能体辩论方法通过让多个模型或多个角色给出独立推理，再经由辩论、投票或评审机制形成最终答案，从而提升事实性和推理鲁棒性[26,30]。面向软件工程和复杂任务执行的 ChatDev[12]、MetaGPT[28]和 AutoGen[29]等框架，则进一步将角色分工、流程控制、工具调用和结果汇总纳入统一协作过程。CAMEL[31]、AgentVerse[32]和 ChatEval[33]等工作从角色扮演、智能体社会和多智能体评估角度探索多个智能体之间的交互方式。这些研究推动了多智能体系统从简单对话走向结构化任务执行，也说明系统性能不仅取决于单个模型能力，还与角色设置、通信方式和信息汇总策略密切相关。

然而，现有多智能体框架为了保证协作信息充分共享，往往倾向于保留较长历史上下文，或采用较密集的通信拓扑。对于小规模任务，这种设计能够降低系统实现难度；但当智能体数量、交互轮次和工具调用次数增加后，完整消息广播会增加 Token 成本和推理延迟。同时，冗长历史并不总是带来更多有效信息，弱相关解释、重复推理和过期状态还可能干扰下游智能体定位关键证据。因此，在多智能体框架逐渐成熟之后，如何提高通信效率成为进一步提升系统可用性的关键问题。

在语义内容压缩方面，国内外研究主要围绕长上下文压缩和提示词压缩展开。SelectiveContext[34]通过词元或短语的信息量估计过滤低信息量内容，LLMLingua[35]进一步提出从粗到细的提示词压缩框架，LLMLingua-2[36]将压缩过程转化为词元级保留预测问题，以提升压缩效率和跨任务泛化能力。后续研究进一步从长上下文场景、软提示压缩和任务反馈等角度提升压缩质量[37-39]。此外，检索增强与选择性压缩方法也

尝试在外部证据进入模型前筛选信息，以减少冗余上下文带来的推理负担[40-42]。这类方法为降低长上下文推理成本提供了重要基础，也为多智能体消息压缩提供了可借鉴的技术路径。

但将通用提示词压缩方法应用于多智能体通信仍存在不足。普通长文本压缩通常把输入视为一个整体文本，主要判断哪些词元、短语或句子应被保留；而多智能体通信消息具有明确的发送方、接收方、前驱节点和轮次状态。同一段推理对求解智能体可能有用，对验证智能体可能只需保留结论和证据；同一事实若已由多个前驱节点重复表达，继续保留全部表述只会增加上下文长度；跨轮历史中真正影响后续推理的也往往不是完整对话，而是共识、分歧和关键依据。因此，多智能体场景中的语义压缩需要结合角色关系、节点关系和历史状态，而不能仅以文本长度缩减作为目标。

在通信结构优化方面，相关研究从图结构学习、图剪枝和工作流搜索等角度减少无效通信。早期深度多智能体通信研究已经从可学习消息、注意力通信和何时通信等角度探索协作结构[43-45]。在大语言模型多智能体系统中，DyLAN[46]通过动态选择参与求解的智能体减少无效讨论轮次，CommFormer[47]、G-Designer[48]和 MCGD[49]等工作从图建模或图生成角度学习通信拓扑。AgentPrune[50]将多智能体系统建模为空间–时间通信图，并通过可学习掩码剪除低贡献通信边；AgentDropout[51]、SafeSieve[52]和 AGP[53]则从节点丢弃、渐进式剪枝和自适应稀疏化等角度进一步优化通信结构。与此同时，GPTSwarm[54]、AFlow[55]和 ADAS[56]等方法把智能体系统视为可搜索或可优化的工作流，通过拓扑搜索或架构搜索获得更高效的协作路径。

上述通信结构优化方法能够有效减少部分低贡献节点和通信边，但在工具调用型多智能体系统中仍面临新的成本建模问题。具备工具使用能力的智能体不仅产生自然语言推理，还可能调用搜索、代码执行或文本检查工具；工具增强语言模型和函数调用框架已经表明，外部工具会改变模型的上下文组织方式和任务执行流程[57-59]。这些工具返回内容常常包含网页片段、运行日志、异常信息或中间证据，长度和贡献差异较大。当这类工具观察沿通信边传播时，一条边的成本不再只由是否存在决定，还与发送方工具调用次数、工具返回 Token 和下游传播范围有关。因此，如果图剪枝方法只依据最终任务效用或边采样概率进行判断，就难以区分低成本高贡献边与高成本低收益边。

综合来看，现有研究已经分别从协作框架、语义内容压缩和通信结构优化三个方向推动了大语言模型多智能体系统的发展，但仍缺少对“消息内容冗余”和“通信边

冗余”的统一分析。本文不以训练更强的基座模型或重构完整智能体框架为目标，而是在现有多智能体系统之上研究可插拔的通信优化方法：一方面，从消息内容层面压缩既定通信边上传递的自然语言信息，使下游智能体接收更短、更集中、更符合角色需求的上下文；另一方面，从通信图结构层面学习不同边在任务正确性和工具成本之间的权衡，减少低贡献通信路径和高成本工具观察传播。

因此，本文将普通多智能体推理任务和工具调用增强任务分别作为两个实验场景。普通推理任务用于检验消息级语义压缩是否能够提高上下文信息密度，工具调用增强任务用于检验通信边成本异质性下的图剪枝效果。本文在评价中同时关注任务准确率、Token 成本、工具调用次数和工具 Token，避免将通信优化简单等同于减少文本长度或减少边数量。只有在基本保持任务质量的前提下降低成本，或在相近成本下获得更高准确率时，多智能体通信优化才具有实际意义。

1.3 本文主要研究内容及贡献

本文围绕多智能体系统中的高效通信技术展开研究，目标是在不改动底层大语言模型参数的前提下，通过消息级压缩和图结构剪枝提升多智能体系统的准确率–成本平衡。总体思路是：首先分析多智能体系统中通信成本和上下文膨胀的来源，将其归纳为语义冗余问题和通信冗余问题；随后分别从通信内容和通信结构两个层面提出方法；最后在多类知识理解、数学推理、代码生成和工具调用任务上验证方法有效性。

为明确本文研究边界，本文将多智能体通信中的基础对象定义如下。设多智能体系统由若干智能体节点构成，通信拓扑表示智能体之间的信息传递路径。若同一轮中某个智能体输出被传递给另一个智能体，则该路径构成空间通信边；若上一轮智能体状态被保留并传递到下一轮，则构成时间通信边。智能体在边上传递的内容称为语义消息，通常包含中间推理、候选答案、工具观察和历史摘要等信息。

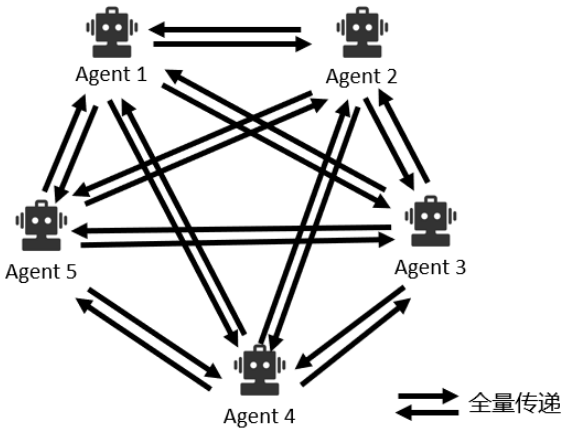


图 1.2　完全连接拓扑（Full Topology）

在完全拓扑中，每个智能体都可以接收其他智能体的输出，如图1.2所示。这种拓扑能够保证信息覆盖，但也最容易产生冗余通信。结合前文分析，本文聚焦以下两个研究问题。

问题 1.1 语义冗余问题：在多智能体持续协作过程中，随着交互轮次增加和上游节点增多，智能体之间传递的自然语言消息会出现角色不匹配、观点重复和历史累积等问题。如何根据接收方角色、前驱节点差异和跨轮历史状态，筛选并保留对后续推理有效的信息，从而在降低 Token 成本的同时保持任务准确率?

问题 1.2 通信冗余问题：在工具调用型多智能体系统中，不同通信边携带的模型输出、工具调用次数和工具观察 Token 差异较大。如何将通信边贡献建模为可学习概率，并结合任务正确性与工具调用成本判断低贡献通信边，从而动态压缩通信图结构?

1.3.1 面向语义冗余的消息压缩框架

针对既定通信边上自然语言消息冗长、重复和弱相关的问题，本文提出面向语义冗余的消息压缩框架。该工作关注“通信时应传递什么内容”，目标是在不改变原有多智能体拓扑和底层模型的前提下，对智能体之间传递的推理内容进行细粒度筛选与聚合。

具体而言，本文设计了角色感知压缩、节点感知聚合和分歧感知压缩三个模块。角色感知压缩根据接收方智能体职责过滤发送方消息中的无关推理内容，解决完整消息与接收方需求不匹配的问题；节点感知聚合对多个前驱智能体传来的相似观点进行去重和来源标注，解决多前驱消息重复的问题；分歧感知压缩从跨轮历史中提取共识

答案、候选分歧及其理由，解决多轮协作中历史上下文持续膨胀的问题。通过上述设计，本文方法能够在保留关键语义信息的同时减少冗余 Token 数量，提高下游智能体接收上下文的信息密度。

在实验方面，本文在 MMLU、GSM8K、AQuA、MultiArith、SVAMP 和 HumanEval 等任务上评估消息压缩框架，并与 Direct、FullConnected 和 AgentPrune 等基线进行对比。实验结果表明，该方法能够在多数任务上保持或提升任务准确率，同时相对于完全通信拓扑降低推理成本。

1.3.2 面向通信边冗余的图剪枝算法

针对工具调用场景中通信边成本差异较大的问题，本文提出面向通信边冗余的图剪枝算法。该工作关注“哪些智能体之间需要通信”，目标是在搜索、代码执行和文本检查等工具增强任务中，识别并剪除低贡献、高成本的通信边，从图结构层面降低多智能体系统的冗余通信开销。

具体而言，本文将智能体通信边建模为可学习概率，在训练过程中结合任务正确性、模型输出 Token、工具调用次数和工具返回 Token 构造边级优化目标。与只根据最终任务效用评估通信结构的方法不同，本文进一步将工具调用带来的额外成本归因到具体发送方和通信边，使系统能够区分高贡献通信边与传播冗余工具观察的低贡献通信边。在此基础上，本文引入 Taylor 一阶重要性评估，根据边参数与梯度共同衡量移除该边对目标函数的影响，并对低重要性边进行动态剪枝。

在实验方面，本文在 AIME、GAIA、GPQA、HLE、MATH500、MuSiQue 和 BigCodeBench 等工具调用任务上验证面向通信边冗余的图剪枝算法的有效性。实验结果表明，该方法能够在工具调用场景中更合理地平衡任务准确率与推理成本，并在多个任务上相对完全通信或原始 AgentPrune 基线减少冗余工具信息传播。

1.4 论文组织结构

本文后续章节组织如下：第2章介绍多智能体系统、语义冗余问题和通信冗余问题相关研究，分析现有方法的优势与不足；第 3 章围绕面向语义冗余的消息压缩框架展开，给出系统执行流程、核心模块设计以及实验结果分析；第4章进一步面向工具调用场景，介绍面向通信边冗余的图剪枝算法及 Taylor 一阶重要性剪枝策略；最后，总结全文工作并讨论后续研究方向。

2 相关工作

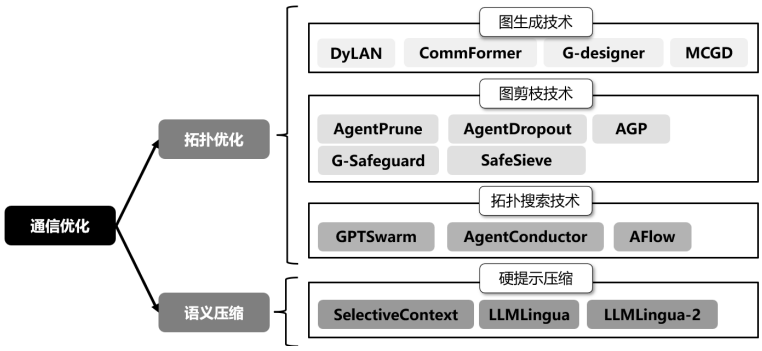


图 2.1　多智能体的两条研究路线

第1章从问题提出角度说明了多智能体系统中的通信瓶颈。本章进一步从已有研究脉络出发，梳理多智能体系统、语义冗余问题和通信冗余问题相关工作。依据优化对象的不同，相关方法可分为两类：一类关注智能体协作的组织方式与通信路径，核心问题是“哪些智能体之间需要通信”；另一类关注通信路径上传递的自然语言内容，核心问题是“通信时应传递什么信息”。本章重点分析各类方法的研究思路、适用范围和不足，为后续两项工作提供方法背景。

2.1 多智能体系统

第1章已从问题提出角度说明多智能体系统的研究动机。本节进一步从系统实现视角归纳现有大语言模型多智能体系统的主要形态。总体来看，相关工作可以分为角色协作型、工具增强型和通信组织型三类；三类方法分别强调任务如何分工、外部能力如何接入以及信息如何在智能体之间流动。

角色协作型系统通过提示词、角色职责和对话协议把复杂任务拆解为多个协作环节。多智能体辩论方法利用多个模型或多个角色之间的交叉质询提升答案可靠性[26,30]；ChatDev 和 MetaGPT 等框架则将软件开发或复杂任务执行组织为阶段化流程，使不同角色在较明确的任务边界内协同工作[12,28]。这类方法的优势在于能够把单模型难以完成的任务拆解为更稳定的协作过程，但其通信方式往往依赖预设流程和较充分的信息共享，容易在多轮交互中累积重复上下文。

工具增强型系统关注智能体如何调用外部模型、API、搜索引擎或代码执行器。MRKL、HuggingGPT 和 Gorilla 等工作从工具路由、模型调度和 API 使用角度增强大

语言模型的执行能力[57-59]；API-Bank、WebGPT 和 ReWOO 等研究进一步表明，工具调用会把检索证据、函数返回和中间观察写入上下文[60-62]。在多智能体场景中，这些外部观察不仅影响当前智能体，还可能被传递给后续智能体，从而使通信成本和工具成本耦合起来。

通信组织型系统则关注智能体之间的信息流如何被组织。可编程对话框架、智能体社会模拟和工作流编排方法为多智能体交互提供了不同组织形式[29,31-32]；外部记忆和并行函数调用等机制也使跨轮状态管理和工具观察传播更加复杂[63-64]。因此，多智能体系统的通信效率不仅取决于是否存在多个角色，还取决于消息内容是否精炼、通信路径是否必要以及工具观察是否被重复传播。基于这一点，后续两节分别从消息内容层面的语义冗余问题和通信路径层面的通信冗余问题展开讨论。

2.2 语义冗余问题

2.2.1 定义和分类

在既定通信拓扑下，从语义维度对智能体传递的上下文消息进行压缩，是降低大语言模型推理成本和上下文占用的另一项重要手段。与拓扑优化关注“哪些智能体之间需要通信”不同，语义冗余问题更关注“沿通信链路传递什么内容”。在多智能体系统中，语义冗余问题通常指智能体之间传递的自然语言消息中包含较多重复推理、弱相关背景、低贡献解释或过长历史记忆，使下游智能体需要在更长上下文中寻找有效信息。

结合多智能体通信过程，语义冗余问题可分为三类。第一类是**角色不匹配冗余**，即发送方完整推理并不完全符合接收方智能体的角色职责，导致下游节点接收较多与自身任务无关的信息。第二类是**多前驱重复冗余**，即多个上游智能体围绕同一事实、同一公式或同一候选答案给出相似表述，增加上下文长度但信息增量有限。第三类是**跨轮历史冗余**，即多轮协作中历史消息逐轮累积，使后续智能体难以从冗长上下文中定位当前共识、关键分歧和有效证据。

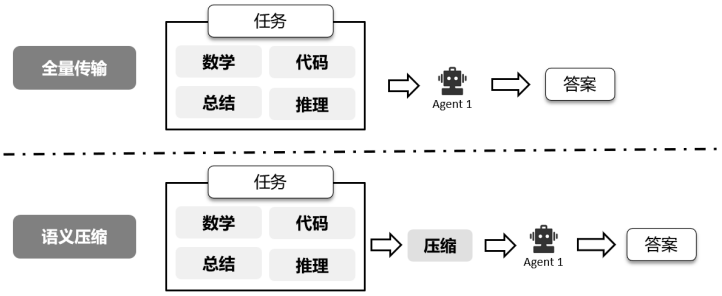


图 2.2　压缩示意图

2.2.2 通用应对策略

硬提示词压缩旨在通过对原始文本进行修改，生成可读且更为精简的自然语言序列。与软提示压缩将上下文映射为不可读的连续向量不同，硬提示词压缩保留了自然语言形式，因此更便于人工检查、跨模型迁移以及在多智能体通信场景中复用。与之相关的软提示和上下文状态压缩方法通常把历史信息压缩为特殊向量、摘要状态或可复用记忆，从而减少后续模型调用中的显式文本长度[38,65]。根据压缩机制的不同，硬提示词压缩相关研究可划分为以下两个方向[66]：

基于过滤的压缩方法：此类方法通过评估词元、短语或句子的重要性，剔除冗余和低信息量的部分，并在保持原文顺序的基础上生成压缩后的上下文。早期代表性工作 SelectiveContext[34]利用较小规模的因果语言模型计算词元的自信息或困惑度，将低自信息内容视为更容易由上下文预测、因而冗余度更高的部分，再按照词元、短语或句子粒度进行过滤。该方法无需额外训练，能够应用于黑盒 LLM，但由于其重要性评估主要依赖语言统计特征，可能误删对特定任务有用但语言上并不突出的信息。LLMLingua[35]进一步提出粗到细的压缩框架，首先通过预算控制器在指令、示例和问题等不同提示词组成部分之间分配压缩率，再利用小模型估计词元困惑度或信息熵，逐步保留高信息量词元。LongLLMLingua 则面向长上下文场景进一步考虑查询相关性和文档级信息筛选[37]。相比简单过滤，上述方法考虑了提示词内部不同模块的重要性差异，并通过迭代式压缩缓解局部删除造成的上下文断裂问题，因此能够在较高压缩率下保持较好的下游任务性能。

后续的 LLMLingua-2[36]则引入了数据蒸馏机制，将压缩任务从基于困惑度的无监督筛选转化为词元级二分类任务。具体而言，该方法先利用强模型生成抽取式压缩结果，再通过自动对齐为原始文本中的词元标注“保留”或“删除”标签，并训练轻量级双向编码器预测每个词元的重要性。推理时，模型按照保留概率选择满足压缩预算的词元，并保持其原始顺序。由于双向编码器能够同时利用左右上下文，LLMLingua-

2 在压缩速度、忠实度和跨任务泛化方面均优于单纯依赖困惑度的方法。进一步地，TACO-RL[39]将强化学习引入过滤式压缩过程，将每个词元的保留或删除视为动作，并根据下游任务表现给予奖励。检索增强场景中的 RECOMP 也体现了选择性保留外部证据、减少冗余文档输入的思路[40]。通过这种方式，压缩器能够根据具体任务目标动态调整剪枝策略，使其更倾向于保留与当前查询或任务评价指标直接相关的信息，从而弥补任务无关过滤方法在语义选择上的不足。

基于重写的压缩方法：与简单的删除词元不同，此类方法利用语言模型的生成与概括能力，主动将冗长的上下文重写为更紧凑的自然语言表达。其核心优势在于能够跨越句子边界进行信息重组，将分散在原文不同位置的关键信息合并为更短的表述，从而避免纯过滤方法可能造成的语义割裂或可读性下降。例如 Nano-Capsulator 框架[67]不再从原始提示词中选择词元，而是训练一个生成式压缩模型，将长提示词封装为更短的 Capsule Prompt。该模型在训练过程中同时考虑语义保持和下游任务效用：一方面要求压缩后的自然语言表示尽可能保留原始提示词的核心含义，另一方面又通过目标 LLM 在相关任务上的输出表现约束压缩结果，使其在压缩长度的同时仍能有效引导模型完成任务。

与过滤式方法相比，基于重写的压缩能够生成较为流畅、连贯且可读的压缩文本，尤其适合处理包含重复解释、长链式推理示例或多轮对话历史的上下文。在多智能体系统中，这类方法可用于将某一智能体的长篇推理过程、观察记录或工具调用结果重写为面向后续智能体的短摘要，从而减少跨智能体传递的词元数量。检索增强生成和多文档问答中的证据压缩同样强调在生成前压缩外部信息，以降低模型读取无关文本的负担[41-42]。然而，这类方法也存在潜在风险：由于压缩过程依赖生成模型，可能出现关键信息遗漏、语义偏移甚至事实性错误。因此，在高精度任务中，重写式压缩通常需要结合任务反馈、事实一致性检测或保守的压缩率设置，以在压缩效率与语义可靠性之间取得平衡。

总体来看，通用提示词压缩方法为缓解语义冗余问题提供了基础，但其优化对象多为单模型输入，通常不显式区分发送方角色、接收方需求、多个前驱节点之间的信息重复以及跨轮历史的时序价值。同时，KV 缓存压缩和流式注意力等系统优化方法主要面向推理内存与上下文窗口效率，并不判断跨智能体消息对接收方是否有用[68-69]。因此，在多智能体通信场景中，语义压缩还需要结合角色关系、节点关系和历史状态进行针对性建模，以避免将对下游智能体有用的关键信息一并删除。

2.3 通信边冗余

2.3.1 定义和分类

通信冗余问题是指多智能体系统中存在低贡献、重复或成本过高的信息传递路径，使系统在没有获得相应任务收益的情况下产生额外 Token 消耗、工具调用开销和上下文膨胀。与语义冗余问题关注单条消息内部内容不同，通信冗余问题关注“哪些边应当存在、哪些边应当被削弱或剪除”。在工具调用场景中，该问题更为突出，因为一条通信边不仅传递发送方的自然语言推理，还可能传播搜索结果、代码执行结果和文本检查结果等高成本工具观察。

通信冗余问题可分为三类。第一类是**空间边冗余**，即同一轮内过密的智能体连接使多个下游节点读取相似或低贡献的上游输出。第二类是**时间边冗余**，即跨轮历史状态被未经筛选地传递，导致早期低贡献历史信息在多轮推理中持续占用上下文。第三类是**工具传播冗余**，即外部工具返回的长观察结果沿通信边反复传播，增加模型输入 Token、工具 Token 和推理成本。

2.3.2 通用应对策略

针对通信冗余问题，现有方法通常将智能体视为节点、通信链路视为边，并通过图生成、图剪枝和拓扑搜索等方式减少低贡献通信路径[70]。这类方法的共同目标是在保持协作收益的同时，使信息只沿更有贡献的边传播。早期多智能体强化学习中的通信学习方法已经验证，可学习消息通道和通信门控能够在协作任务中减少无效交互[43-45]。

基于图生成的策略：图生成方法旨在根据任务条件自适应构造通信拓扑，而非完全依赖人工预设结构。

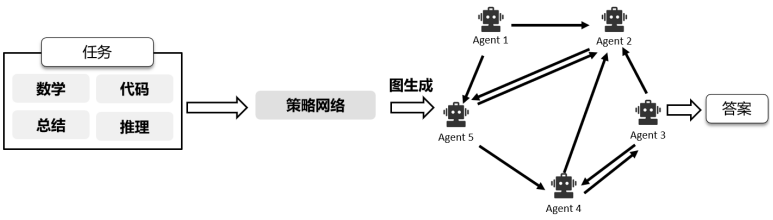


图 2.3　图生成技术示意图

DyLAN（Dynamic LLM-Agent Network）[46]不预先固定所有智能体之间的通信关系，而是将多智能体协作过程建模为随任务推进变化的前馈式动态网络。其核心机制

包括两个阶段：首先在候选智能体集合中进行团队优化，利用 Agent Importance Score 评估不同智能体在当前任务上的边际贡献；随后在任务求解阶段，根据每一轮智能体输出的有效性动态选择后续参与通信的节点。DyLAN 还引入早停机制，当系统已经形成足够稳定的答案或共识时提前终止多轮交互。因此，该方法主要通过减少低贡献智能体的参与次数和削减无效讨论轮次降低成本，并动态生成更贴合当前查询的通信图。注意力通信、图信息瓶颈和目标通信等方法也为稀疏化智能体交互提供了图建模基础[71-73]。

CommFormer[47]将多智能体强化学习中的智能体表示为图节点，将通信信道表示为有向边，并通过可微的图结构学习机制直接优化通信拓扑。其关键做法是对离散边选择进行连续松弛，使邻接矩阵能够参与梯度更新，同时在 Transformer 结构中引入关系增强注意力，以建模智能体间的依赖关系。G-Designer[48]面向 LLM 多智能体系统，将每个智能体的基础模型、角色、状态、工具插件等编码为节点特征，并额外引入任务虚拟节点来表达当前查询需求，随后使用变分图自编码器生成面向特定任务的通信图。MCGD[49]则从多智能体强化学习角度构建稀疏协调图，通过图扩散模型学习有效交互模式，体现了只显式建模关键邻居关系、避免全体智能体两两交互的思路。

基于图剪枝的策略：图剪枝方法通常从密集拓扑出发，逐步删除低贡献节点或通信边，使冗余通信图收敛为更稀疏的协作结构。

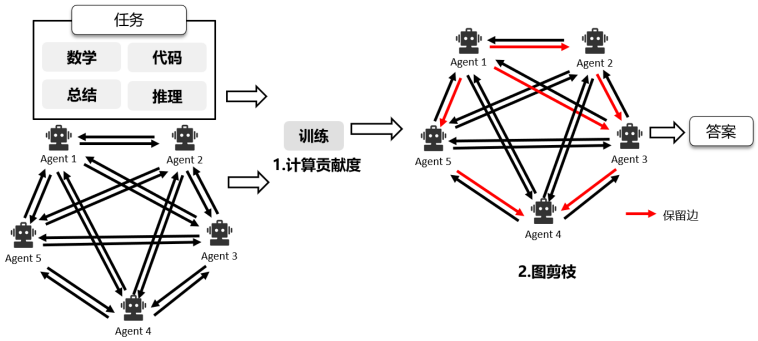


图 2.4　图剪枝技术示意图

AgentPrune[50]将 LLM 多智能体系统表示为空间-时间通信图：同一轮智能体之间的信息交换为“空间边”，跨轮历史传递为“时间边”。它为这些边学习可剪枝的图掩码，并通过系统效用评估器判断不同边对任务结果的贡献。由于外部 LLM 调用和任务评估通常不可微，AgentPrune 使用策略梯度近似优化掩码参数，并最终执行一次性硬剪枝。AgentDropout[51]在边剪枝基础上进一步引入节点丢弃，通过 Node Dropout 和 Edge Dropout 同时减少智能体输入、输出和后续通信边。SafeSieve[52]采用渐进式软剪

枝策略，结合 LLM 语义评估、角色互补性和历史任务表现修正边权，并利用聚类机制保持核心功能簇连通性。AGP（Adaptive Graph Pruning）[53]同时进行节点级硬剪枝和边级软剪枝，使系统能够针对不同查询生成不同规模的稀疏拓扑。G-Safeguard[74]则从安全角度构建 multi-agent utterance graph，用于识别异常节点与异常话语，并通过隔离风险节点或剪断高风险外发边阻止恶意信息扩散。

基于拓扑搜索的策略：拓扑搜索通过在智能体算子和通信边构成的较大搜索空间中探索高效工作流，通常结合强化学习、蒙特卡洛树搜索或网络架构搜索算法。

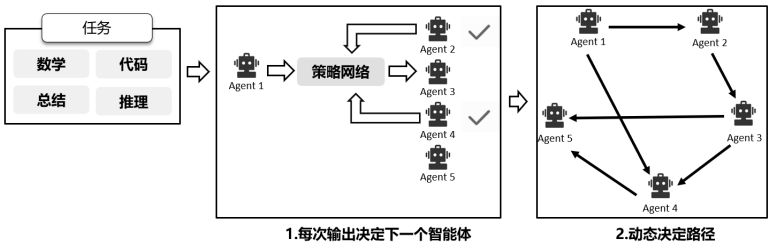


图 2.5　拓扑搜索技术示意图

GPTSwarm[54]将语言智能体系统统一建模为可优化图：节点可以是 LLM 调用、工具或数据处理函数，边表示信息流。它为候选边分配可学习的采样概率，在无环图空间中采样候选拓扑，并通过 REINFORCE 等策略梯度方法根据任务效用更新边概率。AgentConductor[75]面向竞赛级代码生成任务，训练 LLM 为每个问题动态生成 YAML 格式的分层 DAG 拓扑，并根据编译、运行和测试反馈多轮调整拓扑。AFlow[55]将 agentic workflow 表示为可执行代码中的算子组合与依赖关系，并使用蒙特卡洛树搜索探索 Generate、Review、Revise、Ensemble、Test、Programmer 等工作流算子。MASS（Multi-Agent System Search）[76]交错优化 prompt 和 topology，并对低收益模块进行影响力剪枝。MaAS（Multi-agent Architecture Search via Agentic Supernet）[77]提出智能体超网，使每个查询只激活少量算子路径。DynaSwarm[78]则在 GPTSwarm 式参数化通信图基础上引入样本级动态选择，根据输入样本路由到不同稀疏候选结构。近期自动化智能体设计和工作流编译研究进一步说明，prompt、工具调用和拓扑结构可以被统一纳入系统级搜索空间[56,79-80]。

上述研究说明，减少无效节点、无效边和低收益工作流能够缓解多智能体系统的通信负担。但现有方法大多将通信边代价近似视为同质，或者主要依据任务效用判断边是否保留，对工具调用场景中“某条边传播了多少工具观察、造成多少下游上下文膨胀、带来了多少额外调用成本”刻画不足。尤其在搜索、代码执行和文本检查等工

具增强任务中，一条边的贡献不仅取决于是否提高最终答案，还取决于它是否传播了高成本、低增益的工具信息。因此，本文第四章提出面向通信边冗余的图剪枝算法，将通信边建模为可学习概率，并把任务正确性、工具调用次数、工具返回 Token 和模型输出 Token 共同纳入边级优化目标，从而解决工具调用场景下通信边贡献异质、成本难以归因和低贡献边难以及时剪除的问题。

2.4 本章小结

本章围绕多智能体系统及其通信效率优化相关研究进行了梳理。首先，多智能体系统通过角色分工、协作推理和工具调用提升复杂任务处理能力，但也带来了通信路径膨胀和上下文累积问题。其次，语义冗余问题主要表现为角色不匹配、多前驱重复和跨轮历史冗余，现有过滤式与重写式压缩方法为减少自然语言上下文提供了基础，但仍需面向多智能体通信场景进一步适配。最后，通信冗余问题主要表现为空间边、时间边和工具传播冗余，现有图生成、图剪枝和拓扑搜索方法能够从结构层面降低系统开销，但对工具调用场景下的边级成本归因、工具观察传播和动态低贡献边识别仍不充分。上述不足共同构成了本文后续两个工作的主要动机：第三章从语义内容层面提出面向语义冗余的消息压缩框架，第四章从通信结构层面提出面向通信边冗余的图剪枝算法。

3 面向语义冗余的消息压缩框架

3.1 引言

上一章从相关工作角度梳理了多智能体系统、语义冗余问题和通信冗余问题。可以看到，现有方法虽然能够在一定程度上降低通信开销，但在多智能体协作场景中仍面临三类细粒度语义冗余问题：发送方完整推理与接收方角色需求不匹配，多个前驱节点传递相似或重复观点，以及多轮历史记忆持续累积导致上下文膨胀。针对这些问题，本章提出面向语义冗余的消息压缩框架，从角色、节点和时序三个维度对通信内容进行压缩，在不改变底层大语言模型能力的前提下提升通信内容的信息密度。

3.2 消息压缩框架

本节首先描述标准多智能体系统的任务执行流程，随后给出消息压缩框架的整体执行过程，并详细介绍角色感知压缩、节点感知聚合和分歧感知压缩三个核心模块。

3.2.1 多智能体系统任务执行流程

多智能体系统通过角色分工与协作推理来完成目标。如图3.1所示，其标准任务执行流程主要包含以下四个核心环节：

1. **任务输入：**接收并标准化外部任务，为智能体构建结构化的上下文环境。
2. **协作推理：**依托预设的通信拓扑，各智能体结合自身角色与前驱节点的历史信息进行多轮次推理，并持续传递中间结果。
3. **结果聚合：**采用投票或共识决策机制，对各智能体的候选答案进行汇总，输出最终可靠结果。
4. **性能评测：**系统性评估模型在任务准确率及通信成本（如词元消耗、推理延迟）上的综合表现。

3.2.2 消息压缩框架执行流程

为解决多智能体协作中的信息冗余问题，本课题在智能体与智能体之间的通信中引入了**消息压缩框架**。该框架从角色、节点和时序三个维度对通信内容进行压缩。

具体执行流程包含以下三个核心步骤：

1. **角色感知压缩：**针对接收方信息需求的不对称性，根据下游角色的具体职责，过

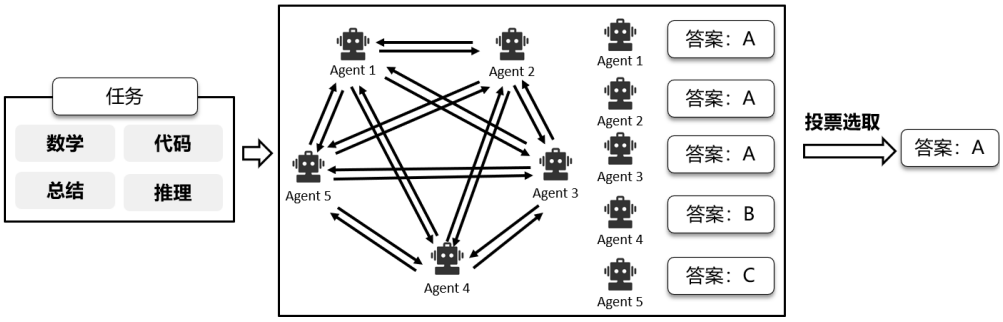


图 3.1　多智能体系统标准任务执行流程示意图

滤前驱智能体消息中的无关推理内容，从而使下游智能体能够获得与自身任务更相关的信息。

2. **节点感知聚合：**针对多个前驱节点可能产生相似推理内容的问题，将不同节点传来的相似推理过程进行去重，避免相同观点在下游智能体上下文中重复出现，从而减少冗余消息传递。

3. **分歧感知压缩：**针对多轮对话记录过长的问题，通过提取历史轮次中的共识与分歧内容，压缩上一轮次传递的信息，并保留有效信息供本轮智能体参考。

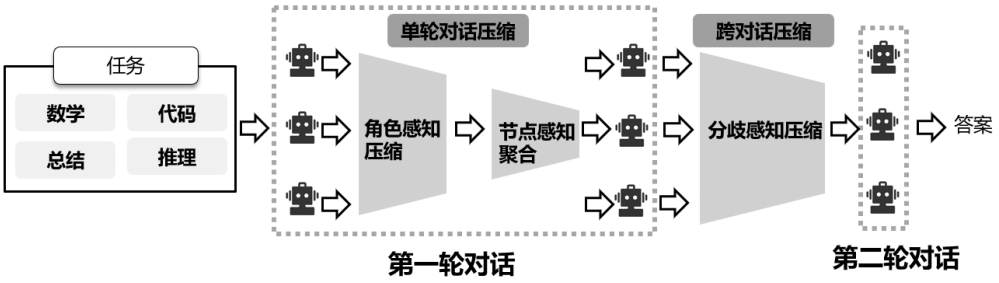


图 3.2　消息压缩框架

3.2.3 功能模块设计

本节介绍消息压缩框架的三个核心模块：角色感知消息压缩、节点感知消息聚合和时序答案一致性摘要。三者分别处理多智能体通信中的三类冗余：第一类是发送方推理内容与接收方角色无关，第二类是多个前驱智能体给出了相似推理，第三类是跨轮历史持续累积导致上下文过长。为避免符号堆叠，本文仅保留必要定义，并重点说明各模块的输入、处理逻辑和输出结果。

设多智能体系统的通信图为 $G = (V, E)$。在第 t 轮中，发送方智能体 u 传递给接收方智能体 v 的消息表示为

$$m_{u \to v}^{(t)} = (r_u^{(t)}, a_u^{(t)}),$$

其中 $r_u^{(t)}$ 表示推理内容，$a_u^{(t)}$ 表示最终答案。本文的压缩操作主要作用于推理内容 $r_u^{(t)}$，原则上不直接改写答案字段，从而避免压缩过程破坏最终判断。

3.2.3.1 角色感知压缩模块

角色感知压缩模块解决的是“消息是否适合当前接收方”的问题。在多智能体系统中，不同智能体承担的职责不同。例如，负责规划的智能体更需要任务拆解和约束信息，负责验证的智能体更关注候选答案、错误风险和反例。如果发送方的完整推理被直接转发给所有下游节点，接收方会同时看到大量与自身职责无关的内容，既增加 token 成本，也容易稀释真正有用的信息。

该模块的处理流程分为三步。首先，将发送方的推理文本按句子切分，得到若干候选推理片段。其次，将每个句子与接收方角色描述进行语义匹配，匹配分数由文本向量的余弦相似度给出：

$$\mathrm{sim}(s, d_v) = \cos(\phi(s), \phi(d_v)),$$

其中 s 表示候选句子，d_v 表示接收方角色描述，$\phi(\cdot)$ 表示文本编码函数。最后，系统根据同一条消息内部的相似度分布自动确定保留阈值，只保留与接收方角色更相关的句子；若保留文本仍超过角色预算，则按原始顺序截断到预算范围内。

该模块的输出仍然是一条结构化消息：推理字段被替换为筛选后的短文本，答案字段保持不变。这样做的好处是，接收方能够获得更贴近自身职责的上下文，同时不会因为压缩推理过程而丢失发送方给出的最终答案。

3.2.3.2 节点感知聚合模块

节点感知聚合模块解决的是“多个前驱消息之间是否重复”的问题。对于同一个接收方节点，多个上游智能体可能从不同角度得出相近结论，也可能在推理过程中反复陈述同一事实。如果将这些内容直接拼接，下游节点会接收到大量重复表达，导致上下文变长，但信息增量有限。

该模块会先收集接收方节点所有前驱智能体的压缩后推理句子，并为每个句子保留来源角色标签。随后，系统按照句子出现顺序逐一检查候选内容：若当前句子与已保留句子的语义相似度高于冗余阈值，则认为它提供的信息已经被覆盖，不再重复加入；若相似度低于阈值，则将其作为新的有效信息保留。本文实现中，冗余判定阈值取 0.70，用于在“去重”和“保留多样观点”之间取得平衡。

聚合后的推理内容由若干带角色标签的句子组成。角色标签的作用是保留信息来源，使下游智能体不仅知道“有哪些观点被保留”，也能知道“这些观点来自哪个角色”。对于多个前驱节点给出的答案，模块采用简单投票生成聚合答案；若出现票数接近或无法明确多数的情况，则保留多个候选答案及其来源，交由后续节点继续判断。

通过该模块，系统不再把多个前驱消息拼接，而是先做跨节点去重和来源标注。这样既能减少重复 token，也能提高下游上下文的信息密度。

3.2.3.3 分歧感知压缩模块

分歧感知压缩模块解决的是“跨轮历史如何保留”的问题。多智能体协作通常需要多轮执行，如果每一轮都完整保存所有智能体的推理和答案，历史记忆会快速膨胀。过长的历史不仅增加推理成本，还可能使模型在后续轮次中难以抓住当前最关键的共识和分歧。

该模块在每一轮协作结束后运行。系统首先收集本轮所有智能体的答案，并对答案文本进行规则化处理，例如去除多余空格、统一大小写、去掉常见答案前缀和标点。经过规则化后，表达相同含义的答案会被归入同一个答案组。基于答案组数量，系统生成两类摘要。

当所有智能体的答案归入同一组时，说明本轮协作已经形成共识。此时摘要只保留共识答案，以及最能代表该结论的简短理由。代表理由通常来自推理内容较完整的智能体，并只保留核心句子，避免把完整推理链再次写入历史。

当答案被分成多个组时，说明智能体之间仍存在分歧。此时摘要会记录每个候选答案、支持该答案的智能体数量，以及对应的简短理由。这样，下一轮智能体能够直接看到当前争议点，而不需要重新阅读上一轮所有冗长输出。

最终生成的摘要会写入各智能体的历史记忆，作为下一轮推理的压缩上下文。该模块只依赖规则化文本处理、答案分组和简短摘要模板，不额外调用大语言模型，因此能够在控制成本的同时保留跨轮协作中最重要的信息。

3.3 实验设置

为验证面向语义冗余的消息压缩框架在不同任务类型和不同基座模型上的有效性，本文在综合知识、数学推理和代码生成任务上开展实验，并从任务准确率与推理成本两个维度进行评估。

3.3.1 数据集

为全面客观地评估模型能力，本文选取多智能体系统研究中常用的 6 个数据集，涵盖综合知识、数学推理和代码生成三个核心能力维度。具体任务特征与选取依据如表3.1所示。

任务类型	数据集名称	描述	样本数量
综合知识	MMLU[81]	涵盖 57 个不同学科的综合性基准	153
数学推理	GSM8K[82]	小学数学应用题数据集	1319
	AQuA[83]	复杂的代数应用题	254
	MultiArith[84]	多步算术运算	600
	SVAMP[85]	语义和扰动生成的数学题	1000
代码生成	HumanEval[86]	生成完整 Python 代码	164

表 3.1　实验评测数据集概览

3.3.2 对比基准

实验设置了四类对比基准。首先是 Direct 方法，即单智能体直接完成任务，不引入智能体间通信，用于衡量单模型基础能力和最低推理成本。其次是 Fullconnect 方法，上游智能体生成的原始输出直接、完整地透传给下游智能体，不进行任何截断，从而保留完整上下文内容，代表多智能体通信开销的上限及任务基础性能的对照标准。第三是 AgentPrune 方法，作为当前多智能体系统拓扑优化的代表性方法，该基线对智能体间的通信边进行剪枝。最后是本文方法，即引入本文设计的消息压缩模块，在智能体交互前对冗长推理和弱相关背景进行压缩，仅保留与后续推理更相关的关键信息。

3.3.3 实现细节

为了保证实验结论的客观性与普适性，本文选取三个主流大语言模型作为多智能体的基座模型。这些模型在 API 调用成本上存在显著差异，具体计费标准如表3.2所示。

模型名称	输入价格（千 tokens）	输出价格（千 tokens）
Qwen2.5-14B-Instruct	¥0.0007	¥0.0007
Qwen3-14B	¥0.0005	¥0.0020
MinMax-M3	¥0.0021	¥0.0084

表 3.2　API 调用单价对比表

Qwen2.5-14B-Instruct：作为 2024 年开源指令模型的代表，其在通用问答、指令遵循与文本生成等任务中表现出较高的稳定性。本研究将其设为基础对照组，旨在与 Qwen3-14B 形成严格的控制变量（参数量级一致）。通过引入该对照组，重点考察在缺乏新一代推理与指令优化机制的前提下，消息压缩策略对任务生成质量、词元消耗及调用成本的具体影响。

Qwen3-14B：作为中等规模参数开源模型的代表，该模型在推理效率、部署成本与基础性能之间实现了较优的平衡。结合表3.2数据可知，其 API 调用成本相对较低。选取该模型旨在探究消息压缩策略在低成本、常规算力约束下，对实际任务效能及经济成本的优化潜力。

MiniMax-M3：引入该闭源商业模型旨在拓展实验基座的架构多样性，并构建高成本模型对照场景。鉴于其 API 调用费率较高（输入与输出单价约为 Qwen3-14B 的 4 倍以上），在处理长文本任务时容易产生较高的边际成本。选取该模型旨在验证消息压缩策略在面对高资源消耗型商业大模型时，能否有效降低计算冗余并实现成本缩减。

在所有实验中，均采用相同的系统提示词、智能体数量、超参数以及数据集划分，以确保实验结果的可比性。本文实验图表均由统一格式的实验结果表生成，表中记录了模型、方法、输入词元数、输出词元数、推理成本和准确率等字段。其中，推理成本按照输入、输出 Token 数量与表3.2中的 API 单价换算，单位为人民币元；同一数据集内各方法采用相同评测规模，因此成本数值主要用于横向比较不同通信策略的相对开销。对于同一数据集、同一模型和同一方法，结果表仅保留一次完整评测结果，避免在论文中选择性呈现局部最优实验。

3.3.4 评估指标

本文主要从任务完成质量与通信成本两个维度，选取了以下两项核心评价指标：

准确率 (Accuracy)：衡量模型完成任务的有效性。针对 MMLU 及四项数学推理

数据集（GSM8K、AQuA、MultiArith、SVAMP），提取模型最终输出的答案与标准答案进行精确匹配以计算正确率；对于 HumanEval 代码生成数据集，则以测试用例的通过率（Pass@1）作为准确率进行评估。

推理成本 (Inference Cost)：衡量多智能体通信过程中的经济开销。具体统计系统完成对应评测集推理时，由输入词元和输出词元产生的 API 调用费用，单位为人民币元。

3.4 实验结果与分析

本阶段实验在 MMLU、GSM8K、AQuA、MultiArith、SVAMP 和 HumanEval 六个数据集上展开，覆盖通用知识理解、数学推理、多项选择推理和代码生成等不同任务类型。实验对比了 Direct、Fullconnect、AgentPrune 和本文方法。

为保证总体结果统计的可解释性，本文在主实验中选取 MiniMax-M3、Qwen3-14B 和 Qwen2.5-14B-Instruct 作为主要分析模型，并按模型分别计算其在可用数据集上的平均表现。三个主分析模型均覆盖 MMLU、GSM8K、AQuA、MultiArith、SVAMP 和 HumanEval 六个数据集，因此总体图中的 $n = 6$ 表示每个模型均按六个数据集求平均。总体实验不将所有模型和数据集混合为单一平均值，而是分别展示三个模型下不同方法的平均表现，以避免不同模型能力水平和价格体系带来的统计偏差。

需要说明的是，本节柱状图展示的是固定评测集上的单次完整评测汇总结果，尚未包含多随机种子重复实验和置信区间。因此，本文在分析中不将 0.1 至 0.3 个百分点以内的小幅差异解释为统计显著优势，而更关注跨数据集趋势、成本下降幅度以及准确率与成本之间的综合权衡。对于 AQuA 和 HumanEval 等本文方法未取得最优准确率的数据集，正文仍保留并分析其原因，以保证实验呈现的完整性。准确率柱状图均采用 0–100% 的完整纵轴范围，避免因截断纵轴放大不同方法之间的视觉差异。

3.4.1 任务准确率结果

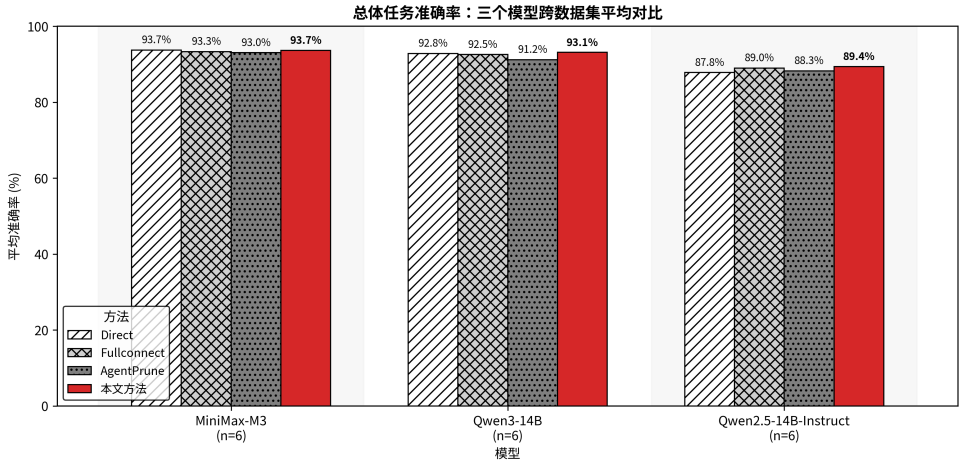
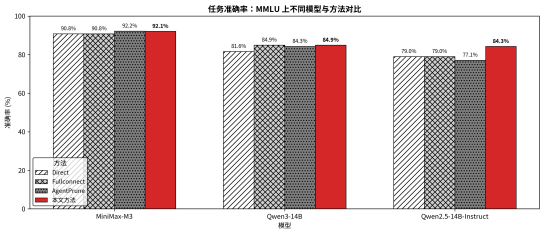


图 3.3　六个数据集在不同模型下的平均准确率对比（纵轴为 0–100%）

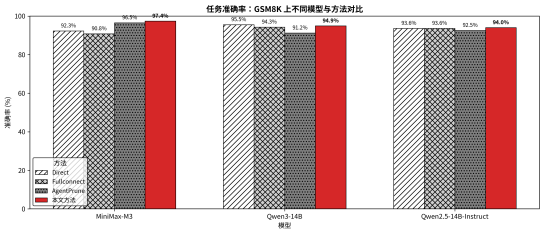
图3.3展示了三个主要模型在不同方法下的跨数据集平均准确率。整体来看，本文方法在 Qwen3-14B 和 Qwen2.5-14B-Instruct 上均取得最高平均准确率，在 MiniMax-M3 上与 Direct 方法基本持平，同时高于 Fullconnect 和 AgentPrune。这说明本文方法在不同模型能力水平下均具有较好的稳定性，尤其在中小规模模型上能够带来更明显的性能收益。

具体而言，在 Qwen3-14B 上，本文方法的平均准确率达到 93.10%，高于 Direct 的 92.80%、Fullconnect 的 92.53% 和 AgentPrune 的 91.20%。在 Qwen2.5-14B-Instruct 上，本文方法的平均准确率为 89.38%，高于 Direct 的 87.78%、Fullconnect 的 89.00% 和 AgentPrune 的 88.27%。在 MiniMax-M3 上，Direct 方法的平均准确率为 93.72%，本文方法为 93.66%，二者差距仅为 0.06 个百分点，基本处于同一水平；同时，本文方法仍高于 Fullconnect 和 AgentPrune。

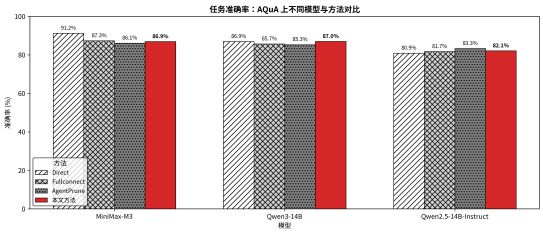
为了避免总体平均掩盖不同任务类型的差异，下面进一步按数据集展开分析。总体上，本文方法在 MMLU、GSM8K、MultiArith 和 SVAMP 上表现较强，在 AQuA 和 HumanEval 上则呈现出更明显的任务依赖性，说明消息级协作更适合知识理解和数学推理类任务，而在多项选择干扰项较强或代码生成需要执行反馈的任务中仍有改进空间。



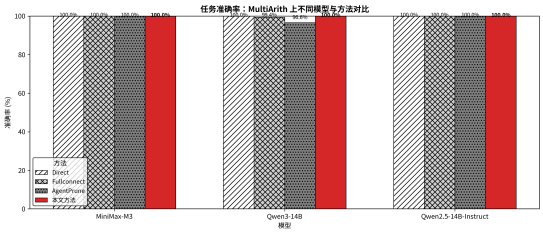
(a) MMLU 准确率



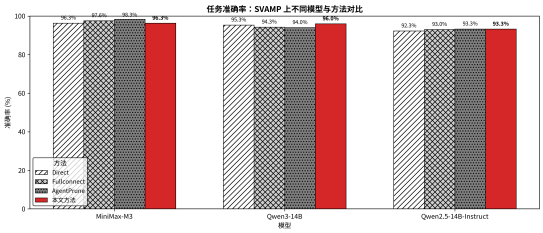
(b) GSM8K 准确率



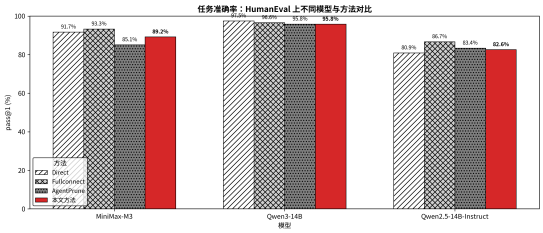
(c) AQuA 准确率



(d) MultiArith 准确率



(e) SVAMP 准确率



(f) HumanEval 准确率

图 3.4　各数据集上不同模型与方法的准确率对比（纵轴为 0–100%）

MMLU 在 MMLU 数据集上，本文方法整体表现较为稳定。在主分析的三个模型中，本文方法的平均准确率为 87.10%，高于 Direct 的 83.80%、Fullconnect 的 84.90% 和 AgentPrune 的 84.53%。其中，Qwen2.5-14B-Instruct 的提升最明显，本文方法达到 84.30%，相比 Direct 和 Fullconnect 均提升 5.30 个百分点，相比 AgentPrune 提升 7.20 个百分点。Qwen3-14B 上，本文方法达到 84.90%，与 Fullconnect 持平，并高于 Direct 和 AgentPrune。MiniMax-M3 上，本文方法为 92.10%，与 AgentPrune 的 92.20% 基本持平，并高于 Direct 和 Fullconnect。

GSM8K 在该数据集上，本文方法在三个主分析模型上的平均准确率为 95.44%，高于 Direct 的 93.80%、Fullconnect 的 92.90% 和 AgentPrune 的 93.40%。其中，MiniMax-M3 使用本文方法达到 97.41%，分别高于 Direct、Fullconnect 和 AgentPrune 5.11、6.61 和 0.91 个百分点，说明消息级协作能够增强复杂算术推理中的答案鲁棒性。Qwen3-14B 上，Direct 方法为 95.50%，略高于本文方法的 94.90%；但本文方法仍高于 Fullconnect 和 AgentPrune。Qwen2.5-14B-Instruct 上，本文方法达到 94.00%，高于 Direct 和 Fullconnect

的 93.60%，也高于 AgentPrune 的 92.50%，说明新增结果进一步支持本文方法在数学推理任务上的稳定收益。

AQuA 在 AQuA 数据集上，结果更具任务依赖性。三个模型上，本文方法的平均准确率为 85.33%，低于 Direct 的 86.33%，但高于 Fullconnect 和 AgentPrune 的 84.90%。分模型看，Qwen3-14B 使用本文方法达到 87.00%，为该模型下最高结果，相比 Direct、Fullconnect 和 AgentPrune 分别提升 0.10、1.30 和 1.69 个百分点；Qwen2.5-14B-Instruct 上，本文方法为 82.10%，高于 Direct 和 Fullconnect，但低于 AgentPrune；MiniMax-M3 上，Direct 方法达到 91.20%，明显高于其他协作方法。这说明多项选择推理任务中，额外消息可能同时带来有用信息和干扰信息，需要更强的任务自适应筛选。

MultiArith 在 MultiArith 数据集上，各方法整体接近饱和。本文方法在三个主分析模型上均达到 100.00%，与 Direct 的平均表现持平，并高于 Fullconnect 的 99.80% 和 AgentPrune 的 98.87%。其中，Qwen3-14B 上 Fullconnect 为 99.40%、AgentPrune 为 96.60%，而本文方法保持 100.00%，说明在较简单的算术推理任务中，消息级协作至少不会破坏已有推理能力，并能够避免部分结构化协作方法带来的性能波动。

SVAMP 相比 MultiArith，SVAMP 更强调语义理解和问题变体。三个主分析模型上，本文方法的平均准确率为 95.21%，与 AgentPrune 的 95.20% 基本持平，并高于 Direct 的 94.63% 和 Fullconnect 的 94.97%。其中，Qwen3-14B 使用本文方法达到 96.00%，高于 Direct、Fullconnect 和 AgentPrune；Qwen2.5-14B-Instruct 上，本文方法达到 93.30%，与 AgentPrune 持平；MiniMax-M3 上，AgentPrune 达到 98.30%，高于本文方法的 96.33%。这说明本文方法在中小规模模型上的收益更明显，而强模型在部分任务上对协作结构的敏感性更高。

HumanEval 在 HumanEval 数据集上，本文方法并未取得最优平均结果。三个主分析模型中，Fullconnect 的平均准确率为 92.20%，Direct 为 90.03%，本文方法为 89.20%，AgentPrune 为 88.10%。分模型看，MiniMax-M3 和 Qwen2.5-14B-Instruct 上 Fullconnect 表现最好，Qwen3-14B 上 Direct 表现最好；本文方法在 MiniMax-M3 上高于 AgentPrune，在 Qwen3-14B 上与 AgentPrune 持平，在 Qwen2.5-14B-Instruct 上高于 Direct 方法 1.70 个百分点但低于 Fullconnect。该结果说明，对于代码生成任务，仅依赖消息级协作可能不足以替代代码执行、单元测试或错误反馈机制，后续应将消息筛选与可执行验证结合起来。

3.4.2 消耗成本结果

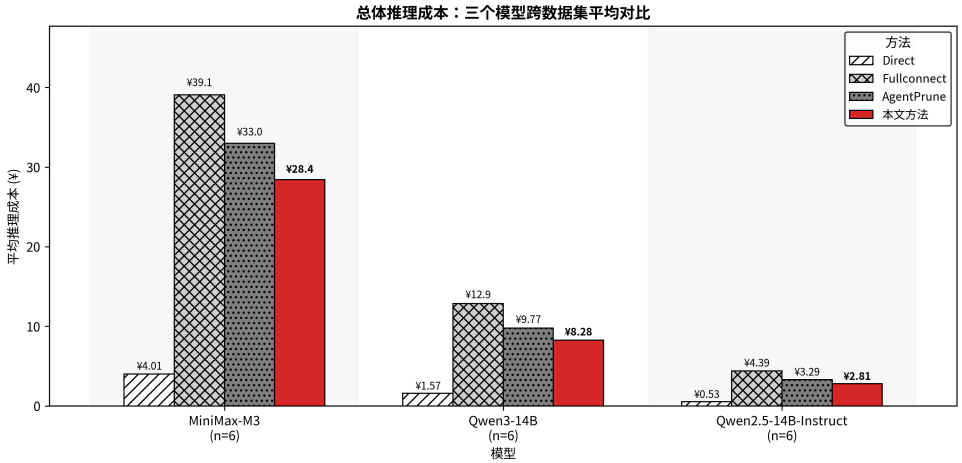
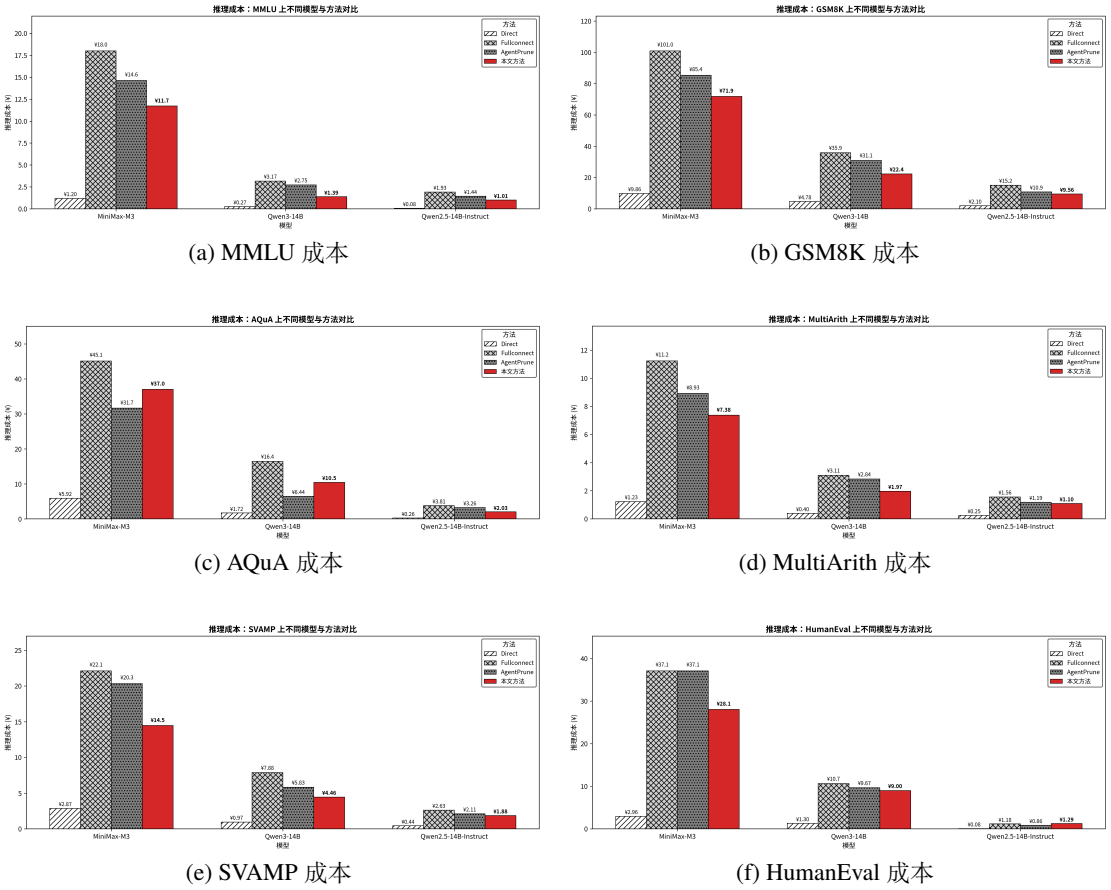


图 3.5　六个数据集在不同模型下的平均推理成本对比（单位：元）

图3.5展示了三个主要模型在不同方法下的跨数据集平均推理成本。Direct 方法由于不引入智能体间通信，具有最低推理成本；Fullconnect 方法虽然提供了最充分的信息交互，但也带来了最高的通信开销。相比之下，本文方法通过消息粒度的信息筛选减少冗余通信，只保留对最终推理有帮助的关键信息，因此在多数数据集上能够有效降低推理成本。

相比 Fullconnect，本文方法在 MMLU 上的平均成本降低约 38.83%，在 GSM8K 上降低约 31.70%，在 SVAMP 上降低约 36.19%，在 MultiArith 上降低约 34.31%，在 HumanEval 上降低约 21.65%。AQuA 上本文方法相比 Fullconnect 仍降低约 24.23%，但相对 AgentPrune 的成本优势不明显，说明在部分多项选择任务中，消息筛选策略仍有进一步优化空间。



(a) MMLU 成本　(b) GSM8K 成本

(c) AQuA 成本　(d) MultiArith 成本

(e) SVAMP 成本　(f) HumanEval 成本

图 3.6　各数据集上不同模型的推理成本比较（单位：元）

图3.6进一步展示了各数据集上的成本差异。Direct 方法消耗最低，但缺少多智能体之间的信息交互；Fullconnect 方法在各数据集上普遍带来更高成本，反映出全连接通信结构的 token 显著增加的问题；AgentPrune 能够通过剪枝降低部分开销，但不同任务上的成本和准确率表现仍存在波动。相比之下，本文方法通常能够在保留任务准确率的同时降低 Fullconnect 带来的额外成本，体现出更好的综合性价比。

3.4.3 结果分析

综合六个数据集的细分结果可以看出，本文方法的优势更适合概括为在多数任务和模型上提升或保持准确率，而不是在所有单项任务上绝对最优。尤其在 MMLU、GSM8K、MultiArith 和 SVAMP 上，本文方法体现出较好的稳定性；而在 AQuA 和 HumanEval 上，不同任务类型对协作信息的需求差异更明显，说明后续需要根据任务类型、模型能力和推理不确定性动态调整消息筛选强度。由于当前实验尚未加入多次重复运行的方差统计，本文对 MiniMax-M3 上 0.06 个百分点这类极小差异只作同等水平处理，不作为方法优劣的主要依据。

综上，本文方法的目标在多智能体协作场景下实现更合理的准确率–成本平衡。实验结果表明，消息级协作能够在减少冗余通信的同时保持多智能体推理收益，为构建更高效的多智能体大模型推理系统提供了一种可行方向。

3.5 本章小结

本章围绕多智能体系统中的语义冗余问题，提出并实现了面向语义冗余的消息压缩框架。首先，本文分析了标准多智能体任务执行流程中的消息传递瓶颈，并将压缩模块嵌入智能体之间的通信链路；其次，分别设计了角色感知压缩、节点感知聚合和分歧感知压缩三个模块，以减少无关推理、重复观点和跨轮历史累积带来的上下文开销；最后，通过多个知识理解、数学推理和代码生成数据集上的实验，验证了该方法能够在多数任务中保持或提升准确率，并降低相对于完全通信拓扑的推理成本。

实验结果表明，消息级压缩能够在不改变底层基座模型的前提下改善多智能体协作的准确率–成本平衡，为后续进一步研究任务自适应压缩强度、压缩模块消融分析以及与拓扑剪枝方法的联合优化提供了基础。

4 面向通信边冗余的图剪枝算法

4.1 引言

上一章从语义内容出发，研究了如何在多智能体系统内部压缩智能体之间传递的自然语言消息。然而，在更复杂的工具调用场景中，仅压缩消息内容仍不足以解决全部通信成本问题。随着大语言模型智能体逐步具备搜索、代码执行、文本检查和外部 API 调用能力[20-21]，以及外部记忆管理、并行函数调用等系统能力[63-64]，多智能体系统的成本不再只来自模型输入输出 Token，还来自工具调用次数、工具返回内容长度以及工具观察结果在智能体之间的重复传播。

工具调用型智能体通常遵循 “推理–行动–观察” 的闭环过程[22]：智能体先根据任务生成中间推理，再决定是否调用搜索、代码执行或文本检查等外部工具，随后把工具返回结果写入上下文并继续推理。在单智能体系统中，工具观察主要影响当前智能体的上下文长度；而在多智能体系统中，某个智能体产生的工具观察还可能沿通信边传播给多个后继智能体，进而触发下游重复分析或二次工具调用。因此，工具调用成本具有明显的图结构放大效应。

在这类场景下，通信边的价值具有更强的异质性。一条边如果连接的是高质量求解智能体和最终验证智能体，可能显著提升任务正确率；但如果该边只是传播冗长的工具观察、重复的中间代码或无关搜索结果，就会增加下游上下文长度，并进一步放大系统开销。因此，面向工具调用任务的通信优化需要同时回答两个问题：第一，哪些智能体之间的通信确实有助于最终任务正确性；第二，哪些通信边会携带高成本工具信息，应当在图结构层面被抑制或剪除。

现有多智能体通信图优化方法通常将边的重要性与任务效用直接关联[50,54]，但较少显式区分普通推理输出和工具调用输出。本文第二个工作点针对这一不足，提出一种面向通信边冗余的图剪枝算法。该方法将智能体通信边建模为可学习概率，在训练过程中结合任务正确性、模型输出 Token、工具调用次数和工具返回 Token 构造边级优化目标；进一步引入 Taylor 一阶重要性评估[87-89]，对低贡献通信边进行动态剪枝，从而在多轮推理中获得更稀疏、成本更可控的通信结构。

4.2 图剪枝算法

4.2.1 工具调用场景建模

考虑一个由 n 个智能体组成的多智能体系统。每个智能体既可以直接基于大语言模型生成推理结果，也可以根据任务需要调用外部工具。系统通信图包含两类边：同一轮内部的空间边和跨轮历史传递的时间边。空间边表示同一轮中智能体输出向后继智能体传递，时间边表示上一轮智能体状态或记忆向下一轮传递。

设第 t 轮中智能体 i 的输出为

$$o_i^{(t)} = (r_i^{(t)}, a_i^{(t)}, q_i^{(t)}), \tag{4.1}$$

其中 $r_i^{(t)}$ 表示推理文本，$a_i^{(t)}$ 表示候选答案，$q_i^{(t)}$ 表示工具调用相关信息。工具调用信息进一步包含工具名称、调用参数、返回观察和调用轮次等元数据。为衡量工具调用带来的通信负担，本文统计三类开销：

$$c_i^{(t)} = \lambda_o \frac{O_i^{(t)}}{N_o} + \lambda_k \frac{K_i^{(t)}}{N_k} + \lambda_z \frac{Z_i^{(t)}}{N_z}, \tag{4.2}$$

其中 $O_i^{(t)}$ 表示智能体 i 在第 t 轮的模型输出 Token 数，$K_i^{(t)}$ 表示工具调用次数，$Z_i^{(t)}$ 表示工具观察结果 Token 数；N_o、N_k 和 N_z 分别为输出 Token、工具调用次数和工具 Token 的归一化系数，$\lambda_o, \lambda_k, \lambda_z$ 为三类开销的权重。该设计将工具调用带来的额外系统消耗显式纳入通信图优化过程。

与普通多智能体推理不同，工具调用场景下的边成本取决于发送方智能体，而不仅取决于接收方。若一条边 $e = (i, j)$ 被选中，则接收方 j 会读取发送方 i 的当前轮输出或上一轮记忆，因此该边会间接携带发送方的模型输出和工具观察成本。基于这一点，本文将边级成本定义为发送方成本在所选通信路径上的归因：

$$\mathcal{C}_e^{(t)} = \mathbf{1}(z_e^{(t)} = 1) c_i^{(\tau_e)}, \tag{4.3}$$

其中 $z_e^{(t)}$ 表示边 e 在第 t 轮是否被采样并实际加入通信图；τ_e 表示成本归因对应的发送方轮次。对于空间边，$\tau_e = t$；对于时间边，$\tau_e = t - 1$。该处理能够区分 “当前轮输出传播” 和 “历史记忆传播” 两种成本来源，使跨轮通信边不会错误归因到接收轮次的工具调用。

4.2.2 可学习通信边概率建模

本文将每条潜在通信边 e 关联一个可学习参数 θ_e。在每轮图构造时，边的保留概率由 Sigmoid 函数给出：

$$p_e = \sigma\left(\frac{\theta_e}{\tau}\right), \tag{4.4}$$

其中 τ 为温度系数。随后按照伯努利分布采样边状态：

$$z_e \sim \text{Bernoulli}(p_e). \tag{4.5}$$

当 $z_e = 1$ 且该边不会破坏空间有向无环执行顺序时，系统将发送方加入接收方的前驱节点集合；当 $z_e = 0$ 时，该边不参与本轮通信。

为了同时支持单图结构和多轮动态图结构，本文分别为全局空间边、全局时间边以及逐轮空间/时间边维护可学习 logit 参数。对于非动态图设置，所有轮次共享同一组空间边和时间边概率；对于动态图设置，每一轮维护独立的空间边概率，跨轮传递则维护对应轮间的时间边概率。这样，系统既可以学习一个全局稀疏通信结构，也可以针对不同推理阶段学习不同通信结构。

在训练过程中，系统记录每条被采样或未采样边的对数概率 $\log \pi_\theta(z_e)$。这些对数概率构成后续策略梯度优化目标的可导部分，使任务正确性和工具成本能够反向影响通信边概率。若某条边长期带来高任务收益且成本可控，其参数 θ_e 会被优化为更高概率；若某条边经常携带高成本工具输出但对最终结果贡献有限，其概率会逐步下降，并在剪枝阶段被移除。

4.2.3 成本感知优化目标

给定一个任务样本 x 及其标准答案 y，多智能体系统输出最终答案 $\hat{y}$。本文使用任务评分函数 $S(\hat{y}, y)$ 衡量正确性，其取值范围为 $[0, 1]$。对于数学题和选择题，该函数通常对应答案是否匹配；对于开放问答任务，则可采用规范化匹配、别名匹配或任务专用评测器。

传统通信图优化通常以任务正确性作为边策略的主要奖励。本文在此基础上引入工具成本惩罚，定义边级效用为

$$R_e^{(t)} = S(\hat{y}, y) - \mathcal{C}_e^{(t)}. \tag{4.6}$$

该式表示：一条通信边只有在能够提高最终任务得分、且不引入过高工具成本时，才应当获得较高效用。对于未被采样的边，工具成本项为 0，其对数概率仍参与策略学习；对于被采样的边，系统根据发送方在对应轮次的输出 Token、工具调用次数和工具 Token 计算成本惩罚。

由于边采样是离散操作，本文采用策略梯度形式优化边概率。对于一次任务执行中记录到的所有边采样事件，边策略损失定义为

$$\mathcal{L}_{\text{pg}} = -\sum_{(e,t)\in\mathcal{E}_{\text{sample}}} \log \pi_\theta(z_e^{(t)}) R_e^{(t)}. \tag{4.7}$$

该损失鼓励系统提高高效用边的采样概率，同时降低低效用边的采样概率。与只在样本级统一扣除工具成本不同，边级成本归因能够区分不同发送方智能体的工具使用情况，使优化过程更精细。例如，若某一代码执行智能体频繁调用工具且产生较长观察结果，但其输出对最终答案帮助有限，则与该智能体相关的出边会获得更低边级效用。

此外，为避免通信图退化为过密结构，本文沿用图结构正则项约束学习到的边参数。设 Θ_s 和 Θ_t 分别为空间边与时间边 logit 矩阵，A_s 和 A_t 分别为初始固定拓扑对应的掩码矩阵，则正则项为

$$\mathcal{L}_{\text{reg}} = \|\Theta_s\|_* + \|\Theta_t\|_* + \text{ReLU}(\|A_s - \Theta_s\|_F - \delta) + \text{ReLU}(\|A_t - \Theta_t\|_F - \delta), \tag{4.8}$$

其中 $\|\cdot\|_*$ 表示核范数，$\|\cdot\|_F$ 表示 Frobenius 范数，δ 为允许偏离初始拓扑的边界。最终优化目标为

$$\mathcal{L} = \mathcal{L}_{\text{pg}} + \mathcal{L}_{\text{reg}}. \tag{4.9}$$

4.2.4 Taylor 一阶重要性剪枝

在边概率训练过程中，仅依赖 logit 大小剪枝可能存在偏差：某些边的当前概率不高，但其梯度较大，说明继续优化可能显著影响任务目标；另一些边虽然概率不低，但梯度接近零，说明其对当前目标的边际影响有限。神经网络剪枝研究通常利用参数幅值、损失扰动或梯度敏感性评估结构重要性[88-90]，后续面向大模型的结构剪枝和稀疏化方法也进一步验证了重要性估计对保持模型能力的重要性[91-93]。受此启发，本文引入 Taylor 一阶近似评估通信边的重要性。

对于边参数 θ_e，若将其移除可近似看作对参数施加扰动 $\Delta\theta_e = -\theta_e$，则损失变化

的一阶近似为

$$\Delta\mathcal{L}_e \approx \frac{\partial\mathcal{L}}{\partial\theta_e}\Delta\theta_e. \tag{4.10}$$

因此，本文定义边重要性为

$$I_e = \left|\theta_e \frac{\partial\mathcal{L}}{\partial\theta_e}\right|. \tag{4.11}$$

该指标同时考虑边当前参数规模和目标函数梯度，能够刻画移除该边对优化目标的一阶影响。训练过程中，在完成一次反向传播后，系统对仍处于活跃状态的边计算 I_e，并按重要性从小到大排序，剪除比例为 ρ 的低重要性边：

$$\mathcal{P} = \text{argmin}_{\mathcal{S}\subseteq\mathcal{E}_{\text{active}},\,|\mathcal{S}|=\rho|\mathcal{E}_{\text{active}}|} \sum_{e\in\mathcal{S}} I_e. \tag{4.12}$$

剪枝后，边掩码被置为 0，后续图构造不再采样这些边。

Taylor 剪枝具有两个优点。首先，它与工具成本感知损失直接耦合，因此剪枝结果会同时反映任务正确性和工具调用成本，而不是只根据通信概率大小做静态排序。其次，它可以自然扩展到多轮动态图设置：系统可分别对每一轮的空间边和时间边计算重要性，从而在不同推理阶段形成不同稀疏结构。与面向模型参数的稀疏化方法不同[94-96]，本文剪枝对象是多智能体通信边，其目标不是减少单个模型参数量，而是降低跨智能体消息传播和工具观察扩散带来的系统级开销。

4.2.5 训练与执行流程

本文方法的整体流程如下：

1. **初始化潜在通信图：**根据智能体数量和初始拓扑生成空间边与时间边掩码，并为每条潜在边初始化可学习 logit。

2. **采样通信结构：**在每轮推理开始时，根据公式4.4和公式4.5采样空间边和时间边，构造当前任务的实际通信图。

3. **执行工具增强推理：**每个智能体读取前驱消息和历史记忆，根据提示词决定是否调用工具，并生成最终输出。系统记录模型输出 Token、工具调用次数和工具观察 Token。

4. **计算边级效用：**根据任务答案评分得到基础正确性奖励，并将发送方工具成本归因到被选中的通信边，形成公式4.6中的边级效用。

5. **更新边概率：**使用公式4.9进行反向传播，更新空间边和时间边 logit。

6. **周期性 Taylor 剪枝：**每隔固定训练轮次，根据公式4.11计算活跃边重要性，剪除低重要性边，更新通信掩码。

7. **评估稀疏图：**在验证集或测试集上运行剪枝后的通信图，统计任务准确率、工具调用次数、工具 Token、模型 Token 成本和图稀疏率。

在实现上，本文方法通过`--tool_aware_loss`开启工具成本感知训练，通过`--taylor_prune`开启 Taylor 一阶剪枝。训练代码在每次图构造时记录空间边与时间边的采样状态、边索引、发送方、接收方、轮次和对数概率；评估代码则按样本、智能体和轮次统计模型 Token 与工具调用元数据。当前实现中，输出 Token、工具调用次数和工具 Token 的惩罚权重分别设为 0.05、0.10 和 0.10，Token 与工具调用次数归一化系数分别设为 10000 和 10；Taylor 剪枝默认每 2 轮训练触发一次，每次剪除 10% 的活跃边。

训练入口已接入 AIME、GAIA、GPQA、HLE、MATH500、MuSiQue 和 BigCodeBench 等工具调用任务。其中 AIME 和 MATH500 默认启用搜索与代码执行工具，BigCodeBench 默认启用代码生成工具，GAIA、GPQA 和 HLE 等开放问答或专家问答任务则可同时启用搜索、代码执行和文本检查工具。

4.3 实验设置

4.3.1 数据集

为验证本文方法在工具调用场景下的有效性，实验选取多个需要外部工具辅助的基准任务进行评测，覆盖数学竞赛推理、开放问答、专家问答、多跳问答和代码生成等任务类型。具体任务、默认工具配置与主要评价指标如表4.1所示。

表 4.1　工具调用实验任务与默认工具配置

数据集	任务类型	默认工具	主要评价指标
AIME[97]	数学竞赛推理	Web 搜索、代码生成	数值答案准确率
GAIA[98]	开放问答	Web 搜索、代码生成、文本检查	问答匹配准确率
GPQA[99]	多项选择专家问答	Web 搜索、代码生成、文本检查	选项准确率
HLE[100]	高难专家问答	Web 搜索、代码生成	问答匹配准确率
MATH500[101]	数学推理	Web 搜索、代码生成	规范化答案准确率
MuSiQue[102]	多跳问答	Web 搜索、代码生成	问答匹配准确率
BigCodeBench[103]	代码生成	代码生成	代码通过率

4.3.2 对比基准

实验设置了四类对比基准，用于比较单智能体、完全通信、多智能体图剪枝以及本文方法在工具调用场景下的准确率–成本表现。

- **DirectAnswer：**单智能体直接回答，可选择是否启用工具。
- **FullConnected：**多智能体完全连接通信，所有智能体输出均可被后续智能体读取。
- **AgentPrune：**基于可学习通信边和图剪枝的多智能体通信优化方法。
- **本文方法：**在 AgentPrune 基础上加入工具成本感知边级损失，并使用 Taylor 一阶重要性进行动态剪枝。

4.3.3 实现细节

本文选取 Qwen3-14B 和 MiniMax-M3[104]作为基座模型。其中，Qwen3-14B 和 MiniMax-M3 均覆盖 AIME、GAIA、GPQA、HLE、MATH500、MuSiQue 和 BigCodeBench 七个工具任务，用于观察不同成本和能力水平的基座模型下面向通信边冗余的图剪枝效果。

对于 AIME 和 MATH500，实验默认启用搜索与代码执行工具；对于 BigCodeBench，实验默认启用代码生成工具；对于 GAIA、GPQA 和 HLE 等开放问答或专家问答任务，实验同时启用搜索、代码执行和文本检查工具。对于需要训练通信边概率的 AgentPrune 和本文方法，训练阶段成本另行记录，不并入测试阶段成本；表中成本均为测试阶段推理成本，由输入 Token、输出 Token 及对应模型 API 价格计算得到，单位为

人民币元。同一数据集内各方法采用相同测试规模，因而成本数值用于比较不同通信图策略在相同任务设置下的相对推理开销。

4.3.4 评估指标

本文主要从任务完成质量、工具使用成本和通信图成本三个维度进行评估。

准确率 (Accuracy)：衡量模型完成任务的有效性。AIME 和 MATH500 采用规范化数值或公式答案匹配，GPQA 采用选项准确率，GAIA、HLE 和 MuSiQue 采用问答匹配准确率，BigCodeBench 采用代码通过率。

工具使用成本 (Tool Cost)：衡量工具调用带来的额外开销，包括工具调用次数和工具返回 Token 数。该指标用于分析外部搜索、代码执行和文本检查结果在多智能体通信图中的传播成本。

推理成本 (Inference Cost)：衡量测试阶段模型输入输出 Token 对应的 API 调用成本，单位为人民币元，同时结合空间边与时间边稀疏率观察通信图压缩效果。由于工具调用会影响后续智能体上下文长度，本文同时统计工具成本和模型 Token 成本，以便分析二者之间的耦合关系。

4.4 实验结果与分析

本章实验图表均以表4.2和表4.3中的测试阶段结果为基础绘制。正文图形用于展示代表性任务上的趋势差异，完整数值仍以结果表为准。为避免图形呈现放大方法差异，所有柱状图纵轴均从 0 开始；对于 HLE、MuSiQue 等准确率数值较低的任务，图中采用较小的纵轴上界以保证读数清晰，具体数值以柱顶标注和结果表为准。与第三章类似，本章结果为固定评测集上的单次完整评测结果，尚未包含多随机种子重复实验和置信区间，因此正文主要分析跨任务趋势和准确率–成本权衡，不将小幅差异单独解释为统计显著优势。

4.4.1 任务准确率结果

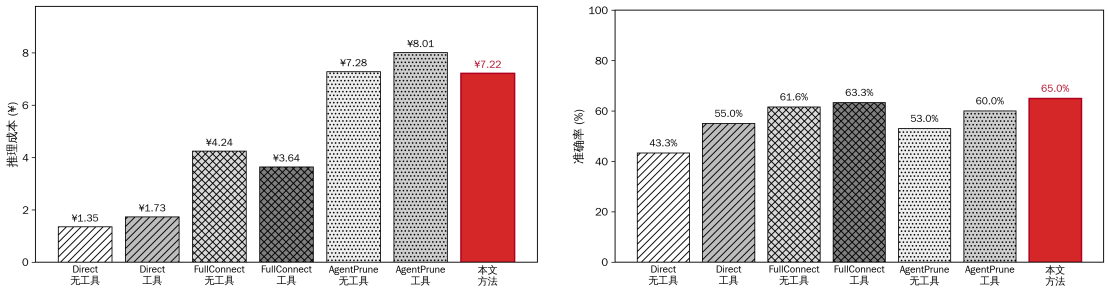
表4.2展示了 Qwen3-14B 在七个工具调用任务上的主要结果。每个单元格以“准确率/推理成本”形式展示。总体来看，本文方法在七个任务上的平均准确率为 40.93%，略高于 FullConnected+Tools 的 40.49% 和 AgentPrune+Tools 的 40.40%；平均推理成本为 5.18，高于 FullConnected+Tools 的 4.61，但与 AgentPrune+Tools 的 4.91 接近。该结果说明，本文图剪枝方法并非单纯追求最低推理成本，而是在可控成本范围内提升通

信边选择质量。

表 4.2　Qwen3-14B 下面向通信边冗余的图剪枝结果（准确率% / 推理成本，单位：元）

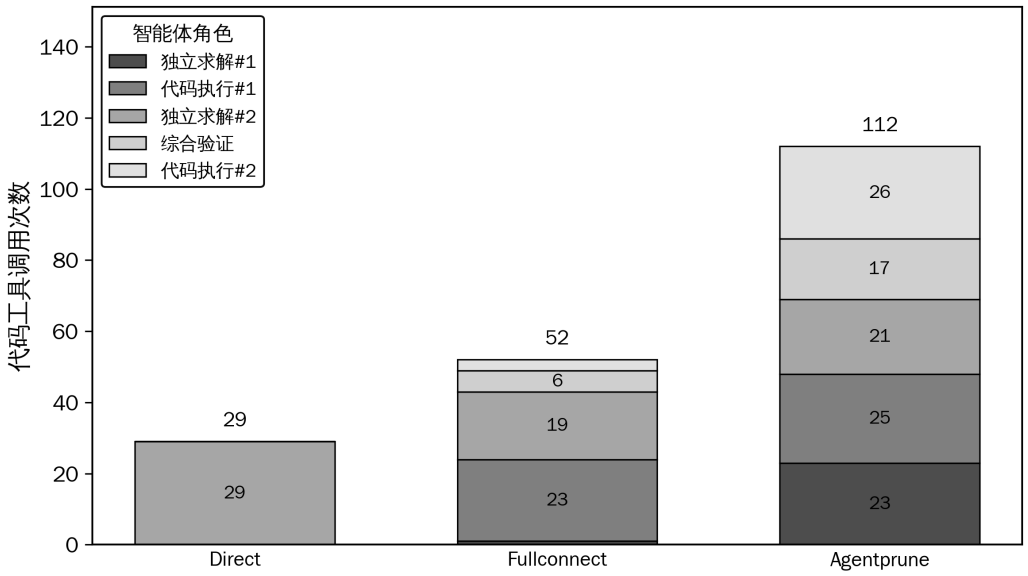
数据集	Direct+Tools	FullConnected+Tools	AgentPrune+Tools	本文方法
AIME	55.00 / 1.73	63.30 / 3.64	60.00 / 8.01	65.00 / 7.22
GAIA	13.90 / 1.21	20.60 / 2.96	16.30 / 3.88	17.50 / 2.81
GPQA	39.00 / 2.73	55.50 / 6.97	56.00 / 3.35	55.00 / 8.53
HLE	4.00 / 3.78	3.00 / 6.15	7.50 / 2.66	7.00 / 2.48
MATH500	78.50 / 2.45	93.50 / 4.59	94.00 / 6.00	92.50 / 5.72
MuSiQue	8.00 / 0.93	7.00 / 2.15	7.50 / 2.66	7.50 / 2.54
BigCodeBench	43.00 / 2.11	40.50 / 5.81	41.50 / 7.83	42.00 / 7.00

从单项任务看，本文方法在 AIME 上取得 65.00% 准确率，高于 Direct+Tools 的 55.00%、FullConnected+Tools 的 63.30% 和 AgentPrune+Tools 的 60.00%。这说明在数学竞赛题中，工具调用带来的代码执行和检索结果需要被选择性传播；完全连接通信虽然提高了信息覆盖度，但仍会传递部分冗余工具观察，而本文方法能够更稳定地保留高价值边。图4.1进一步展示了 AIME 任务上成本、准确率、工具调用次数和工具 Token 的变化。

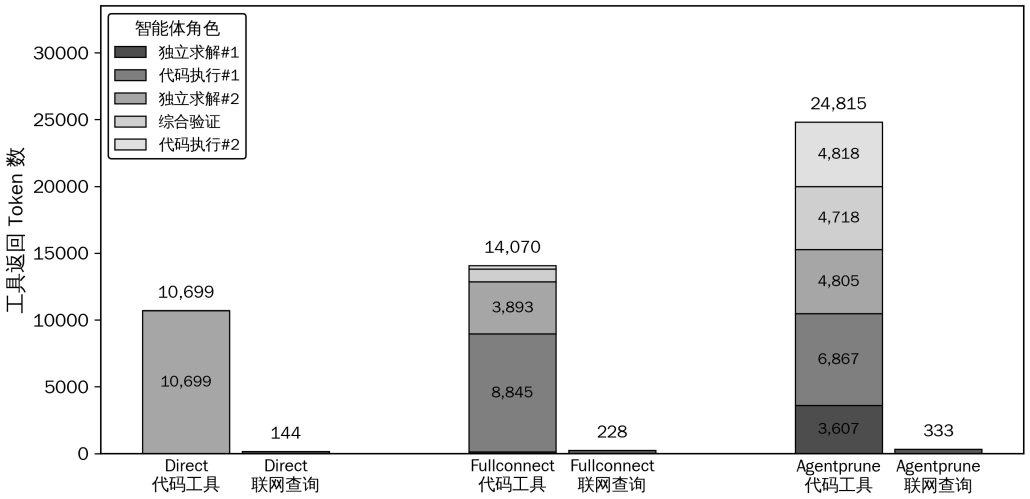


(a) 推理成本　　(b) 准确率

图 4.1　Qwen3-14B 在 AIME 任务上的推理成本（单位：元）与准确率结果



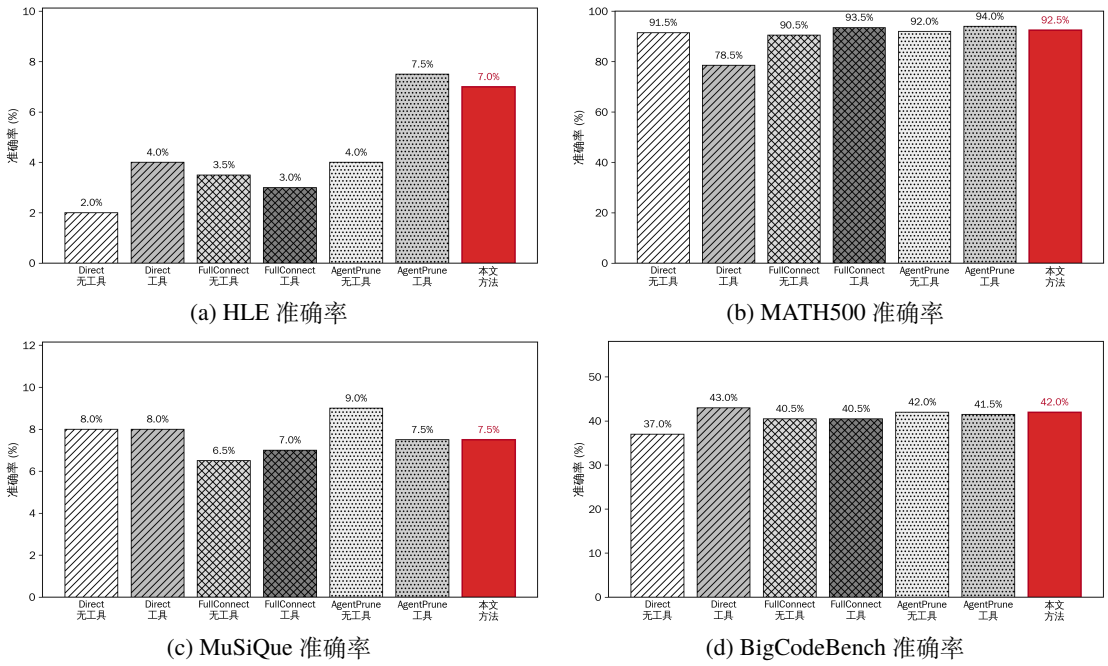
(a) 工具调用次数



(b) 工具 Token 数量

图 4.2　Qwen3-14B 在 AIME 任务上的工具调用次数与工具 Token 结果

在 HLE、MuSiQue 和 BigCodeBench 等任务上，本文方法的准确率与最优工具基线接近，同时相对 AgentPrune+Tools 保持更低推理成本。例如，HLE 上本文方法准确率为 7.00%，略低于 AgentPrune+Tools 的 7.50%，但推理成本降低约 7.00%；BigCodeBench 上本文方法达到 42.00%，高于 FullConnected+Tools 和 AgentPrune+Tools，并使成本相对 AgentPrune+Tools 降低约 10.58%。在 MATH500 上，本文方法为 92.50%，低于 AgentPrune+Tools 的 94.00%，但成本降低约 4.72%。这些结果说明，工具成本惩罚能够在多个任务上抑制低价值工具信息传播，但在部分强推理任务中仍可能牺牲少量准确率。

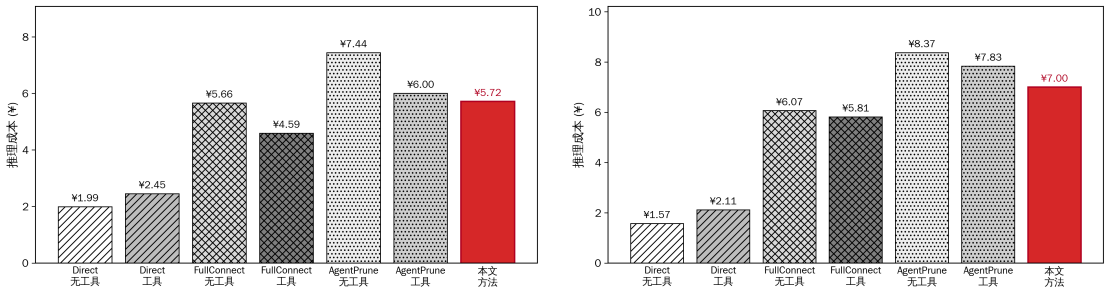


(a) HLE 准确率　(b) MATH500 准确率

(c) MuSiQue 准确率　(d) BigCodeBench 准确率

图 4.3　Qwen3-14B 在扩展工具任务上的准确率结果

为进一步展示 Qwen3-14B 在新增任务上的成本表现，图4.4给出了 MATH500 和 BigCodeBench 的推理成本对比。MATH500 上，本文方法成本为 5.72，低于 AgentPrune+Tools 的 6.00，但准确率由 94.00% 小幅下降至 92.50%；BigCodeBench 上，本文方法成本为 7.00，低于 AgentPrune+Tools 的 7.83，同时准确率由 41.50% 提升至 42.00%，并高于 FullConnected+Tools 的 40.50%。因此，Qwen3-14B 结果同样能够支撑本文方法在代码生成任务中改善准确率–成本平衡的结论，而 MATH500 结果则更适合作为成本控制与准确率轻微波动之间的权衡分析。



(a) MATH500 成本　(b) BigCodeBench 成本

图 4.4　Qwen3-14B 在 MATH500 和 BigCodeBench 任务上的推理成本结果（单位：元）

MiniMax-M3 补充结果。

表4.3展示了 MiniMax-M3 上的补充结果。可以看到，本文方法在 AIME、GAIA 和 GPQA 三个任务上均取得当前工具调用对比组中的最高准确率；在 MATH500 和

BigCodeBench 两个新增任务上，本文方法虽然并非所有指标均为最优，但相对 AgentPrune+Tools 保持了更低推理成本，并在 BigCodeBench 上取得更高准确率；在 HLE 和 MuSiQue 两个更具开放性和多跳性的任务上，本文方法未取得最高准确率，但同样能够降低 AgentPrune+Tools 的推理成本，体现出成本控制与证据充分性之间的权衡。整体来看，本文方法在七个 MiniMax-M3 工具任务上的平均准确率为 57.05%，高于 AgentPrune+Tools 的 56.07%；平均推理成本为 33.90，低于 AgentPrune+Tools 的 37.62。

AIME 上，本文方法达到 98.33%，高于 Direct+Tools 的 73.30%、FullConnected+Tools 的 88.30% 和 AgentPrune+Tools 的 95.00%；GAIA 上，本文方法达到 32.00%，同时高于 Direct+Tools、FullConnected+Tools 和 AgentPrune+Tools，并且推理成本低于 FullConnected+Tools 和 AgentPrune+Tools；GPQA 上，本文方法达到 90.00%，比 AgentPrune+Tools 高 3.00 个百分点，且成本相对 AgentPrune+Tools 降低约 15.64%。在 MATH500 上，本文方法达到 95.00%，与 FullConnected+Tools 持平，成本相对 AgentPrune+Tools 降低约 7.56%；在 BigCodeBench 上，本文方法达到 46.50%，比 AgentPrune+Tools 高 4.50 个百分点，成本降低约 4.61%。这些结果进一步说明，在高成本闭源模型上，图剪枝并不总是带来单项最高准确率，但能够在多个任务上改善准确率–成本平衡。

表 4.3　MiniMax-M3 下面向通信边冗余的图剪枝结果（准确率% / 推理成本，单位：元）

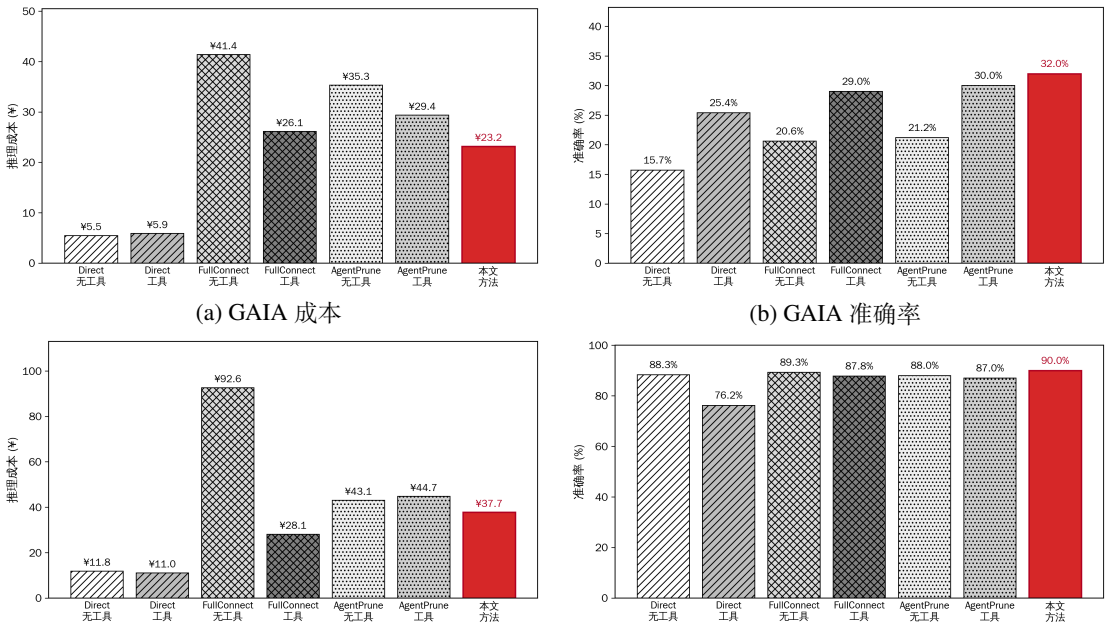
数据集	Direct+Tools	FullConnected+Tools	AgentPrune+Tools	本文方法
AIME	73.30 / 5.87	88.30 / 16.18	95.00 / 22.99	98.33 / 27.19
GAIA	25.40 / 5.87	29.00 / 26.11	30.00 / 29.36	32.00 / 23.16
GPQA	76.20 / 11.03	87.80 / 28.06	87.00 / 44.75	90.00 / 37.75
HLE	17.50 / 21.00	22.50 / 86.43	26.00 / 111.93	22.00 / 97.46
MATH500	85.00 / 3.59	95.00 / 10.35	95.50 / 11.89	95.00 / 10.99
MuSiQue	16.50 / 6.26	14.50 / 25.72	17.00 / 26.54	15.50 / 25.57
BigCodeBench	17.50 / 21.00	47.00 / 12.68	42.00 / 15.88	46.50 / 15.15

4.4.2 消耗成本结果

从推理成本看，工具调用场景中的成本变化不仅来自智能体之间的消息长度，也受到工具调用次数和工具返回 Token 数影响。Qwen3-14B 结果显示，本文方法的平均推理成本为 5.18，略高于 FullConnected+Tools 的 4.61，但与 AgentPrune+Tools 的 4.91

较为接近；MiniMax-M3 结果显示，本文方法的七任务平均推理成本为 33.90，低于 AgentPrune+Tools 的 37.62，说明工具成本感知目标在高成本闭源模型上更容易体现成本控制作用。

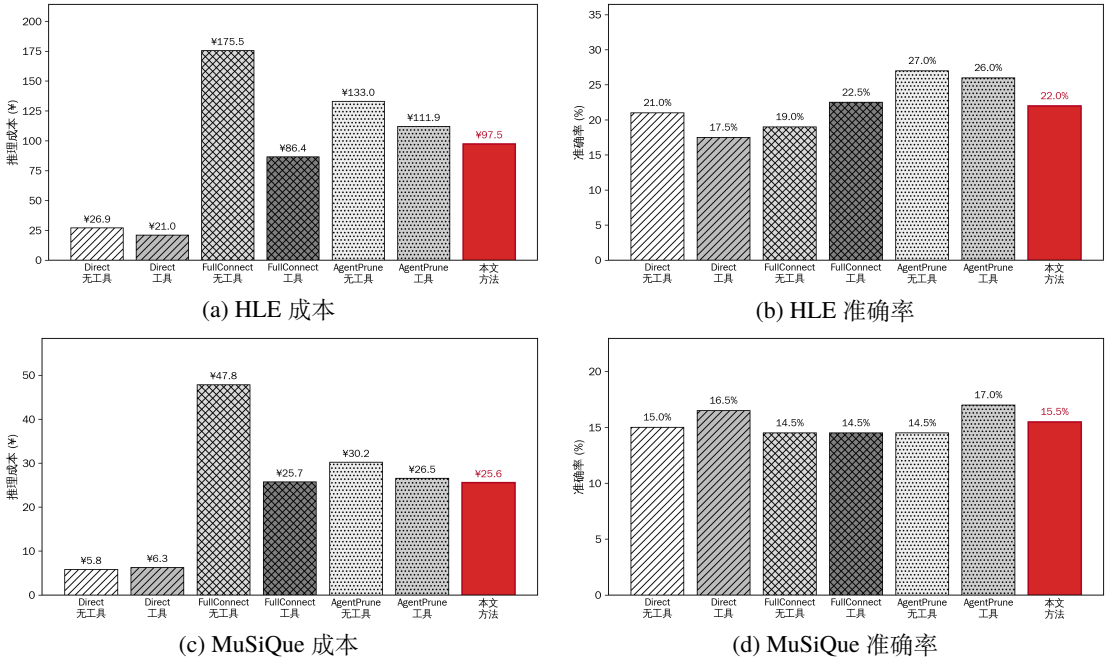
进一步看，本文方法在 HLE、MATH500、MuSiQue、BigCodeBench 等任务上通常能够相对 AgentPrune+Tools 降低推理成本。例如，HLE 上 Qwen3-14B 的本文方法成本为 2.48，低于 AgentPrune+Tools 的 2.66；BigCodeBench 上 Qwen3-14B 的本文方法成本为 7.00，低于 AgentPrune+Tools 的 7.83。MiniMax-M3 上，GAIA、GPQA、MATH500 和 BigCodeBench 任务中本文方法的推理成本均低于 AgentPrune+Tools，并在 GAIA、GPQA 和 BigCodeBench 上保持或提升准确率，说明在工具观察较长、通信边价值差异明显的任务中，成本感知剪枝能够减少低价值工具信息传播。



(a) GAIA 成本　(b) GAIA 准确率

(c) GPQA 成本　(d) GPQA 准确率

图 4.5　MiniMax-M3 在 GAIA 和 GPQA 任务上的推理成本（单位：元）与准确率结果

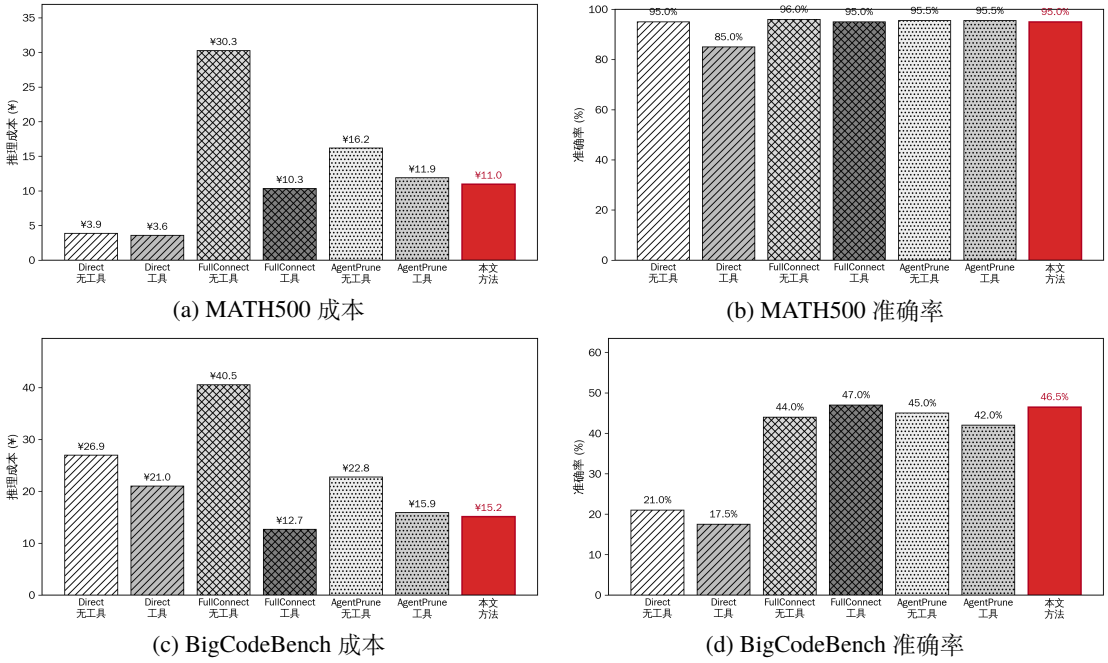


(a) HLE 成本　(b) HLE 准确率

(c) MuSiQue 成本　(d) MuSiQue 准确率

图 4.6　MiniMax-M3 在 HLE 和 MuSiQue 任务上的推理成本（单位：元）与准确率结果

为进一步展示新增数学推理和代码生成任务上的结果，图4.7给出了 MiniMax-M3 在 MATH500 和 BigCodeBench 上的成本与准确率对比。MATH500 结果表明，在准确率接近饱和的数学推理任务中，本文方法更主要体现为相对 AgentPrune+Tools 的成本降低；BigCodeBench 结果则表明，在代码生成任务中，本文方法能够在降低 AgentPrune+Tools 成本的同时提升通过率。



(a) MATH500 成本　(b) MATH500 准确率

(c) BigCodeBench 成本　(d) BigCodeBench 准确率

图 4.7　MiniMax-M3 在 MATH500 和 BigCodeBench 任务上的推理成本（单位：元）与准确率结果

4.4.3 结果分析

综合 Qwen3-14B 和 MiniMax-M3 结果可以看出，本文方法更适用于两类场景。第一类是工具观察冗余较多、通信边价值差异明显的任务，如 AIME、GAIA、MiniMax-M3 下的 GPQA 以及 BigCodeBench。在这些任务中，工具成本感知边级目标能够促使系统保留与最终验证、证据整合和代码检查更相关的通信边，从而提升准确率或改善准确率–成本平衡。第二类是工具调用成本较高但任务收益有限的任务，如 HLE、MATH500 和 MuSiQue。在这些任务中，本文方法通常能够相对 AgentPrune 降低推理成本，但准确率可能与最优基线存在小幅差距。

同时，实验也表明工具调用并非总是带来稳定收益。以 Qwen3-14B 的 GPQA 为例，Direct 无工具设置达到 57.50%，高于 Direct+Tools 的 39.00%；这说明外部工具返回的信息若不能被有效筛选，可能反而干扰模型原有推理。本文方法虽然通过边级成本惩罚减少了部分冗余传播，但对于强知识型、多选项干扰任务，仍需要进一步引入工具观察质量评估或任务难度自适应权重。

总体而言，本文方法的优势不在于所有任务上同时实现最高准确率和最低成本，而在于把工具调用成本纳入通信图学习目标，使剪枝结果更接近真实部署中的成本–质量权衡。相比仅根据边概率或静态拓扑进行剪枝，工具成本感知策略能够更细粒度地区分不同发送方、不同轮次和不同工具观察带来的边际价值。

4.5 本章小结

本章提出了面向通信边冗余的图剪枝算法。该方法首先将多智能体系统中的空间边和时间边建模为可学习概率，并通过采样构造任务执行时的实际通信图；随后结合任务正确性、模型输出 Token、工具调用次数和工具观察 Token 构造边级效用，使通信边学习过程能够感知外部工具带来的额外成本；最后引入 Taylor 一阶重要性评估，在反向传播后剪除低重要性边，实现多轮推理过程中的动态图压缩。

实验结果表明，在 MiniMax-M3 上，本文方法在 AIME、GAIA 和 GPQA 三个代表性工具任务中取得最高准确率，在 MATH500 上保持与 FullConnected+Tools 相同的准确率并降低 AgentPrune+Tools 成本，在 BigCodeBench 上相对 AgentPrune+Tools 同时提升准确率并降低成本；在 Qwen3-14B 上，本文方法在七个工具任务上的平均准确率略高于 FullConnected+Tools 和 AgentPrune+Tools，并在多数任务中相对 AgentPrune 降低推理成本。对于 GPQA、MATH500、HLE 和 MuSiQue 等任务，结果显示工具成本控制与证据充分性之间仍需进一步平衡。该工作从图结构层面补充了上一章的语义消息压缩方法，共同构成面向多智能体系统高效通信的两条优化路径。

结论

本文采用……（结论作为学位论文正文的最后部分单独排写，但不加章号。结论是对整个论文主要结果的总结。在结论中应明确指出本研究的创新点，对其应用前景和社会、经济价值等加以预测和评价，并指出今后进一步在本研究方向进行研究工作的展望与设想。结论部分的撰写应简明扼要，突出创新性。）

参考文献

[1] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.[Z].

[2] ACHIAM J, ADLER S, AGARWAL S, et al. Gpt-4 technical report[J]. arXiv preprint arXiv:2303.08774, 2023.[EB/OL]. https://arxiv.org/abs/2303.08774.

[3] TOUVRON H, LAVRIL T, IZACARD G, et al. Llama: Open and efficient foundation language models[J]. arXiv preprint arXiv:2302.13971, 2023.[EB/OL]. https://arxiv.org/abs/2302.13971.

[4] TOUVRON H, MARTIN L, STONE K, et al. Llama 2: Open foundation and fine-tuned chat models[J]. arXiv preprint arXiv:2307.09288, 2023.[EB/OL]. https://arxiv.org/abs/2307.09288.

[5] GRATTAFIORI A, DUBEY A, JAUHRI A, et al. The llama 3 herd of models[J]. arXiv preprint arXiv:2407.21783, 2024.[EB/OL]. https://arxiv.org/abs/2407.21783.

[6] BAI J, BAI S, CHU Y, et al. Qwen technical report[J]. arXiv preprint arXiv:2309.16609, 2023.[EB/OL]. https://arxiv.org/abs/2309.16609.

[7] HUI B, YANG J, CUI Z, et al. Qwen2.5-coder technical report[J]. arXiv preprint arXiv:2409.12186, 2024.[EB/OL]. https://arxiv.org/abs/2409.12186.

[8] YANG A, LI A, YANG B, et al. Qwen3 technical report[J]. arXiv preprint arXiv:2505.09388, 2025.[EB/OL]. https://arxiv.org/abs/2505.09388.

[9] LAZARIDOU A, KUNCORO A, GRIBOVSKAYA E, et al. Mind the gap: Assessing temporal generalization in neural language models[J]. Advances in Neural Information Processing Systems, 2021, 34: 29348-29363.[Z].

[10] LIU N F, LIN K, HEWITT J, et al. Lost in the middle: How language models use long contexts[J]. Transactions of the association for computational linguistics, 2024, 12: 157-173.[Z].

[11] BAI Y, LV X, ZHANG J, et al. Longbench: A bilingual, multitask benchmark for long context understanding[C]//Proceedings of the 62nd annual meeting of the association for computational linguistics (volume 1: Long papers). 2024: 3119-3137.[Z].

[12] QIAN C, LIU W, LIU H, et al. Chatdev: Communicative agents for software development[C]//Proceedings of the 62nd annual meeting of the association for computational linguistics (volume 1: Long papers). 2024: 15174-15186.[Z].

[13] BOIKO D A, MACKNIGHT R, KLINE B, et al. Autonomous chemical research with large language models[J]. Nature, 2023, 624(7992): 570-578.[Z].

[14] DRIESS D, XIA F, SAJJADI M S M, et al. Palm-e: An embodied multimodal language model[J]. arXiv preprint arXiv:2303.03378, 2023.[EB/OL]. https://arxiv.org/abs/2303.03378.

[15] XI Z, CHEN W, GUO X, et al. The rise and potential of large language model based agents: A survey[J]. Science China Information Sciences, 2025, 68(2): 121101.[Z].

[16] WEI J, WANG X, SCHUURMANS D, et al. Chain-of-thought prompting elicits reasoning in large language models[J]. Advances in neural information processing systems, 2022, 35: 24824-24837.[Z].

[17] WANG X, WEI J, SCHUURMANS D, et al. Self-consistency improves chain of thought reasoning in language models[J]. arXiv preprint arXiv:2203.11171, 2022.[EB/OL]. https://arxiv.org/abs/2203.11171.

[18] YAO S, YU D, ZHAO J, et al. Tree of thoughts: Deliberate problem solving with large language models[J]. Advances in neural information processing systems, 2023, 36: 11809-11822.[Z].

[19] BESTA M, BLACH N, KUBICEK A, et al. Graph of thoughts: Solving elaborate problems with large language models[C]//Proceedings of the AAAI conference on artificial intelligence. 2024, 38(16): 17682-17690.[Z].

[20] SCHICK T, DWIVEDI-YU J, DESSÌ R, et al. Toolformer: Language models can teach themselves to use tools[J]. Advances in neural information processing systems, 2023, 36: 68539-68551.[Z].

[21] QIN Y, LIANG S, YE Y, et al. Toolllm: Facilitating large language models to master 16000+ real-world apis[C]//International Conference on Learning Representations. 2024, 2024: 9695-9717.[Z].

[22] YAO S, ZHAO J, YU D, et al. React: Synergizing reasoning and acting in language models[J]. arXiv preprint arXiv:2210.03629, 2022.[EB/OL]. https://arxiv.org/abs/2210.03629.

[23] SHINN N, CASSANO F, GOPINATH A, et al. Reflexion: Language agents with verbal reinforcement learning[J]. Advances in neural information processing systems, 2023, 36: 8634-8652.[Z].

[24] PARK J S, O'BRIEN J, CAI C J, et al. Generative agents: Interactive simulacra of human behavior[C]//Proceedings of the 36th annual acm symposium on user interface software and technology. 2023: 1-22.[Z].

[25] WANG G, XIE Y, JIANG Y, et al. Voyager: An open-ended embodied agent with large language models[J]. arXiv preprint arXiv:2305.16291, 2023.[EB/OL]. https://arxiv.org/abs/2305.16291.

[26] DU Y, LI S, TORRALBA A, et al. Improving factuality and reasoning in language models through multiagent debate[J]. arXiv preprint arXiv:2305.14325, 2023.[EB/OL]. https://arxiv.org/abs/2305.14325.

[27] GUO T, CHEN X, WANG Y, et al. Large language model based multi-agents: A survey of progress and challenges[J]. arXiv preprint arXiv:2402.01680, 2024.[EB/OL]. https://arxiv.org/abs/2402.01680.

[28] HONG S, ZHUGE M, CHEN J, et al. MetaGPT: Meta programming for a multi-agent collaborative framework[C]//International Conference on Learning Representations. 2024, 2024: 23247-23275.[Z].

[29] WU Q, BANSAL G, ZHANG J, et al. Autogen: Enabling next-gen llm applications via multi-agent conversation[J]. arXiv preprint arXiv:2308.08155, 2023.[EB/OL]. https://arxiv.org/abs/2308.08155.

[30] LIANG T, HE Z, JIAO W, et al. Encouraging divergent thinking in large language models through multi-agent debate[C]//Proceedings of the 2024 conference on empirical methods in natural language processing. 2024: 17889-17904.[Z].

[31] LI G, HAMMOUD H, ITANI H, et al. Camel: Communicative agents for" mind" exploration of large language model society[J]. Advances in neural information processing systems, 2023, 36: 51991-52008.[Z].

[32] CHEN W, SU Y, ZUO J, et al. AgentVerse: Facilitating multi-agent collaboration and exploring emergent behaviors[J]. arXiv preprint arXiv:2308.10848, 2023.[EB/OL]. https://arxiv.org/abs/2308.10848.

[33] CHAN C M, CHEN W, SU Y, et al. ChatEval: Towards better LLM-based evaluators through multi-agent debate[J]. arXiv preprint arXiv:2308.07201, 2023.[EB/OL]. https://arxiv.org/abs/2308.07201.

[34] LI Y, DONG B, GUERIN F, et al. Compressing context to enhance inference efficiency of large language models[C]//Proceedings of the 2023 conference on empirical methods in natural language processing. 2023: 6342-6353.[Z].

[35] JIANG H, WU Q, LIN C Y, et al. Llmlingua: Compressing prompts for accelerated inference of large language models[C]//Proceedings of the 2023 conference on empirical methods in natural language processing. 2023: 13358-13376.[Z].

[36] PAN Z, WU Q, JIANG H, et al. Llmlingua-2: Data distillation for efficient and faithful task-agnostic prompt compression[C]//Findings of the Association for Computational Linguistics: ACL 2024. 2024: 963-981.[Z].

[37] JIANG H, WU Q, LUO X, et al. LongLLMLingua: Accelerating and enhancing LLMs in long context scenarios via prompt compression[C]//Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics. 2024.[Z].

[38] MU J, LI X L, GOODMAN N. Learning to compress prompts with gist tokens[J]. arXiv preprint arXiv:2304.08467, 2023.[EB/OL]. https://arxiv.org/abs/2304.08467.

[39] SHANDILYA S, XIA M, GHOSH S, et al. Taco-rl: Task aware prompt compression optimization with reinforcement learning[C]//Findings of the Association for Computational Linguistics: ACL 2025. 2025: 1582-1597.[Z].

[40] XU F, SHI W, CHOI E. RECOMP: Improving retrieval-augmented LMs with compression and selective augmentation[J]. arXiv preprint arXiv:2310.04408, 2023.[EB/OL]. https://arxiv.org/abs/2310.04408.

[41] LEWIS P, PEREZ E, PIKTUS A, et al. Retrieval-augmented generation for knowledge-intensive NLP tasks[C]//Advances in Neural Information Processing Systems. 2020, 33: 9459-9474.[Z].

[42] IZACARD G, GRAVE E. Leveraging passage retrieval with generative models for open domain question answering[C]//Proceedings of the 16th Conference of the European Chapter of the Association for Computational Linguistics. 2021: 874-880.[Z].

[43] SUKHBAATAR S, SZLAM A, FERGUS R. Learning multiagent communication with backpropagation[C]//Advances in Neural Information Processing Systems. 2016, 29: 2244-2252.[Z].

[44] FOERSTER J, ASSAEL I A, DE FREITAS N, et al. Learning to communicate with deep multi-agent reinforcement learning[C]//Advances in Neural Information Processing Systems. 2016, 29.[Z].

[45] SINGH A, JAIN T, SUKHBAATAR S. Learning when to communicate at scale in multiagent cooperative and competitive tasks[C]//International Conference on Learning Representations. 2019.[Z].

[46] LIU Z, ZHANG Y, LI P, et al. Dynamic llm-agent network: An llm-agent collaboration framework with agent team optimization[J]. arXiv preprint arXiv:2310.02170, 2023.[EB/OL]. https://arxiv.org/abs/2310.02170.

[47] HU S, SHEN L, ZHANG Y, et al. Learning multi-agent communication from graph modeling perspective[J]. arXiv preprint arXiv:2405.08550, 2024.[EB/OL]. https://arxiv.org/abs/2405.08550.

[48] ZHANG G, YUE Y, SUN X, et al. G-designer: Architecting multi-agent communication topologies via graph neural networks[J]. arXiv preprint arXiv:2410.11782, 2024.[EB/OL]. https://arxiv.org/abs/2410.11782.

[49] ZENG X, SU H, WANG Z, et al. Graph diffusion for robust multi-agent coordination[C]//Forty-second International Conference on Machine Learning. 2025.[Z].

[50] ZHANG G, YUE Y, LI Z, et al. Cut the crap: An economical communication pipeline for llm-based multi-agent systems[C]//International Conference on Learning Representations. 2025, 2025: 75389-75428.[Z].

[51] WANG Z, WANG Y, LIU X, et al. Agentdropout: Dynamic agent elimination for token-efficient and high-performance llm-based multi-agent collaboration[C]//Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2025: 24013-24035.[Z].

[52] ZHANG R, ZHAO X, WANG R, et al. Safesieve: From heuristics to experience in progressive pruning for llm-based multi-agent communication[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2026, 40(35): 29892-29900.[Z].

[53] LI B, ZHAO Z, LEE D H, et al. Adaptive graph pruning for multi-agent communication[J]. arXiv preprint arXiv:2506.02951, 2025.[EB/OL]. https://arxiv.org/abs/2506.02951.

[54] ZHUGE M, WANG W, KIRSCH L, et al. Gptswarm: Language agents as optimizable graphs[C]//Forty-first International Conference on Machine Learning. 2024.[Z].

[55] ZHANG J, XIANG J, YU Z, et al. Automating agentic workflow generation, 2024a[J]. URL https://arxiv.org/abs/2410.10762.[Z].

[56] HU S, LU C, CLUNE J. Automated design of agentic systems[J]. arXiv preprint arXiv:2408.08435, 2024.[EB/OL]. https://arxiv.org/abs/2408.08435.

[57] KARPAS E, ABEND O, BELINKOV Y, et al. MRKL systems: A modular, neuro-symbolic architecture that combines large language models, external knowledge sources and discrete reasoning[J]. arXiv preprint arXiv:2205.00445, 2022.[EB/OL]. https://arxiv.org/abs/2205.00445.

[58] SHEN Y, SONG K, TAN X, et al. HuggingGPT: Solving AI tasks with ChatGPT and its friends in Hugging Face[J]. arXiv preprint arXiv:2303.17580, 2023.[EB/OL]. https://arxiv.org/abs/2303.17580.

[59] PATIL S G, ZHANG T, WANG X, et al. Gorilla: Large language model connected with massive APIs[J]. arXiv preprint arXiv:2305.15334, 2023.[EB/OL]. https://arxiv.org/abs/2305.15334.

[60] LI M, ZHAO Y, YU B, et al. API-Bank: A comprehensive benchmark for tool-augmented LLMs[C]//Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing. 2023.[Z].

[61] NAKANO R, HILTON J, BALAJI S, et al. WebGPT: Browser-assisted question-answering with human feedback[J]. arXiv preprint arXiv:2112.09332, 2021.[EB/OL]. https://arxiv.org/abs/2112.09332.

[62] XU B, PENG Z, LEI B, et al. ReWOO: Decoupling reasoning from observations for efficient augmented language models[J]. arXiv preprint arXiv:2305.18323, 2023.[EB/OL]. https://arxiv.org/abs/2305.18323.

[63] PACKER C, FANG V, PATIL S G, et al. MemGPT: Towards LLMs as operating systems[J]. arXiv preprint arXiv:2310.08560, 2023.[EB/OL]. https://arxiv.org/abs/2310.08560.

[64] KIM S, MOON S, TUMANOV A. An LLM compiler for parallel function calling[J]. arXiv preprint arXiv:2312.04511, 2023.[EB/OL]. https://arxiv.org/abs/2312.04511.

[65] CHEVALIER A, WETTIG A, AJITH A, et al. Adapting language models to compress contexts[C]//Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing. 2023.[Z].

[66] LI Z, LIU Y, SU Y, et al. Prompt compression for large language models: A survey[C]//Proceedings of the 2025 Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers). 2025: 7182-7195.[Z].

[67] CHUANG Y N, XING T, CHANG C Y, et al. Learning to compress prompt in natural language formats[C]//Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers). 2024: 7756-7767.[Z].

[68] ZHANG Z, SHENG Y, ZHOU T, et al. H2O: Heavy-hitter oracle for efficient generative inference of large language models[J]. arXiv preprint arXiv:2306.14048, 2023.[EB/OL]. https://arxiv.org/abs/2306.14048.

[69] XIAO G, TIAN Y, CHEN B, et al. Efficient streaming language models with attention sinks[J]. arXiv preprint arXiv:2309.17453, 2023.[EB/OL]. https://arxiv.org/abs/2309.17453.

[70] WEI T, LI T W, LIU Z, et al. Agentic reasoning for large language models[J]. arXiv preprint arXiv:2601.12538, 2026.[EB/OL]. https://arxiv.org/abs/2601.12538.

[71] DAS A, GERVET T, ROMOFF J, et al. TarMAC: Targeted multi-agent communication[C]//Proceedings of the 36th International Conference on Machine Learning. 2019: 1538-1546.[Z].

[72] DING S, DU W, DING L, et al. Learning efficient and robust multi-agent communication via graph information bottleneck[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2024, 38(16): 17346-17353.[Z].

[73] JIANG J, LU Z. Learning attentional communication for multi-agent cooperation[C]//Advances in Neural Information Processing Systems. 2018, 31: 7265-7275.[Z].

[74] WANG S, ZHANG G, YU M, et al. G-safeguard: A topology-guided security lens and treatment on llm-based multi-agent systems[C]//Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2025: 7261-7276.[Z].

[75] WANG S, LU R, YANG Z, et al. Agentconductor: Topology evolution for multi-agent competition-level code generation[J]. arXiv preprint arXiv:2602.17100, 2026.[EB/OL]. https://arxiv.org/abs/2602.17100.

[76] ZHOU H, WAN X, SUN R, et al. Multi-agent design: Optimizing agents with better prompts and topologies[J]. arXiv preprint arXiv:2502.02533, 2025.[EB/OL]. https://arxiv.org/abs/2502.02533.

[77] ZHANG G, NIU L, FANG J, et al. Multi-agent architecture search via agentic supernet[J]. arXiv preprint arXiv:2502.04180, 2025.[EB/OL]. https://arxiv.org/abs/2502.04180.

[78] LEONG H Y, WU Y. DynaSwarm: Dynamically graph structure selection for llm-based multi-agent system[J]. arXiv preprint arXiv:2507.23261, 2025.[EB/OL]. https://arxiv.org/abs/2507.23261.

[79] YUAN S, SONG K, CHEN J, et al. EvoAgent: Towards automatic multi-agent generation via evolutionary algorithms[J]. arXiv preprint arXiv:2406.14228, 2024.[EB/OL]. https://arxiv.org/abs/2406.14228.

[80] KHATTAB O, SINGHVI A, MAHESHWARI P, et al. DSPy: Compiling declarative language model calls into self-improving pipelines[J]. arXiv preprint arXiv:2310.03714, 2023.[EB/OL]. https://arxiv.org/abs/2310.03714.

[81] Hendrycks D, Burns C, Basart S, et al. Measuring Massive Multitask Language Understanding[J]. ArXiv preprint arXiv:2009.03300, 2020.

[82] Cobbe K, Kosaraju V, Bavarian M, et al. Training Verifiers to Solve Math Word Problems[J]. ArXiv preprint arXiv:2110.14168, 2021.

[83] Ling W, Yogatama D, Dyer C, et al. Program Induction by Rationale Generation: Learning to Solve and Explain Algebraic Word Problems[C]. Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2017: 158-167.

[84] Roy S, Roth D. Solving General Arithmetic Word Problems[C]. Proceedings of the 2015 Conference on Empirical Methods in Natural Language Processing. 2015: 1743-1752.

[85] Patel A, Bhattamishra S, Goyal N. Are NLP Models Really Able to Solve Simple Math Word Problems?[C]. Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. 2021: 2080-2094.

[86] Chen M, Tworek J, Jun H, et al. Evaluating Large Language Models Trained on Code[J]. ArXiv preprint arXiv:2107.03374, 2021.

[87] Molchanov P, Tyree S, Karras T, et al. Pruning Convolutional Neural Networks for Resource Efficient Inference[C]. International Conference on Learning Representations. 2017.

[88] LECUN Y, DENKER J S, SOLLA S A. Optimal brain damage[C]//Advances in Neural Information Processing Systems. 1989, 2: 598-605.[Z].

[89] LEE N, AJANTHAN T, TORR P H S. SNIP: Single-shot network pruning based on connection sensitivity[C]//International Conference on Learning Representations. 2019.[Z].

[90] HASSIBI B, STORK D G, WOLFF G J. Optimal brain surgeon and general network pruning[C]//IEEE International Conference on Neural Networks. 1993: 293-299.[Z].

[91] SANH V, WOLF T, RUSH A M. Movement pruning: Adaptive sparsity by fine-tuning[C]//Advances in Neural Information Processing Systems. 2020, 33: 20378-20389.[Z].

[92] FRANKLE J, CARBIN M. The lottery ticket hypothesis: Finding sparse, trainable neural networks[C]//International Conference on Learning Representations. 2019.[Z].

[93] FRANTAR E, ALISTARH D. SparseGPT: Massive language models can be accurately pruned in one-shot[J]. arXiv preprint arXiv:2301.00774, 2023.[EB/OL]. https://arxiv.org/abs/2301.00774.

[94] SUN M, LIU Z, BOWEN T, et al. A simple and effective pruning approach for large language models[J]. arXiv preprint arXiv:2306.11695, 2023.[EB/OL]. https://arxiv.org/abs/2306.11695.

[95] MA X, FANG G, WANG X. LLM-Pruner: On the structural pruning of large language models[C]//Advances in Neural Information Processing Systems. 2023, 36.[Z].

[96] XIA M, GAO T, ZENG Z, et al. Sheared LLaMA: Accelerating language model pre-training via structured pruning[J]. arXiv preprint arXiv:2310.06694, 2023.[EB/OL]. https://arxiv.org/abs/2310.06694.

[97] Mathematical Association of America. American Invitational Mathematics Examination[Z]. Contest problem set. 2025.

[98] MIALON G, FOURRIER C, SWIFT C, et al. Gaia: a benchmark for general ai assistants[C]//International Conference on Learning Representations. 2024.[Z].

[99] REIN D, HOU B L, STICKLAND A C, et al. GPQA: A graduate-level google-proof q&a benchmark[C]//First Conference on Language Modeling. 2024.[Z].

[100] PHAN L, GATTI A, HAN Z, et al. Humanity's last exam[J]. arXiv preprint arXiv:2501.14249, 2025.[EB/OL]. https://arxiv.org/abs/2501.14249.

[101] HENDRYCKS D, BURNS C, KADAVATH S, et al. Measuring mathematical problem solving with the math dataset[C]//Proceedings of the Neural Information Processing Systems Track on Datasets and Benchmarks. 2021.[Z].

[102] TRIVEDI H, BALASUBRAMANIAN N, KHOT T, et al. Musique: Multihop questions via single-hop question composition[J]. Transactions of the Association for Computational Linguistics, 2022, 10: 539-554.[Z].

[103] ZHUO T Y, VU M C, CHIM J, et al. Bigcodebench: Benchmarking code generation with diverse function calls and complex instructions[C]//International Conference on Learning Representations. 2025.[Z].

[104] Lai X, Xu W, Yang Y, et al. MiniMax Sparse Attention[J]. ArXiv preprint arXiv:2606.13392, 2026.

附录 A
费马大定理的证明

关于此，我确信已发现了一种美妙的证法，可惜这里空白的地方太小，写不下。

附录 B

Maxwell Equations

因为在柱坐标系下，$\bar{\bar{\mu}}$ 是对角的，所以 Maxwell 方程组中电场 **E** 的旋度

所以 **H** 的各个分量可以写为：

$$H_r = \frac{1}{\mathbf{i}\omega\mu_r}\frac{1}{r}\frac{\partial E_z}{\partial\theta} \tag{B.1a}$$

$$H_\theta = -\frac{1}{\mathbf{i}\omega\mu_\theta}\frac{\partial E_z}{\partial r} \tag{B.1b}$$

同样地，在柱坐标系下，$\bar{\bar{\epsilon}}$ 是对角的，所以 Maxwell 方程组中磁场 **H** 的旋度

$$\nabla\times\mathbf{H} = -\mathbf{i}\omega\mathbf{D} \tag{B.2a}$$

$$\left[\frac{1}{r}\frac{\partial}{\partial r}(rH_\theta) - \frac{1}{r}\frac{\partial H_r}{\partial\theta}\right]\hat{\mathbf{z}} = -\mathbf{i}\omega\bar{\bar{\epsilon}}\mathbf{E} = -\mathbf{i}\omega\epsilon_z E_z\hat{\mathbf{z}} \tag{B.2b}$$

$$\frac{1}{r}\frac{\partial}{\partial r}(rH_\theta) - \frac{1}{r}\frac{\partial H_r}{\partial\theta} = -\mathbf{i}\omega\epsilon_z E_z \tag{B.2c}$$

由此我们可以得到关于 E_z 的波函数方程：

$$\frac{1}{\mu_\theta\epsilon_z}\frac{1}{r}\frac{\partial}{\partial r}\left(r\frac{\partial E_z}{\partial r}\right) + \frac{1}{\mu_r\epsilon_z}\frac{1}{r^2}\frac{\partial^2 E_z}{\partial\theta^2} + \omega^2 E_z = 0 \tag{B.3}$$

附录 C
要求

有些材料编入文章主体会有损于编排的条理性和逻辑性，或有碍于文章结构的紧凑和突出主题思想等，这些材料可作为附录另页排在参考文献之后，也可以单编成册。下列内容可作为附录：

1. 为了整篇论文材料的完整，但编入正文有损于编排的条理性和逻辑性的材料，这一类材料包括比正文更为详尽的信息、研究方法和技术等更深入的叙述，以及建议可阅读的参考文献题录和对了解正文内容有用的补充信息等；
2. 由于篇幅过大或取材的复制资料不便于编入正文的材料；
3. 不便于编入正文的罕见珍贵资料；
4. 一般读者无须阅读，但对本专业同行有参考价值的资料；
5. 某些重要的原始数据、推导、计算程序、框图、结构图、注释、统计表、计算机打印输出件等；

C.1 一级标题

C.1.1 二级标题

攻读学位期间发表论文与研究成果清单

[1] Doe J, **Zhang S**. The Book with Title[M]. Dummy Publisher, 2000. (已出版.)

[2] **张**三, 李杰, 罗运军. 交联型与线形水性聚氨酯的形状记忆性能比较[J]. 化工进展, 2006(01): 78-81. (EI 收录, 检索号:06129773469. 已刊出.)

[3] 李杰, **张**三, 罗运军. 交联型与线形水性聚氨酯的形状记忆性能比较[J]. 化工进展, 2007(01): 78-81. (EI 收录, 检索号:06129773469. 已刊出.)

[4] **Zhang S**. The Book without Title[M]. Dummy Publisher, 2100. (已出版.)

作者简介

本人……

早年对作者简介的要求：“硕士学位论文不必提供作者简介。博士学位论文应该提供作者简介，主要包括：姓名、性别、出生年月、民族、出生地；简要学历、工作经历（职务）；攻读学位期间取得的其他研究成果或奖励。”