面向多智能体系统的高效通信技术研究

姓名：柯逸宸

学号：3220241499

学院：计算机学院

2026 年 6 月

专

面向多智能体系统的高效通信技术研究

柯逸宸

北京理工大学

中图分类号：TQ028.1
UDC 分类号：540
学校代码：10007

★ 学生类型
□ 工程硕博士专项
□ 交叉研究方向
□ 政府项目留学生

面向多智能体系统的高效通信技术研究

作 者 姓 名　柯逸宸
二级培养单位　计算机学院
指 导 教 师　李四教授
行业合作导师　李五教授
答辩委员会主席　王五教授
申 请 类 别　材料与化工博士
学 位 领 域　计算机技术
学位授予单位　北京理工大学
论文提交日期　2026 年 6 月

Synthesis and Application on textile of the Shape Memory Polyurethane

Candidate Name:	Yichen Ke
School or Department:	Materials Science and Engineering
Faculty Advisor:	Prof. Li Si
Industry Collaboration Mentor:	Prof. Li Wu
Chair of the Defense Committee:	Prof. Wang Wu
Degree:	Doctor of Materials
	and Chemical Engineering
Major:	Materials Science and Engineering
Degree by:	Beijing Institute of Technology
Submission date:	June, 2026

研究成果声明

本人郑重声明：所提交的学位论文是我本人在指导教师的指导下独立完成的研究成果。文中所撰写内容符合以下学术规范（请勾选）：

☑ 论文综述遵循“适当引用”的规范，全部引用的内容不超过 50%。

☑ 论文中的研究数据及结果不存在篡改、剽窃、抄袭、伪造等学术不端行为，并愿意承担因学术不端行为所带来的一切后果和法律责任。

☑ 文中依法引用他人的成果，均已做出明确标注或得到许可。

☑ 论文内容未包含法律意义上已属于他人的任何形式的研究成果，也不包含本人已用于其他学位申请的论文或成果。

☑ 与本人一同工作的合作者对此研究工作所做的任何贡献均已在学位论文中作了明确的说明并表示了谢意。

特此声明。

签　　名：　　日 期：

关于学位论文使用权的说明

本人完全了解北京理工大学有关保管、使用学位论文的规定，其中包括：

① 学校有权保管、并向有关部门送交学位论文的原件与复印件；

② 学校可以采用影印、缩印或其它复制手段复制并保存学位论文；

③ 学校可允许学位论文被查阅或借阅；

④ 学校可以学术交流为目的，复制赠送和交换学位论文；

⑤ 学校可以公布学位论文的全部或部分内容（保密学位论文在解密后遵守此规定）。

签　　名：　　日　期：

导师签名：　　日　期：

致谢

本论文的工作是在导师……

对学位论文的编写或相关工作的开展等给予帮助的组织和个人宜致谢，包括：

——国家科学基金，资助研究工作的奖学金基金，合同单位，资助或支持的企业、组织或个人；

——协助完成研究工作和提供便利条件的组织或个人；

——在研究工作中提出建议和提供帮助的人；

——给予转载和引用权的资料、图片、文献、研究思想和设想的所有者；

——其他应感谢的组织和个人。

面向多智能体系统的高效通信技术研究

摘要：本文……

（摘要是一篇具有独立性和完整性的短文，应概括而扼要地反映出本论文的主要内容。包括研究目的、研究方法、研究结果和结论等，特别要突出研究结果和结论。中文摘要力求语言精炼准确，博士学位论文建议 1000~1200 字，硕士学位论文摘要建议 500~800 字。摘要中不可出现参考文献、图、表、化学结构式、非公知公用的符号和术语。英文摘要与中文摘要的内容应完全一致，在语法、用词上应准确无误，语言简练通顺。以外文撰写的学位论文，应以同种语言撰写外文摘要。除外文摘要外，应有中文摘要，置于外文摘要页的后面，并标注中文关键词，为能完整描述学位论文的主要内容，中文摘要宜不少于 5000 字。）

关键词：多智能体系统；通信技术；（**硕士**一般选 3 ~ 6 个单词或专业术语，**博士**一般选 3 ~ 8 个单词或专业术语，且中英文关键词必须对应。【提醒】关键词不要与学科或专业名称等专有名词一致或相近。）——请在“main.tex”开头设置

Synthesis and Application on textile of the Shape Memory Polyurethane

Abstract: In order to exploit...

Lorem ipsum dolor sit amet, officia excepteur ex fugiat reprehenderit enim labore culpa sint ad nisi Lorem pariatur mollit ex esse exercitation amet. Nisi anim cupidatat excepteur officia. Reprehenderit nostrud nostrud ipsum Lorem est aliquip amet voluptate voluptate dolor minim nulla est proident. Nostrud officia pariatur ut officia. Sit irure elit esse ea nulla sunt ex occaecat reprehenderit commodo officia dolor Lorem duis laboris cupidatat officia voluptate. Culpa proident adipisicing id nulla nisi laboris ex in Lorem sunt duis officia eiusmod. Aliqua reprehenderit commodo ex non excepteur duis sunt velit enim. Voluptate laboris sint cupidatat ullamco ut ea consectetur et est culpa et culpa duis.

Key Words: shape memory properties; polyurethane; textile; synthesis; application

目次

1 绪论 1
1.1 研究背景及意义 1
1.2 国内外研究现状 5
1.3 本文主要研究内容及贡献 6
1.3.1 面向语义冗余的消息压缩框架 6
1.3.2 面向通信边冗余的图剪枝算法 6
1.4 论文组织结构 7
2 相关工作 8
2.1 多智能体系统 8
2.2 语义冗余问题 9
2.2.1 定义和分类 9
2.2.2 通用应对策略 10
2.3 通信边冗余问题 11
2.3.1 定义和分类 11
2.3.2 通用应对策略 12
2.4 本章小结 14
3 面向语义冗余的消息压缩框架 15
3.1 引言 15
3.2 消息压缩算法 15
3.2.1 多智能体系统任务执行流程 15
3.2.2 消息压缩框架执行流程 15
3.2.3 功能模块设计 16
3.3 实验设置 19
3.3.1 数据集 19
3.3.2 对比基准 19
3.3.3 实现细节 19
3.3.4 评估指标 20

3.4 实验结果与分析 21
3.4.1 任务准确率结果 21
3.4.2 成本对比实验结果 24
3.4.3 结果分析 25
3.5 本章小结 26
4 面向通信边冗余的图剪枝算法 27
4.1 引言 27
4.2 图剪枝算法 28
4.2.1 工具调用场景建模 28
4.2.2 可学习通信边概率建模 29
4.2.3 成本感知优化目标 29
4.2.4 Taylor 一阶重要性剪枝 30
4.2.5 训练与执行流程 31
4.3 实验设置 32
4.4 实验结果与分析 33
4.4.1 Qwen3-14B 整体结果 33
4.4.2 MiniMax-M3 补充结果 35
4.4.3 结果讨论 37
4.5 本章小结 38
结论 39
参考文献 40
附录 A 费马大定理的证明 46
附录 B Maxwell Equations 47
附录 C 要求 48
C.1 一级标题 48
C.1.1 二级标题 48
攻读学位期间发表论文与研究成果清单 49
作者简介 50

插图

图 1.1 多智能体系统的 token 消耗对比和不同智能体数量下的输入 token 变化 ... 2
图 1.2 完全拓扑 (Full Topology) ... 4
图 2.1 多智能体的两条研究路线 ... 8
图 2.2 压缩示意图 ... 9
图 2.3 图生成技术示意图 ... 12
图 2.4 图剪枝技术示意图 ... 13
图 2.5 拓扑搜索技术示意图 ... 13
图 3.1 多智能体系统标准任务执行流程示意图 ... 16
图 3.2 消息压缩框架 ... 16
图 3.3 六个数据集在不同模型下的平均准确率对比 ... 21
图 3.4 各数据集上不同模型与方法的准确率对比 ... 22
图 3.5 六个数据集在不同模型下的平均推理成本对比 ... 24
图 3.6 各数据集上不同模型的推理成本比较 ... 25
图 4.1 Qwen3-14B 在 AIME 任务上的工具调用实验结果 ... 34
图 4.2 Qwen3-14B 在扩展工具任务上的准确率结果 ... 35
图 4.3 MiniMax-M3 在 GAIA 和 GPQA 任务上的成本与准确率结果 ... 36
图 4.4 MiniMax-M3 在 HLE 和 MuSiQue 任务上的成本与准确率结果 ... 37

表格

表 3.1　实验评测数据集概览 19
表 3.2　API 调用单价对比表 20
表 4.1　工具调用实验任务与默认工具配置 33
表 4.2　Qwen3-14B 下面向通信边冗余的图剪枝结果（准确率% / 推理成本） 34
表 4.3　MiniMax-M3 下面向通信边冗余的图剪枝结果（准确率% / 推理成本） ... 36

主要符号对照表

BIT	北京理工大学的英文缩写
LaTeX	一个很棒的排版系统
LaTeX 2_ε	一个很棒的排版系统的最新稳定版
ctex	成套的中文 LaTeX 解决方案，由一帮天才们开发
$e^{\pi i} + 1 = 0$	一个集自然界五大常数一体的炫酷方程

1 绪论

1.1 研究背景及意义

研究背景：近年来，以 Transformer 架构为基础的大语言模型（Large Language Models，LLMs）[1]，如 OpenAI 的 GPT-4 系列[2]，以及开源生态中的 LLaMA 系列[3-5]、Qwen 系列[6-8]等，在自然语言理解、逻辑推理与文本生成任务中展现出强大的性能。然而，随着应用场景向高度复杂的现实任务（如软件工程[9]、科学计算[10]、具身智能探索等[11]）拓展，大语言模型的局限性日益凸显[12]。

为了突破这一局限，学术界提出了赋予大语言模型自主性的智能体（Agent）概念[12]。智能体以大语言模型强大的逻辑推理能力为基础，包括早期的思维链（Chain of Thought，CoT）[13]、随后提出的思维一致性（Self-Consistency）[14]，以及更复杂的思维树（Tree of Thoughts，ToT）[15]和思维图（Graph of Thoughts，GoT）[16]。在此基础上，智能体进一步融合了工具调用（Tool Calling/API Use）[17-18]、环境感知与动态反馈机制，以及长周期复杂任务的拆解与规划能力[19]，现已成为当前人工智能领域的核心发展范式[20-22]。以 ReAct（Reasoning and Acting）[23]为代表的方法，将模型的逻辑推理与外部环境执行协同，构建了“思考—行动—观察”的动态闭环，从而显著提升了模型在复杂交互环境中的执行能力[24]；同时，Reflexion 等基于自然语言反馈的自我修正机制[25]，以及 Generative Agents、Voyager 等[26-27]引入长时记忆架构，有效克服了大语言模型无状态交互的局限，提升了其可靠性与跨轮次持续学习能力。尽管智能体技术发展迅猛，其能力上限仍受制于三个瓶颈：

1. 受限于模型训练数据的日期，其内部权重难以包含最新的知识[28]。

2. 在上下文窗口限制下，超长输入不仅会带来高昂的计算开销与推理延迟，更易导致关键信息被稀释，引发“迷失在中间（Lost in the Middle）”现象，致使模型丧失对长文本中核心细节的捕捉能力[29-30]。

3. 单智能体受限于单一的推理视角与预设的角色提示词（Prompt），在应对高度复杂、需多学科交叉分析的任务时，极易陷入局部最优的认知局限[31]。

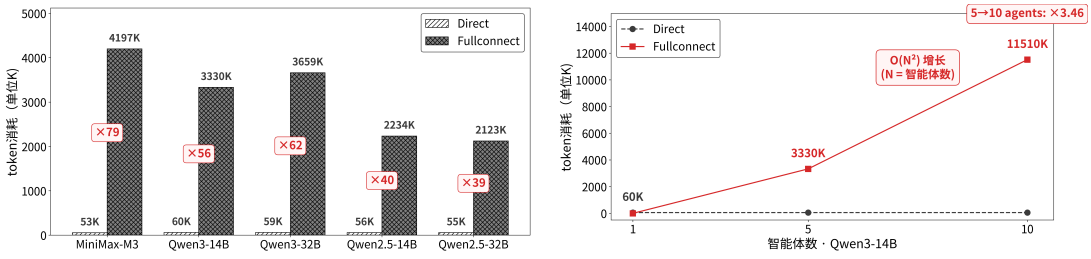
为此，学术界与工业界的研究范式正从单体 Agent 向多智能体系统（Multi-Agent Systems，MAS）演进[31-32]。MAS 通过模拟人类社会的组织与协作机制，引入了明确的角色分工（如程序员、测试员、产品经理的职能划分）与交叉验证辩论体系[33-34]。

大量前沿研究已经初步论证了 MAS 在复杂场景下的优越性：例如，清华大学提出的 ChatDev 将软件开发过程建模为瀑布流式的多智能体协作网络，大幅降低了代码漏洞率[9]；MetaGPT 通过引入标准化操作程序（SOPs），将复杂任务严密拆解为多角色的流水线作业，有效缓解幻觉[35]；微软的 AutoGen 则提供了一种面向对话编程的可定制化多智能体交互模式，支持多个智能体间的灵活组网[36]。这些研究充分表明，MAS 能够有效突破单智能体的能力天花板，在复杂协同任务中的综合任务成功率、代码通过率与系统鲁棒性均实现了提升。

然而，随着 MAS 能力的提升，其底层通信机制的瓶颈也暴露出来，成为核心障碍：当前主流的多智能体框架[35-36]在拓扑维度上多依赖静态的拓扑结构，在语义维度上则普遍采用完全传递的策略。这意味着，每当一个智能体生成内容，其原始输出会被全量且未经筛选地复制给所有相关的下游接收节点。这种密集的交互模式引发了两个问题：

1. 通信成本增加：目前模型大多按词元计费。如图1.1所示，一旦智能体数量增多，系统内的消息量就会呈指数级或平方级暴涨，带来巨大的成本压力。

2. 关键信息淹没：冗余上下文会导致 LLM 出现“长上下文注意力衰减”。接收方智能体在处理大量重复和无关的消息时，极易漏掉关键信息，反而拉低了任务的成功率。



(a) 多智能体系统的 token 消耗　　(b) 不同智能体数量下的输入 token

图 1.1　多智能体系统的 token 消耗对比和不同智能体数量下的输入 token 变化

因此，如何减少 MAS 中的高昂通信成本，并在压缩通信开销的同时保持多智能体协作收益，已成为当前大模型多智能体领域需要解决的问题。进一步来看，多智能体通信冗余主要体现在两个层面：一方面，在既定通信边上传递的自然语言消息往往包含大量重复推理、弱相关背景和冗长历史信息，需要从语义内容层面进行压缩[37-39]；另一方面，在具备工具调用能力的复杂任务中，外部搜索、代码执行和文本检查等工具观察会沿通信边继续传播[17-18,23]，使通信边本身也具有不同的成本与价值，需要从

图结构层面判断哪些边应当保留、哪些边应当剪除[40-42]。基于上述分析，本文围绕“语义冗余压缩”和“通信边冗余剪枝”两个互补方向展开研究：首先提出面向语义冗余的消息压缩框架，以减少冗余 Token 并提升下游信息密度；随后提出面向通信边冗余的图剪枝算法，将任务正确性与工具调用成本共同纳入边级优化目标，从而进一步提升多智能体系统的准确率–成本平衡。

研究意义：针对当前多智能体系统在通信成本与上下文处理上面临的严峻挑战，本文分析了面向多智能体系统的高效通信方法具有重要的理论价值与实际意义，体现在以下两个层面：

1. 理论意义：本文从语义信息熵与多智能体通信机制的交叉视角出发，打破了多智能体框架中全量广播的交互范式。通过探索并建立动态、自适应的冗余信息过滤与核心语义保留机制，为解决大语言模型在多轮复杂交互中的“长上下文注意力衰减（Lost in the Middle）”问题提供了新的理论视角。

2. 实际意义：本文通过对多智能体系统中传输消息的压缩，大幅减少模型推理过程中的冗余 Token 消耗，从而直接降低 API 调用开销，提高多智能体系统在工业级、企业级场景中大规模部署的经济可行性。同时，消息压缩能够为下游智能体保留更高密度的关键信息，避免有效信息被海量历史对话和重复推理内容淹没，有助于提升多智能体协作过程中的任务完成质量与整体成功率。

研究基础与目标：

研究基础：

基于上述背景，在这一部分中，我们将给出大语言模型多智能体系统通信机制中的基础定义，并明确本课题的研究问题。

定义 1 拓扑结构：表示多智能体系统中各智能体（Agent）节点之间信息交互路径的连接关系。

定义 2 常见通信拓扑类型：在多智能体协同系统中，根据信息交互路径的组织方式，拓扑结构主要可以划分为以下四种典型范式：

- **完全拓扑（Full Topology）：**指多智能体系统中任意两个智能体节点间均存在双向的信息传输通路。在该拓扑范式下，每个智能体均接收所有其他智能体的输出内容，并将其全量作为历史上下文。
- **层状拓扑（Layered Topology）：**指智能体按层级结构进行划分，当前层的智能体仅接收并处理上一层智能体的输出信息，适用于具有明显阶段划分的复杂任

务。

- **链式拓扑（Chain Topology）：**指信息以串行方式依次传递，从初始输入开始，每个智能体顺次处理并将结果单向传递给下一个智能体。
- **星状拓扑（Star Topology）：**指引入中心管理智能体，由其统一负责全局信息的收集、分发与汇总，其余外围智能体与中心节点进行交互。

定义 3 语义内容：指在既定的通信拓扑路径上，智能体之间实际传递的信息内容。在大语言模型多智能体系统中，语义内容通常表现为自然语言文本、结构化提示或中间推理状态。

定义 4.1 单轮内对话：指多智能体在单个任务对话周期内，通过协同交互共同完成结果输出的交互架构。本研究所探讨的单轮内对话拓扑结构特指完全拓扑，具体如1.2所示。

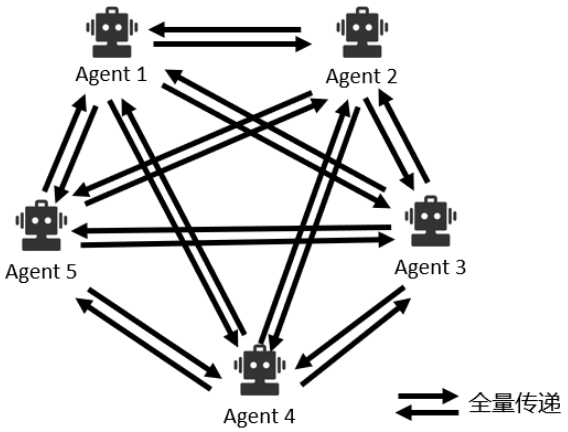


图 1.2　完全拓扑 (Full Topology)

定义 4.2 多轮间通信：指多智能体跨对话轮次进行信息传递与历史信息的协作架构。具体表现为在每一轮交互中，每个智能体均接收并利用上一轮所有智能体的输出信息。

问题 1.1 语义冗余压缩：在多智能体持续协作过程中，随着交互轮次的增加，系统内传递的自然语言上下文会产生严重的语义冗余。如何根据接收方角色、前驱节点差异和跨轮历史状态，筛选并保留对后续推理真正有用的信息，从而在降低 Token 成本的同时保持任务准确率?

问题 1.2 通信边冗余剪枝：在工具调用型多智能体系统中，不同通信边携带的模型输出、工具调用次数和工具观察 Token 差异显著。如何将通信边价值建模为可学习

概率，并结合任务正确性与工具调用成本判断低价值通信边，从而动态压缩通信图结构?

围绕上述研究问题，本课题目前已具备以下研究基础：

1. 理论与文献基础：已对 MetaGPT、AutoGen 等主流多智能体协作框架进行了系统性的调研与解构。重点梳理了其底层的交互逻辑、角色分工范式、协同机制以及现有的通信模式。这为本课题重新审视多智能体间的通信瓶颈、进行精确的数学与逻辑建模提供了坚实的理论支撑。

2. 技术储备：在通信网络优化的两个核心维度已掌握关键技术，为算法设计提供了直接的方法论支撑。在拓扑结构层面，已掌握图生成、图剪枝及网络拓扑搜索等图论与图学习前沿技术。在语义处理层面，已熟练掌握文本信息压缩相关技术，并深入研究了基于困惑度及轻量化模型辅助的提示词过滤与精简策略。

3. 实验环境与资源支持：已具备开展大规模多智能体实验的软硬件条件。目前已获取 Qwen、MiniMax[43]等主流大型语言模型的 API 权限及计算资源。

研究目标：针对当前多智能体系统（MAS）中由于全量传递所引发的问题，本研究的核心目标是：设计并构建面向语义冗余的内容压缩方法与面向通信边冗余的结构剪枝方法，在保障或提升任务准确率的前提下，尽可能降低系统的 Token 消耗、工具调用开销和整体推理成本。

1.2 国内外研究现状

围绕多智能体系统通信效率问题，现有研究主要沿两条路径展开：一类方法从通信结构出发，尝试减少不必要的智能体连接、节点参与和跨轮信息传递；另一类方法从语义内容出发，直接压缩沿通信链路传递的自然语言上下文。前者强调“哪些智能体之间需要通信”，后者强调“通信时应传递什么内容”。两类研究共同指向一个核心目标：在保持多智能体协作收益的同时，降低 Token 消耗、上下文长度和系统部署成本。

从已有工作看，通信结构优化方法能够有效减少通信边或智能体数量，但通常需要额外的搜索、训练或剪枝流程；语义压缩方法具备更强的即插即用特性，可以直接作用于黑盒大语言模型接口，但需要在压缩率与语义保真之间取得平衡。本文围绕这两类路线分别展开研究：一方面从语义内容层面压缩智能体之间传递的自然语言消息，另一方面从图结构层面剪除低价值通信边，并在第2章对多智能体系统、语义冗

余问题和通信边冗余问题进行系统梳理。

1.3 本文主要研究内容及贡献

本文围绕多智能体系统中的通信冗余问题，研究如何在不改变底层大语言模型能力的前提下，通过消息级压缩与图结构剪枝提升协作过程的准确率–成本平衡。整体而言，本文首先构建多智能体通信冗余问题分析框架，结合空间通信和跨轮历史传递过程，分析全量消息广播带来的 Token 开销、上下文膨胀和关键信息淹没问题；随后分别从语义内容和通信结构两个层面提出具体方法。主要研究内容和贡献如下。

1.3.1 面向语义冗余的消息压缩框架

针对既定通信边上自然语言消息冗长、重复和弱相关的问题，本文提出面向语义冗余的消息压缩框架。该工作关注“通信时应传递什么内容”，目标是在不改变原有多智能体拓扑和底层模型的前提下，对智能体之间传递的推理内容进行细粒度筛选与聚合。

具体而言，本文设计了角色感知压缩、节点感知聚合和分歧感知压缩三个模块。角色感知压缩根据接收方智能体的职责过滤发送方消息中的无关推理内容，解决完整消息与接收方需求不匹配的问题；节点感知聚合对多个前驱智能体传来的相似观点进行去重和来源标注，解决多前驱消息重复的问题；分歧感知压缩从跨轮历史中提取共识答案、候选分歧及其理由，解决多轮协作中历史上下文持续膨胀的问题。通过上述设计，本文方法能够在保留关键语义信息的同时减少冗余 Token，提高下游智能体接收上下文的信息密度。

在实验方面，本文在 MMLU、GSM8K、AQuA、MultiArith、SVAMP 和 HumanEval 等任务上评估消息压缩框架，并与 Direct、FullConnected 和 AgentPrune 等基线进行对比。实验结果表明，该方法能够在多数任务上保持或提升任务准确率，同时显著降低相对于完全通信拓扑的推理成本。

1.3.2 面向通信边冗余的图剪枝算法

针对工具调用场景中通信边成本差异显著的问题，本文提出面向通信边冗余的图剪枝算法。该工作关注“哪些智能体之间需要通信”，目标是在搜索、代码执行和文本检查等工具增强任务中，识别并剪除低价值、高成本的通信边，从图结构层面降低多智能体系统的冗余通信开销。

具体而言，本文将智能体通信边建模为可学习概率，在训练过程中结合任务正确性、模型输出 Token、工具调用次数和工具返回 Token 构造边级优化目标。与只根据最终任务效用评估通信结构的方法不同，本文进一步将工具调用带来的额外成本归因到具体发送方和通信边，使系统能够区分高价值通信边与传播冗余工具观察的低价值通信边。在此基础上，本文引入 Taylor 一阶重要性评估，根据边参数与梯度共同衡量移除该边对目标函数的影响，并对低重要性边进行动态剪枝。

在实验方面，本文在 AIME、GAIA、GPQA、HLE、MATH500、MuSiQue 和 BigCodeBench 等工具调用任务上验证面向通信边冗余的图剪枝算法的有效性。实验结果表明，该方法能够在工具调用场景中更合理地平衡任务准确率与推理成本，并在多个任务上相对完全通信或原始 AgentPrune 基线减少冗余工具信息传播。

1.4 论文组织结构

本文后续章节组织如下：第2章介绍多智能体系统、语义冗余问题和通信边冗余问题相关研究，分析现有方法的优势与不足；第 3 章围绕面向语义冗余的消息压缩框架展开，给出系统执行流程、核心模块设计以及实验结果分析；第4章进一步面向工具调用场景，介绍面向通信边冗余的图剪枝算法及 Taylor 一阶重要性剪枝策略；最后，总结全文工作并讨论后续研究方向。

2 相关工作

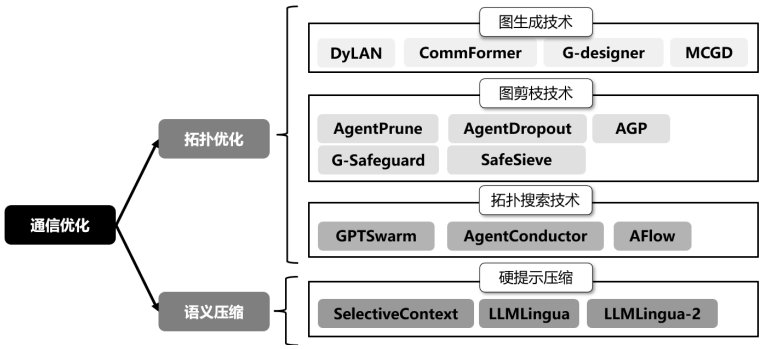


图 2.1　多智能体的两条研究路线

为了应对多智能体系统中日益凸显的通信瓶颈，近年来学术界与工业界在通信机制优化方面进行了大量探索。依据优化对象的不同，现有研究主要可以分为两类：一类关注智能体协作的组织方式与通信路径，核心问题是“哪些智能体之间需要通信”；另一类关注通信路径上传递的自然语言内容，核心问题是“通信时应传递什么信息”。本章首先介绍多智能体系统的基本范式，随后分别围绕语义冗余问题和通信边冗余问题梳理相关研究，为后续两项工作提供研究脉络。

2.1 多智能体系统

多智能体系统（Multi-Agent Systems，MAS）通常由多个具备不同角色、能力或工具权限的智能体组成，各智能体通过通信、协商、验证和分工协作共同完成复杂任务。与单智能体方法相比，MAS 能够引入多视角推理和交叉验证机制，使系统在软件开发、复杂问答、数学推理和开放环境交互等任务上表现出更强的任务拆解能力与鲁棒性[9,31,35-36]。

现有大语言模型多智能体系统大多围绕角色分工和通信机制展开。ChatDev[9]将软件开发流程拆解为多个具有明确职责的智能体，并通过阶段化对话完成需求分析、编码和测试；MetaGPT[35]引入标准化操作程序，将产品经理、架构师、工程师等角色组织为结构化流水线；AutoGen[36]则提供灵活的对话式多智能体编程框架，使不同智能体可以根据任务需要进行自由组网和交互。这些工作说明，多智能体系统的性能不仅取决于单个基座模型的能力，还取决于角色设置、通信拓扑、历史记忆和工具使用方式。

从通信结构看，MAS 常见拓扑包括完全连接、链式、层状、星状和二分图拓扑等[44]。完全连接拓扑有利于信息充分共享，但通信边数会随智能体数量呈平方级增长；链式或层状拓扑能够控制传递路径，但可能限制跨角色的信息互补；星状拓扑依赖中心智能体完成调度和汇总，易形成瓶颈。随着任务轮次增加和工具观察写入上下文，静态拓扑和全量消息传递会进一步放大 Token 消耗，并导致关键信息被冗余历史淹没。因此，后续研究逐渐从两个层面优化 MAS 通信：一是压缩通信内容，解决语义冗余问题；二是优化通信路径，解决通信边冗余问题。

2.2 语义冗余问题

2.2.1 定义和分类

除了在通信拓扑层面减少冗余交互外，在语义维度直接对智能体传递的上下文消息进行压缩，是降低大型语言模型（LLMs）推理成本、提升内存利用率的另一项重要手段。与拓扑优化关注“哪些智能体之间需要通信”不同，语义冗余问题更关注“沿通信链路传递什么内容”。在多智能体系统中，语义冗余通常指智能体之间传递的自然语言消息中包含大量重复推理、弱相关背景、低价值解释或过长历史记忆，使下游智能体需要在更长上下文中寻找真正有用的信息。

结合多智能体通信过程，语义冗余主要可以分为三类。第一类是**角色不匹配冗余**，即发送方完整推理并不完全符合接收方智能体的角色职责，导致下游节点接收大量与自身任务无关的信息。第二类是**多前驱重复冗余**，即多个上游智能体围绕同一事实、同一公式或同一候选答案给出相似表述，增加上下文长度但信息增量有限。第三类是**跨轮历史冗余**，即多轮协作中历史消息逐轮累积，使后续智能体难以从冗长上下文中定位当前共识、关键分歧和有效证据。

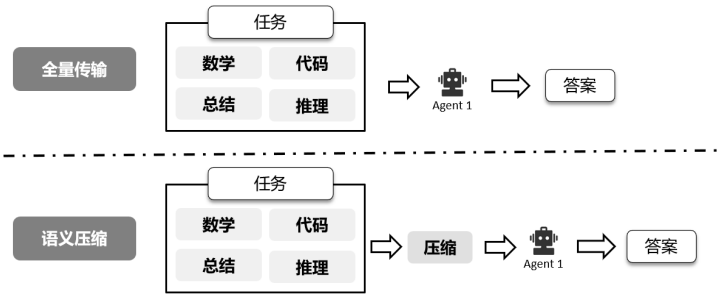


图 2.2　压缩示意图

2.2.2 通用应对策略

硬提示词压缩旨在通过对原始文本进行修改，生成人类可读的、更为精简的自然语言序列。与软提示压缩将上下文映射为不可读的连续向量不同，硬提示词压缩保留了自然语言形式，因此更便于人工检查、跨模型迁移以及在多智能体通信场景中复用。根据压缩机制的不同，主流研究主要可划分为以下两个方向[37]：

基于过滤的压缩方法：此类方法通过评估词元、短语或句子的重要性，剔除冗余和低信息量的部分，并在保持原文顺序的基础上生成压缩后的上下文。早期代表性工作 SelectiveContext[45]利用较小规模的因果语言模型计算词元的自信息或困惑度，将低自信息内容视为更容易由上下文预测、因而冗余度更高的部分，再按照词元、短语或句子粒度进行过滤。该方法无需额外训练，能够直接应用于黑盒 LLM，但由于其重要性评估主要依赖语言统计特征，可能误删对特定任务有用但语言上并不突出的信息。LLMLingua[38]进一步提出粗到细的压缩框架，首先通过预算控制器在指令、示例和问题等不同提示词组成部分之间分配压缩率，再利用小模型估计词元困惑度或信息熵，逐步保留高信息量词元。相比简单过滤，LLMLingua 考虑了提示词内部不同模块的重要性差异，并通过迭代式压缩缓解局部删除造成的上下文断裂问题，因此能够在较高压缩率下保持较好的下游任务性能。

后续的 LLMLingua-2[39]则引入了数据蒸馏机制，将压缩任务从基于困惑度的无监督筛选转化为词元级二分类任务。具体而言，该方法先利用强模型生成抽取式压缩结果，再通过自动对齐为原始文本中的词元标注“保留”或“删除”标签，并训练轻量级双向编码器预测每个词元的重要性。推理时，模型按照保留概率选择满足压缩预算的词元，并保持其原始顺序。由于双向编码器能够同时利用左右上下文，LLMLingua-2 在压缩速度、忠实度和跨任务泛化方面均优于单纯依赖困惑度的方法。进一步地，TACO-RL[46]将强化学习引入过滤式压缩过程，将每个词元的保留或删除视为动作，并根据下游任务表现给予奖励。例如，在问答任务中可依据答案 F1 值评估压缩效果，在摘要任务中可依据生成文本与参考文本的相似度计算奖励。通过这种方式，TACO-RL 能够根据具体任务目标动态调整剪枝策略，使压缩器更倾向于保留与当前查询或任务评价指标直接相关的信息，从而弥补任务无关过滤方法在语义选择上的不足。

基于重写的压缩方法：与简单的删除词元不同，此类方法利用语言模型强大的生成与概括能力，主动将冗长的上下文重写为更紧凑的自然语言表达。其核心优势在于能够跨越句子边界进行信息重组，将分散在原文不同位置的关键信息合并为更短的表

述，从而避免纯过滤方法可能造成的语义割裂或可读性下降。例如 Nano-Capsulator 框架[47]不再直接从原始提示词中选择词元，而是训练一个生成式压缩模型，将长提示词封装为更短的 Capsule Prompt。该模型在训练过程中同时考虑语义保持和下游任务效用：一方面要求压缩后的自然语言表示尽可能保留原始提示词的核心含义，另一方面又通过目标 LLM 在相关任务上的输出表现约束压缩结果，使其不仅短，而且仍然能够有效引导模型完成任务。

与过滤式方法相比，基于重写的压缩能够生成更加流畅、连贯且人类可读的压缩文本，尤其适合处理包含重复解释、长链式推理示例或多轮对话历史的上下文。在多智能体系统中，这类方法可用于将某一智能体的长篇推理过程、观察记录或工具调用结果重写为面向后续智能体的短摘要，从而减少跨智能体传递的词元数量。然而，这类方法也存在一定风险：由于压缩过程依赖生成模型，可能出现关键信息遗漏、语义偏移甚至幻觉。因此，在高精度任务中，重写式压缩通常需要结合任务反馈、事实一致性检测或保守的压缩率设置，以在压缩效率与语义可靠性之间取得平衡。

2.3 通信边冗余问题

2.3.1 定义和分类

通信边冗余问题是指多智能体系统中存在大量低价值、重复或成本过高的信息传递路径，使系统在没有获得相应任务收益的情况下产生额外 Token 消耗、工具调用开销和上下文膨胀。与语义冗余关注单条消息内部内容不同，通信边冗余关注“哪些边应当存在、哪些边应当被削弱或剪除”。在工具调用场景中，该问题更加突出，因为一条通信边不仅传递发送方的自然语言推理，还可能传播搜索结果、代码执行结果和文本检查结果等高成本工具观察。

通信边冗余主要可以分为三类。第一类是**空间边冗余**，即同一轮内过密的智能体连接使多个下游节点读取相似或低贡献的上游输出。第二类是**时间边冗余**，即跨轮历史状态被机械传递，导致早期低价值信息在多轮推理中持续占用上下文。第三类是**工具传播冗余**，即外部工具返回的长观察结果沿通信边反复传播，进一步放大模型输入 Token、工具 Token 和推理成本。

2.3.2 通用应对策略

针对通信边冗余，现有方法通常将智能体视为节点、通信链路视为边，并通过图生成、图剪枝和拓扑搜索等方式减少低价值通信路径[48]。这类方法的共同目标是在保持协作收益的同时，使信息只沿更有贡献的边传播。

基于图生成的策略：图生成方法旨在根据任务条件自适应构造通信拓扑，而不是完全依赖人工预设结构。

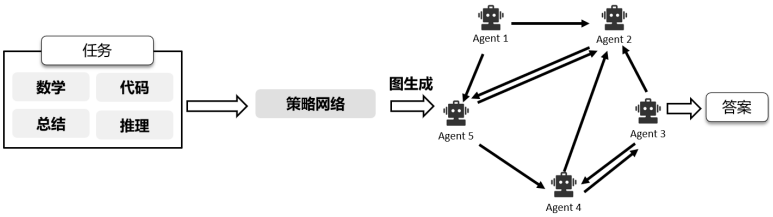


图 2.3　图生成技术示意图

DyLAN（Dynamic LLM-Agent Network）[49]并不预先固定所有智能体之间的通信关系，而是将多智能体协作过程建模为随任务推进变化的前馈式动态网络。其核心机制包括两个阶段：首先在候选智能体集合中进行团队优化，利用 Agent Importance Score 评估不同智能体在当前任务上的边际贡献；随后在任务求解阶段，根据每一轮智能体输出的有效性动态选择后续参与通信的节点。DyLAN 还引入早停机制，当系统已经形成足够稳定的答案或共识时提前终止多轮交互。因此，它降低成本的方式不是压缩单条消息，而是减少低贡献智能体的参与次数、削减无效讨论轮次，并动态生成更贴合当前查询的通信图。

CommFormer[40]将多智能体强化学习中的智能体表示为图节点，将通信信道表示为有向边，并通过可微的图结构学习机制直接优化通信拓扑。其关键做法是对离散边选择进行连续松弛，使邻接矩阵能够参与梯度更新，同时在 Transformer 结构中引入关系增强注意力，以建模智能体间的依赖关系。G-Designer[50]面向 LLM 多智能体系统，将每个智能体的基础模型、角色、状态、工具插件等编码为节点特征，并额外引入任务虚拟节点来表达当前查询需求，随后使用变分图自编码器生成面向特定任务的通信图。MCGD[51]则从多智能体强化学习角度构建稀疏协调图，通过图扩散模型学习有效交互模式，体现了只显式建模关键邻居关系、避免全体智能体两两交互的思路。

基于图剪枝的策略：图剪枝方法通常从密集拓扑出发，逐步删除低贡献节点或通信边，使原本冗余的通信图收敛为更稀疏的协作结构。

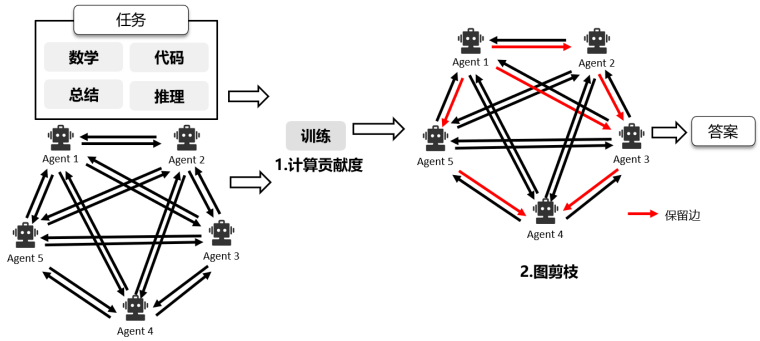


图 2.4　图剪枝技术示意图

AgentPrune[41]将 LLM 多智能体系统表示为空间-时间通信图：同一轮智能体之间的信息交换为“空间边”，跨轮历史传递为“时间边”。它为这些边学习可剪枝的图掩码，并通过系统效用评估器判断不同边对任务结果的贡献。由于外部 LLM 调用和任务评估通常不可微，AgentPrune 使用策略梯度近似优化掩码参数，并最终执行一次性硬剪枝。AgentDropout[52]在边剪枝基础上进一步引入节点丢弃，通过 Node Dropout 和 Edge Dropout 同时减少智能体输入、输出和后续通信边。SafeSieve[53]采用渐进式软剪枝策略，结合 LLM 语义评估、角色互补性和历史任务表现修正边权，并利用聚类机制保持核心功能簇连通性。AGP（Adaptive Graph Pruning）[54]同时进行节点级硬剪枝和边级软剪枝，使系统能够针对不同查询生成不同规模的稀疏拓扑。G-Safeguard[55]则从安全角度构建 multi-agent utterance graph，用于识别异常节点与异常话语，并通过隔离风险节点或剪断高风险外发边阻止恶意信息扩散。

基于拓扑搜索的策略：拓扑搜索通过在智能体算子和通信边构成的庞大空间中探索高效工作流，通常结合强化学习、蒙特卡洛树搜索或网络架构搜索算法。

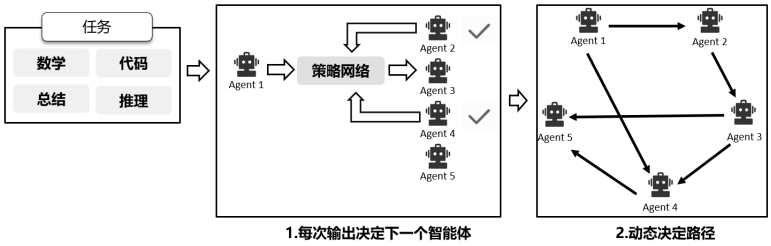


图 2.5　拓扑搜索技术示意图

GPTSwarm[42]将语言智能体系统统一建模为可优化图：节点可以是 LLM 调用、工具或数据处理函数，边表示信息流。它为候选边分配可学习的采样概率，在无环图空间中采样候选拓扑，并通过 REINFORCE 等策略梯度方法根据任务效用更新边概率。AgentConductor[56]面向竞赛级代码生成任务，训练 LLM 为每个问题动态生成 YAML

格式的分层 DAG 拓扑，并根据编译、运行和测试反馈多轮调整拓扑。AFlow[57]将 agentic workflow 表示为可执行代码中的算子组合与依赖关系，并使用蒙特卡洛树搜索探索 Generate、Review、Revise、Ensemble、Test、Programmer 等工作流算子。MASS（Multi-Agent System Search）[58]交错优化 prompt 和 topology，并对低收益模块进行影响力剪枝。MaAS（Multi-agent Architecture Search via Agentic Supernet）[59]提出智能体超网，使每个查询只激活少量算子路径。DynaSwarm[60]则在 GPTSwarm 式参数化通信图基础上引入样本级动态选择，根据输入样本路由到不同稀疏候选结构。

上述研究说明，减少无效节点、无效边和低收益工作流能够显著缓解多智能体系统的通信负担。但现有方法大多将通信边代价近似视为同质，或者主要依据任务效用判断边是否保留，对工具调用场景中“某条边传播了多少工具观察、触发了多少下游上下文膨胀、带来了多少额外调用成本”刻画不足。尤其在搜索、代码执行和文本检查等工具增强任务中，一条边的价值不仅取决于是否提高最终答案，还取决于它是否传播了高成本、低增益的工具信息。因此，本文第四章提出面向通信边冗余的图剪枝算法，将通信边建模为可学习概率，并把任务正确性、工具调用次数、工具返回 Token 和模型输出 Token 共同纳入边级优化目标，从而解决工具调用场景下通信边价值异质、成本难以归因和低贡献边难以及时剪除的问题。

2.4 本章小结

本章围绕多智能体系统及其通信效率优化相关研究进行了梳理。首先，多智能体系统通过角色分工、协作推理和工具调用提升复杂任务处理能力，但也带来了通信路径膨胀和上下文累积问题。其次，语义冗余问题主要表现为角色不匹配、多前驱重复和跨轮历史冗余，现有过滤式与重写式压缩方法为减少自然语言上下文提供了基础，但仍需面向多智能体通信场景进一步适配。最后，通信边冗余问题主要表现为空间边、时间边和工具传播冗余，现有图生成、图剪枝和拓扑搜索方法能够从结构层面降低系统开销，但对工具调用场景下的边级成本归因、工具观察传播和动态低价值边识别仍不充分。上述不足共同构成了本文后续两个工作的主要动机：第三章从语义内容层面提出面向语义冗余的消息压缩框架，第四章从通信结构层面提出面向通信边冗余的图剪枝算法。

3 面向语义冗余的消息压缩框架

3.1 引言

上一章从相关工作角度梳理了多智能体系统、语义冗余问题和通信边冗余问题。可以看到，现有方法虽然能够在一定程度上降低通信开销，但在多智能体协作场景中仍面临三类细粒度语义冗余：发送方完整推理与接收方角色需求不匹配，多个前驱节点传递相似或重复观点，以及多轮历史记忆持续累积导致上下文膨胀。针对这些问题，本章提出面向语义冗余的消息压缩框架，从角色、节点和时序三个维度对通信内容进行压缩，在不改变底层大语言模型能力的前提下提升通信内容的信息密度。

3.2 消息压缩算法

本节首先描述标准多智能体系统的任务执行流程，随后给出消息压缩框架的整体执行过程，并详细介绍角色感知压缩、节点感知聚合和分歧感知压缩三个核心模块。

3.2.1 多智能体系统任务执行流程

多智能体系统通过角色分工与协作推理来完成目标。如图3.1所示，其标准任务执行流程主要包含以下四个核心环节：

1. **任务输入：**接收并标准化外部任务，为智能体构建结构化的上下文环境。
2. **协作推理：**依托预设的通信拓扑，各智能体结合自身角色与前驱节点的历史信息进行多轮次推理，并持续传递中间结果。
3. **结果聚合：**采用投票或共识决策机制，对各智能体的候选答案进行汇总，输出最终可靠结果。
4. **性能评测：**系统性评估模型在任务准确率及通信成本（如词元消耗、推理延迟）上的综合表现。

3.2.2 消息压缩框架执行流程

为解决多智能体协作中的信息冗余问题，本课题在智能体与智能体之间的通信中引入了**消息压缩框架**。该框架从角色、节点和时序三个维度对通信内容进行压缩。

具体执行流程包含以下三个核心步骤：

1. **角色感知压缩：**针对接收方信息需求的不对称性，根据下游角色的具体职责，过

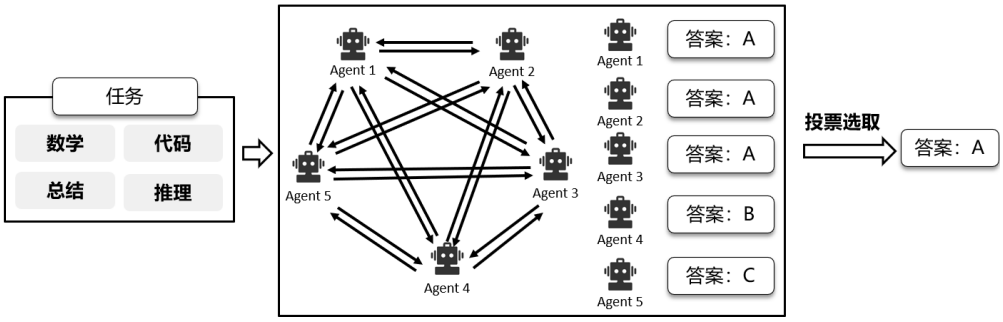


图 3.1　多智能体系统标准任务执行流程示意图

滤前驱智能体消息中的无关推理内容，从而使下游智能体能够获得与自身任务更相关的信息。

2. **节点感知聚合：**针对多个前驱节点可能产生相似推理内容的问题，将不同节点传来的相似推理过程进行去重，避免相同观点在下游智能体上下文中重复出现，从而减少冗余消息传递。

3. **分歧感知压缩：**针对多轮对话记录过长的问题，通过提取历史轮次中的共识与分歧内容，压缩上一轮次传递的信息，并保留有效信息供本轮智能体参考。

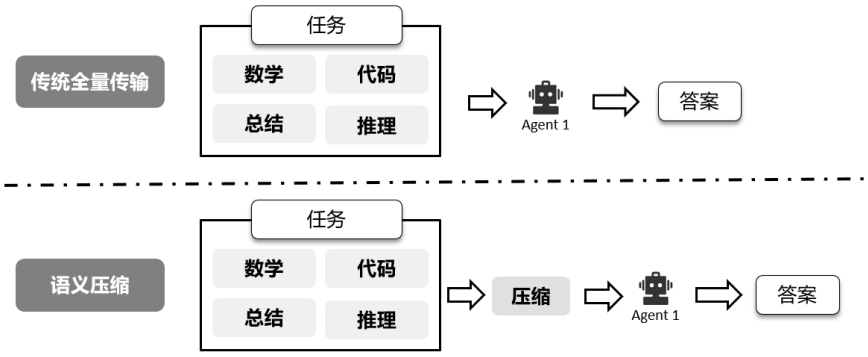


图 3.2　消息压缩框架

3.2.3 功能模块设计

本节介绍消息压缩框架的三个核心模块：角色感知消息压缩、节点感知消息聚合和时序答案一致性摘要。三者分别处理多智能体通信中的三类冗余：第一类是发送方推理内容与接收方角色无关，第二类是多个前驱智能体给出了相似推理，第三类是跨轮历史持续累积导致上下文过长。为避免符号堆叠，本文仅保留必要定义，并重点说明各模块的输入、处理逻辑和输出结果。

设多智能体系统的通信图为 $G = (V, E)$。在第 t 轮中，发送方智能体 u 传递给接

收方智能体 v 的消息表示为

$$m_{u\to v}^{(t)} = (r_u^{(t)}, a_u^{(t)}),$$

其中 $r_u^{(t)}$ 表示推理内容，$a_u^{(t)}$ 表示最终答案。本文的压缩操作主要作用于推理内容 $r_u^{(t)}$，原则上不直接改写答案字段，从而避免压缩过程破坏最终判断。

3.2.3.1 角色感知压缩模块

角色感知压缩模块解决的是“消息是否适合当前接收方”的问题。在多智能体系统中，不同智能体承担的职责不同。例如，负责规划的智能体更需要任务拆解和约束信息，负责验证的智能体更关注候选答案、错误风险和反例。如果发送方的完整推理被直接转发给所有下游节点，接收方会同时看到大量与自身职责无关的内容，既增加 token 成本，也容易稀释真正有用的信息。

该模块的处理流程分为三步。首先，将发送方的推理文本按句子切分，得到若干候选推理片段。其次，将每个句子与接收方角色描述进行语义匹配，匹配分数由文本向量的余弦相似度给出：

$$\text{sim}(s, d_v) = \cos(\phi(s), \phi(d_v)),$$

其中 s 表示候选句子，d_v 表示接收方角色描述，$\phi(\cdot)$ 表示文本编码函数。最后，系统根据同一条消息内部的相似度分布自动确定保留阈值，只保留与接收方角色更相关的句子；若保留文本仍超过角色预算，则按原始顺序截断到预算范围内。

该模块的输出仍然是一条结构化消息：推理字段被替换为筛选后的短文本，答案字段保持不变。这样做的好处是，接收方能够获得更贴近自身职责的上下文，同时不会因为压缩推理过程而丢失发送方给出的最终答案。

3.2.3.2 节点感知聚合模块

节点感知聚合模块解决的是“多个前驱消息之间是否重复”的问题。对于同一个接收方节点，多个上游智能体可能从不同角度得出相近结论，也可能在推理过程中反复陈述同一事实。如果将这些内容直接拼接，下游节点会接收到大量重复表达，导致上下文变长，但信息增量有限。

该模块会先收集接收方节点所有前驱智能体的压缩后推理句子，并为每个句子保留来源角色标签。随后，系统按照句子出现顺序逐一检查候选内容：若当前句子与已

保留句子的语义相似度高于冗余阈值，则认为它提供的信息已经被覆盖，不再重复加入；若相似度低于阈值，则将其作为新的有效信息保留。本文实现中，冗余判定阈值取 0.70，用于在“去重”和“保留多样观点”之间取得平衡。

聚合后的推理内容由若干带角色标签的句子组成。角色标签的作用是保留信息来源，使下游智能体不仅知道“有哪些观点被保留”，也能知道“这些观点来自哪个角色”。对于多个前驱节点给出的答案，模块采用简单投票生成聚合答案；若出现票数接近或无法明确多数的情况，则保留多个候选答案及其来源，交由后续节点继续判断。

通过该模块，系统不再把多个前驱消息拼接，而是先做跨节点去重和来源标注。这样既能减少重复 token，也能提高下游上下文的信息密度。

3.2.3.3 分歧感知压缩模块

分歧感知压缩模块解决的是“跨轮历史如何保留”的问题。多智能体协作通常需要多轮执行，如果每一轮都完整保存所有智能体的推理和答案，历史记忆会快速膨胀。过长的历史不仅增加推理成本，还可能使模型在后续轮次中难以抓住当前最关键的共识和分歧。

该模块在每一轮协作结束后运行。系统首先收集本轮所有智能体的答案，并对答案文本进行规则化处理，例如去除多余空格、统一大小写、去掉常见答案前缀和标点。经过规则化后，表达相同含义的答案会被归入同一个答案组。基于答案组数量，系统生成两类摘要。

当所有智能体的答案归入同一组时，说明本轮协作已经形成共识。此时摘要只保留共识答案，以及最能代表该结论的简短理由。代表理由通常来自推理内容较完整的智能体，并只保留核心句子，避免把完整推理链再次写入历史。

当答案被分成多个组时，说明智能体之间仍存在分歧。此时摘要会记录每个候选答案、支持该答案的智能体数量，以及对应的简短理由。这样，下一轮智能体能够直接看到当前争议点，而不需要重新阅读上一轮所有冗长输出。

最终生成的摘要会写入各智能体的历史记忆，作为下一轮推理的压缩上下文。该模块只依赖规则化文本处理、答案分组和简短摘要模板，不额外调用大语言模型，因此能够在控制成本的同时保留跨轮协作中最重要的信息。

3.3 实验设置

目前，消息压缩框架实现已完成，我们在一些数据集中进行了实验，在本章节中将会展示已经完成的实验结果，并给出对应结果的分析。

3.3.1 数据集

为全面客观地评估模型能力，本文从多智能体系统领域广泛认可的 6 个数据集，涵盖综合知识、数学推理和代码生成三个核心能力维度。具体任务特征与选取依据如表3.1所示。

任务类型	数据集名称	描述	样本数量
综合知识	MMLU[61]	涵盖 57 个不同学科的综合性基准	153
数学推理	GSM8K[62]	小学数学应用题数据集	1319
	AQuA[63]	复杂的代数应用题	254
	MultiArith[64]	多步算术运算	600
	SVAMP[65]	语义和扰动生成的数学题	1000
代码生成	HumanEval[66]	生成完整 Python 代码	164

表 3.1　实验评测数据集概览

3.3.2 对比基准

实验设置了四类对比基准。首先是 Direct 方法，即单智能体直接完成任务，不引入智能体间通信，用于衡量单模型基础能力和最低推理成本。其次是 Fullconnect 方法，上游智能体生成的原始输出直接、完整地透传给下游智能体，不进行任何截断，从而保留完整上下文内容，代表多智能体通信开销的上限及任务基础性能的对照标准。第三是 AgentPrune 方法，作为当前多智能体系统拓扑优化的代表性方法，该基线对智能体间的通信边进行剪枝。最后是本文方法，即引入本文设计的消息压缩模块，在智能体交互前对冗长推理和弱相关背景进行压缩，仅保留与后续推理更相关的关键信息。

3.3.3 实现细节

为了保证实验结论的客观性与普适性，本文选取三个主流大语言模型作为多智能体的基座模型。这些模型在 API 调用成本上存在显著差异，具体计费标准如表3.2所

示。

模型名称	输入价格（千 tokens）	输出价格（千 tokens）
Qwen2.5-14B-Instruct	¥0.0007	¥0.0007
Qwen3-14B	¥0.0005	¥0.0020
MinMax-M3	¥0.0021	¥0.0084

表 3.2　API 调用单价对比表

Qwen2.5-14B-Instruct：作为 24 年开源指令模型的代表，其在通用问答、指令遵循与文本生成等任务中表现出较高的稳定性。本研究将其设为基础对照组，旨在与 Qwen3-14B 形成严格的控制变量（参数量级一致）。通过引入该对照组，重点考察在缺乏新一代推理与指令优化机制的前提下，消息压缩策略对任务生成质量、词元（Token）消耗及调用成本的具体影响。

Qwen3-14B：作为中等规模参数开源模型的代表，该模型在推理效率、部署成本与基础性能之间实现了较优的平衡。结合表3.2数据可知，其 API 调用成本相对低廉。选取该模型旨在探究消息压缩策略在低成本、常规算力约束下，对实际任务效能及经济成本的优化潜力。

MinMax-M3：引入该闭源商业模型旨在拓展实验基座的架构多样性，并构建高成本模型对照场景。鉴于其 API 调用费率显著较高（输入与输出单价约为 Qwen3-14B 的 4 倍以上），在处理长文本任务时极易产生高昂的边际成本。选取该模型旨在验证消息压缩策略在面对高资源消耗型商业大模型时，能否有效降低计算冗余并实现显著的成本缩减。

在所有实验中，均采用相同的系统提示词、智能体数量、超参数以及数据集划分，以确保实验结果的可比性。

3.3.4 评估指标

本文主要从任务完成质量与通信成本两个维度，选取了以下两项核心评价指标：

准确率 (Accuracy,)：衡量模型完成任务的有效性。针对 MMLU 及四项数学推理数据集（GSM8K、AQuA、MultiArith、SVAMP），提取模型最终输出的答案与标准答案进行精确匹配以计算正确率；对于 HumanEval 代码生成数据集，则以测试用例的通过率（Pass@1）作为准确率进行评估。

词元花费 (Token Cost)：衡量多智能体通信过程中的经济开销。具体统计系统在完成单次完整任务时，所消耗 token 的价格。

3.4 实验结果与分析

本阶段实验在 MMLU、GSM8K、AQuA、MultiArith、SVAMP 和 HumanEval 六个数据集上展开，覆盖通用知识理解、数学推理、多项选择推理和代码生成等不同任务类型。实验对比了 Direct、Fullconnect、Agentprune 和本文方法。

为保证总体结果统计的可解释性，本文在主实验中选取 MiniMax-M3、Qwen3-14B 和 Qwen2.5-14B-Instruct 作为主要分析模型，并按模型分别计算其在可用数据集上的平均表现。其中 MiniMax-M3 和 Qwen3-14B 覆盖 MMLU、GSM8K、AQuA、MultiArith、SVAMP 和 HumanEval 六个数据集；Qwen2.5-14B-Instruct 目前覆盖除 GSM8K 外的五个数据集。总体实验不将所有模型和数据集混合为单一平均值，而是分别展示三个模型下不同方法的平均表现，以避免模型覆盖范围不同带来的统计偏差。

3.4.1 任务准确率结果

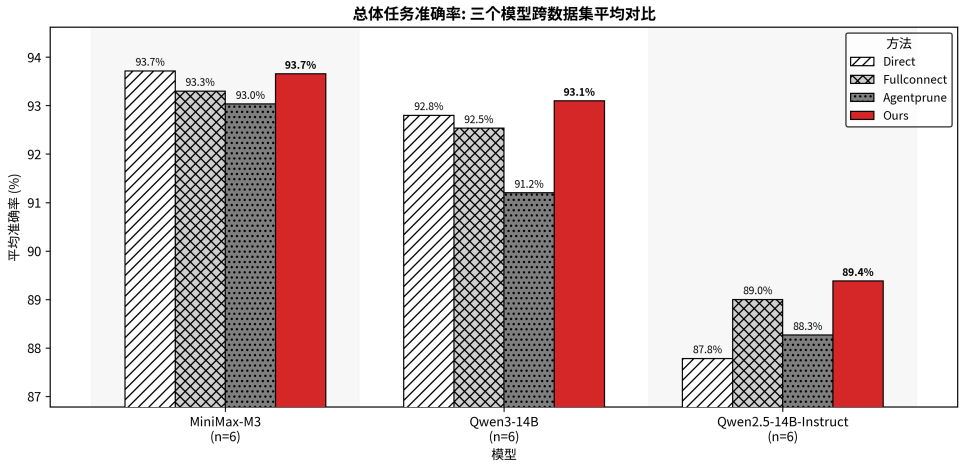
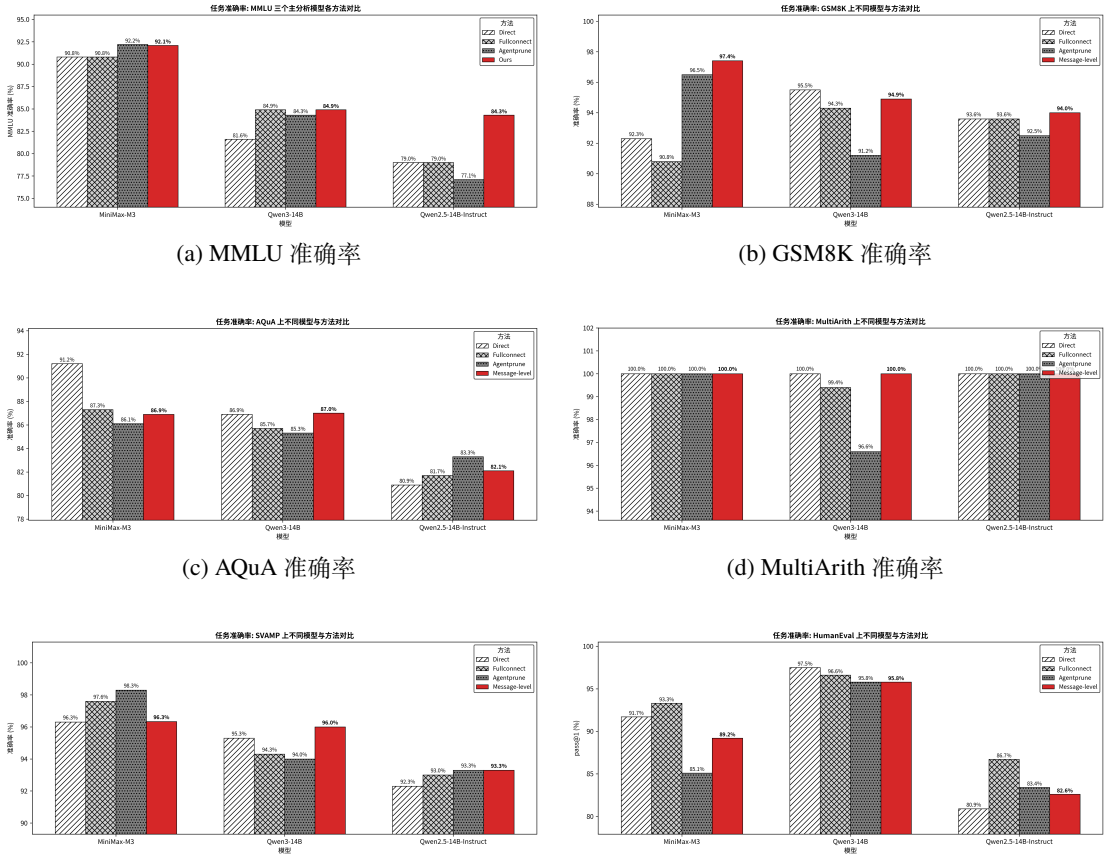


图 3.3　六个数据集在不同模型下的平均准确率对比

图3.3展示了三个主要模型在不同方法下的跨数据集平均准确率。整体来看，本文方法在 Qwen3-14B 和 Qwen2.5-14B-Instruct 上均取得最高平均准确率，在 MiniMax-M3 上与 Direct 方法基本持平，同时高于 Fullconnect 和 Agentprune。这说明本文方法在不同模型能力水平下均具有较好的稳定性，尤其在中小规模模型上能够带来更明显的性能收益。

具体而言，在 Qwen3-14B 上，本文方法的平均准确率达到 93.10%，高于 Direct 的 92.80%、Fullconnect 的 92.53% 和 Agentprune 的 91.20%。在 Qwen2.5-14B-Instruct 上，本文方法的平均准确率为 88.46%，高于 Direct 的 86.62%、Fullconnect 的 88.08% 和 Agentprune 的 87.42%。在 MiniMax-M3 上，Direct 方法的平均准确率为 93.72%，本文方法为 93.66%，二者差距仅为 0.06 个百分点，基本处于同一水平；同时，本文方法仍高于 Fullconnect 和 Agentprune。

为了避免总体平均掩盖不同任务类型的差异，下面进一步按数据集展开分析。总体上，本文方法在 MMLU、GSM8K、MultiArith 和 SVAMP 上表现较强，在 AQuA 和 HumanEval 上则呈现出更明显的任务依赖性，说明消息级协作更适合知识理解和数学推理类任务，而在多项选择干扰项较强或代码生成需要执行反馈的任务中仍有改进空间。



(a) MMLU 准确率

(b) GSM8K 准确率

(c) AQuA 准确率

(d) MultiArith 准确率

(e) SVAMP 准确率

(f) HumanEval 准确率

图 3.4　各数据集上不同模型与方法的准确率对比

MMLU 在 MMLU 数据集上，本文方法整体表现较为稳定。在主分析的三个模型中，本文方法的平均准确率为 87.10%，高于 Direct 的 83.80%、Fullconnect 的 84.90% 和 Agent-

prune 的 84.53%。其中，Qwen2.5-14B-Instruct 的提升最明显，本文方法达到 84.30%，相比 Direct 和 Fullconnect 均提升 5.30 个百分点，相比 Agentprune 提升 7.20 个百分点。Qwen3-14B 上，本文方法达到 84.90%，与 Fullconnect 持平，并高于 Direct 和 Agentprune。MiniMax-M3 上，本文方法为 92.10%，与 Agentprune 的 92.20% 基本持平，并高于 Direct 和 Fullconnect。

GSM8K 在该数据集上，本文方法在两个可用模型上的平均准确率为 96.16%，高于 Direct 的 93.90%、Fullconnect 的 92.55% 和 Agentprune 的 93.85%。其中，MiniMax-M3 使用本文方法达到 97.41%，分别高于 Direct、Fullconnect 和 Agentprune 5.11、6.61 和 0.91 个百分点，说明消息级协作能够增强复杂算术推理中的答案鲁棒性。Qwen3-14B 上，Direct 方法为 95.50%，略高于本文方法的 94.90%；但本文方法仍高于 Fullconnect 和 Agentprune，说明在该模型上协作信息需要进一步控制以避免轻微干扰。

AQuA 在 AQuA 数据集上，结果更具任务依赖性。三个模型上，本文方法的平均准确率为 85.33%，低于 Direct 的 86.33%，但高于 Fullconnect 和 Agentprune 的 84.90%。分模型看，Qwen3-14B 使用本文方法达到 87.00%，为该模型下最高结果，相比 Direct、Fullconnect 和 Agentprune 分别提升 0.10、1.30 和 1.69 个百分点；Qwen2.5-14B-Instruct 上，本文方法为 82.10%，高于 Direct 和 Fullconnect，但低于 Agentprune；MiniMax-M3 上，Direct 方法达到 91.20%，明显高于其他协作方法。这说明多项选择推理任务中，额外消息可能同时带来有用信息和干扰信息，需要更强的任务自适应筛选。

MultiArith 在 MultiArith 数据集上，各方法整体接近饱和。本文方法在三个主分析模型上均达到 100.00%，与 Direct 的平均表现持平，并高于 Fullconnect 的 99.80% 和 Agentprune 的 98.87%。其中，Qwen3-14B 上 Fullconnect 为 99.40%、Agentprune 为 96.60%，而本文方法保持 100.00%，说明在较简单的算术推理任务中，消息级协作至少不会破坏已有推理能力，并能够避免部分结构化协作方法带来的性能波动。

SVAMP 相比 MultiArith，SVAMP 更强调语义理解和问题变体。三个主分析模型上，本文方法的平均准确率为 95.21%，与 Agentprune 的 95.20% 基本持平，并高于 Direct 的 94.63% 和 Fullconnect 的 94.97%。其中，Qwen3-14B 使用本文方法达到 96.00%，高于 Direct、Fullconnect 和 Agentprune；Qwen2.5-14B-Instruct 上，本文方法达到 93.30%，与 Agentprune 持平；MiniMax-M3 上，Agentprune 达到 98.30%，高于本文方法的 96.33%。这说明本文方法在中小规模模型上的收益更明显，而强模型在部分任务上对协作结构的敏感性更高。

HumanEval 在 HumanEval 数据集上，本文方法并未取得最优平均结果。三个主分析模型中，Fullconnect 的平均准确率为 92.20%，Direct 为 90.03%，本文方法为 89.20%，Agentprune 为 88.10%。分模型看，MiniMax-M3 和 Qwen2.5-14B-Instruct 上 Fullconnect 表现最好，Qwen3-14B 上 Direct 表现最好；本文方法在 MiniMax-M3 上高于 Agentprune，在 Qwen3-14B 上与 Agentprune 持平，在 Qwen2.5-14B-Instruct 上高于 Direct 方法 1.70 个百分点但低于 Fullconnect。该结果说明，对于代码生成任务，仅依赖消息级协作可能不足以替代代码执行、单元测试或错误反馈机制，后续应将消息筛选与可执行验证结合起来。

3.4.2 成本对比实验结果

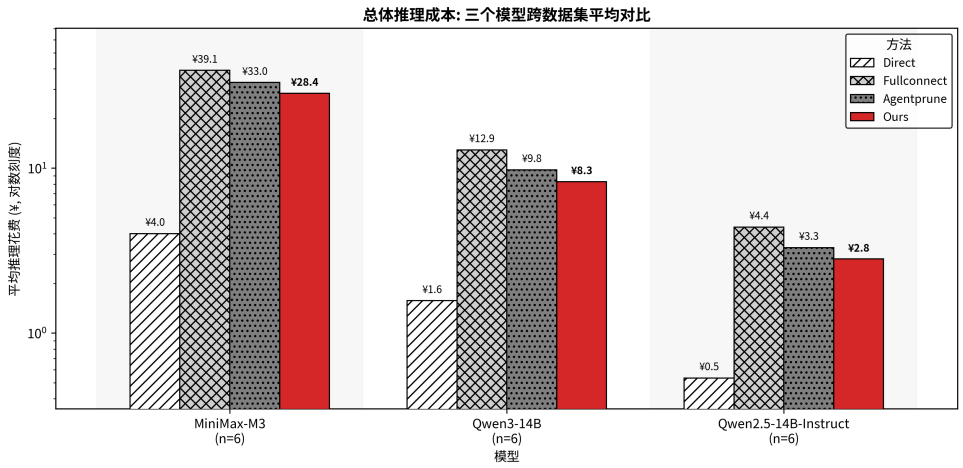
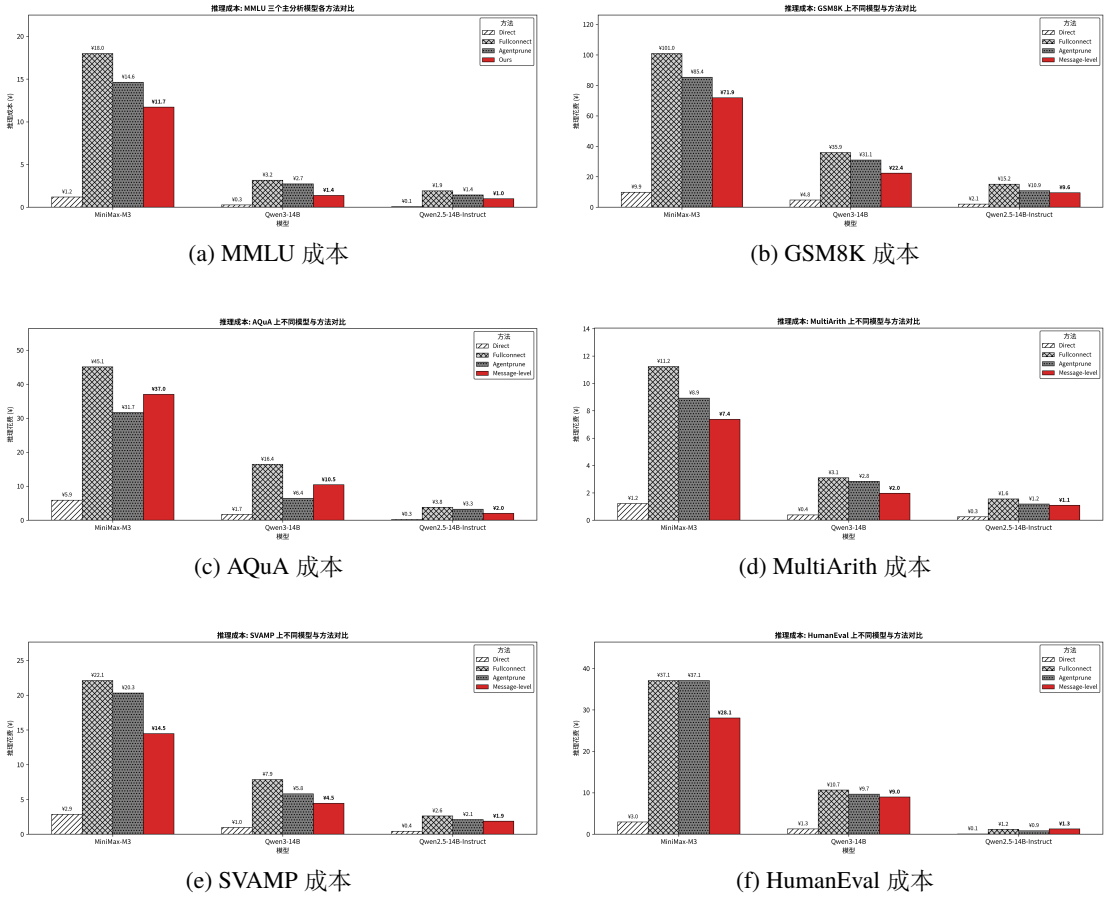


图 3.5　六个数据集在不同模型下的平均推理成本对比

图3.5展示了三个主要模型在不同方法下的跨数据集平均推理成本。Direct 方法由于不引入智能体间通信，具有最低推理成本；Fullconnect 方法虽然提供了最充分的信息交互，但也带来了最高的通信开销。相比之下，本文方法通过消息粒度的信息筛选减少冗余通信，只保留对最终推理有帮助的关键信息，因此在多数数据集上能够显著降低推理成本。

相比 Fullconnect，本文方法在 MMLU 上的平均成本降低约 38.83%，在 GSM8K 上降低约 31.10%，在 SVAMP 上降低约 36.19%，在 MultiArith 上降低约 34.31%，在 HumanEval 上降低约 21.65%。AQuA 上本文方法相比 Fullconnect 仍降低约 24.23%，但相对 Agentprune 的成本优势不明显，说明在部分多项选择任务中，消息筛选策略仍有进一步优化空间。



(a) MMLU 成本　(b) GSM8K 成本

(c) AQuA 成本　(d) MultiArith 成本

(e) SVAMP 成本　(f) HumanEval 成本

图 3.6　各数据集上不同模型的推理成本比较

图3.6进一步展示了各数据集上的成本差异。Direct 方法消耗最低，但缺少多智能体之间的信息交互；Fullconnect 方法在各数据集上普遍带来更高成本，反映出全连接通信结构的 token 显著增加的问题；Agentprune 能够通过剪枝降低部分开销，但不同任务上的成本和准确率表现仍存在波动。相比之下，本文方法通常能够在保留任务准确率的同时降低 Fullconnect 带来的额外成本，体现出更好的综合性价比。

3.4.3 结果分析

综合六个数据集的细分结果可以看出，本文方法的优势更适合概括为在多数任务和模型上提升或保持准确率，而不是在所有单项任务上绝对最优。尤其在 MMLU、GSM8K、MultiArith 和 SVAMP 上，本文方法体现出较好的稳定性；而在 AQuA 和 HumanEval 上，不同任务类型对协作信息的需求差异更明显，说明后续需要根据任务类型、模型能力和推理不确定性动态调整消息筛选强度。

综上，本文方法的目标在多智能体协作场景下实现更合理的准确率–成本平衡。实验结果表明，消息级协作能够在减少冗余通信的同时保持多智能体推理收益，为构

建更高效的多智能体大模型推理系统提供了一种可行方向。

3.5 本章小结

本章围绕多智能体系统中的语义冗余问题，提出并实现了面向语义冗余的消息压缩框架。首先，本文分析了标准多智能体任务执行流程中的消息传递瓶颈，并将压缩模块嵌入智能体之间的通信链路；其次，分别设计了角色感知压缩、节点感知聚合和分歧感知压缩三个模块，以减少无关推理、重复观点和跨轮历史累积带来的上下文开销；最后，通过多个知识理解、数学推理和代码生成数据集上的实验，验证了该方法能够在多数任务中保持或提升准确率，并显著降低相对于完全通信拓扑的推理成本。

实验结果表明，消息级压缩能够在不改变底层基座模型的前提下改善多智能体协作的准确率–成本平衡，为后续进一步研究任务自适应压缩强度、压缩模块消融分析以及与拓扑剪枝方法的联合优化提供了基础。

4 面向通信边冗余的图剪枝算法

4.1 引言

上一章从语义内容出发，研究了如何在多智能体系统内部压缩智能体之间传递的自然语言消息。然而，在更复杂的工具调用场景中，仅压缩消息内容仍不足以解决全部通信成本问题。随着大语言模型智能体逐步具备搜索、代码执行、文本检查和外部 API 调用能力[17-18]，多智能体系统的成本不再只来自模型输入输出 Token，还来自工具调用次数、工具返回内容长度以及工具观察结果在智能体之间的重复传播。

工具调用型智能体通常遵循 “推理–行动–观察” 的闭环过程[23]：智能体先根据任务生成中间推理，再决定是否调用搜索、代码执行或文本检查等外部工具，随后把工具返回结果写入上下文并继续推理。在单智能体系统中，工具观察主要影响当前智能体的上下文长度；而在多智能体系统中，某个智能体产生的工具观察还可能沿通信边传播给多个后继智能体，进而触发下游重复分析或二次工具调用。因此，工具调用成本具有明显的图结构放大效应。

在这类场景下，通信边的价值具有更强的异质性。一条边如果连接的是高质量求解智能体和最终验证智能体，可能显著提升任务正确率；但如果该边只是传播冗长的工具观察、重复的中间代码或无关搜索结果，就会增加下游上下文长度，并进一步放大系统开销。因此，面向工具调用任务的通信优化需要同时回答两个问题：第一，哪些智能体之间的通信确实有助于最终任务正确性；第二，哪些通信边会携带高成本工具信息，应当在图结构层面被抑制或剪除。

现有多智能体通信图优化方法通常将边的重要性与任务效用直接关联[41-42]，但较少显式区分普通推理输出和工具调用输出。本文第二个工作点针对这一不足，提出一种面向通信边冗余的图剪枝算法。该方法将智能体通信边建模为可学习概率，在训练过程中结合任务正确性、模型输出 Token、工具调用次数和工具返回 Token 构造边级优化目标；进一步引入 Taylor 一阶重要性评估[67]，对低贡献通信边进行动态剪枝，从而在多轮推理中获得更稀疏、成本更可控的通信结构。

4.2 图剪枝算法

4.2.1 工具调用场景建模

考虑一个由 n 个智能体组成的多智能体系统。每个智能体既可以直接基于大语言模型生成推理结果，也可以根据任务需要调用外部工具。系统通信图包含两类边：同一轮内部的空间边和跨轮历史传递的时间边。空间边表示同一轮中智能体输出向后继智能体传递，时间边表示上一轮智能体状态或记忆向下一轮传递。

设第 t 轮中智能体 i 的输出为

$$o_i^{(t)} = (r_i^{(t)}, a_i^{(t)}, q_i^{(t)}), \tag{4.1}$$

其中 $r_i^{(t)}$ 表示推理文本，$a_i^{(t)}$ 表示候选答案，$q_i^{(t)}$ 表示工具调用相关信息。工具调用信息进一步包含工具名称、调用参数、返回观察和调用轮次等元数据。为衡量工具调用带来的通信负担，本文统计三类开销：

$$c_i^{(t)} = \lambda_o \frac{O_i^{(t)}}{N_o} + \lambda_k \frac{K_i^{(t)}}{N_k} + \lambda_z \frac{Z_i^{(t)}}{N_z}, \tag{4.2}$$

其中 $O_i^{(t)}$ 表示智能体 i 在第 t 轮的模型输出 Token 数，$K_i^{(t)}$ 表示工具调用次数，$Z_i^{(t)}$ 表示工具观察结果 Token 数；N_o、N_k 和 N_z 分别为输出 Token、工具调用次数和工具 Token 的归一化系数，$\lambda_o, \lambda_k, \lambda_z$ 为三类开销的权重。该设计将工具调用带来的额外系统消耗显式纳入通信图优化过程。

与普通多智能体推理不同，工具调用场景下的边成本取决于发送方智能体，而不仅取决于接收方。若一条边 $e = (i, j)$ 被选中，则接收方 j 会读取发送方 i 的当前轮输出或上一轮记忆，因此该边会间接携带发送方的模型输出和工具观察成本。基于这一点，本文将边级成本定义为发送方成本在所选通信路径上的归因：

$$\mathcal{C}_e^{(t)} = \mathbf{1}(z_e^{(t)} = 1) c_i^{(\tau_e)}, \tag{4.3}$$

其中 $z_e^{(t)}$ 表示边 e 在第 t 轮是否被采样并实际加入通信图；τ_e 表示成本归因对应的发送方轮次。对于空间边，$\tau_e = t$；对于时间边，$\tau_e = t - 1$。该处理能够区分 “当前轮输出传播” 和 “历史记忆传播” 两种成本来源，使跨轮通信边不会错误归因到接收轮次的工具调用。

4.2.2 可学习通信边概率建模

本文将每条潜在通信边 e 关联一个可学习参数 θ_e。在每轮图构造时，边的保留概率由 Sigmoid 函数给出：

$$p_e = \sigma\left(\frac{\theta_e}{\tau}\right), \tag{4.4}$$

其中 τ 为温度系数。随后按照伯努利分布采样边状态：

$$z_e \sim \text{Bernoulli}(p_e). \tag{4.5}$$

当 $z_e = 1$ 且该边不会破坏空间有向无环执行顺序时，系统将发送方加入接收方的前驱节点集合；当 $z_e = 0$ 时，该边不参与本轮通信。

为了同时支持单图结构和多轮动态图结构，本文分别为全局空间边、全局时间边以及逐轮空间/时间边维护可学习 logit 参数。对于非动态图设置，所有轮次共享同一组空间边和时间边概率；对于动态图设置，每一轮维护独立的空间边概率，跨轮传递则维护对应轮间的时间边概率。这样，系统既可以学习一个全局稀疏通信结构，也可以针对不同推理阶段学习不同通信结构。

在训练过程中，系统记录每条被采样或未采样边的对数概率 $\log \pi_\theta(z_e)$。这些对数概率构成后续策略梯度优化目标的可导部分，使任务正确性和工具成本能够反向影响通信边概率。若某条边长期带来高任务收益且成本可控，其参数 θ_e 会被优化为更高概率；若某条边经常携带高成本工具输出但对最终结果贡献有限，其概率会逐步下降，并在剪枝阶段被移除。

4.2.3 成本感知优化目标

给定一个任务样本 x 及其标准答案 y，多智能体系统输出最终答案 $\hat{y}$。本文使用任务评分函数 $S(\hat{y}, y)$ 衡量正确性，其取值范围为 $[0, 1]$。对于数学题和选择题，该函数通常对应答案是否匹配；对于开放问答任务，则可采用规范化匹配、别名匹配或任务专用评测器。

传统通信图优化通常以任务正确性作为边策略的主要奖励。本文在此基础上引入工具成本惩罚，定义边级效用为

$$R_e^{(t)} = S(\hat{y}, y) - \mathcal{C}_e^{(t)}. \tag{4.6}$$

该式表示：一条通信边只有在能够提高最终任务得分、且不引入过高工具成本时，才应当获得较高效用。对于未被采样的边，工具成本项为 0，其对数概率仍参与策略学习；对于被采样的边，系统根据发送方在对应轮次的输出 Token、工具调用次数和工具 Token 计算成本惩罚。

由于边采样是离散操作，本文采用策略梯度形式优化边概率。对于一次任务执行中记录到的所有边采样事件，边策略损失定义为

$$\mathcal{L}_{\text{pg}} = -\sum_{(e,t)\in\mathcal{E}_{\text{sample}}} \log \pi_\theta(z_e^{(t)}) R_e^{(t)}. \tag{4.7}$$

该损失鼓励系统提高高效用边的采样概率，同时降低低效用边的采样概率。与只在样本级统一扣除工具成本不同，边级成本归因能够区分不同发送方智能体的工具使用情况，使优化过程更精细。例如，若某一代码执行智能体频繁调用工具且产生较长观察结果，但其输出对最终答案帮助有限，则与该智能体相关的出边会获得更低边级效用。

此外，为避免通信图退化为过密结构，本文沿用图结构正则项约束学习到的边参数。设 Θ_s 和 Θ_t 分别为空间边与时间边 logit 矩阵，A_s 和 A_t 分别为初始固定拓扑对应的掩码矩阵，则正则项为

$$\mathcal{L}_{\text{reg}} = \|\Theta_s\|_* + \|\Theta_t\|_* + \text{ReLU}(\|A_s - \Theta_s\|_F - \delta) + \text{ReLU}(\|A_t - \Theta_t\|_F - \delta), \tag{4.8}$$

其中 $\|\cdot\|_*$ 表示核范数，$\|\cdot\|_F$ 表示 Frobenius 范数，δ 为允许偏离初始拓扑的边界。最终优化目标为

$$\mathcal{L} = \mathcal{L}_{\text{pg}} + \mathcal{L}_{\text{reg}}. \tag{4.9}$$

4.2.4 Taylor 一阶重要性剪枝

在边概率训练过程中，仅依赖 logit 大小剪枝可能存在偏差：某些边的当前概率不高，但其梯度较大，说明继续优化可能显著影响任务目标；另一些边虽然概率不低，但梯度接近零，说明其对当前目标的边际影响有限。为更准确地评估边的重要性，本文引入 Taylor 一阶近似。

对于边参数 θ_e，若将其移除可近似看作对参数施加扰动 $\Delta\theta_e = -\theta_e$，则损失变化

的一阶近似为

$$\Delta\mathcal{L}_e \approx \frac{\partial\mathcal{L}}{\partial\theta_e}\Delta\theta_e. \tag{4.10}$$

因此，本文定义边重要性为

$$I_e = \left|\theta_e \frac{\partial\mathcal{L}}{\partial\theta_e}\right|. \tag{4.11}$$

该指标同时考虑边当前参数规模和目标函数梯度，能够刻画移除该边对优化目标的一阶影响。训练过程中，在完成一次反向传播后，系统对仍处于活跃状态的边计算 I_e，并按重要性从小到大排序，剪除比例为 ρ 的低重要性边：

$$\mathcal{P} = \text{argmin}_{\mathcal{S}\subseteq\mathcal{E}_{\text{active}},\,|\mathcal{S}|=\rho|\mathcal{E}_{\text{active}}|} \sum_{e\in\mathcal{S}} I_e. \tag{4.12}$$

剪枝后，边掩码被置为 0，后续图构造不再采样这些边。

Taylor 剪枝具有两个优点。首先，它与工具成本感知损失直接耦合，因此剪枝结果会同时反映任务正确性和工具调用成本，而不是只根据通信概率大小做静态排序。其次，它可以自然扩展到多轮动态图设置：系统可分别对每一轮的空间边和时间边计算重要性，从而在不同推理阶段形成不同稀疏结构。

4.2.5 训练与执行流程

本文方法的整体流程如下：

1. **初始化潜在通信图：**根据智能体数量和初始拓扑生成空间边与时间边掩码，并为每条潜在边初始化可学习 logit。

2. **采样通信结构：**在每轮推理开始时，根据公式4.4和公式4.5采样空间边和时间边，构造当前任务的实际通信图。

3. **执行工具增强推理：**每个智能体读取前驱消息和历史记忆，根据提示词决定是否调用工具，并生成最终输出。系统记录模型输出 Token、工具调用次数和工具观察 Token。

4. **计算边级效用：**根据任务答案评分得到基础正确性奖励，并将发送方工具成本归因到被选中的通信边，形成公式4.6中的边级效用。

5. **更新边概率：**使用公式4.9进行反向传播，更新空间边和时间边 logit。

6. **周期性 Taylor 剪枝：**每隔固定训练轮次，根据公式4.11计算活跃边重要性，剪除

低重要性边，更新通信掩码。

7. **评估稀疏图：**在验证集或测试集上运行剪枝后的通信图，统计任务准确率、工具调用次数、工具 Token、模型 Token 成本和图稀疏率。

在实现上，本文方法通过`--tool_aware_loss`开启工具成本感知训练，通过`--taylor_prune`开启 Taylor 一阶剪枝。训练代码在每次图构造时记录空间边与时间边的采样状态、边索引、发送方、接收方、轮次和对数概率；评估代码则按样本、智能体和轮次统计模型 Token 与工具调用元数据。当前实现中，输出 Token、工具调用次数和工具 Token 的惩罚权重分别设为 0.05、0.10 和 0.10，Token 与工具调用次数归一化系数分别设为 10000 和 10；Taylor 剪枝默认每 2 轮训练触发一次，每次剪除 10% 的活跃边。

训练入口已接入 AIME、GAIA、GPQA、HLE、MATH500、MuSiQue 和 BigCodeBench 等工具调用任务。其中 AIME 和 MATH500 默认启用搜索与代码执行工具，BigCodeBench 默认启用代码生成工具，GAIA、GPQA 和 HLE 等开放问答或专家问答任务则可同时启用搜索、代码执行和文本检查工具。

4.3 实验设置

为验证本文方法在工具调用场景下的有效性，实验选取 Qwen3-14B 和 MiniMax-M3[43]作为基座模型，并在多个需要外部工具辅助的基准任务上进行评测。其中，Qwen3-14B 覆盖 AIME、GAIA、GPQA、HLE、MATH500、MuSiQue 和 BigCodeBench 七个工具任务；MiniMax-M3 覆盖 AIME、GAIA、GPQA、HLE 和 MuSiQue 五个代表性任务，用于观察更强闭源模型下面向通信边冗余的图剪枝效果。对比方法包括：

- **DirectAnswer：**单智能体直接回答，可选择是否启用工具。
- **FullConnected：**多智能体完全连接通信，所有智能体输出均可被后续智能体读取。
- **AgentPrune：**基于可学习通信边和图剪枝的多智能体通信优化方法。
- **本文方法：**在 AgentPrune 基础上加入工具成本感知边级损失，并使用 Taylor 一阶重要性进行动态剪枝。

实验主要关注三类指标。第一类是任务完成质量，使用准确率或任务专用评分函数衡量；第二类是工具使用成本，包括工具调用次数和工具返回 Token 数；第三类是通信图成本，包括空间边与时间边稀疏率，以及模型输入输出 Token 和 API 调用成本。表中成本均为测试阶段推理成本，由输入 Token、输出 Token 及对应模型 API 价格计

算得到；对于需要训练通信边概率的 AgentPrune 和本文方法，训练阶段成本另行记录，不并入测试阶段成本。由于工具调用会影响后续智能体上下文长度，本文同时统计工具成本和模型 Token 成本，以便分析二者之间的耦合关系。

表 4.1　工具调用实验任务与默认工具配置

数据集	任务类型	默认工具	主要评价指标
AIME[68]	数学竞赛推理	Web 搜索、代码生成	数值答案准确率
GAIA[69]	开放问答	Web 搜索、代码生成、文本检查	问答匹配准确率
GPQA[70]	多项选择专家问答	Web 搜索、代码生成、文本检查	选项准确率
HLE[71]	高难专家问答	Web 搜索、代码生成	问答匹配准确率
MATH500[72]	数学推理	Web 搜索、代码生成	规范化答案准确率
MuSiQue[73]	多跳问答	Web 搜索、代码生成	问答匹配准确率
BigCodeBench[74]	代码生成	代码生成	代码通过率

4.4 实验结果与分析

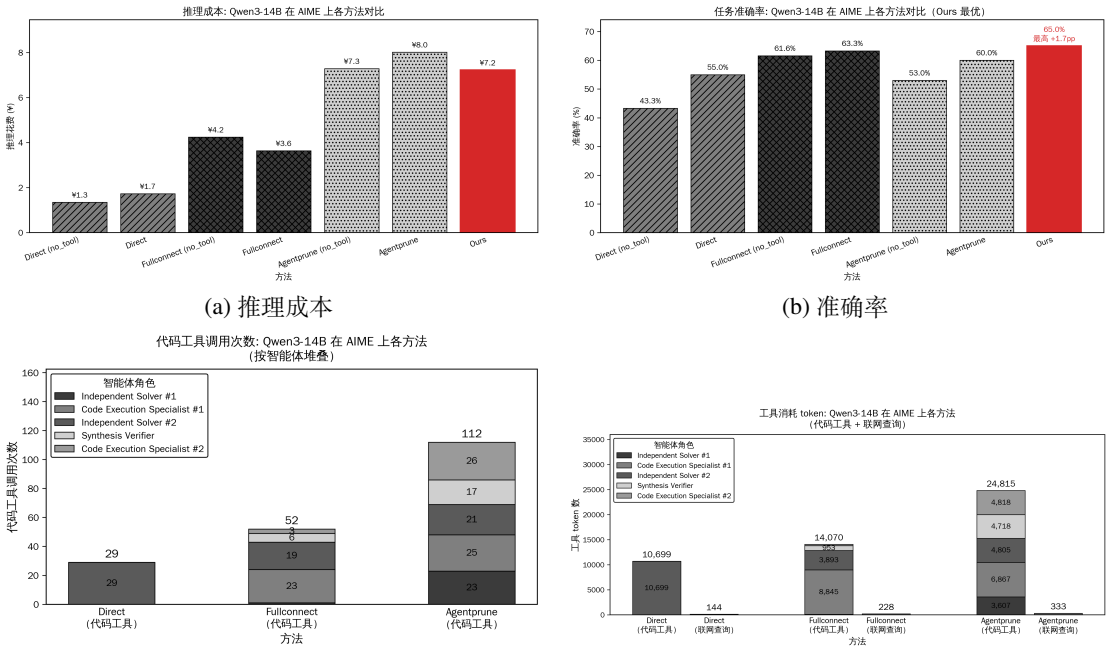
4.4.1 Qwen3-14B 整体结果

表4.2展示了 Qwen3-14B 在七个工具调用任务上的主要结果。每个单元格以“准确率/推理成本” 形式展示。总体来看，本文方法在七个任务上的平均准确率为 40.93%，略高于 FullConnected+Tools 的 40.49% 和 AgentPrune+Tools 的 40.40%；平均推理成本为 5.18，高于 FullConnected+Tools 的 4.61，但与 AgentPrune+Tools 的 4.91 接近。该结果说明，本文图剪枝方法并非单纯追求最低推理成本，而是在可控成本范围内提升通信边选择质量。

表 4.2　Qwen3-14B 下面向通信边冗余的图剪枝结果（准确率% / 推理成本）

数据集	Direct+Tools	FullConnected+Tools	AgentPrune+Tools	本文方法
AIME	55.00 / 1.73	63.30 / 3.64	60.00 / 8.01	65.00 / 7.22
GAIA	13.90 / 1.21	20.60 / 2.96	16.30 / 3.88	17.50 / 2.81
GPQA	39.00 / 2.73	55.50 / 6.97	56.00 / 3.35	55.00 / 8.53
HLE	4.00 / 3.78	3.00 / 6.15	7.50 / 2.66	7.00 / 2.48
MATH500	78.50 / 2.45	93.50 / 4.59	94.00 / 6.00	92.50 / 5.72
MuSiQue	8.00 / 0.93	7.00 / 2.15	7.50 / 2.66	7.50 / 2.54
BigCodeBench	43.00 / 2.11	40.50 / 5.81	41.50 / 7.83	42.00 / 7.00

从单项任务看，本文方法在 AIME 上取得 65.00% 准确率，高于 Direct+Tools 的 55.00%、FullConnected+Tools 的 63.30% 和 AgentPrune+Tools 的 60.00%。这说明在数学竞赛题中，工具调用带来的代码执行和检索结果需要被选择性传播；完全连接通信虽然提高了信息覆盖度，但仍会传递部分冗余工具观察，而本文方法能够更稳定地保留高价值边。图4.1进一步展示了 AIME 任务上成本、准确率、工具调用次数和工具 Token 的变化。

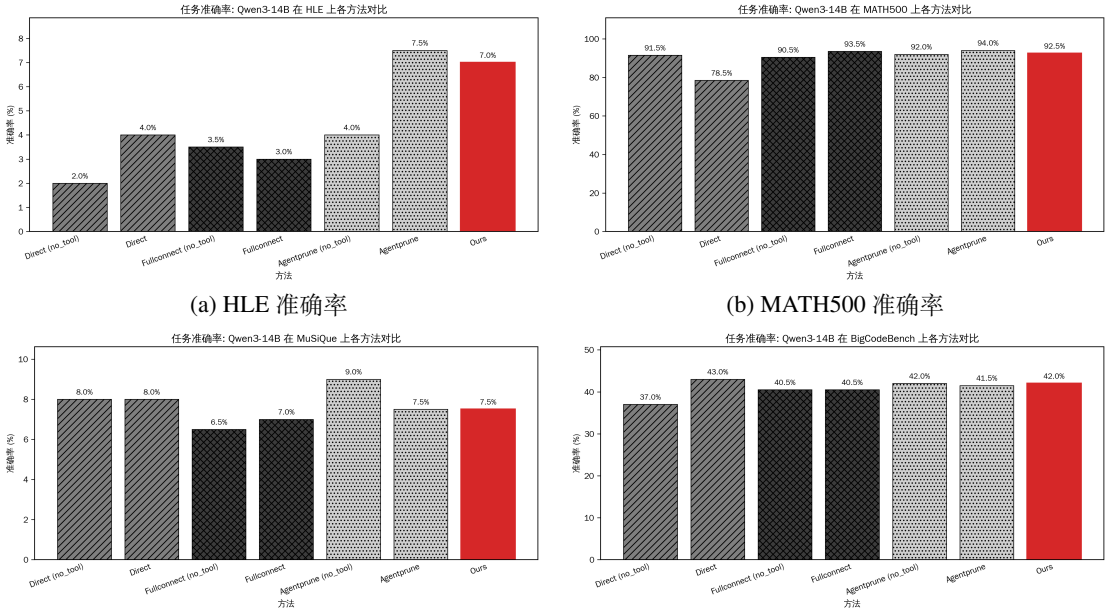


(a) 推理成本　(b) 准确率

(c) 工具调用次数　(d) 工具 Token 数量

图 4.1　Qwen3-14B 在 AIME 任务上的工具调用实验结果

在 HLE、MuSiQue 和 BigCodeBench 等任务上，本文方法的准确率与最优工具基线接近，同时相对 AgentPrune+Tools 保持更低推理成本。例如，HLE 上本文方法准确率为 7.00%，略低于 AgentPrune+Tools 的 7.50%，但推理成本降低约 7.00%；BigCodeBench 上本文方法达到 42.00%，高于 FullConnected+Tools 和 AgentPrune+Tools，并使成本相对 AgentPrune+Tools 降低约 10.58%。在 MATH500 上，本文方法为 92.50%，低于 AgentPrune+Tools 的 94.00%，但成本降低约 4.72%。这些结果说明，工具成本惩罚能够在多个任务上抑制低价值工具信息传播，但在部分强推理任务中仍可能牺牲少量准确率。



(a) HLE 准确率　(b) MATH500 准确率

(c) MuSiQue 准确率　(d) BigCodeBench 准确率

图 4.2　Qwen3-14B 在扩展工具任务上的准确率结果

4.4.2 MiniMax-M3 补充结果

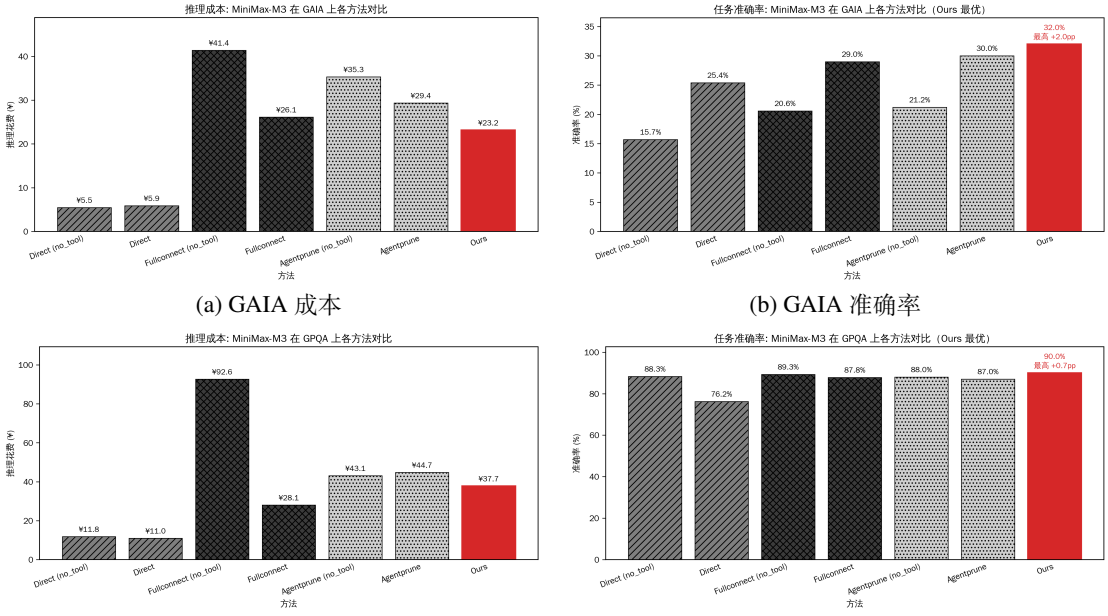
表4.3展示了 MiniMax-M3 上的补充结果。可以看到，本文方法在 AIME、GAIA 和 GPQA 三个任务上均取得当前工具调用对比组中的最高准确率；在 HLE 和 MuSiQue 两个更具开放性和多跳性的任务上，本文方法未取得最高准确率，但相对 AgentPrune+Tools 降低了推理成本，体现出成本控制与证据充分性之间的权衡。整体来看，本文方法在五个 MiniMax-M3 工具任务上的平均准确率为 51.57%，略高于 AgentPrune+Tools 的 51.00%，平均推理成本为 42.23，低于 AgentPrune+Tools 的 47.11。

AIME 上，本文方法达到 98.33%，高于 Direct+Tools 的 73.30%、FullConnected+Tools 的 88.30% 和 AgentPrune+Tools 的 95.00%；GAIA 上，本文方法达到 32.00%，同时高

于 Direct+Tools、FullConnected+Tools 和 AgentPrune+Tools，并且推理成本低于 FullConnected+Tools 和 AgentPrune+Tools；GPQA 上，本文方法达到 90.00%，比 AgentPrune+Tools 高 3.00 个百分点，且成本相对 AgentPrune+Tools 降低约 15.64%。新增的 HLE 和 MuSiQue 结果进一步说明，在高成本闭源模型上，图剪枝并不总是带来单项最高准确率，但能够揭示工具信息传播过多时的边际收益下降问题。

表 4.3　MiniMax-M3 下面向通信边冗余的图剪枝结果（准确率% / 推理成本）

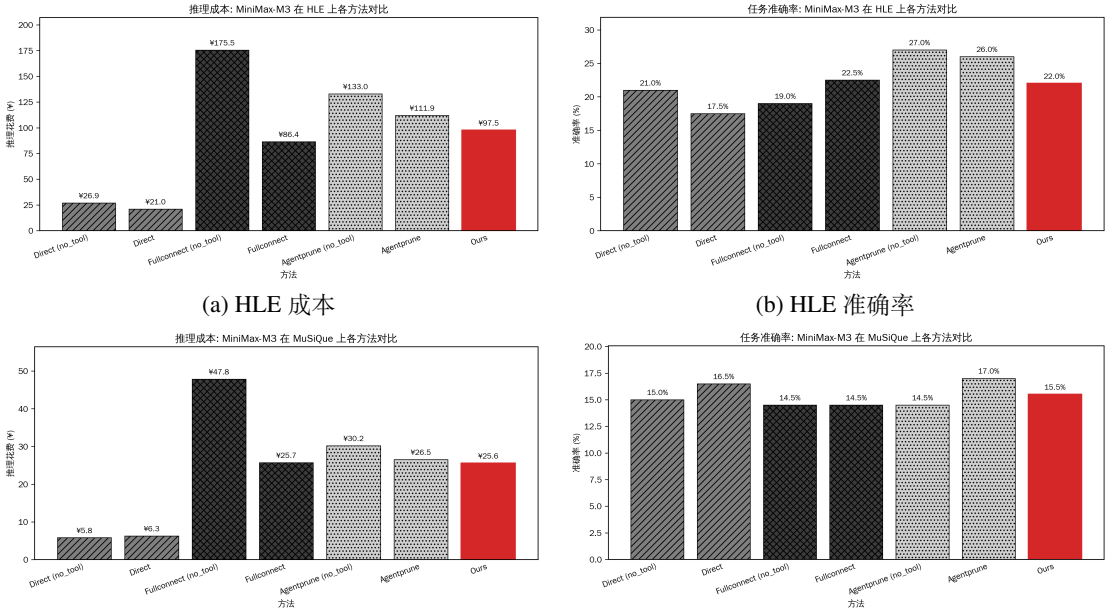
数据集	Direct+Tools	FullConnected+Tools	AgentPrune+Tools	本文方法
AIME	73.30 / 5.87	88.30 / 16.18	95.00 / 22.99	98.33 / 27.19
GAIA	25.40 / 5.87	29.00 / 26.11	30.00 / 29.36	32.00 / 23.16
GPQA	76.20 / 11.03	87.80 / 28.06	87.00 / 44.75	90.00 / 37.75
HLE	17.50 / 21.00	22.50 / 86.43	26.00 / 111.93	22.00 / 97.46
MuSiQue	16.50 / 6.26	14.50 / 25.72	17.00 / 26.54	15.50 / 25.57



(a) GAIA 成本　(b) GAIA 准确率

(c) GPQA 成本　(d) GPQA 准确率

图 4.3　MiniMax-M3 在 GAIA 和 GPQA 任务上的成本与准确率结果



(a) HLE 成本　(b) HLE 准确率

(c) MuSiQue 成本　(d) MuSiQue 准确率

图 4.4　MiniMax-M3 在 HLE 和 MuSiQue 任务上的成本与准确率结果

4.4.3 结果讨论

综合 Qwen3-14B 和 MiniMax-M3 结果可以看出，本文方法更适用于两类场景。第一类是工具观察冗余较多、通信边价值差异明显的任务，如 AIME、GAIA 和 MiniMax-M3 下的 GPQA。在这些任务中，工具成本感知边级目标能够促使系统保留与最终验证、证据整合和代码检查更相关的通信边，从而提升准确率。第二类是工具调用成本较高但任务收益有限的任务，如 HLE、MATH500、MuSiQue 和 BigCodeBench。在这些任务中，本文方法通常能够相对 AgentPrune 降低推理成本，但准确率可能与最优基线存在小幅差距。

同时，实验也表明工具调用并非总是带来稳定收益。以 Qwen3-14B 的 GPQA 为例，Direct 无工具设置达到 57.50%，高于 Direct+Tools 的 39.00%；这说明外部工具返回的信息若不能被有效筛选，可能反而干扰模型原有推理。本文方法虽然通过边级成本惩罚减少了部分冗余传播，但对于强知识型、多选项干扰任务，仍需要进一步引入工具观察质量评估或任务难度自适应权重。

总体而言，本文方法的优势不在于所有任务上同时实现最高准确率和最低成本，而在于把工具调用成本纳入通信图学习目标，使剪枝结果更接近真实部署中的成本–质量权衡。相比仅根据边概率或静态拓扑进行剪枝，工具成本感知策略能够更细粒度地区分不同发送方、不同轮次和不同工具观察带来的边际价值。

4.5 本章小结

本章提出了面向通信边冗余的图剪枝算法。该方法首先将多智能体系统中的空间边和时间边建模为可学习概率，并通过采样构造任务执行时的实际通信图；随后结合任务正确性、模型输出 Token、工具调用次数和工具观察 Token 构造边级效用，使通信边学习过程能够感知外部工具带来的额外成本；最后引入 Taylor 一阶重要性评估，在反向传播后剪除低重要性边，实现多轮推理过程中的动态图压缩。

实验结果表明，在 MiniMax-M3 上，本文方法在 AIME、GAIA 和 GPQA 三个代表性工具任务中取得最高准确率，并在 HLE 和 MuSiQue 上相对 AgentPrune+Tools 降低推理成本；在 Qwen3-14B 上，本文方法在七个工具任务上的平均准确率略高于 FullConnected+Tools 和 AgentPrune+Tools，并在多数任务中相对 AgentPrune 降低推理成本。对于 GPQA、MATH500、HLE 和 MuSiQue 等任务，结果显示工具成本控制与证据充分性之间仍需进一步平衡。该工作从图结构层面补充了上一章的语义消息压缩方法，共同构成面向多智能体系统高效通信的两条优化路径。

结论

本文采用……（结论作为学位论文正文的最后部分单独排写，但不加章号。结论是对整个论文主要结果的总结。在结论中应明确指出本研究的创新点，对其应用前景和社会、经济价值等加以预测和评价，并指出今后进一步在本研究方向进行研究工作的展望与设想。结论部分的撰写应简明扼要，突出创新性。）

参考文献

[1] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.[Z].

[2] ACHIAM J, ADLER S, AGARWAL S, et al. Gpt-4 technical report[J]. arXiv preprint arXiv:2303.08774, 2023.[Z].

[3] TOUVRON H, LAVRIL T, IZACARD G, et al. Llama: Open and efficient foundation language models[J]. arXiv preprint arXiv:2302.13971, 2023.[Z].

[4] TOUVRON H, MARTIN L, STONE K, et al. Llama 2: Open foundation and fine-tuned chat models[J]. arXiv preprint arXiv:2307.09288, 2023.[Z].

[5] GRATTAFIORI A, DUBEY A, JAUHRI A, et al. The llama 3 herd of models[J]. arXiv preprint arXiv:2407.21783, 2024.[Z].

[6] BAI J, BAI S, CHU Y, et al. Qwen technical report[J]. arXiv preprint arXiv:2309.16609, 2023.[Z].

[7] HUI B, YANG J, CUI Z, et al. Qwen2.5-coder technical report[J]. arXiv preprint arXiv:2409.12186, 2024.[Z].

[8] YANG A, LI A, YANG B, et al. Qwen3 technical report[J]. arXiv preprint arXiv:2505.09388, 2025.[Z].

[9] QIAN C, LIU W, LIU H, et al. Chatdev: Communicative agents for software development[C]//Proceedings of the 62nd annual meeting of the association for computational linguistics (volume 1: Long papers). 2024: 15174-15186.[Z].

[10] BOIKO D A, MACKNIGHT R, KLINE B, et al. Autonomous chemical research with large language models[J]. Nature, 2023, 624(7992): 570-578.[Z].

[11] DRIESS D, XIA F, SAJJADI M S M, et al. Palm-e: An embodied multimodal language model[J]. arXiv preprint arXiv:2303.03378, 2023.[Z].

[12] XI Z, CHEN W, GUO X, et al. The rise and potential of large language model based agents: A survey[J]. Science China Information Sciences, 2025, 68(2): 121101.[Z].

[13] WEI J, WANG X, SCHUURMANS D, et al. Chain-of-thought prompting elicits reasoning in large language models[J]. Advances in neural information processing systems, 2022, 35: 24824-24837.[Z].

[14] WANG X, WEI J, SCHUURMANS D, et al. Self-consistency improves chain of thought reasoning in language models[J]. arXiv preprint arXiv:2203.11171, 2022.[Z].

[15] YAO S, YU D, ZHAO J, et al. Tree of thoughts: Deliberate problem solving with large language models[J]. Advances in neural information processing systems, 2023, 36: 11809-11822.[Z].

[16] BESTA M, BLACH N, KUBICEK A, et al. Graph of thoughts: Solving elaborate problems with large language models[C]//Proceedings of the AAAI conference on artificial intelligence. 2024, 38(16): 17682-17690.[Z].

[17] SCHICK T, DWIVEDI-YU J, DESSÌ R, et al. Toolformer: Language models can teach themselves to use tools[J]. Advances in neural information processing systems, 2023, 36: 68539-68551.[Z].

[18] QIN Y, LIANG S, YE Y, et al. Toolllm: Facilitating large language models to master 16000+ real-world apis[C]//International Conference on Learning Representations. 2024, 2024: 9695-9717.[Z].

[19] WANG L, XU W, LAN Y, et al. Plan-and-solve prompting: Improving zero-shot chain-of-thought reasoning by large language models[C]//Proceedings of the 61st annual meeting of the association for computational linguistics (volume 1: long papers). 2023: 2609-2634.[Z].

[20] WANG L, MA C, FENG X, et al. A survey on large language model based autonomous agents[J]. Frontiers of Computer Science, 2024, 18(6): 186345.[Z].

[21] LIU Z, BAI X, CHEN K, et al. A survey on the feedback mechanism of LLM-based AI agents[C]//Proceedings of the Thirty-Fourth International Joint Conference on Artificial Intelligence. International Joint Conferences on Artificial Intelligence, 2025: 10582-10592.[Z].

[22] CHENG M, WANG D, YU S, et al. A Comprehensive Survey of the LLM-Based Agent: The Contextual Cognition Perspective[J]. 2026.[Z].

[23] YAO S, ZHAO J, YU D, et al. React: Synergizing reasoning and acting in language models[J]. arXiv preprint arXiv:2210.03629, 2022.[Z].

[24] AHN M, BROHAN A, BROWN N, et al. Do as i can, not as i say: Grounding language in robotic affordances[J]. arXiv preprint arXiv:2204.01691, 2022.[Z].

[25] SHINN N, CASSANO F, GOPINATH A, et al. Reflexion: Language agents with verbal reinforcement learning[J]. Advances in neural information processing systems, 2023, 36: 8634-8652.[Z].

[26] PARK J S, O'BRIEN J, CAI C J, et al. Generative agents: Interactive simulacra of human behavior[C]//Proceedings of the 36th annual acm symposium on user interface software and technology. 2023: 1-22.[Z].

[27] WANG G, XIE Y, JIANG Y, et al. Voyager: An open-ended embodied agent with large language models[J]. arXiv preprint arXiv:2305.16291, 2023.[Z].

[28] LAZARIDOU A, KUNCORO A, GRIBOVSKAYA E, et al. Mind the gap: Assessing temporal generalization in neural language models[J]. Advances in Neural Information Processing Systems, 2021, 34: 29348-29363.[Z].

[29] LIU N F, LIN K, HEWITT J, et al. Lost in the middle: How language models use long contexts[J]. Transactions of the association for computational linguistics, 2024, 12: 157-173.[Z].

[30] BAI Y, LV X, ZHANG J, et al. Longbench: A bilingual, multitask benchmark for long context understanding[C]//Proceedings of the 62nd annual meeting of the association for computational linguistics (volume 1: Long papers). 2024: 3119-3137.[Z].

[31] DU Y, LI S, TORRALBA A, et al. Improving factuality and reasoning in language models through multiagent debate[J]. arXiv preprint arXiv:2305.14325, 2023.[Z].

[32] GUO T, CHEN X, WANG Y, et al. Large language model based multi-agents: A survey of progress and challenges[J]. arXiv preprint arXiv:2402.01680, 2024.[Z].

[33] TALEBIRAD Y, NADIRI A. Multi-agent collaboration: Harnessing the power of intelligent llm agents[J]. arXiv preprint arXiv:2306.03314, 2023.[Z].

[34] LIANG T, HE Z, JIAO W, et al. Encouraging divergent thinking in large language models through multi-agent debate[C]//Proceedings of the 2024 conference on empirical methods in natural language processing. 2024: 17889-17904.[Z].

[35] HONG S, ZHUGE M, CHEN J, et al. MetaGPT: Meta programming for a multi-agent collaborative framework[C]//International Conference on Learning Representations. 2024, 2024: 23247-23275.[Z].

[36] WU Q, BANSAL G, ZHANG J, et al. Autogen: Enabling next-gen llm applications via multi-agent conversation[J]. arXiv preprint arXiv:2308.08155, 2023.[Z].

[37] LI Z, LIU Y, SU Y, et al. Prompt compression for large language models: A survey[C]//Proceedings of the 2025 Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers). 2025: 7182-7195.[Z].

[38] JIANG H, WU Q, LIN C Y, et al. Llmlingua: Compressing prompts for accelerated inference of large language models[C]//Proceedings of the 2023 conference on empirical methods in natural language processing. 2023: 13358-13376.[Z].

[39] PAN Z, WU Q, JIANG H, et al. Llmlingua-2: Data distillation for efficient and faithful task-agnostic prompt compression[C]//Findings of the Association for Computational Linguistics: ACL 2024. 2024: 963-981.[Z].

[40] HU S, SHEN L, ZHANG Y, et al. Learning multi-agent communication from graph modeling perspective[J]. arXiv preprint arXiv:2405.08550, 2024.[Z].

[41] ZHANG G, YUE Y, LI Z, et al. Cut the crap: An economical communication pipeline for llm-based multi-agent systems[C]//International Conference on Learning Representations. 2025, 2025: 75389-75428.[Z].

[42] ZHUGE M, WANG W, KIRSCH L, et al. Gptswarm: Language agents as optimizable graphs[C]//Forty-first International Conference on Machine Learning. 2024.[Z].

[43] Lai X, Xu W, Yang Y, et al. MiniMax Sparse Attention[J]. ArXiv preprint arXiv:2606.13392, 2026.

[44] LI G, HAMMOUD H, ITANI H, et al. Camel: Communicative agents for" mind" exploration of large language model society[J]. Advances in neural information processing systems, 2023, 36: 51991-52008.[Z].

[45] LI Y, DONG B, GUERIN F, et al. Compressing context to enhance inference efficiency of large language models[C]//Proceedings of the 2023 conference on empirical methods in natural language processing. 2023: 6342-6353.[Z].

[46] SHANDILYA S, XIA M, GHOSH S, et al. Taco-rl: Task aware prompt compression optimization with reinforcement learning[C]//Findings of the Association for Computational Linguistics: ACL 2025. 2025: 1582-1597.[Z].

[47] CHUANG Y N, XING T, CHANG C Y, et al. Learning to compress prompt in natural language formats[C]//Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers). 2024: 7756-7767.[Z].

[48] WEI T, LI T W, LIU Z, et al. Agentic reasoning for large language models[J]. arXiv preprint arXiv:2601.12538, 2026.[Z].

[49] LIU Z, ZHANG Y, LI P, et al. Dynamic llm-agent network: An llm-agent collaboration framework with agent team optimization[J]. arXiv preprint arXiv:2310.02170, 2023.[Z].

[50] ZHANG G, YUE Y, SUN X, et al. G-designer: Architecting multi-agent communication topologies via graph neural networks[J]. arXiv preprint arXiv:2410.11782, 2024.[Z].

[51] ZENG X, SU H, WANG Z, et al. Graph diffusion for robust multi-agent coordination[C]//Forty-second International Conference on Machine Learning. 2025.[Z].

[52] WANG Z, WANG Y, LIU X, et al. Agentdropout: Dynamic agent elimination for token-efficient and high-performance llm-based multi-agent collaboration[C]//Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2025: 24013-24035.[Z].

[53] ZHANG R, ZHAO X, WANG R, et al. Safesieve: From heuristics to experience in progressive pruning for llm-based multi-agent communication[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2026, 40(35): 29892-29900.[Z].

[54] LI B, ZHAO Z, LEE D H, et al. Adaptive graph pruning for multi-agent communication[J]. arXiv preprint arXiv:2506.02951, 2025.[Z].

[55] WANG S, ZHANG G, YU M, et al. G-safeguard: A topology-guided security lens and treatment on llm-based multi-agent systems[C]//Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2025: 7261-7276.[Z].

[56] WANG S, LU R, YANG Z, et al. Agentconductor: Topology evolution for multi-agent competition-level code generation[J]. arXiv preprint arXiv:2602.17100, 2026.[Z].

[57] ZHANG J, XIANG J, YU Z, et al. Automating agentic workflow generation, 2024a[J]. URL https://arxiv.org/abs/2410.10762.[Z].

[58] ZHOU H, WAN X, SUN R, et al. Multi-agent design: Optimizing agents with better prompts and topologies[J]. arXiv preprint arXiv:2502.02533, 2025.[Z].

[59] ZHANG G, NIU L, FANG J, et al. Multi-agent architecture search via agentic supernet[J]. arXiv preprint arXiv:2502.04180, 2025.[Z].

[60] LEONG H Y, WU Y. DynaSwarm: Dynamically graph structure selection for llm-based multi-agent system[J]. arXiv preprint arXiv:2507.23261, 2025.[Z].

[61] Hendrycks D, Burns C, Basart S, et al. Measuring Massive Multitask Language Understanding[J]. ArXiv preprint arXiv:2009.03300, 2020.

[62] Cobbe K, Kosaraju V, Bavarian M, et al. Training Verifiers to Solve Math Word Problems[J]. ArXiv preprint arXiv:2110.14168, 2021.

[63] Ling W, Yogatama D, Dyer C, et al. Program Induction by Rationale Generation: Learning to Solve and Explain Algebraic Word Problems[C]. Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2017: 158-167.

[64] Roy S, Roth D. Solving General Arithmetic Word Problems[C]. Proceedings of the 2015 Conference on Empirical Methods in Natural Language Processing. 2015: 1743-1752.

[65] Patel A, Bhattamishra S, Goyal N. Are NLP Models Really Able to Solve Simple Math Word Problems?[C]. Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. 2021: 2080-2094.

[66] Chen M, Tworek J, Jun H, et al. Evaluating Large Language Models Trained on Code[J]. ArXiv preprint arXiv:2107.03374, 2021.

[67] Molchanov P, Tyree S, Karras T, et al. Pruning Convolutional Neural Networks for Resource Efficient Inference[C]. International Conference on Learning Representations. 2017.

[68] Mathematical Association of America. American Invitational Mathematics Examination[Z]. Contest problem set. 2025.

[69] MIALON G, FOURRIER C, SWIFT C, et al. Gaia: a benchmark for general ai assistants[C]//International Conference on Learning Representations. 2024.[Z].

[70] REIN D, HOU B L, STICKLAND A C, et al. GPQA: A graduate-level google-proof q&a benchmark[C]//First Conference on Language Modeling. 2024.[Z].

[71] PHAN L, GATTI A, HAN Z, et al. Humanity's last exam[J]. arXiv preprint arXiv:2501.14249, 2025.[Z].

[72] HENDRYCKS D, BURNS C, KADAVATH S, et al. Measuring mathematical problem solving with the math dataset[C]//Proceedings of the Neural Information Processing Systems Track on Datasets and Benchmarks. 2021.[Z].

[73] TRIVEDI H, BALASUBRAMANIAN N, KHOT T, et al. Musique: Multihop questions via single-hop question composition[J]. Transactions of the Association for Computational Linguistics, 2022, 10: 539-554.[Z].

[74] ZHUO T Y, VU M C, CHIM J, et al. Bigcodebench: Benchmarking code generation with diverse function calls and complex instructions[C]//International Conference on Learning Representations. 2025.[Z].

附录 A
费马大定理的证明

关于此，我确信已发现了一种美妙的证法，可惜这里空白的地方太小，写不下。

附录 B

Maxwell Equations

因为在柱坐标系下，$\bar{\bar{\mu}}$ 是对角的，所以 Maxwell 方程组中电场 **E** 的旋度

所以 **H** 的各个分量可以写为：

$$H_r = \frac{1}{\mathbf{i}\omega\mu_r}\frac{1}{r}\frac{\partial E_z}{\partial\theta} \tag{B.1a}$$

$$H_\theta = -\frac{1}{\mathbf{i}\omega\mu_\theta}\frac{\partial E_z}{\partial r} \tag{B.1b}$$

同样地，在柱坐标系下，$\bar{\bar{\epsilon}}$ 是对角的，所以 Maxwell 方程组中磁场 **H** 的旋度

$$\nabla\times\mathbf{H} = -\mathbf{i}\omega\mathbf{D} \tag{B.2a}$$

$$\left[\frac{1}{r}\frac{\partial}{\partial r}(rH_\theta) - \frac{1}{r}\frac{\partial H_r}{\partial\theta}\right]\hat{\mathbf{z}} = -\mathbf{i}\omega\bar{\bar{\epsilon}}\mathbf{E} = -\mathbf{i}\omega\epsilon_z E_z\hat{\mathbf{z}} \tag{B.2b}$$

$$\frac{1}{r}\frac{\partial}{\partial r}(rH_\theta) - \frac{1}{r}\frac{\partial H_r}{\partial\theta} = -\mathbf{i}\omega\epsilon_z E_z \tag{B.2c}$$

由此我们可以得到关于 E_z 的波函数方程：

$$\frac{1}{\mu_\theta\epsilon_z}\frac{1}{r}\frac{\partial}{\partial r}\left(r\frac{\partial E_z}{\partial r}\right) + \frac{1}{\mu_r\epsilon_z}\frac{1}{r^2}\frac{\partial^2 E_z}{\partial\theta^2} + \omega^2 E_z = 0 \tag{B.3}$$

附录 C
要求

有些材料编入文章主体会有损于编排的条理性和逻辑性，或有碍于文章结构的紧凑和突出主题思想等，这些材料可作为附录另页排在参考文献之后，也可以单编成册。下列内容可作为附录：

1. 为了整篇论文材料的完整，但编入正文有损于编排的条理性和逻辑性的材料，这一类材料包括比正文更为详尽的信息、研究方法和技术等更深入的叙述，以及建议可阅读的参考文献题录和对了解正文内容有用的补充信息等；
2. 由于篇幅过大或取材的复制资料不便于编入正文的材料；
3. 不便于编入正文的罕见珍贵资料；
4. 一般读者无须阅读，但对本专业同行有参考价值的资料；
5. 某些重要的原始数据、推导、计算程序、框图、结构图、注释、统计表、计算机打印输出件等；

C.1 一级标题

C.1.1 二级标题

攻读学位期间发表论文与研究成果清单

[1] Doe J, **Zhang S**. The Book with Title[M]. Dummy Publisher, 2000. (已出版.)

[2] **张**三, 李杰, 罗运军. 交联型与线形水性聚氨酯的形状记忆性能比较[J]. 化工进展, 2006(01): 78-81. (EI 收录, 检索号:06129773469. 已刊出.)

[3] 李杰, **张**三, 罗运军. 交联型与线形水性聚氨酯的形状记忆性能比较[J]. 化工进展, 2007(01): 78-81. (EI 收录, 检索号:06129773469. 已刊出.)

[4] **Zhang S**. The Book without Title[M]. Dummy Publisher, 2100. (已出版.)

作者简介

本人……

早年对作者简介的要求：“硕士学位论文不必提供作者简介。博士学位论文应该提供作者简介，主要包括：姓名、性别、出生年月、民族、出生地；简要学历、工作经历（职务）；攻读学位期间取得的其他研究成果或奖励。”